Burkina Faso

La Patrie ou la Mort, nous Vaicrons

Ministère de l'Enseignement Supérieur
et de la Recherche Scientifique

Université Joseph Ki-Zerbo

Institut Burkinabè des Arts et Métiers

MÉMOIRE POUR L'OBTENTION DU MASTER II EN INFORMATIQUE

Option : Ingénierie des Systèmes d'Information en Entreprise

Par

Sanou Lougoudoro

Adaptation et enrichissement d'une ontologie pour un accès intelligent et traçable aux connaissances scientifiques sur les plantes médicinales du Burkina Faso

Encadreur : Dr. Belko Abdoul Aziz DIALLO **PhD**

Annee Universitaire 2025 – 2026

Dédicace

Remerciements

Resumé

Abstract

Table des figures

1 Dispersion des connaissances scientifiques 2
2 Démarche méthodologique adoptée 4

Liste des tableaux

I.1 Synthèse comparative des ontologies de la littérature 27

II.1 Sources du corpus documentaire 33
II.2 Ontologies candidates pour la comparaison 34
II.3 Modes d'accès à Llama 3 70B 34
II.4 Caractéristiques de Neo4j Desktop 35
II.5 Composants LangChain utilisés 35
II.6 Bibliothèques Python utilisées 36
II.7 Récapitulatif du matériel 37
II.8 Correspondance entre le matériel et les phases 37
II.9 Grille de critères de comparaison 38
II.10 Notation des ontologies candidates 39
II.11 Critères d'évaluation de l'ontologie 45
II.12 Critères d'évaluation du système RAG 45
II.13 Critères d'évaluation de l'application web 46
II.14 Correspondance entre les phases, les objectifs et les livrables 46

Liste des sigles et abréviations

Sigle ou abréviation	Signification
API	Application Programming Interface
BERT	Bidirectional Encoder Representations from Transformers
BFO	Basic Formal Ontology
CI50	Concentration Inhibitrice 50 %
CSV	Comma-Separated Values
DL50	Dose Létale 50 %
DOI	Digital Object Identifier
DPPH	2,2-diphényl-1-picrylhydrazyle
DrOn	Drug Ontology
FLOPO	Flora Ontology
FOODON	Food Ontology
GC-MS	Gas Chromatography-Mass Spectrometry
GPT	Generative Pre-trained Transformer
GPU	Graphics Processing Unit
HPLC	High-Performance Liquid Chromatography
HTM	Health and Traditional Medicine Ontology
IA	Intelligence Artificielle
IC50	Concentration Inhibitrice médiane de 50 %
IHTSDO	International Health Terminology Standards Development Organisation
INERA	Institut National de l'Environnement et de la Recherche Appliquée
JSON	JavaScript Object Notation
LLM	Large Language Model
NER	Named Entity Recognition
NLP	Natural Language Processing
OCR	Optical Character Recognition
OMS	Organisation Mondiale de la Santé
OTM	Ontology of Traditional Medicine
OWL	Web Ontology Language
PNPMT	Programme National de Promotion de la Médecine Traditionnelle
PO	Plant Ontology
RAG	Retrieval-Augmented Generation
RDF	Resource Description Framework
RDFS	RDF Schema
SKOS	Simple Knowledge Organization System
SNOMED CT	Systematized Nomenclature of Medicine – Clinical Terms
SPARQL	SPARQL Protocol and RDF Query Language
T5	Text-to-Text Transfer Transformer
TALN	Traitement Automatique du Langage Naturel
TPU	Tensor Processing Unit
UICN	Union Internationale pour la Conservation de la Nature
W3C	World Wide Web Consortium
WATRIMed	West African Traditional Medicine
XML	Extensible Markup Language

Table des matières

Dédicace i

Remerciements ii

Resumé iii

Abstract iv

Table des figures v

Liste des tableaux vi

Liste des sigles et abréviations vii

Introduction générale 1

I Cadre théorique et revue de littérature 9
- I.1 Plantes médicinales et connaissances scientifiques au Burkina Faso . . . 9
  - I.1.1 Concepts fondamentaux . . . 9
  - I.1.2 Plantes médicinales documentées dans la littérature scientifique . . . 10
  - I.1.3 Types de connaissances et niveaux de preuve . . . 11
- I.2 Ingénierie des connaissances et ontologies . . . 12
  - I.2.1 Représentation des connaissances . . . 12
  - I.2.2 Ontologies et réutilisation d'ontologies existantes . . . 13
  - I.2.3 Adaptation, alignement et enrichissement ontologique . . . 14
  - I.2.4 Bases de connaissances et interrogation sémantique . . . 15
- I.3 Intelligence artificielle pour l'accès aux connaissances . . . 16
  - I.3.1 Traitement des requêtes en langage naturel . . . 16
  - I.3.2 Extraction et structuration assistées par IA . . . 17
  - I.3.3 Recherche sémantique et génération de réponses . . . 18
  - I.3.4 Traçabilité et fiabilité des réponses . . . 19
- I.4 Travaux connexes et positionnement scientifique . . . 20
  - I.4.1 Ontologies dans le domaine des plantes médicinales . . . 21
  - I.4.2 Systèmes intelligents d'accès aux connaissances . . . 28
  - I.4.3 Positionnement de notre recherche . . . 29

Conclusion du chapitre . . . 29

II Matériel et méthodologie 31
- II.1 Matériel . . . 31
  - II.1.1 Corpus documentaire . . . 31
  - II.1.2 Ontologies candidates . . . 33
  - II.1.3 Outils et environnement technique . . . 34

II.1.4 Tableau récapitulatif du matériel 36
II.1.5 Tableau de correspondance Matériel - Phases 36
II.2 Méthodologie 38
II.2.1 Phase 1 : Identification et étude comparative des ontologies 38
II.2.2 Phase 2 : Définition des critères de recherche et de sélection des documents . 39
II.2.3 Phase 3 : Constitution du corpus scientifique 40
II.2.4 Phase 4 : Adaptation de l'ontologie sélectionnée 41
II.2.5 Phase 5 : Enrichissement de l'ontologie à partir de la littérature scientifique . 42
II.2.6 Phase 6 : Construction et interrogation de la base de connaissances 43
II.2.7 Phase 7 : Exploitation par IA et développement de l'application web 44
II.2.8 Phase 8 : Évaluation et validation 45
II.3 Synthèse et transition 46
II.3.1 Tableau de correspondance Phases - Livrables 46
Conclusion du chapitre 46

III Conception et développement du système **48**

IV Résultats et discussion **49**

Conclusion générale **50**

Bibliographie **50**

Introduction générale

Contexte et justification du sujet

Au Burkina Faso, les plantes médicinales occupent une place importante dans les pratiques de santé. Elles font l'objet de nombreux travaux scientifiques. Ces travaux portent sur leur identification, leurs usages, leurs propriétés pharmacologiques et leur toxicité[25].

Cependant, les connaissances disponibles sont reparties dans la littérature scientifique [45]. Elles se trouvent dans des articles, des thèses, des mémoires et des rapports de recherche. Elles sont aussi présentes dans des inventaires ethnobotaniques et des plateformes numériques. Ces documents utilisent souvent des terminologies différentes. Une même plante peut être désignée par plusieurs synonymes ou noms vernaculaires.

Cette dispersion rend l'accès aux connaissances plus difficile. Elle limite la comparaison des résultats entre les études. Elle rend difficile la recherche d'informations sur une plante, une pathologie ou une recette donnée. Enfin, elle rend difficile le suivi de la source scientifique qui soutient une information.

Les ontologies peuvent structurer ces connaissances. Elles permettent de représenter les concepts d'un domaine et les relations entre ces concepts. Elles facilitent aussi l'interopérabilité et l'interrogation des connaissances[44].

Notre travail s'inscrit dans cette perspective. Il ne consiste pas à construire une ontologie entièrement nouvelle. Nous partirons d'une ontologie existante consacrée aux plantes médicinales. Nous chercherons à l'adapter au contexte du Burkina Faso et à l'enrichir avec des connaissances issues de la littérature scientifique. L'intelligence artificielle sera utilisée pour faciliter l'accès aux connaissances. Elle pourra notamment aider à interpréter les requêtes formulées en langage naturel et à retrouver les informations pertinentes dans la base de connaissances. Une application web sera développée pour permettre aux utilisateurs de consulter ces informations de manière simple et intelligente. Les réponses devront rester liées aux sources scientifiques utilisées.

Ainsi, notre recherche vise à rapprocher trois éléments : une ontologie existante, les connaissances scientifiques sur les plantes médicinales du Burkina Faso et des mécanismes d'accès intelligent fondés sur l'intelligence artificielle comme illustré dans la figure 1.

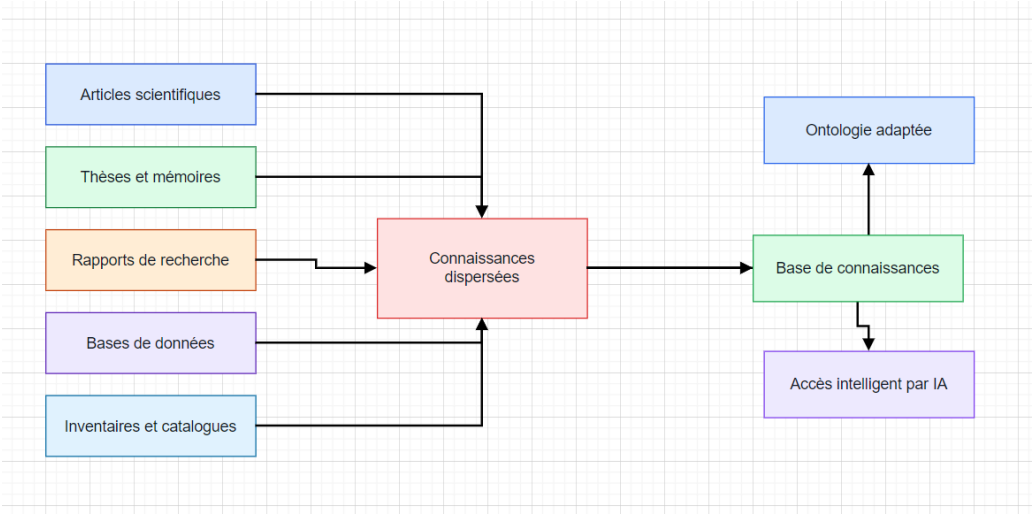


FIGURE 1 – Dispersion des connaissances scientifiques

Problématique de la recherche

Les connaissances scientifiques sur les plantes médicinales du Burkina Faso sont abondantes mais dispersées[25]. Elles proviennent de sources variées : articles scientifiques, thèses, mémoires, rapports de recherche et bases de données institutionnelles [45]. Cette dispersion rend leur exploitation difficile. Les ontologies peuvent structurer ces connaissances [28]. Elles permettent de représenter les concepts d'un domaine et les relations entre ces concepts. Elles facilitent l'interopérabilité et l'interrogation des connaissances. Toutefois, toutes les ontologies existantes ne répondent pas nécessairement aux besoins du contexte burkinabè. Il est donc nécessaire d'identifier les modèles disponibles et d'étudier leur pertinence avant d'en sélectionner un. Un défi concerne l'accès aux connaissances. Une base structurée peut être riche mais peu compréhensible. L'intelligence artificielle peut faciliter cet accès [23]. Elle peut permettre de formuler des requêtes en langage naturel, de rechercher les informations pertinentes et de présenter les résultats de manière plus accessible.

Notre étude cherchera donc à relier trois dimensions. La première concerne les connaissances issues de la littérature scientifique. La deuxième concerne leur organisation dans une ontologie adaptée et enrichie. La troisième concerne leur exploitation par l'intelligence artificielle au moyen d'une application web. Nous formulons ainsi la question principale suivante :

> *Comment enrichir une ontologie existante à partir de la littérature scientifique sur les plantes médicinales du Burkina Faso, puis utiliser l'intelligence artificielle pour l'interroger et obtenir des reponses pertinentes, traçables, en langage naturel et fidèles aux sources scientifiques ?*

Pour préciser cette question principale, nous retenons les questions spécifiques suivantes :

— Quelles ontologies existantes peuvent représenter les connaissances sur les plantes médicinales, et quels critères permettent de les comparer pour sélectionner la plus pertinente pour le contexte burkinabè ?

— Quelles adaptations et quels enrichissements sont nécessaires pour intégrer les connaissances issues de la littérature scientifique sur les plantes médicinales du Burkina Faso, tout en garantissant la traçabilité vers les sources ?

— Comment exploiter l'ontologie adaptée et enrichie avec l'intelligence artificielle (LLM, RAG) pour faciliter l'accès aux connaissances en langage naturel ?

— Comment concevoir une application web permettant la consultation, la recherche et la compréhension des connaissances documentées sur les plantes médicinales du Burkina Faso ?

Objectif général et objectifs spécifiques

La problématique ainsi posée permet de définir l'objectif général et les objectifs spécifiques de notre recherche. L'objectif général exprime la finalité de notre travail. Les objectifs spécifiques décomposent cet objectif en actions concrètes et mesurables. Ils guideront notre démarche méthodologique et permettront d'évaluer notre contribution.

Objectif général

Notre objectif général est d'adapter et d'enrichir une ontologie existante afin de représenter les connaissances issues de la littérature scientifique sur les plantes médicinales du Burkina Faso, puis d'exploiter ces connaissances par l'intelligence artificielle au moyen d'une application web pour faciliter leur accès et leur diffusion.

Objectifs spécifiques

— Identifier et comparer les ontologies existantes dans le domaine des plantes médicinales afin de sélectionner la plus pertinente pour le contexte burkinabè.

— Adapter et enrichir l'ontologie sélectionnée à partir de la littérature scientifique sur les plantes médicinales du Burkina Faso, en assurant la traçabilité des connaissances vers leurs sources.

— Construire une base de connaissances orientée graphe et mettre en place un système d'accès intelligent (RAG) exploitant l'ontologie enrichie.

— Développer une application web permettant la recherche, la consultation et la compréhension des connaissances documentées sur les plantes médicinales du Burkina Faso.

Hypothèses de recherche

Pour répondre aux questions de recherche et atteindre les objectifs fixés, notre étude repose sur des hypothèses organisées selon une progression logique. La première hypothèse porte sur la démarche ontologique. La deuxième concerne la méthodologie d'extraction. La troisième traite de l'adaptation et de l'enrichissement. La quatrième aborde l'accès intelligent. La cinquième concerne la diffusion des connaissances. Ces hypothèses seront vérifiées tout au long de notre recherche.

1. **Hypothèse 1 :** Une revue méthodique et systématique de la littérature scientifique permet d'identifier et d'enrichir un modèle ontologique capable de représenter les connaissances sur les plantes médicinales du Burkina Faso
2. **Hypothèse 2 :** L'utilisation de modèles de langue de grande taille (LLM) améliore l'extraction automatique des connaissances à partir de la littérature scientifique, comparativement aux méthodes manuelles.
3. **Hypothèse 3 :** L'adaptation et l'enrichissement de l'ontologie sélectionnée permettent de mieux représenter les connaissances documentées dans la littérature scientifique sur les plantes médicinales du Burkina Faso, tout en assurant leur traçabilité.
4. **Hypothèse 4 :** L'exploitation de l'ontologie enrichie par un système RAG facilite la recherche et la compréhension des connaissances en langage naturel.

5. **Hypothèse 5 :** Une application web intégrant le système RAG permet de mieux vulgariser et diffuser les connaissances scientifiques documentées sur les plantes médicinales du Burkina Faso.

Démarche méthodologique adoptée

Pour répondre à notre problématique, nous adopterons une démarche progressive et structurée. Cette démarche combine la revue de littérature, l'étude comparative des ontologies, l'ingénierie des connaissances, l'intelligence artificielle et le développement logiciel. Elle est organisée en huit phases complémentaires représentées dans la figure 2. Chaque phase produit des livrables qui alimentent la phase suivante. La validation est réalisée à plusieurs étapes pour garantir la qualité des résultats.

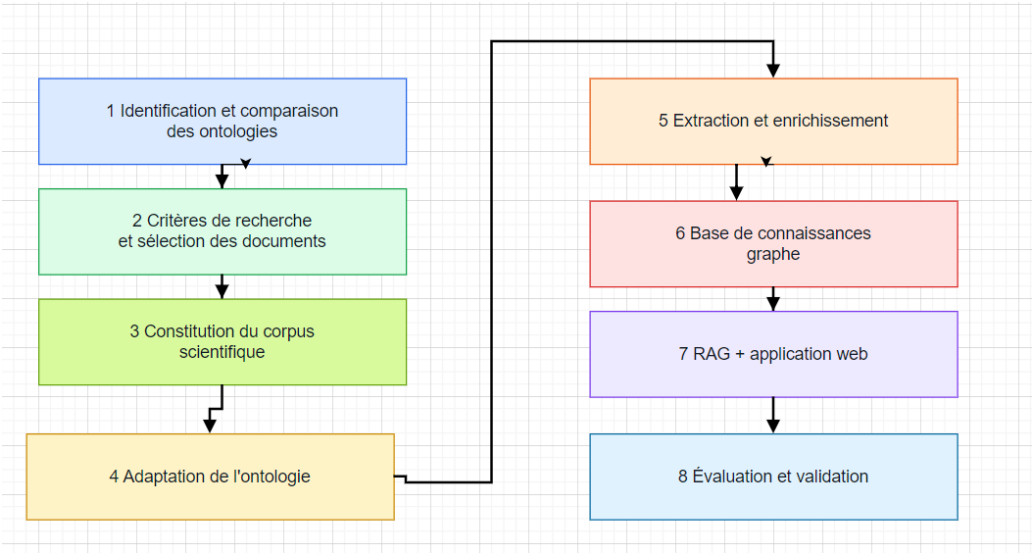


FIGURE 2 – Démarche méthodologique adoptée

Phase 1 : Identification et étude comparative des ontologies

La première phase consiste à identifier les ontologies existantes dans le domaine des plantes médicinales. Nous rechercherons ces ontologies dans la littérature scientifique et les bases de données spécialisées. Nous définirons une grille de critères pour les comparer. Ces critères porteront sur la couverture du domaine, la richesse sémantique, la disponibilité, la documentation, l'interopérabilité, l'adaptabilité au contexte burkinabè, la traçabilité et la prise en compte des savoirs locaux. Nous noterons chaque ontologie selon cette grille. Nous sélectionnerons l'ontologie qui obtient le score le plus élevé. Cette phase est fondamentale car elle détermine le modèle conceptuel qui guidera toute la suite de notre travail. Le livrable de cette phase est l'ontologie sélectionnée.

Phase 2 : Définition des critères de collection des documents

La deuxième phase consiste à définir les critères qui guideront la recherche et la sélection des documents scientifiques. Ces critères permettront de garantir la pertinence, la qualité et la cohérence des sources utilisées. Les critères de recherche incluront les plantes, les parties utilisées, les pathologies et usages médicinaux, les modes de préparation, les niveaux de preuve, les propriétés pharmacologiques et la composition chimique. Les critères de sélection incluront la pertinence, l'identification de la plante, la disponibilité d'une référence scientifique, la fiabilité et l'actualité. Cette phase permet de

disposer d'un corpus fiable et cohérent. Le livrable de cette phase est la grille de critères de recherche et de sélection.

Phase 3 : Constitution du corpus scientifique

La troisième phase consiste à constituer un corpus de documents scientifiques portant sur les plantes médicinales du Burkina Faso. Les sources comprendront des articles scientifiques, des thèses, des mémoires et des rapports de recherche. Nous appliquerons les critères d'inclusion et d'exclusion définis dans la phase précédente. Nous vérifierons notamment la pertinence du document, l'identification de la plante et la disponibilité d'une référence scientifique. Les informations retenues seront conservées avec leur provenance. Cette phase permettra de disposer d'un corpus fiable et cohérent. Il constituera la base documentaire de notre étude. Le livrable de cette phase est un corpus de documents scientifiques organisé et indexé.

Phase 4 : Adaptation de l'ontologie sélectionnée

La quatrième phase consiste à adapter l'ontologie sélectionnée au contexte des plantes médicinales du Burkina Faso. Nous analyserons les concepts présents dans l'ontologie retenue. Nous identifierons les concepts qui peuvent être conservés, ceux qui doivent être modifiés et ceux qui doivent être ajoutés. Nous ajouterons des classes pour les maladies spécifiques au Burkina Faso, les noms vernaculaires en langues locales, les régions et les niveaux de preuve. Nous ajouterons des propriétés pour les noms vernaculaires, la localisation géographique, les niveaux de preuve et la traçabilité. Nous modifierons les relations pour préciser la sémantique et assurer la traçabilité. Nous chercherons à préserver la compatibilité avec la structure initiale de l'ontologie. Les adaptations seront documentées. Le livrable de cette phase est une ontologie adaptée au contexte burkinabè.

Phase 5 : Enrichissement de l'ontologie à partir de la littérature scientifique

La cinquième phase consiste à enrichir l'ontologie à partir des connaissances extraites de la littérature scientifique. Nous extrairons les connaissances pertinentes à partir du corpus constitué en phase 3 et filtré selon les critères définis en phase 2. L'extraction sera assistée par l'intelligence artificielle via des prompts adressés à des modèles de langue de grande taille (LLM). Ces prompts guideront le modèle pour identifier les plantes, leurs usages, les parties utilisées, les modes de préparation et les propriétés pharmacologiques tels que documentés dans les sources scientifiques. Les résultats seront produits dans des formats structurés (JSON, CSV). Nous conserverons les références bibliographiques et, lorsque cela sera possible, la page ou la section à l'origine de chaque information. Nous distinguerons les usages rapportés dans les études ethnobotaniques des résultats issus d'études expérimentales. Une validation humaine systématique sera effectuée pour garantir la qualité des données extraites. Le livrable de cette phase est un ensemble de données structurées prêtes à être intégrées.

Phase 6 : Construction et interrogation de la base de connaissances

La sixième phase consiste à construire la base de connaissances orientée graphe. L'ontologie adaptée et enrichie servira de structure à la base de connaissances. Les données extraites seront transformées en instances correspondant aux concepts définis. La base sera implémentée sous forme de base de connaissances orientée graphe. Ce choix permet une modélisation naturelle des relations complexes entre les plantes, les usages, les propriétés et les sources. Chaque connaissance importante sera associée à une source scientifique. La base devra permettre de retrouver l'origine d'une information. L'interrogation se fera via le langage Cypher ou SPARQL, qui permettent des requêtes puissantes sur les graphes. Nous définirons des scénarios de recherche sur une plante, un usage médicinal, une

partie utilisée ou une source scientifique. Le livrable de cette phase est une base Neo4j peuplée et interrogeable.

Phase 7 : Exploitation par IA et développement de l'application web

La septième phase constitue le cœur de l'objectif d'accès intelligent. L'accès sera assuré par un système RAG (Retrieval-Augmented Generation). Ce système combine la recherche d'informations dans la base de connaissances graphe et la génération de réponses par un modèle de langage. Le RAG interprète les requêtes en langage naturel. Il interroge la base de connaissances pour retrouver les informations pertinentes. Il génère ensuite des réponses basées sur les faits retrouvés. Cette approche garantit la traçabilité des réponses, car chaque information est associée à sa source scientifique. Nous développerons une application web qui servira d'interface entre les utilisateurs et le système. L'application proposera une recherche en langage naturel. Elle présentera des fiches sur les plantes, leurs usages documentés, les parties utilisées, les modes de préparation et les références scientifiques. Les réponses resteront liées aux sources disponibles. Le système sera conçu pour la consultation des connaissances. Il ne constituera pas un outil de diagnostic médical ni un système de prescription. Le livrable de cette phase est un système RAG fonctionnel et une application web fonctionnelle.

Phase 8 : Évaluation et validation

La huitième phase consiste à évaluer et valider notre approche. L'évaluation portera sur trois niveaux. Le premier niveau concerne l'ontologie. Nous vérifierons sa couverture, sa cohérence, sa traçabilité et son extensibilité. Le deuxième niveau concerne le système RAG. Nous mesurerons sa pertinence, sa fidélité, son exactitude et sa traçabilité. Le troisième niveau concerne l'application web. Nous évaluerons sa facilité d'utilisation, sa compréhension, son utilité et ses performances. Nous solliciterons des participants incluant des étudiants, des chercheurs et des tradipraticiens. Le livrable de cette phase est un rapport d'évaluation et de validation.

Délimitation du champ d'étude

Notre étude porte sur les plantes médicinales documentées au Burkina Faso. Elle s'intéresse aux connaissances relatives à leurs usages médicinaux et à leurs propriétés biologiques lorsqu'elles sont rapportées par des sources scientifiques.

Les connaissances étudiées proviendront principalement de la littérature scientifique accessible et vérifiable. Nous ne réaliserons pas d'enquête de terrain directe dans le cadre de cette étude.

Le travail portera sur la sélection d'une ontologie existante, son adaptation et son enrichissement. Le choix de l'ontologie sera effectué après une étude comparative.

Sur le plan technique, le travail comprendra une base de connaissances orientée graphe, un système RAG pour l'accès intelligent et une application web. L'extraction des connaissances sera assistée par des prompts d'IA. L'intelligence artificielle sera intégrée pour faciliter l'accès aux connaissances structurées, mais ne sera pas considérée comme une source scientifique autonome. Les documents scientifiques resteront les sources de référence.

Le système sera conçu comme un outil de consultation, de vulgarisation et de diffusion scientifique. Il ne remplacera pas l'avis d'un professionnel de santé et ne servira pas à établir un diagnostic ou une prescription.

Résultats attendus

Au terme de notre recherche, nous attendons :

— La constitution d'un corpus scientifique organisé sur les plantes médicinales du Burkina Faso, avec des connaissances vérifiées et associées à leurs sources.

— La réalisation d'une étude comparative des ontologies existantes afin de sélectionner celle qui nous semble la plus pertinente.

— L'adaptation et l'enrichissement de cette ontologie avec les connaissances issues de la littérature scientifique.

— La mise en place d'une base de connaissances graphe traçable, exploitée par le système RAG qui combine la recherche sémantique et la génération de réponses.

— Le développement d'une application web permettant de rechercher, consulter et comprendre les connaissances documentées sur les plantes médicinales du Burkina Faso.

L'intelligence artificielle facilitera l'interprétation des requêtes et l'accès aux informations pertinentes. Les résultats proposés resteront fondés sur les données de la base et sur les références scientifiques associées.

Contribution attendue

La contribution principale de notre recherche sera de réutiliser une ontologie existante et de l'adapter au contexte des plantes médicinales du Burkina Faso. L'objectif sera de l'enrichir à partir de connaissances issues de la littérature scientifique.

Sur le plan scientifique, le travail contribuera à mieux structurer des connaissances dispersées dans plusieurs publications. Il permettra aussi de conserver le lien entre les connaissances et leurs sources.

Sur le plan technique, la recherche aboutira à une ontologie enrichie, une base de connaissances et un mécanisme d'accès intelligent. L'intelligence artificielle sera utilisée pour faciliter l'interrogation des connaissances via une application web.

Sur le plan pratique, le système pourra aider les chercheurs, les étudiants et les autres utilisateurs autorisés à accéder plus facilement aux informations documentées. Il pourra aussi faciliter la recherche bibliographique et l'exploration des relations entre les plantes et les connaissances scientifiques associées.

Structuration du mémoire

Afin de présenter progressivement notre démarche, le mémoire est organisé en quatre chapitres numérotés en chiffres romains, précédés de l'introduction générale et suivis de la conclusion générale.

— **Introduction générale (non numérotée).** Nous y exposons le contexte et la justification du sujet. Nous présentons ensuite la problématique, les questions de recherche, les objectifs et les hypothèses. Nous décrivons également la démarche méthodologique, la délimitation du champ d'étude et les résultats attendus.

— **Chapitre I :** Cadre théorique et revue de littérature. Nous présentons les notions liées aux plantes médicinales et aux connaissances scientifiques sur le Burkina Faso. Nous abordons ensuite l'ingénierie des connaissances, les ontologies, les bases de connaissances et l'intelligence artificielle. Nous analysons enfin les travaux connexes.

— **Chapitre II :** Matériel et méthodologie. Nous décrivons le corpus scientifique, les critères de sélection et les méthodes d'analyse. Nous présentons les ontologies identifiées, les critères de comparaison et la méthode de sélection. Les étapes d'adaptation, d'enrichissement et de validation sont détaillées.

— **Chapitre III :** Conception et développement du système. Nous présentons l'ontologie sélectionnée et les adaptations réalisées. Nous décrivons ensuite la base de connaissances. Enfin, nous présentons l'intégration de l'intelligence artificielle et le développement de l'application web.

— **Chapitre IV :** Résultats et discussion. Nous exposons les résultats de l'étude comparative des ontologies. Nous présentons l'ontologie adaptée et enrichie ainsi que la base de connaissances. Nous analysons ensuite l'accès intelligent et les fonctionnalités de l'application web. Les limites du système sont également discutées.

Le mémoire se termine par une conclusion générale. Nous y rappelons les principaux résultats. Nous montrons dans quelle mesure les objectifs et les hypothèses ont été atteints. Nous présentons enfin les limites et les perspectives d'amélioration.

Chapitre I

Cadre théorique et revue de littérature

Introduction du chapitre

Ce chapitre pose les fondements théoriques de notre recherche. Il présente les concepts clés mobilisés dans notre travail. Il analyse l'état de l'art dans les domaines concernés. Il situe notre recherche par rapport aux travaux existants. Le chapitre est structuré en quatre sections. La première section traite des plantes médicinales et des connaissances scientifiques au Burkina Faso. La deuxième section aborde l'ingénierie des connaissances et les ontologies. La troisième section explore l'intelligence artificielle pour l'accès aux connaissances. La quatrième section présente les travaux connexes et positionne notre recherche.

I.1 Plantes médicinales et connaissances scientifiques au Burkina Faso

I.1.1 Concepts fondamentaux

Définition des plantes médicinales L'Organisation Mondiale de la Santé (OMS) définit une plante médicinale comme toute plante dont une ou plusieurs parties contiennent des substances pouvant être utilisées à des fins thérapeutiques. Ces substances sont des principes actifs. Elles exercent une action pharmacologique sur l'organisme. Elles peuvent prévenir, soulager ou guérir des affections [41].

Selon l'Union Internationale pour la Conservation de la Nature (UICN), les plantes médicinales sont des ressources végétales utilisées dans les systèmes de médecine traditionnelle. Elles sont également utilisées comme matières premières pour l'industrie pharmaceutique. Leur exploitation doit être durable pour préserver la biodiversité.

Médecine traditionnelle et pharmacopée L'OMS définit la médecine traditionnelle comme l'ensemble des connaissances, compétences et pratiques de soins [41]. Ces pratiques sont fondées sur des théories, des croyances et des expériences propres à chaque culture. Elles sont utilisées pour maintenir la santé. Elles servent aussi à prévenir, diagnostiquer et traiter les maladies [43].

La pharmacopée traditionnelle désigne l'ensemble des remèdes et préparations utilisés en médecine traditionnelle [41]. Elle inclut les recettes de préparation. Elle précise les posologies. Elle décrit les modes d'administration. Elle mentionne les contre-indications et les précautions d'usage.

Ethnobotanique et ethnomédecine L'ethnobotanique est une discipline scientifique qui étudie les relations entre les plantes et les sociétés humaines [42]. Elle documente les usages traditionnels des plantes. Elle recueille les savoirs locaux. Elle analyse comment les populations perçoivent, nomment, classifient et utilisent les végétaux.

L'ethnomédecine est une branche de l'ethnobotanique. Elle se concentre spécifiquement sur les pratiques médicales. Elle étudie les systèmes de soins traditionnels. Elle analyse les conceptions de la maladie et de la guérison. Elle documente les rituels et les pratiques thérapeutiques [42].

Contexte burkinabè Au Burkina Faso, la médecine traditionnelle est largement pratiquée. Elle couvre environ 80 % des besoins de santé primaire [2]. Elle est accessible et abordable. Elle est ancrée dans les habitudes culturelles. Les tradipraticiens sont des acteurs clés du système.

Zerbo et al. [44] ont étudié les plantes médicinales chez les Sanan du Burkina Faso. Leur travail documente 85 espèces utilisées. Ils identifient 63 affections traitées. Ils décrivent les modes de préparation et d'administration. Leur étude montre la richesse des connaissances traditionnelles.

Ouedraogo et al. [25] ont réalisé une revue des plantes médicinales à potentiel aromatique du Burkina Faso. Ils recensent 42 espèces. Ils identifient leurs propriétés et leurs usages. Leur travail souligne l'importance de ces ressources pour la pharmacopée locale.

Ces savoirs ne sont pas homogènes. Ils varient selon les ethnies. Ils diffèrent selon les régions. Ils évoluent dans le temps. Ils s'enrichissent de nouvelles découvertes. Cette diversité rend leur documentation complexe [20].

I.1.2 Plantes médicinales documentées dans la littérature scientifique

Inventaires et recensements La littérature scientifique burkinabè est riche. Elle recense plusieurs centaines d'espèces médicinales. Les travaux de Guinko [12] ont identifié 304 espèces utilisées en médecine traditionnelle. Nacoulma [21] a documenté 280 espèces et leurs usages. Zerbo et al.[44] ont recensé 85 espèces chez les Sanan.

Ces plantes appartiennent à des familles botaniques variées. Les plus représentées sont les Fabacées, les Combretacées, les Rubiacées et les Euphorbiacées [21]. La diversité reflète la richesse de la flore burkinabè.

Aspects botaniques et écologiques Les travaux de recherche couvrent plusieurs aspects :

- **Identification botanique :** les plantes sont collectées et décrites. Leurs caractéristiques morphologiques sont notées. Les spécimens sont conservés dans des herbiers de référence. La taxonomie est précisée.
- **Distribution géographique :** les zones de présence sont cartographiées. La répartition est liée aux conditions climatiques et édaphiques. Certaines plantes sont endémiques à certaines régions [12].
- **Périodes de récolte :** les moments optimaux de collecte sont déterminés. La teneur en principes actifs varie selon la saison. Cette connaissance est importante pour la qualité des remèdes.
- **Parties utilisées :** les feuilles sont les plus fréquemment employées (45 % des cas)[44]. Viennent ensuite les racines (25 %), les écorces (15 %), les fruits (10 %) et les graines (5 %) [44]. La partie utilisée dépend de la plante et de l'usage visé.
- **Modes de préparation :** les décoctions sont courantes (ébullition dans l'eau). Les macérations sont aussi pratiquées (trempage à froid). Les poudres sont obtenues par séchage et broyage. Les extraits alcooliques sont moins fréquents [21].

Usages thérapeutiques Les affections courantes sont traitées. Le paludisme est une cible fréquente. Les infections respiratoires et digestives sont aussi concernées. Les pathologies chroniques comme le diabète ou l'hypertension sont étudiées [25].

Propriétés pharmacologiques Les études expérimentales évaluent les activités pharmacologiques :

- **Activité antimicrobienne :** les extraits sont testés sur des bactéries et des champignons. Les souches testées incluent *Staphylococcus aureus*, *Escherichia coli*, *Candida albicans*. Les résultats montrent souvent des activités prometteuses [21].
- **Activité antipaludique :** les extraits sont testés sur des souches de *Plasmodium falciparum*. Des plantes comme *Artemisia annua*, *Cryptolepis sanguinolenta* sont étudiées. Certaines montrent une forte activité [25].
- **Activité anti-inflammatoire :** les modèles d'inflammation sont utilisés. L'œdème de la patte de rat est un test courant. Plusieurs plantes montrent des effets significatifs.
- **Activité antioxydante :** les piégeurs de radicaux libres sont mesurés. Les méthodes DPPH et ABTS sont utilisées. Les polyphénols sont souvent impliqués.
- **Toxicité :** la toxicité aiguë et subchronique est évaluée. Les doses létales (DL50) sont déterminées. Certaines plantes sont toxiques à forte dose. Ces informations sont cruciales pour la sécurité [21].

Composition chimique Les analyses phytochimiques identifient les métabolites secondaires :

- **Alcaloïdes :** composés azotés aux propriétés pharmacologiques variées. La quinine, la morphine en sont des exemples.
- **Flavonoïdes :** composés phénoliques aux propriétés antioxydantes et anti-inflammatoires. La quercétine, la rutine en sont des exemples.
- **Tanins :** composés polyphénoliques aux propriétés astringentes et antimicrobiennes.
- **Saponines :** composés aux propriétés moussantes et immunostimulantes.
- **Huiles essentielles :** mélanges complexes de terpènes aux propriétés variées [25].

I.1.3 Types de connaissances et niveaux de preuve

Typologie des connaissances Les connaissances sur les plantes médicinales sont de nature variée. Chaque type a sa propre valeur et ses propres limites.

Connaissances ethnobotaniques Ces connaissances viennent des populations locales. Elles sont recueillies par enquêtes et entretiens. Elles reflètent le savoir traditionnel accumulé. Elles décrivent les usages, les préparations et les croyances.

Ces connaissances sont précieuses. Elles guident la recherche vers des plantes prometteuses. Elles préservent le patrimoine culturel. Mais elles comportent des biais. Les informateurs peuvent donner des informations incomplètes. Les usages peuvent varier d'un guérisseur à l'autre. Les connaissances peuvent être perdues.

Connaissances phytochimiques Ces connaissances concernent la composition chimique des plantes. Elles identifient les molécules actives. Elles précisent leur concentration. Elles comparent les profils chimiques entre espèces.

Connaissances pharmacologiques Ces connaissances viennent d'études expérimentales. Elles testent les effets biologiques des extraits. Elles utilisent des modèles *in vitro* (cellules, micro-organismes). Elles utilisent aussi des modèles *in vivo* (animaux de laboratoire) (Heinrich et al., 2004).

Les résultats sont quantitatifs. Ils mesurent la concentration efficace (CI50). Ils comparent à des témoins positifs. Ils évaluent la toxicité. Mais les études sur les animaux ne prédisent pas toujours l'effet chez l'homme.

Connaissances cliniques Ces connaissances proviennent d'essais sur l'homme. Elles sont rares pour les plantes médicinales. Elles sont coûteuses et complexes. Elles exigent des autorisations éthiques et des essais rigoureux. Les essais cliniques offrent le plus haut niveau de preuve. Ils mesurent l'efficacité réelle. Ils évaluent les effets secondaires. Ils comparent au placebo ou au traitement standard. Ils sont la référence en médecine fondée sur les preuves [27].

Hiérarchie des niveaux de preuve La médecine fondée sur les preuves (*evidence-based medicine*) établit une hiérarchie :

1. **Méta-analyses et revues systématiques :** preuve la plus forte. Elles synthétisent plusieurs essais cliniques.
2. **Essais cliniques randomisés contrôlés :** preuve très forte. Ils comparent un traitement à un placebo ou à un standard.
3. **Études de cohorte :** preuve modérée. Elles suivent des groupes dans le temps.
4. **Études cas-témoins :** preuve modérée. Elles comparent des cas à des témoins.
5. **Études expérimentales animales :** preuve faible. Elles ne sont pas directement transposables à l'homme.
6. **Études *in vitro* :** preuve très faible. Elles sont éloignées des conditions réelles.
7. **Savoirs traditionnels et avis d'experts :** preuve anecdotique. Ils sont utiles pour générer des hypothèses mais non validés.

I.2 Ingénierie des connaissances et ontologies

I.2.1 Représentation des connaissances

Définition et enjeux La représentation des connaissances est une discipline de l'intelligence artificielle. Elle vise à formaliser l'information pour la rendre exploitable par la machine [6]. Elle utilise des langages structurés et interprétables. Elle permet le raisonnement automatique et l'interrogation.

Les enjeux sont majeurs. Il s'agit de capturer la sémantique des connaissances. Il s'agit de les rendre interopérables. Il s'agit de permettre leur réutilisation. Il s'agit de faciliter leur évolution.

Principaux modèles de représentation

- **Les réseaux sémantiques :** Ce sont des graphes de concepts reliés par des arcs. Les nœuds représentent des entités. Les arcs représentent des relations. Ce modèle est simple et intuitif. Il est utilisé dans les premières bases de connaissances.
  Limites : ils n'ont pas de sémantique formelle. Ils ne permettent pas le raisonnement complexe. Ils sont difficiles à partager.
- **Les cadres (*frames*) :** Ce sont des structures de données. Chaque cadre a des attributs (*slots*). Les attributs peuvent avoir des valeurs par défaut. Les cadres peuvent être organisés en hiérarchies (héritage).
  Avantages : ils sont structurés. Ils permettent l'héritage. Ils sont faciles à implémenter.
  Limites : ils n'ont pas de sémantique formelle. L'héritage peut être ambigu.
- **Les règles :** Ce sont des expressions logiques conditionnelles. Elles ont la forme « SI condition ALORS conclusion ». Elles permettent le raisonnement déductif. Elles sont utilisées dans les systèmes experts.
  Avantages : elles sont expressives. Elles permettent le raisonnement. Elles sont faciles à comprendre.

Limites : elles peuvent être nombreuses. Elles peuvent interagir de manière complexe. Leur maintenance est difficile.

- **Les ontologies :** Ce sont des modèles formels d'un domaine [11]. Elles définissent des classes et des propriétés. Elles spécifient des relations et des axiomes. Elles offrent une expressivité élevée. Elles sont adaptées aux connaissances complexes.
  Avantages : elles ont une sémantique formelle. Elles sont interopérables. Elles permettent le raisonnement. Elles sont réutilisables.

Notre recherche utilisera les ontologies. Elles sont les plus adaptées à la structuration des connaissances scientifiques. Elles permettent une interrogation fine. Elles facilitent l'intégration de sources multiples.

I.2.2 Ontologies et réutilisation d'ontologies existantes

Définition formelle Une ontologie est définie comme « une spécification explicite et formelle d'une conceptualisation partagée » [11]. Cette définition comporte plusieurs éléments :

- **Spécification explicite :** les concepts sont définis clairement. Les termes sont précis. Les définitions sont non ambiguës.
- **Spécification formelle :** l'ontologie est exprimée dans un langage logique. Elle est interprétable par la machine. Elle permet le raisonnement.
- **Conceptualisation :** l'ontologie représente une vision du monde. Elle sélectionne les concepts pertinents. Elle ignore les détails non pertinents.
- **Partagée :** l'ontologie est consensuelle. Elle est acceptée par une communauté. Elle facilite la communication.

Composants d'une ontologie Les ontologies sont composées de plusieurs éléments [31] :

- **Classes (ou concepts) :** ce sont les entités du domaine. Par exemple : Plante, Maladie, Substance active, Mode de préparation. Les classes sont organisées en hiérarchies (taxonomies) [30].
- **Propriétés (ou attributs) :** ce sont les caractéristiques des classes. Par exemple : nom scientifique, nom vernaculaire, partie utilisée, dosage. Les propriétés peuvent avoir des valeurs (chaînes, nombres, dates) [30].
- **Relations :** ce sont les liens entre les classes. Par exemple : *« traite »* (une plante traite une maladie), *« contient »* (une plante contient une substance), *« est_préparée_par »* (une préparation utilise un mode) [30].
- **Axiomes :** ce sont des contraintes logiques. Ils assurent la cohérence de l'ontologie. Par exemple : « une plante peut avoir plusieurs usages » ou « une partie utilisée doit être une partie de la plante »[30].
- **Instances (ou individus) :** ce sont les exemples concrets. Par exemple : *« Cassia alata »* est une instance de Plante. *« Paludisme »* est une instance de Maladie.

Langages d'ontologies Plusieurs langages sont utilisés pour représenter les ontologies :

- **RDF (Resource Description Framework) :** langage de base pour le Web sémantique. Il utilise des triplets (sujet-prédicat-objet). Il est simple mais peu expressif [38].
- **RDFS (RDF Schema) :** extension de RDF. Il permet de définir des classes et des propriétés. Il permet l'héritage. Il a une expressivité limitée [38].
- **OWL (Web Ontology Language) :** langage standard du W3C. Il est plus expressif que RDFS. Il permet des axiomes complexes. Il existe OWL-Lite, OWL-DL et OWL-Full, de complexité croissante [37].

- **SKOS (Simple Knowledge Organization System) :** langage pour les thésaurus et taxonomies. Il est adapté aux systèmes d'organisation des connaissances [39].

Réutilisation d'ontologies La réutilisation d'ontologies existantes est une pratique recommandée [19]. Elle présente plusieurs avantages :

- **Économie de temps et de coûts :** on ne repart pas de zéro. On s'appuie sur un travail déjà validé. On évite de « réinventer la roue ».
- **Fiabilité :** les ontologies existantes ont souvent été testées et corrigées. Elles sont éprouvées. Elles intègrent l'expertise de plusieurs chercheurs.
- **Interopérabilité :** l'utilisation d'ontologies standards facilite l'échange de données. Elle permet l'intégration avec d'autres systèmes. Elle favorise la réutilisation dans d'autres contextes.
- **Communauté :** les ontologies existantes ont souvent une communauté d'utilisateurs. On peut bénéficier de leur expertise. On peut contribuer à leur amélioration.

Plusieurs ontologies sont disponibles dans les domaines biomédicaux et pharmaceutiques. Certaines portent spécifiquement sur les plantes médicinales. D'autres couvrent la médecine traditionnelle [28]. Notre travail partira d'une de ces ontologies.

I.2.3 Adaptation, alignement et enrichissement ontologique

Adaptation d'une ontologie L'adaptation modifie une ontologie pour un nouveau contexte (Klein & Fensel, 2001). Elle est nécessaire quand l'ontologie source ne couvre pas parfaitement le domaine visé. Elle est également nécessaire quand le contexte d'utilisation diffère.

L'adaptation peut inclure :

- **Ajout de classes :** pour couvrir des concepts absents. Par exemple, ajouter des classes pour les maladies spécifiques au Burkina Faso (paludisme, onchocercose, méningite).
- **Ajout de propriétés :** pour décrire des attributs non prévus. Par exemple, ajouter une propriété pour le nom vernaculaire en langue locale (mooré, dioula, fulfuldé).
- **Modification de relations :** pour adapter la sémantique. Par exemple, préciser la relation *« traite »* avec des attributs de niveau de preuve.
- **Suppression de classes :** si elles ne sont pas pertinentes. Mais on évite de supprimer pour préserver la compatibilité. On peut les marquer comme obsolètes.
- **Redéfinition de restrictions :** pour adapter les contraintes logiques.

Alignement d'ontologies L'alignement établit des correspondances entre ontologies [9]. Il relie des concepts équivalents ou similaires. Il permet de fusionner des connaissances de sources différentes. Il facilite l'interopérabilité.

Les correspondances peuvent être :

- **Équivalence :** les concepts sont identiques (`owl:equivalentClass`).
- **Spécialisation :** un concept est un sous-concept de l'autre (`rdfs:subClassOf`).
- **Association :** les concepts sont liés par une relation.
- **Correspondance approximative :** les concepts sont similaires mais pas identiques.

Les méthodes d'alignement peuvent être :

- **Manuelles :** un expert établit les correspondances. C'est précis mais coûteux.
- **Automatiques :** des algorithmes comparent les termes. Ils utilisent des mesures de similarité. Ils sont efficaces mais moins précis.
- **Semi-automatiques :** l'outil propose des correspondances. L'expert les vérifie et les corrige. C'est un bon compromis.

Enrichissement ontologique L'enrichissement ajoute de nouvelles connaissances à l'ontologie (Navigli et al., 2003). Il intègre des données issues de sources externes. Il peut être manuel (expert humain) ou assisté par des outils.

Les sources d'enrichissement peuvent être :

- Textes scientifiques : articles, thèses, rapports.
- Bases de données : bases de données botaniques, pharmacologiques.
- Ontologies tierces : pour aligner et intégrer.
- Connaissances d'experts : savoirs d'experts du domaine.

Les étapes de l'enrichissement sont :

1. **Identification des sources :** sélectionner les sources pertinentes.
2. **Extraction des connaissances :** extraire les faits des sources.
3. **Transformation :** convertir les faits dans le format de l'ontologie.
4. **Intégration :** ajouter les faits à l'ontologie.
5. **Validation :** vérifier la cohérence et la correction.
6. **Documentation :** tracer les modifications.

Démarche pour notre recherche Notre recherche suivra une démarche d'adaptation et d'enrichissement. Nous partirons d'une ontologie existante. Nous l'adapterons au contexte burkinabè. Nous ajouterons des classes pour les plantes locales. Nous ajouterons des propriétés pour les noms vernaculaires. Nous modifierons les relations, si nécessaire. Nous enrichirons avec des données de la littérature. Nous documenterons toutes les modifications.

I.2.4 Bases de connaissances et interrogation sémantique

Définition et structure Une base de connaissances est un système qui stocke des connaissances structurées (Guarino, 1995). Elle contient des instances (individus) et des faits. La base est typée par une ontologie. L'ontologie sert de schéma conceptuel.

Par exemple, l'ontologie définit la classe *« Plante »* et la propriété *« aPourUsage »*. La base de connaissances contient des instances comme *« Cassia alata »*. Elle contient des faits comme *« Cassia alata aPourUsage Paludisme »*.

Bases de connaissances orientées graphe Notre recherche utilisera une base de connaissances orientée graphe (*graph database*). Ce type de base est particulièrement adapté aux données fortement interconnectées. Elle stocke les données sous forme de nœuds et de relations.

Les avantages des bases de données graphe sont :

- **Performance :** les requêtes de parcours de graphe sont efficaces. Les relations sont des « citoyens de première classe ».
- **Flexibilité :** le schéma est flexible. On peut ajouter de nouveaux types de nœuds et de relations facilement.
- **Expressivité :** on peut modéliser des relations complexes. On peut naviguer dans le graphe.
- **Intuitivité :** le modèle est proche de la représentation humaine. Les concepts sont des nœuds. Les liens sont des relations.

Les langages de requête pour les graphes incluent :

- **Cypher :** langage de Neo4j, le plus populaire. Il est déclaratif et expressif. Il permet des requêtes complexes sur les graphes.
- **Gremlin :** langage d'Apache TinkerPop. Il est utilisé par plusieurs bases de données graphe. Il est plus bas niveau que Cypher.

Interrogation avec Cypher Cypher est le langage de requête pour Neo4j. Une requête Cypher typique :

```
MATCH (p:Plante {nomVernaculaire: "Néré"}) RETURN p.nomScientifique,
                                p.usages
```

Cette requête retrouve le nom scientifique et les usages de la plante appelée « Néré ».

Les requêtes Cypher peuvent utiliser :

- `MATCH` : pour retrouver des motifs dans le graphe.
- `WHERE` : pour filtrer les résultats.
- `RETURN` : pour spécifier ce qui est renvoyé.
- `OPTIONAL MATCH` : pour des correspondances optionnelles.
- `CREATE` : pour créer de nouveaux nœuds et relations.

Avantages des bases de connaissances graphe Les bases de connaissances graphe offrent plusieurs avantages :

- **Interrogation puissante :** on peut formuler des requêtes complexes. On peut combiner plusieurs critères. On peut naviguer à travers les relations.
- **Découverte de connaissances implicites :** le parcours du graphe peut révéler des connexions non évidentes. Par exemple, on peut trouver des plantes qui partagent des usages ou des propriétés.
- **Traçabilité :** chaque fait peut être associé à sa source. On peut remonter à l'origine de l'information. On peut vérifier la fiabilité.
- **Intégration :** on peut combiner des données de différentes sources. L'ontologie sert de cadre unificateur.
- **Évolutivité :** on peut ajouter de nouvelles connaissances sans tout reconstruire. La base est extensible.

Application à notre recherche Notre base de connaissances sera construite à partir de l'ontologie adaptée. Elle utilisera un modèle orienté graphe. Elle contiendra des informations sur les plantes, leurs usages, leurs propriétés et leurs sources. Elle permettra des requêtes sémantiques riches. Elle sera interrogeable via l'application web.

I.3 Intelligence artificielle pour l'accès aux connaissances

I.3.1 Traitement des requêtes en langage naturel

Introduction au TALN Le traitement automatique du langage naturel (TALN) est une branche de l'intelligence artificielle (IA). Il vise à faire comprendre les textes humains par les machines [16]. Il analyse la syntaxe et la sémantique. Il convertit les requêtes en formalismes exploitables. Il permet la communication entre l'homme et la machine.

Techniques fondamentales Les techniques de Traitement Automatique du Langage Naturel (NLP) incluent :

- **Tokenisation :** découpage du texte en unités (mots, ponctuations). Exemple : « Quelles plantes traitent le paludisme ? » devient `["Quelles", "plantes", "traitent", "le", "paludisme", "?"]`.

- **Analyse morphologique :** identification des racines des mots. Exemple : « traitent » a pour racine « traiter ». Cela permet de normaliser les variantes (lemmatisation et *stemming*).
- **Étiquetage morphosyntaxique :** reconnaissance des catégories grammaticales. On identifie les noms, les verbes, les adjectifs, etc. (*part-of-speech tagging*).
- **Reconnaissance d'entités nommées (NER) :** détection des concepts clés. On identifie les plantes, les maladies, les parties de plantes, les modes de préparation [22].
- **Analyse de dépendances :** compréhension des relations entre mots. On identifie le sujet, le verbe, l'objet. On détermine les relations syntaxiques.
- **Analyse sémantique :** compréhension du sens des phrases. On peut utiliser des représentations vectorielles (*embeddings*) ou des graphes de connaissances.

Approches modernes : les transformers Les modèles récents utilisent les *transformers* [36]. Ces modèles sont basés sur le mécanisme d'attention. Ils capturent des contextes larges. Ils sont entraînés sur de grandes quantités de textes.

Les modèles populaires incluent :

- **BERT (*Bidirectional Encoder Representations from Transformers*) :** modèle de Devlin et al. [7]. Il est bidirectionnel. Il capture le contexte gauche et droit. Il excelle pour la compréhension.
- **GPT (*Generative Pre-trained Transformer*) :** modèle de Radford et al. [26]. Il est unidirectionnel. Il excelle pour la génération. Il est utilisé dans ChatGPT.
- **T5 (*Text-to-Text Transfer Transformer*) :** modèle de Raffel et al. [26]. Il traite toutes les tâches comme des transformations texte-texte.

Ces modèles sont pré-entraînés sur des corpus généraux. Ils peuvent être affinés (*fine-tunés*) sur des données spécifiques. Ils donnent de meilleurs résultats que les approches traditionnelles.

Application à notre recherche Notre système interprétera des requêtes variées. Il utilisera des modèles NLP pour comprendre les demandes. Il extraira les entités et les relations. Il transformera les requêtes naturelles en requêtes formelles pour la base de connaissances graphe. Il permettra une interaction naturelle avec le système.

Exemples de requêtes :

- « Quelles plantes sont utilisées contre le paludisme ? »
- « Comment prépare-t-on le remède contre la diarrhée ? »
- « La plante X a-t-elle des propriétés anti-inflammatoires ? »
- « Quelles études existent sur la toxicité de Y ? »
- « Quelles plantes du Burkina Faso sont utilisées pour le diabète et ont des études pharmacologiques ? »

I.3.2 Extraction et structuration assistées par IA

Extraction d'information L'extraction d'information est une tâche de NLP (Grishman, 2019). Elle identifie des faits à partir de textes non structurés. Elle reconnaît les entités et les relations. Elle produit des données structurées exploitables.

Les étapes de l'extraction sont :

1. **Reconnaissance des entités :** identifier les entités nommées (plantes, maladies, substances).
2. **Reconnaissance des relations :** identifier les relations entre entités (*traite*, *contient*, *prévient*).
3. **Normalisation :** standardiser les entités (synonymes, variantes orthographiques).
4. **Structuration :** organiser les faits en format structuré.

Approche par prompts d'IA Notre recherche utilisera une approche par *prompts* d'IA pour l'extraction. Cette approche utilise des modèles de langage de grande taille (LLM) comme GPT, Claude ou des modèles *open source*.

Le principe repose sur quatre phases :

- **Préparation du prompt :** on conçoit un *prompt* qui demande au modèle d'extraire des informations spécifiques d'un texte. Le *prompt* précise les entités et les relations à extraire.
- **Soumission au modèle :** on envoie le texte et le *prompt* au modèle. Le modèle génère une réponse structurée.
- **Extraction :** on extrait les informations de la réponse. On les convertit dans le format souhaité.
- **Validation :** on vérifie la qualité de l'extraction. On corrige si nécessaire.

Les avantages de cette approche sont :

- **Flexibilité :** on peut adapter le *prompt* à différents types de documents.
- **Rapidité :** l'extraction est rapide pour de grands volumes de textes.
- **Adaptabilité :** on peut modifier le *prompt* pour extraire différents types d'informations.
- **Utilisation de modèles pré-entraînés :** on bénéficie des connaissances générales du modèle.

Les limites sont :

- **Hallucinations :** le modèle peut générer des informations fausses.
- **Incohérence :** le modèle peut donner des réponses variables.
- **Coût :** l'utilisation de modèles commerciaux peut être coûteuse.

Dans notre recherche, nous utiliserons des *prompts* d'IA pour l'extraction. Une validation humaine sera systématique. L'expert vérifiera et corrigera les propositions.

Structuration des données La structuration convertit les faits extraits en formats standardisés. Pour notre base de connaissances graphe, nous utiliserons :

- **Format d'importation :** les données seront préparées en JSON ou CSV. Ces formats sont compatibles avec les outils d'importation de Neo4j.
- **Modèle de données :** les données seront structurées selon l'ontologie. Les nœuds et les relations seront définis.
- **Propriétés :** chaque nœud aura des propriétés (nom, type, etc.). Chaque relation aura des propriétés (type, source, niveau de preuve).

Application à notre recherche Dans notre recherche, l'IA assistera l'extraction via des *prompts*. Elle repérera les mentions de plantes, usages, parties et propriétés. Elle identifiera les relations entre ces entités. Elle produira des données structurées. Une validation humaine restera systématique.

I.3.3 Recherche sémantique et génération de réponses

Recherche sémantique La recherche sémantique va au-delà de la simple correspondance de mots [4]. Elle utilise le sens des termes. Elle s'appuie sur l'ontologie et la base de connaissances. Elle retrouve des informations pertinentes même avec des formulations différentes.

Le processus de recherche sémantique se déroule comme suit :

1. **Analyse de la requête :** le NLP analyse la requête utilisateur. Il identifie les concepts et les relations.

2. **Désambiguïsation :** si un terme est ambigu, le système utilise le contexte. Par exemple, « paludisme » pourrait être « malaria » ou « fièvre des marais ». Le système choisit le concept approprié.
3. **Transformation en requête formelle :** la requête naturelle est convertie en requête pour la base de connaissances graphe (Cypher). Les concepts sont mappés sur les nœuds et relations.
4. **Exécution :** la requête est exécutée sur la base de connaissances. Les résultats sont récupérés.
5. **Filtrage et classement :** les résultats sont filtrés et triés par pertinence. On peut utiliser des critères de fiabilité (niveau de preuve) ou de proximité sémantique.
6. **Génération de la réponse :** les résultats sont transformés en texte lisible.

Système RAG (*Retrieval-Augmented Generation*) Notre recherche utilisera un système RAG (*Retrieval-Augmented Generation*) pour l'accès intelligent aux connaissances. Le RAG combine la recherche d'informations et la génération de réponses [18].

Le fonctionnement d'un système RAG s'articule ainsi :

- **Interprétation de la requête :** le système comprend la demande de l'utilisateur.
- **Recherche :** le système interroge la base de connaissances. Il retrouve les informations pertinentes (nœuds, relations, propriétés).
- **Contexte :** les informations retrouvées sont organisées en contexte. Ce contexte est présenté au modèle de langage.
- **Génération :** le modèle de langage génère une réponse. La réponse est basée sur le contexte retrouvé. Elle est donc factuelle et traçable.
- **Affichage des sources :** les sources des informations sont affichées. L'utilisateur peut vérifier l'origine.

Les avantages du RAG sont :

- **Fiabilité :** les réponses sont basées sur des faits de la base. Les hallucinations sont réduites.
- **Traçabilité :** on peut remonter aux sources. On peut vérifier l'information.
- **Actualisation :** on peut mettre à jour la base. Les réponses sont automatiquement mises à jour.
- **Adaptabilité :** on peut adapter la base à différents contextes.

Application à notre recherche Notre système utilisera une architecture RAG. Il interprétera les requêtes en langage naturel. Il interrogera la base de connaissances graphe. Il générera des réponses basées sur les faits retrouvés. Les réponses incluront les sources et les niveaux de preuve. L'utilisateur pourra vérifier l'origine des informations.

I.3.4 Traçabilité et fiabilité des réponses

Importance de la traçabilité La traçabilité est essentielle pour la crédibilité d'un système (Floridi et al., 2018). Elle associe chaque information à sa source. Elle permet de vérifier l'origine. Elle renforce la confiance des utilisateurs. Elle est cruciale en contexte médical.

Sans traçabilité, les informations sont difficiles à vérifier. Elles peuvent être erronées ou obsolètes. Les utilisateurs ne peuvent pas évaluer leur fiabilité. Le système perd en crédibilité.

Mécanismes de traçabilité Les mécanismes de traçabilité incluent :

- **Stockage des références :** chaque fait est stocké avec un identifiant de source. La source est décrite (titre, auteur, année, éditeur, DOI).
- **Association information-source :** dans la base, l'information est liée à la source par une relation. Exemple : `(information)-[:PROVIENT_DE]->(source)`.
- **Affichage des sources :** les réponses affichent les sources. On peut cliquer pour obtenir le détail. On peut voir la page ou la section exacte. On peut voir le DOI ou l'URL.
- **Citations :** on utilise des citations numérotées comme dans les articles scientifiques. On peut renvoyer à une bibliographie.
- **Lien vers les documents :** si les documents sont disponibles en ligne, on fournit des liens.

Fiabilité des réponses La fiabilité dépend de la qualité des sources. Nous utiliserons des sources scientifiques validées :

- **Articles évalués par les pairs :** publiés dans des revues scientifiques.
- **Thèses et mémoires :** validés par des jurys académiques.
- **Rapports de recherche :** produits par des institutions reconnues.
- **Livres et chapitres de livres :** publiés par des maisons d'édition scientifiques.

Nous éviterons les sources non vérifiées (sites web non référencés, articles de vulgarisation non validés, témoignages non vérifiés, informations sans attribution).

Distinction des niveaux de preuve Nous distinguerons clairement les niveaux de preuve :

- **Usage traditionnel :** nous indiquons que c'est un usage rapporté, non démontré scientifiquement.
- **Activité *in vitro* :** nous mentionnons que l'activité a été testée en laboratoire sur des cellules ou des micro-organismes.
- **Activité *in vivo* :** nous précisons que l'efficacité a été démontrée sur des animaux.
- **Essai clinique :** nous mettons en avant le niveau de preuve le plus élevé.
- **Toxicité :** nous signalons toute information sur la toxicité ou les effets secondaires.

Gestion des incertitudes Nous indiquerons aussi les incertitudes :

- Si une information est contestée ou non confirmée, nous le mentionnons.
- Si les données sont contradictoires, nous les présentons toutes.
- Si les études sont limitées, nous le signalons.
- Si une information est ancienne, nous indiquons la date.

Limites de l'IA L'IA ne créera pas de nouvelles connaissances thérapeutiques. Elle ne remplacera pas l'expertise humaine. Elle facilitera l'accès aux connaissances existantes. La responsabilité de l'interprétation reste à l'utilisateur. Le système est un outil d'aide à la consultation, pas un outil de diagnostic ou de prescription.

I.4 Travaux connexes et positionnement scientifique

Cette section présente les travaux existants dans le domaine de la modélisation des connaissances en médecine traditionnelle à base de plantes. Elle analyse les ontologies et systèmes développés en Afrique et au Burkina Faso. Elle positionne notre recherche par rapport à ces travaux.

I.4.1 Ontologies dans le domaine des plantes médicinales

Ontologies internationales

Plusieurs ontologies couvrent le domaine des plantes médicinales. Chacune a ses forces et ses limites.

- **Flora Ontology (FLOPO) :** Cette ontologie décrit la structure botanique des plantes [14]. Elle inclut les parties de plantes. Elle couvre les stades de développement. Elle est très complète pour la botanique. Mais elle ne couvre pas les usages médicinaux ni les connaissances ethnobotaniques.
- **Plant Ontology (PO) :** Cette ontologie est similaire à FLOPO [5]. Elle se concentre sur l'anatomie et le développement des plantes. Elle est utilisée pour l'annotation de données génomiques. Elle n'inclut pas les connaissances ethnobotaniques ni pharmacologiques.
- **Ontology of Traditional Medicine (OTM) :** Cette ontologie est dédiée à la médecine traditionnelle [28]. Elle couvre les concepts comme les maladies, les traitements, les remèdes. Elle intègre des notions de la médecine traditionnelle chinoise et de l'Ayurvéda. Elle est prometteuse mais encore en développement et non spécifique aux plantes d'Afrique.
- **Drug Ontology (DrOn) :** Cette ontologie couvre les propriétés pharmaceutiques [13]. Elle décrit les médicaments, leurs ingrédients, leurs effets. Elle est utile pour les aspects pharmacologiques, mais centrée sur les médicaments modernes.
- **Food Ontology (FOODON) :** Cette ontologie couvre la nutrition et les aliments [8]. Elle inclut certaines plantes comestibles. Elle peut être partiellement réutilisée pour les aspects alimentaires, mais n'est pas spécifique aux usages médicinaux.
- **SNOMED CT :** SNOMED CT est une terminologie clinique large (IHTSDO, 2020). Elle couvre de nombreux domaines médicaux et inclut certains concepts sur les plantes. Mais elle n'est pas structurée comme une ontologie formelle.

Ontologies de la médecine traditionnelle africaine

Plusieurs travaux récents ont développé des ontologies spécifiques à la médecine traditionnelle africaine. Ces travaux reconnaissent les particularités des systèmes de soins africains. Ils intègrent des dimensions culturelles, spirituelles et sociales.

WATRIMed et HTM Ontology : une ontologie régionale de la médecine traditionnelle ouest-africaine Le projet WATRIMed (West African Traditional Medicine) [40] constitue l'une des initiatives les plus abouties en matière de modélisation sémantique de la médecine traditionnelle à base de plantes en Afrique de l'Ouest. Il s'appuie sur une ontologie formelle, appelée HTM Ontology (Herbal-based Traditional Medicine Ontology), dont l'objectif est de structurer les connaissances sur les plantes médicinales, les recettes traditionnelles et les maladies traitées dans la sous-région.

Cette ontologie comporte plusieurs centaines de concepts et de propriétés. Elle est organisée autour d'entités centrales telles que :

- **MedicinalPlant** (plante médicinale),
- **Recipe** (recette / remède traditionnel),
- **Disease/Symptom** (maladie / symptôme),
- **PlantPart** (partie de plante utilisée),
- **PreparationMethod**, **AdministrationMode**, **Dosage**,
- **ChemicalCompound**, **ContraIndication**, **TherapeuticIndication**,
- **Source** (référence bibliographique, base de données).

Les relations principales entre ces entités incluent :

- Recipe uses MedicinalPlant (une recette utilise une ou plusieurs plantes),
- Recipe treats Disease/Symptom (une recette traite une ou plusieurs pathologies),
- Recipe hasPart PlantPart (parties utilisées : racine, feuille, écorce, etc.),
- Recipe hasPreparationMethod, hasAdministrationMode, hasDosage,
- MedicinalPlant contains ChemicalCompound, etc.

WATRIMed couvre l'ensemble de l'Afrique de l'Ouest, notamment les pays membres de l'UEMOA et de l'OUA. Elle s'appuie en partie sur la Pharmacopée Herbal de l'UA/OUA, qui inclut des données sur le Burkina Faso. Les maladies et recettes modélisées sont représentatives des réalités sanitaires de la sous-région (paludisme, troubles digestifs, dermatoses, etc.).

Les apports principaux de ce travail résident dans la richesse de l'ontologie, son alignement avec d'autres bases de connaissances biomédicales, et sa vocation à soutenir la phytovigilance et la recherche en médecine traditionnelle.

Sources principales :

- « Enabling West African Herbal-Based Traditional Medicine Digitizing : The WATRIMed » (IOS Press, Studies in Health Technology and Informatics).
- « Design Considerations for a Knowledge . . . » (IOS Press, WATRIMed knowledge graph).

ontoMEDTRAD : ontologie visuelle pour l'Afrique de l'Ouest ontoMEDTRAD est une autre initiative importante, développée pour la médecine traditionnelle ouest-africaine [17]. Elle se distingue par son approche à la fois formelle et visuelle. L'ontologie est divisée en deux modules complémentaires :

- **ontoCONCEPT-Term** : ontologie terminologique de domaine (plantes, recettes, maladies, préparations, etc.),
- **ontoICONE** : module iconique qui associe à ces concepts des représentations iconiques destinées à faciliter la compréhension par des tradipraticiens souvent illettrés dans les langues officielles.

ontoMEDTRAD modélise explicitement les entités suivantes : Plant (plante), Recipe (recette / remède), Disease/Symptom (maladie / symptôme), PlantPart (partie de plante utilisée), PreparationMethod, AdministrationMode, représentations iconiques associées.

Les relations clés incluent : Recipe usesPlant Plant (une recette utilise une ou plusieurs plantes), Recipe treats Disease (une recette traite une ou plusieurs pathologies), Recipe hasPreparation, hasAdministration, etc.

Bien que conçue dans un contexte ouest-africain (Côte d'Ivoire, Sénégal, etc.), ontoMEDTRAD est théoriquement applicable au Burkina Faso. Elle met l'accent sur la représentation des recettes multi-plantes, en particulier antipaludéennes. Elle propose une méthode originale pour dépasser les barrières linguistiques et l'illettrisme grâce à la dimension iconique.

Sources principales :

- Thèse : « Système de gestion de la médecine traditionnelle dans une plateforme web social et sémantique : une approche basée sur une ontologie visuelle », C. Appoh, Université de Bretagne Occidentale, 2018 (HAL : tel-01842116).
- Article : « Visual Representation of African Traditional Medicine Recipes Using Icons and a Formal Ontology, ontoMEDTRAD », HAL, 2020/2021.

ATHMed Ontology : un système à base de connaissances pour la médecine traditionnelle africaine L'ontologie ATHMed (African Traditional Herbal Medicine) a été développée dans un contexte ghanéen, mais avec une vocation généralisable à l'ensemble de l'Afrique. Elle vise à concevoir un système à base de connaissances permettant la capture, le stockage, l'indexation et la recherche d'informations sur la médecine traditionnelle à base de plantes.

ATHMed structure les connaissances autour d'entités telles que :

- Plant (plante),
- Treatment/Recipe (traitement / recette),
- Disease/Symptom (maladie / symptôme),
- Preparation (préparation),
- Dosage (dosage),
- DosingDevice (dispositif de dosage),
- Activity (activité de traitement / diagnostic).

Les relations principales incluent : Treatment usesPlant Plant (un traitement utilise une ou plusieurs plantes), Treatment treats Disease (un traitement traite une ou plusieurs pathologies), Treatment hasPreparation, hasDosage, etc.

Une originalité de cette approche réside dans son hybridation entre ontologie et techniques de machine learning. L'objectif est d'extraire et de structurer automatiquement ou semi-automatiquement des connaissances à partir de textes.

Source principale :

- Article : « Toward a Knowledge-Based System for African Traditional Herbal Medicine : A Design Science Research Approach », Frontiers in Artificial Intelligence, 2022 (PMC8959699).

Travaux sur les « deep ontologies » de la médecine traditionnelle africaine Parallèlement à ces initiatives, plusieurs travaux conceptuels ont proposé des « deep ontologies » pour la médecine traditionnelle africaine. Ces ontologies visent à intégrer non seulement les aspects cliniques et pharmacologiques (plantes, maladies, traitements), mais aussi des dimensions contextuelles, culturelles et symboliques propres à la médecine traditionnelle, telles que les rites et les croyances.

Ces modèles s'appuient sur des méthodologies d'ingénierie des connaissances comme METHONTOLOGY. Ils sont généralement implémentés dans des outils tels que Protégé (OWL). Ils mettent en avant la nécessité de modéliser des entités comme : TherapeuticRecipe, TherapeuticProcess, Ritual, Belief, en plus des classes plus classiques (Plant, Disease, Symptom).

Exemples concrets d'articles :

- Ayimdji A., Koussoubé S., Fotso L. P., Konfé B. O. (2011). « Towards a "Deep" Ontology for African Traditional Medicine » [3], Intelligent Information Management, vol. 3, n° 6, p. 244–251.

  Cet article propose une première version d'une ontologie « profonde » pour la médecine traditionnelle africaine. Il insiste sur la nécessité de prendre en compte des aspects contextuels et culturels au-delà des simples relations plante–maladie–traitement.

- Ayimdji A., Koussoubé S., Fotso L. P., Konfé B. O. (2012). « Using METHONTOLOGY to Build a Deep Ontology for African Traditional Medicine : First Steps », ARIMA, p. 1–12.

  Ce travail décrit les premières étapes de construction d'une ontologie profonde en appliquant la méthodologie METHONTOLOGY. Il présente une implémentation dans Protégé et une réflexion sur l'intégration des dimensions rituelles et symboliques.

Ces travaux offrent une réflexion méthodologique précieuse sur la manière de construire des ontologies « profondes » capables de rendre compte de la complexité de la médecine traditionnelle africaine. Cependant, ils restent majoritairement conceptuels. Ils ont peu de déploiements opérationnels à grande échelle. Ils proposent peu d'outils de consultation concrets destinés aux acteurs de terrain.

Ontologie pour les tradipraticiens (bone-setters) en Afrique de l'Ouest (2024) Un travail récent (2024) propose une ontologie pour les tradipraticiens spécialisés dans le traitement des fractures. Cette ontologie, appelée ontoFRACTURECARE, est dérivée du domaine des bone-setters en Afrique de l'Ouest.

Les auteurs constatent que les bone-setters restent le premier recours pour les populations rurales. Leur pratique se prouve là où la médecine conventionnelle montre ses limites. Mais la plupart des praticiens sont âgés et analphabètes. Il y a un manque d'intérêt chez les jeunes générations.

L'ontologie vise à structurer, mettre en valeur et fournir une désignation consensuelle des concepts pertinents. Elle servira de guide pour la prise de décision intelligente dans le processus de soins.

Modèle d'intégration des connaissances (Angole, 2021) Angole (2021) a développé un modèle basé sur une ontologie pour intégrer les connaissances de la médecine moderne et de la médecine traditionnelle africaine. Cette recherche a impliqué 237 professionnels de santé et 25 experts en médecine traditionnelle.

Le modèle utilise Basic Formal Ontology comme ontologie supérieure standard. Il s'aligne avec l'Ontologie de la Science Médicale Générale. Les terminologies médicales sont dérivées de l'Ontologie des Maladies Infectieuses.

L'objectif est de permettre la reconnaissance de la médecine traditionnelle africaine et son incorporation dans le système de santé. L'ontologie développée est capable de s'intégrer aux ontologies de la médecine moderne.

Ontologies nationales et ethniques Des ontologies ont été développées pour des contextes spécifiques. L'ontologie visuelle ontoMEDTRAD couvre l'Afrique de l'Ouest, principalement la Côte d'Ivoire et le Sénégal.

D'autres travaux documentent les systèmes nosologiques locaux. Par exemple, Souley [29] a étudié les entités nosologiques populaires chez les Haoussa. Ces travaux identifient des concepts médicaux locaux comme zahí, sanyi et shawara.

Particularités ontologiques de la médecine traditionnelle africaine Les travaux sur les ontologies de la médecine traditionnelle africaine révèlent des particularités importantes :

- **Holisme :** Le corps est une entité interconnectée composée de composantes naturelles et surnaturelles [34]. La santé est un bien-être physique, mental, spirituel, social et écologique complet.
- **Causalité téléologique :** Les maladies ne sont pas simplement des dysfonctionnements mécaniques. Elles peuvent résulter d'un effondrement de l'harmonie cosmique.
- **Traitement magico-rationnel :** Il combine les pouvoirs des plantes et ceux du guérisseur.

Inventaires et structuration de données ethnobotaniques au Burkina Faso

Au niveau du Burkina Faso, de nombreux travaux ont été menés pour recenser les plantes médicinales et leurs usages thérapeutiques. Il s'agit principalement :

- d'études ethnobotaniques publiées dans des revues scientifiques,
- de thèses et mémoires (pharmacie, biologie, médecine),
- de rapports de projets (AI4D, herbier national, chimiothèque, etc.).

Réalisés dans différentes régions du pays (Hauts-Bassins, Sud-Ouest, Centre-Est, etc.), ces travaux produisent des inventaires floristiques et des enquêtes auprès des tradipraticiens. Ils documentent :

- les noms scientifiques et vernaculaires des plantes,
- les parties utilisées,
- les pathologies traitées,
- les modes de préparation et d'administration,
- parfois les dosages et les toxicités.

Exemples d'articles, thèses et rapports sur les plantes médicinales du Burkina Faso :

- **Tibiri A. et al. (2020)** [33]. « Countrywide Survey of Plants Used for Liver Disease Management by Traditional Healers in Burkina Faso », Frontiers in Pharmacology, 2020.
  Enquête à l'échelle nationale sur les plantes utilisées contre les maladies hépatiques. Plus de 2 000 entrées de plantes correspondant à 212 espèces. Géolocalisation des tradipraticiens. Analyse statistique sous R.
- **Ouédraogo L., Endl J., Sombié P. A. E. D., Schaefer H., Kiendrebeogo M. (2020)** [24]. « Ethnobotanical use and conservation assessment of medicinal plants sold in markets of Burkina Faso », Ethnobotany Research and Applications, 20 :1–25, 2020.
  Enquête auprès de 30 commerçants de plantes médicinales dans six grandes villes. Identification de 104 espèces utilisées pour diverses pathologies (troubles gastro-intestinaux, paludisme, etc.). Évaluation du statut de conservation.
- **Nadembega P. et al. (2025)**. « An ethnobotanical survey of medicinal plants used for children's healthcare in Centre-Est Burkina Faso », Ethnobotany Research and Applications, 33, 2025.
  Enquête sur les plantes utilisées pour la santé des enfants dans la région du Centre-Est. Documentation de 185 espèces issues de 52 familles.
- **Zongo et al. (2025)** [46]. « Ethnopharmacological study on medicinal plants used for jaundice and liver-related disorders management in the Province of Kouritenga in the Central-Eastern of Burkina Faso », Journal of Advanced Translational and Preclinical Biomedicine, 2025.
  Étude ethnopharmacologique ciblée sur les plantes utilisées contre la jaunisse et les troubles hépatiques dans une province spécifique.
- **Traoré S., Diawara/Zimé H., Ouédraogo S., et al.** [35]. « Ethnobotanical Survey on Plants Used in the Treatment of Wounds by Traditional Health Practitioners in Burkina Faso », International Journal of Plant, Animal and Environmental Sciences, 15, 2025.
  Enquête sur les plantes utilisées par les tradipraticiens pour le traitement des plaies. Identification de 70 espèces.
- **Projet AI4D** [1]. « Création d'une base de données sur les plantes médicinales pour faciliter l'exploitation des connaissances ethnopharmacologiques locales ».
  Projet visant à construire une base de données ouverte et interrogeable sur les plantes médicinales du Burkina Faso. Champs standardisés : nom scientifique, famille, noms en mooré/dioula/fulfuldé, localisation spatiale, statut de conservation, usages médicaux.
- **Flahaut E.** [10]. « Pharmacopée et médecine traditionnelle dans l'ouest du Burkina Faso : plantes médicinales et soins du couple mère–enfant », Thèse de Doctorat en Pharmacie, Université de Lille II.
  Thèse ancienne mais souvent citée. Documente les plantes médicinales et les soins traditionnels dans l'ouest du Burkina Faso, en particulier pour la mère et l'enfant.
- **Étude synthétique sur les soins infantiles (2010)**. « Contribution à l'étude des plantes médicinales et des recettes médicamenteuses utilisées dans les soins infantiles au Burkina Faso », publication synthétique (13 pages, 4 tableaux, 42 références).
  Recense 79 espèces médicinales utilisées dans les soins infantiles, avec 167 recettes médicamenteuses documentées.

L'Herbier National des Plantes Médicinales du Burkina Faso (projet « Herbier avec chimiothèque ») L'Herbier National des Plantes Médicinales du Burkina Faso est un projet souvent désigné sous le nom de projet « Herbier avec chimiothèque ». Ce projet vise à créer un herbier national spécifiquement dédié aux plantes médicinales, couplé à une chimiothèque contenant des marqueurs chimiques des plantes répertoriées.

Le projet a les objectifs principaux suivants :

- réaliser des enquêtes ethnobotaniques régionales auprès des tradipraticiens de santé, en commençant par les régions du Centre et du Plateau central,
- établir un inventaire des plantes médicinales utilisées pour le traitement des dix pathologies prioritaires définies par le ministère de la Santé,
- identifier et géolocaliser ces plantes, et confectionner des spécimens d'herbier,
- procéder à l'identification botanique et au dosage de marqueurs chimiques pour les vingt plantes les plus couramment utilisées pour chaque pathologie,
- alimenter une base de données nationale sur les plantes médicinales, accessible via une application mobile et un site web.

Ce projet se veut la phase préliminaire d'une initiative plus ambitieuse, qui étendrait les enquêtes ethnobotaniques à toutes les régions du pays. Il s'inscrit dans une dynamique plus large de valorisation de la pharmacopée traditionnelle, avec notamment :

- la création de bosquets à plantes médicinales dans chaque province (annonce présidentielle de 2024–2025),
- l'approbation par le gouvernement de dizaines de produits issus de la pharmacopée traditionnelle,
- la mise en place de sites de conservation et de culture contrôlée des espèces médicinales.

Le projet « Herbier avec chimiothèque » se distingue des autres herbiers nationaux par sa focalisation explicite sur les plantes médicinales. Il combine :

- un herbier (spécimens botaniques identifiés et conservés),
- une chimiothèque (marqueurs chimiques identifiés et dosés),
- une base de données (informations ethnobotaniques, usages thérapeutiques, géolocalisation).

Il coexiste avec d'autres herbiers reconnus au Burkina Faso, notamment :

- l'Herbier National du Burkina (HNBU) du CNRST/INERA, héritier de la section de l'IFAN créée en 1954,
- l'herbier du Centre National de Semences Forestières (CNSF) (environ 15 000 spécimens),
- l'herbier de l'Université Joseph Ki-Zerbo (OUA).

Ces herbiers jouent un rôle important dans la conservation de la diversité végétale. Mais le projet « Herbier avec chimiothèque » est le seul à viser explicitement une base de données nationale structurée sur les plantes médicinales, avec une dimension ethnobotanique et chimique.

Ces travaux constituent une base empirique essentielle et spécifiquement burkinabè. Ils offrent des outils méthodologiques précieux (questionnaires, grilles de saisie) et des données de terrain riches. Cependant, ils ne proposent pas d'ontologie formelle explicite. Les connaissances sont principalement organisées dans des tableaux, des bases relationnelles simples ou des documents PDF, sans modèle sémantique unifié. De plus, les données restent dispersées entre différentes études, bases locales et projets (AI4D, herbier national, chimiothèque, etc.). Il n'existe pas encore d'application web centralisée permettant une consultation aisée et globale de ces connaissances dans une perspective de recherche et de modélisation sémantique.

Synthèse comparative des ontologies existantes

L'analyse de ces différents travaux met en évidence plusieurs points communs et différences.

Points communs

Les ontologies régionales (WATRIMed/HTM, ontoMEDTRAD, ATHMed) partagent une ambition commune : structurer de manière formelle les connaissances sur la médecine traditionnelle à base de plantes en Afrique. Elles modélisent explicitement les plantes, les recettes, les maladies, les parties utilisées, les modes de préparation et d'administration, et les relations entre ces entités. Toutes prennent

en compte le fait que plusieurs plantes peuvent être combinées dans une même recette pour traiter une ou plusieurs pathologies, via une entité centrale de type Recipe ou Treatment.

Différences

Elles diffèrent cependant sur plusieurs aspects :

- **Zone géographique de référence** : Afrique de l'Ouest vs Afrique générale.
- **Niveau de détail** : certaines incluent des composés chimiques, des rituels, des icônes ; d'autres restent plus simples.
- **Degré de formalisation** : ontologies OWL riches vs modèles plus légers.
- **Volume de données modélisées** : de quelques dizaines à quelques centaines de plantes et recettes.
- **Existence d'applications web** : peu d'outils opérationnels et accessibles aux acteurs locaux.

Le tableau I.1 présente une synthèse comparative des ontologies identifiées dans la littérature.

TABLE I.1 – Synthèse comparative des ontologies de la littérature

Ontologie	Domaine	Couverture	Particularité	Limite principale
FLOPO	Botanique	Structure des plantes	Très complète	Pas d'usages médicinaux
PO	Botanique	Anatomie végétale	Standard génomique	Pas d'ethnobotanique
OTM	Médecine trad.	Maladies, traitements	Intègre médecines asiatiques	Pas spécifique Afrique
DrOn	Pharmacologie	Médicaments, effets	Standard pharmaceutique	Pas de préparations trad.
FOODON	Alimentation	Plantes comestibles	Couverture large	Pas d'usages médicinaux
SNOMED CT	Clinique	Terminologie médicale	Large couverture	Structure non ontologique
WATRIMed/HTM	Med. trad. Ouest-Afr.	Plantes, recettes, maladies	Afrique de l'Ouest, riche	Peu d'applications web
ontoMEDTRAD (2018)	Med. trad. Ouest-Afr.	Plantes, recettes	Approche visuelle iconique	Côte d'Ivoire / Sénégal
ATHMed (2022)	Med. trad. Afr.	Plantes, traitements	Hybride ontologie/ML	Ghana
Deep Ontologies	Med. trad. Afr.	Plantes, rituels, croyances	Intègre dimensions culturelles	Conceptuel, peu opérationnel
Angole (2021)	Intégration Med.	Maladies, traitements	Alignement BFO	Général Afrique
ontoFRACTURECARE (2024)	Med. trad. (fractures)	Bone-setters	Structuration des connaissances	Domaine spécifique

Analyse synthétique

Le tableau révèle plusieurs constats. Les ontologies botaniques (FLOPO, PO) couvrent bien l'aspect plante mais ignorent les usages médicinaux. Les ontologies pharmaceutiques (DrOn) sont centrées sur les médicaments modernes. L'OTM est prometteuse mais non spécifique à l'Afrique.

Pour l'Afrique, plusieurs ontologies se distinguent. Celle de Tekemetieu [32] intègre les dimensions mystiques mais est limitée au Gabon et au Cameroun. Celle d'Angole (2021) offre une intégration avec la médecine moderne mais reste générale. ontoMEDTRAD (Appoh et al., 2018) est la plus aboutie pour l'Afrique de l'Ouest, avec son approche visuelle. WATRIMed/HTM couvre l'Afrique de l'Ouest et inclut le Burkina Faso.

Aucune de ces ontologies n'est spécifiquement dédiée aux plantes médicinales du Burkina Faso. Aucune n'intègre systématiquement la traçabilité des sources et les niveaux de preuve. Notre recherche vise à combler ces lacunes.

Apports de notre travail par rapport aux travaux existants

Notre travail s'inscrit dans un paysage déjà riche en initiatives de recensement, de structuration et de modélisation des connaissances sur les plantes médicinales en Afrique et plus particulièrement au Burkina Faso. Il existe d'une part des ontologies et systèmes à base de connaissances à vocation régionale ou continentale (WATRIMed/HTM, ontoMEDTRAD, ATHMed, deep ontologies de la médecine traditionnelle africaine). Il existe d'autre part de nombreux inventaires ethnobotaniques, thèses, rapports et projets de bases de données au Burkina Faso (enquêtes sur les plantes médicinales, projet AI4D, projet « Herbier avec chimiothèque », etc.).

Par rapport à cet existant, notre travail apporte une valeur ajoutée spécifique sur plusieurs plans : scientifique, méthodologique, technologique et sociétal.

Sur le plan scientifique, nous produisons une ontologie enrichie et une base de connaissances structurée, issues de la littérature scientifique burkinabè. Nous mettons en évidence les plantes, pathologies et régions les plus étudiées ainsi que les principales lacunes (dosages, toxicités, zones sous-documentées).

Sur le plan méthodologique, nous proposons une méthode d'extraction assistée par IA (prompts sur LLM) et un modèle conceptuel adapté au contexte burkinabè. Ce modèle intègre les noms vernaculaires (mooré, dioula, fulfuldé), les recettes multi-plantes lorsqu'elles sont documentées, et les coordonnées géographiques issues de l'INERA. Une validation humaine systématique garantit la qualité des données extraites.

Sur le plan technologique, nous implémentons une base de connaissances orientée graphe (Neo4j). Nous développons une application web de consultation (Streamlit) permettant des requêtes en langage naturel via un système RAG (Llama 3 + LangChain). L'application propose un chatbot, une recherche par plante ou pathologie, et des fiches descriptives avec sources et niveaux de preuve.

Sur le plan sociétal, nous contribuons à la valorisation du patrimoine végétal thérapeutique burkinabè. Nous fournissons une base structurée et traçable, utile pour la recherche, la préservation des connaissances endogènes et la diffusion scientifique.

Notre travail se positionne comme une couche complémentaire aux infrastructures existantes (ontologies régionales, inventaires, herbier national). Il apporte une modélisation sémantique centrée sur les usages thérapeutiques documentés, spécifiquement pour le Burkina Faso, avec une traçabilité systématique vers les sources scientifiques.

I.4.2 Systèmes intelligents d'accès aux connaissances

Typologie des systèmes Des systèmes existent pour l'accès aux connaissances médicinales. Ils utilisent différentes approches :

- **Systèmes experts :** Ils utilisent des règles logiques (Buchanan & Shortliffe, 1984) pour modéliser l'expertise humaine (ex. MYCIN). *Limites :* Difficiles à adapter aux connaissances traditionnelles, maintenance lourde.
- **Systèmes à base de cas :** Ils réutilisent des cas similaires (Kolodner, 1993). *Limites :* Nécessitent une base de cas très riche, difficulté avec les nouveaux cas.

- **Portails de connaissances :** Recherche par mots-clés (Chaudhry et al., 2006) comme PubMed ou Google Scholar. *Limites :* Absence de compréhension sémantique, pas de raisonnement possible.
- **Chatbots médicaux :** Interaction en langage naturel [15] comme Ada ou Babylon Health. *Limites :* Bases parfois limitées, fiabilité variable.
- **Plateformes d'ontologies :** Permettent des requêtes sémantiques formelles (Studer et al., 1998). *Limites :* Interfaces souvent complexes réservées aux experts.

Systèmes RAG pour l'accès aux connaissances Les systèmes RAG (*Retrieval-Augmented Generation*) représentent une avancée récente (Lewis et al., 2020). Des déclinaisons existent déjà dans certains domaines : *HealthRAG* (médical), *BioRAG* (biologique), *LegalRAG* (juridique).

Limites communes des systèmes existants

- Bases de connaissances incomplètes ou hétérogènes.
- Manque de traçabilité systématique vers les sources d'origine.
- Non-adaptation aux spécificités et langues locales.
- Absence de pondération par niveaux de preuve scientifique.

Positionnement de notre système Notre système se distingue par l'adaptation locale (Burkina Faso), l'enrichissement scientifique, la traçabilité systématique, l'intégration explicite des niveaux de preuve, et l'accès naturel facilité par RAG couplé à une base de données graphe (Neo4j).

I.4.3 Positionnement de notre recherche

Originalité de notre recherche Notre recherche occupe une position originale en réunissant :

1. **Réutilisation d'ontologie :** Gain de temps et garantie d'interopérabilité.
2. **Adaptation locale :** Prise en compte du contexte burkinabè et des noms vernaculaires locales (*mooré*, *dioula*, *fulfuldé*).
3. **Enrichissement scientifique :** Exploitation des thèses, articles et travaux locaux validés.
4. **Traçabilité des sources :** Chaque fait est lié à sa référence scientifique.
5. **Accès intelligent par RAG :** Requêtes formulées en langage naturel.
6. **Base de connaissances graphe :** Flexibilité de modélisation orientée graphe.
7. **Niveaux de preuve :** Distinction claire entre savoirs traditionnels, études *in vitro*, *in vivo* et essais cliniques.

Conclusion du chapitre

Ce chapitre a posé les fondements théoriques de notre recherche. Nous avons défini les concepts clés liés aux plantes médicinales et au patrimoine ethnobotanique. Nous avons présenté les principes de l'ingénierie des connaissances et des ontologies. Nous avons exploré les applications de l'intelligence artificielle pour l'accès aux connaissances, notamment à travers le traitement du langage naturel et les architectures de génération augmentée par récupération (*Retrieval-Augmented Generation* – RAG). Enfin, nous avons analysé les travaux connexes, en particulier les ontologies développées pour la médecine traditionnelle africaine.

La revue de la littérature montre qu'il existe des lacunes importantes. Aucune ontologie n'est spécifiquement dédiée aux plantes médicinales du Burkina Faso. Les ontologies existantes pour

l'Afrique de l'Ouest, telles que *ontoMEDTRAD* et *WATRIMed/HTM*, couvrent principalement la Côte d'Ivoire et le Sénégal. De plus, la traçabilité des connaissances et l'intégration systématique de sources scientifiques multiples restent des défis majeurs non résolus dans la littérature actuelle.

Notre recherche vise à combler ces lacunes. Elle apportera des contributions scientifiques, techniques et pratiques en proposant un modèle structuré, tracé et facilement accessible en langage naturel. Elle s'inscrit pleinement dans une démarche de valorisation et de préservation des savoirs locaux, tout en contribuant à l'essor et à l'intégration de la médecine traditionnelle en Afrique.

Le chapitre suivant présentera la démarche méthodologique adoptée pour mener à bien cette recherche. Nous y décrirons la constitution du corpus d'études, l'analyse comparative des ontologies existantes, la démarche d'adaptation et d'enrichissement de l'ontologie retenue, ainsi que la conception et le développement de notre système intelligent d'accès aux connaissances.

Chapitre II

Matériel et méthodologie

Introduction du chapitre

Ce chapitre présente le matériel utilisé et la démarche méthodologique adoptée pour notre recherche. Contrairement au chapitre précédent qui a défini les concepts théoriques et analysé l'état de l'art, ce chapitre décrit les choix opérationnels et les étapes concrètes de notre travail. Il constitue le pont entre la réflexion théorique et la mise en œuvre technique.

Le chapitre est structuré en trois parties principales. La première partie présente le matériel mobilisé : le corpus documentaire, les ontologies candidates et l'environnement technique. La deuxième partie détaille la méthodologie en huit phases, de l'identification et de la comparaison des ontologies à l'évaluation et la validation du système. La troisième partie présente une synthèse de la méthodologie et une transition vers le chapitre suivant.

Chaque phase de la méthodologie est décrite avec précision. Nous présentons pour chaque phase l'objectif poursuivi, les actions concrètes menées, les méthodes utilisées, les outils mobilisés et les livrables produits. Cette approche permet de garantir la reproductibilité de notre démarche et de faciliter l'évaluation de notre contribution.

II.1 Matériel

Cette section décrit l'ensemble des ressources utilisées dans notre recherche. Elle présente d'abord le corpus documentaire, ensuite les ontologies candidates, puis l'environnement technique. Un tableau de correspondance entre le matériel et les phases méthodologiques est fourni à la fin de cette section.

Le matériel mobilisé dans cette recherche est de nature variée. Il comprend des ressources documentaires (articles, thèses, rapports, bases de données), des ressources conceptuelles (ontologies existantes) et des ressources techniques (modèles de langage, bases de données, frameworks, bibliothèques). Chaque ressource est décrite avec précision afin de permettre la compréhension de son rôle dans la démarche globale.

II.1.1 Corpus documentaire

La constitution du corpus documentaire a été précédée par l'identification et la sélection de l'ontologie. Cette démarche permet de définir les concepts et les relations qui guideront l'extraction des connaissances. Elle assure une meilleure structuration des données dès la phase de collecte. Le corpus est constitué de documents scientifiques et techniques portant sur les plantes médicinales du Burkina Faso. Il comprend trois catégories de sources : les sources scientifiques publiées, les données de l'Herbier National des Plantes Médicinales du Burkina Faso, les données de l'INERA et les rapports de projets.

Sources scientifiques publiées

Nous avons collecté 35 rapports de recherche, articles scientifiques, thèses et mémoires. Ces documents proviennent de revues scientifiques, d'universités et d'institutions de recherche burkinabè. Ils couvrent des études ethnobotaniques, ethnopharmacologiques et phytochimiques menées dans différentes régions du pays. Ces études documentent les noms scientifiques et vernaculaires des plantes, les parties utilisées, les pathologies traitées, les modes de préparation et, parfois, les dosages et les toxicités.

Ces documents constituent la base principale de notre corpus. Ils ont été sélectionnés pour leur rigueur scientifique et leur pertinence pour le contexte burkinabè. Ils couvrent une période allant des travaux fondateurs aux publications récentes. La diversité des sources permet de couvrir un large éventail de plantes, de pathologies et de pratiques thérapeutiques.

Parmi ces documents, nous pouvons citer à titre d'exemples :

— Zerbo et al. (2011) ont étudié les plantes médicinales chez les Sanan du Burkina Faso. Leur travail documente 85 espèces utilisées pour traiter 63 affections.

— Ouedraogo et al. (2024) ont réalisé une revue des plantes médicinales à potentiel aromatique du Burkina Faso. Ils recensent 42 espèces et identifient leurs propriétés et usages.

— Tibiri et al. (2020) ont mené une enquête à l'échelle nationale sur les plantes utilisées contre les maladies hépatiques. Plus de 2 000 entrées de plantes correspondant à 212 espèces ont été documentées.

— Ouédraogo et al. (2020) ont enquêté auprès de 30 commerçants de plantes médicinales dans six grandes villes. Ils ont identifié 104 espèces utilisées pour diverses pathologies.

Ces travaux constituent une base empirique essentielle et spécifiquement burkinabè. Ils offrent des outils méthodologiques précieux et des données de terrain riches.

Données de l'Herbier National des Plantes Médicinales du Burkina Faso

Le site burkinaherbiermed.org met à disposition des données sur les plantes médicinales du Burkina Faso. Ces données incluent des informations botaniques, des usages thérapeutiques et des références bibliographiques. Elles sont issues du projet « Herbier avec chimiothèque » piloté par le Ministère de la Santé.

Ce projet vise à créer un herbier national dédié aux plantes médicinales, couplé à une chimiothèque contenant des marqueurs chimiques. Il documente les plantes utilisées pour les dix pathologies prioritaires définies par le ministère. Il géolocalise les plantes et confectionne des spécimens d'herbier. Il alimente une base de données nationale accessible via une application mobile et un site web.

Ce projet se distingue des autres herbiers nationaux par sa focalisation explicite sur les plantes médicinales. Il combine un herbier (spécimens botaniques identifiés et conservés), une chimiothèque (marqueurs chimiques identifiés et dosés) et une base de données (informations ethnobotaniques, usages thérapeutiques, géolocalisation). Il coexiste avec d'autres herbiers reconnus au Burkina Faso, notamment l'Herbier National du Burkina (HNBU) du CNRST/INERA, l'herbier du Centre National de Semences Forestières (CNSF) et l'herbier de l'Université Joseph Ki-Zerbo.

Données de l'INERA

L'Institut de l'Environnement et de Recherches Agricoles (INERA) dispose d'une base de données contenant plus de 7 000 espèces végétales. Ces données incluent les coordonnées géographiques des lieux où les plantes peuvent être trouvées. Elles permettent une analyse spatiale de la distribution des espèces. Elles complètent les données ethnobotaniques en fournissant une dimension géographique.

Ces données sont particulièrement précieuses pour notre recherche. Elles permettent de localiser les plantes sur le territoire burkinabè. Elles facilitent l'analyse de la répartition géographique des espèces.

Elles enrichissent la base de connaissances avec des informations spatiales. Ces données permettent également de croiser les usages traditionnels avec la distribution géographique des plantes, ce qui peut révéler des patterns régionaux intéressants.

Rapports de projets

Des rapports de projets sur les plantes médicinales documentent des centaines d'espèces. Ils proviennent de projets de recherche, d'ONG et d'institutions nationales. Ils fournissent des données complémentaires sur les usages traditionnels et les propriétés des plantes. Ils incluent également des informations sur les projets en cours, comme le projet AI4D et le projet « Herbier avec chimiothèque ».

Le projet AI4D (2020) vise à construire une base de données ouverte et interrogeable sur les plantes médicinales du Burkina Faso. Les champs standardisés incluent le nom scientifique, la famille, les noms en mooré/dioula/fulfulde, la localisation spatiale, le statut de conservation et les usages médicaux. Ce projet est particulièrement pertinent pour notre recherche car il partage des objectifs similaires de structuration et de diffusion des connaissances.

Le tableau II.1 récapitule les sources du corpus.

TABLE II.1 – Sources du corpus documentaire

Source	**Type**	**Volume estimé**	**Contenu principal**
Articles et thèses	Publications scientifiques	35 documents	Études ethnobotaniques, pharmacologiques
burkinaherbiermed.org	Base de données en ligne	Plusieurs centaines de plantes	Données botaniques, usages, références
INERA	Base de données institutionnelle	> 7 000 espèces	Coordonnées géographiques, identification
Rapports de projets	Littérature grise	Plusieurs centaines de plantes	Usages traditionnels, propriétés

Ce corpus présente une richesse et une diversité importantes. Il couvre différentes régions du Burkina Faso, différentes pathologies et différentes approches méthodologiques. Il constitue une base solide pour l'extraction des connaissances et l'enrichissement de l'ontologie. La sélection de l'ontologie en amont a permis de cibler les informations à extraire et d'organiser le corpus en fonction des concepts et relations définis. Cette approche méthodologique garantit une meilleure cohérence entre les données collectées et le modèle conceptuel utilisé.

II.1.2 Ontologies candidates

Pour notre étude comparative, nous avons identifié cinq ontologies candidates. Ces ontologies ont été présentées dans le chapitre I, aux sections I.4.1 et I.4.1. Elles couvrent des domaines variés : la botanique, la médecine traditionnelle, la pharmacologie et l'ethnomédecine. Le tableau II.2 présente ces ontologies avec leurs caractéristiques descriptives.

Ces ontologies seront comparées selon une grille de critères définie dans la Phase 1 (section II.2.1). La comparaison permettra de sélectionner l'ontologie la plus adaptée à notre contexte. Cette sélection est effectuée avant la constitution du corpus documentaire. Elle détermine le modèle conceptuel qui guidera l'extraction des connaissances.

Chacune de ces ontologies présente des forces et des faiblesses. Les ontologies botaniques (FLOPO, PO) couvrent bien l'aspect plante mais ignorent les usages médicinaux. Les ontologies pharmaceutiques (DrOn) sont centrées sur les médicaments modernes. L'OTM est prometteuse mais non spécifique à

TABLE II.2 – Ontologies candidates pour la comparaison

N°	Ontologie	Domaine	Zone géographique	Format	Source d'accès
1	WATRIMed / HTM	Médecine traditionnelle	Afrique de l'Ouest	OWL	IOS Press
2	ontoMEDTRAD	Médecine traditionnelle	Afrique de l'Ouest	OWL + iconique	Thèse C. Appoh
3	ATHMed	Médecine traditionnelle	Afrique (Ghana)	OWL	Frontiers in AI
4	Deep Ontologies	Médecine traditionnelle	Afrique	OWL (Protégé)	Articles ARIMA
5	FLOPO, PO	Botanique	International	OWL	OBO Foundry

l'Afrique. Les ontologies africaines (WATRIMed/HTM, ontoMEDTRAD, ATHMed) intègrent les dimensions culturelles et les recettes multi-plantes. Leur comparaison détaillée est présentée dans la Phase 1.

II.1.3 Outils et environnement technique

Cette section décrit les outils techniques utilisés dans notre recherche. Ces outils sont mobilisés dans différentes phases de la méthodologie. Pour chaque outil, nous précisons les phases concernées et les raisons de son choix.

Modèle de langage : Llama 3

Nous utilisons **Llama 3 70B** (Meta, 2024) comme modèle de langage. Llama 3 70B est un modèle open source de grande taille. Il offre des performances élevées en compréhension et en génération de textes. Il supporte le français, ce qui est essentiel pour traiter les documents scientifiques burkinabè. Il est également capable de suivre des instructions complexes, ce qui est indispensable pour l'extraction structurée.

Phases d'utilisation : Phase 5 (Extraction des connaissances) et Phase 7 (Génération de réponses RAG).

Le tableau II.3 présente les modes d'accès à Llama 3.

TABLE II.3 – Modes d'accès à Llama 3 70B

Usage	Mode d'accès	Environnement
Extraction	Ollama + Google Colab	Notebooks Colab avec GPU
Génération RAG	API via ngrok	Serveur local exposé

Le choix de Llama 3 70B se justifie par plusieurs raisons. Premièrement, ses performances surpassent celles des modèles plus petits sur les tâches complexes. Deuxièmement, il est open source, ce qui permet une utilisation sans contrainte de licence. Troisièmement, il supporte le français et peut être adapté aux langues locales. Quatrièmement, Ollama permet une exécution locale, tandis que ngrok permet un accès API distant pour l'application web. Cinquièmement, sa taille (70 milliards de paramètres) lui permet de capturer des nuances sémantiques fines, ce qui est crucial pour l'extraction de connaissances spécialisées.

Plateforme d'exécution : Google Colab

Les expériences d'extraction sont menées sur **Google Colab**. Colab est une plateforme de notebooks hébergée par Google. Elle offre un accès gratuit à des GPU (T4, V100, A100) adaptés à l'inférence de Llama 3 70B.

Phase d'utilisation : Phase 5 (Extraction des connaissances).

Google Colab présente plusieurs avantages. Il ne nécessite pas d'infrastructure locale coûteuse. Il offre un accès à des GPU performants. Il permet une exécution interactive et itérative. Il facilite la reproductibilité des expériences. Il s'intègre avec Google Drive pour le stockage des données et des résultats. Il permet également de partager facilement les notebooks avec d'autres chercheurs, ce qui favorise la collaboration et la validation.

Base de connaissances : Neo4j Desktop

Nous utilisons **Neo4j Desktop** comme base de connaissances orientée graphe. Neo4j Desktop est une version locale de Neo4j. Elle permet de créer, gérer et interroger des graphes de connaissances.

Phase d'utilisation : Phase 6 (Construction et interrogation de la base).

Le tableau II.4 présente les caractéristiques de Neo4j Desktop.

TABLE II.4 – Caractéristiques de Neo4j Desktop

Caractéristique	**Valeur**
Type	Base de données orientée graphe
Langage de requête	Cypher
Version	Desktop (locale)
Format d'import	CSV, JSON
Interface	Neo4j Browser, Bloom

Neo4j est particulièrement adapté à notre projet. Il permet une modélisation naturelle des relations complexes entre les plantes, les usages, les propriétés et les sources. Il offre une interrogation puissante avec Cypher. Il garantit la traçabilité des informations via des relations explicites. Il est extensible pour ajouter de nouvelles connaissances sans reconstruire la base. Il permet également de visualiser le graphe de connaissances, ce qui facilite la compréhension des relations entre les entités.

Orchestration RAG : LangChain

Nous utilisons **LangChain** comme framework d'orchestration du système RAG. LangChain permet de chaîner les composants : interprétation de la requête, recherche dans Neo4j, génération de la réponse.

Phase d'utilisation : Phase 7 (Exploitation par l'IA et développement web).

Le tableau II.5 présente les composants LangChain utilisés.

TABLE II.5 – Composants LangChain utilisés

Composant	**Rôle**
GraphCypherQAChain	Génération de requêtes Cypher à partir de questions naturelles
Neo4jGraph	Connexion à la base Neo4j
ChatOpenAI / Ollama	Intégration du modèle Llama 3
PromptTemplate	Construction des prompts
Memory	Gestion de l'historique de conversation

LangChain est le framework le plus mature pour les systèmes RAG. Il offre une intégration native avec Neo4j via `GraphCypherQAChain`. Il permet de gérer l'historique de conversation. Il est extensible

et bien documenté. Il s'intègre facilement avec Streamlit. Il permet également de définir des chaînes de traitement complexes tout en gardant le code lisible et maintenable.

Interface web : Streamlit

Nous utilisons **Streamlit** pour développer l'application web. Streamlit est un framework Python qui permet de créer des applications web interactives rapidement.

Phase d'utilisation : Phase 7 (Exploitation par l'IA et développement web).

L'application web proposera plusieurs fonctionnalités. Un chatbot en langage naturel permettra de poser des questions. Une recherche par plante, pathologie ou région sera disponible. Des fiches descriptives présenteront les plantes et leurs usages. Les sources et niveaux de preuve seront affichés. Une visualisation du graphe de connaissances sera intégrée.

Streamlit a été choisi pour plusieurs raisons. Il est simple à utiliser et permet un développement rapide. Il gère l'état de session pour les conversations. Il s'intègre facilement avec LangChain. Il produit une interface professionnelle et ergonomique. Il permet également de déployer l'application facilement sur des serveurs ou des plateformes cloud.

Bibliothèques Python

Les bibliothèques Python sont utilisées dans les phases 5, 6 et 7. Le tableau II.6 liste les bibliothèques Python utilisées.

TABLE II.6 – Bibliothèques Python utilisées

Bibliothèque	**Version**	**Rôle**
`neo4j`	5.x	Driver de connexion à Neo4j
`langchain`	0.1.x	Orchestration RAG
`langchain-community`	0.0.x	Intégrations Neo4j, Ollama
`streamlit`	1.30+	Interface web
`transformers`	4.40+	Chargement de Llama 3
`ollama`	0.1.x	Client Ollama
`sentence-transformers`	2.5+	Embeddings
`owlready2`	0.45+	Manipulation ontologies OWL
`rdflib`	7.0+	Format RDF/OWL
`pandas`	2.0+	Manipulation de données
`plotly`	5.18+	Visualisation

Ces bibliothèques couvrent l'ensemble des besoins techniques de notre recherche : connexion à la base de données, orchestration du système RAG, développement de l'interface web, chargement du modèle de langage, manipulation des ontologies, traitement des données et visualisation.

II.1.4 Tableau récapitulatif du matériel

Le tableau II.7 récapitule l'ensemble du matériel utilisé.

II.1.5 Tableau de correspondance Matériel - Phases

Le tableau II.8 établit la correspondance entre le matériel et les phases méthodologiques. Ce tableau permet de comprendre comment chaque ressource est mobilisée dans la démarche.

TABLE II.7 – Récapitulatif du matériel

Catégorie	**Élément**	**Spécification**
Corpus	Documents scientifiques	35 rapports, articles, thèses
	Base burkinaherbiermed.org	Plusieurs centaines de plantes
	Base INERA	> 7 000 espèces géolocalisées
	Rapports de projets	Centaines de plantes documentées
Ontologies	WATRIMed/HTM	OWL, Afrique de l'Ouest
	ontoMEDTRAD	OWL + iconique, Afrique de l'Ouest
	ATHMed	OWL, Ghana
	Deep Ontologies	OWL, Afrique
	FLOPO, PO	OWL, botanique
Modèle de langage	Llama 3 70B	Via Ollama + Colab (extraction), API ngrok (RAG)
Plateforme	Google Colab	GPU T4/V100/A100
Base de connaissances	Neo4j Desktop	Orientée graphe, Cypher
Orchestration RAG	LangChain	GraphCypherQAChain
Interface web	Streamlit	Chatbot, recherche, fiches
Bibliothèques	Python	neo4j, langchain, streamlit, transformers, etc.

TABLE II.8 – Correspondance entre le matériel et les phases

Matériel	**Phase**	**Utilisation**
Corpus documentaire	Phase 3	Constitution du corpus
Ontologies candidates	Phase 1	Comparaison et sélection
Llama 3 70B	Phase 5, Phase 7	Extraction, génération RAG
Google Colab	Phase 5	Exécution de l'extraction
Neo4j Desktop	Phase 6	Base de connaissances
LangChain	Phase 7	Orchestration RAG
Streamlit	Phase 7	Interface web
Bibliothèques Python	Phase 5, 6, 7	Développement

II.2 Méthodologie

Cette section détaille les huit phases opérationnelles de notre démarche. Chaque phase décrit les actions concrètes, les méthodes utilisées et les livrables attendus. Les phases sont organisées selon une progression logique : identification et comparaison des ontologies, définition des critères de recherche, constitution du corpus, adaptation de l'ontologie, enrichissement, construction de la base de connaissances, exploitation par l'intelligence artificielle et développement de l'application web, et enfin évaluation et validation.

Cette organisation méthodologique reflète notre souci de cohérence et de rigueur. En commençant par l'identification et la sélection de l'ontologie, nous nous assurons de disposer d'un cadre conceptuel solide avant de collecter les données. Cette approche garantit que les données collectées seront pertinentes et structurées selon le modèle choisi. Elle facilite également l'extraction des connaissances en ciblant les informations pertinentes dès la phase de collecte.

II.2.1 Phase 1 : Identification et étude comparative des ontologies

Objectif : Sélectionner l'ontologie la plus pertinente pour notre contexte.

La comparaison des ontologies suit une démarche en trois temps. Premièrement, nous définissons une grille de critères. Deuxièmement, nous notons chaque ontologie selon cette grille. Troisièmement, nous sélectionnons l'ontologie avec le score le plus élevé. Cette phase est fondamentale car elle détermine le modèle conceptuel qui guidera toute la suite de notre travail.

Définition de la grille de critères

Nous avons défini huit critères pour comparer les ontologies. Ces critères ont été choisis en fonction de nos besoins spécifiques : représenter les connaissances sur les plantes médicinales du Burkina Faso, intégrer les savoirs locaux, assurer la traçabilité des sources et permettre l'adaptation au contexte burkinabè. Le tableau II.9 présente ces critères.

TABLE II.9 – Grille de critères de comparaison

N°	Critère	Description	Pondération
1	Couverture du domaine	Capacité à représenter plantes, usages, propriétés, maladies	Élevée (3)
2	Richesse sémantique	Nombre et qualité des classes, relations, axiomes	Élevée (3)
3	Disponibilité	Ontologie accessible et téléchargeable	Élevée (3)
4	Documentation	Qualité de la documentation et des exemples	Moyenne (2)
5	Interopérabilité	Compatibilité avec OWL, RDF, SPARQL	Moyenne (2)
6	Adaptabilité	Facilité d'adaptation au contexte burkinabè	Élevée (3)
7	Traçabilité	Capacité à associer les connaissances aux sources	Élevée (3)
8	Prise en compte des savoirs locaux	Intégration des noms vernaculaires, recettes multi-plantes	Élevée (3)

Chaque critère est pondéré en fonction de son importance pour notre recherche. Les critères de pondération élevée (3) sont ceux qui sont essentiels pour notre contexte. Les critères de pondération

moyenne (2) sont importants mais moins critiques. Cette pondération permet de calculer un score global pour chaque ontologie.

Notation des ontologies

Chaque ontologie est notée de 1 (très faible) à 5 (très élevé) pour chaque critère. Le tableau II.10 présente les résultats.

TABLE II.10 – Notation des ontologies candidates

Ontologie	C1	C2	C3	C4	C5	C6	C7	C8	Score
WATRIMed/HTM	5	5	4	4	5	4	3	5	4.4
ontoMEDTRAD	5	4	3	3	4	5	2	5	4.0
ATHMed	4	4	3	3	4	3	2	3	3.3
Deep Ontologies	3	4	2	2	3	3	2	4	2.9
FLOPO / PO	2	3	5	4	5	2	1	1	2.8

L'analyse de ce tableau révèle plusieurs tendances. Les ontologies africaines (WATRIMed/HTM, ontoMEDTRAD, ATHMed) obtiennent les meilleurs scores grâce à leur couverture du domaine et leur prise en compte des savoirs locaux. Les ontologies botaniques (FLOPO, PO) sont bien notées sur la disponibilité et l'interopérabilité mais faibles sur la couverture des usages médicinaux et la prise en compte des savoirs locaux. L'ontologie WATRIMed/HTM se distingue par sa couverture complète (plantes, recettes, maladies, parties utilisées, modes de préparation) et sa capacité à modéliser les recettes multi-plantes.

Sélection de l'ontologie

L'ontologie WATRIMed/HTM obtient le score le plus élevé (4.4). Elle couvre l'Afrique de l'Ouest, inclut le Burkina Faso, et modélise les recettes multi-plantes. Elle dispose d'une documentation riche et d'une structure formelle adaptée. Elle est donc retenue pour notre étude.

Cette sélection préalable permet de disposer d'un cadre conceptuel solide pour l'extraction et l'organisation des connaissances. Elle guidera la constitution du corpus documentaire et l'adaptation de l'ontologie au contexte burkinabè.

Livrable : Ontologie WATRIMed/HTM sélectionnée.

II.2.2 Phase 2 : Définition des critères de recherche et de sélection des documents

Objectif : Définir les critères qui guideront la recherche et la sélection des documents scientifiques.

La définition des critères suit une démarche en deux temps. Premièrement, nous définissons les critères de recherche. Deuxièmement, nous définissons les critères de sélection des documents. Ces critères permettront de garantir la pertinence, la qualité et la cohérence des sources utilisées.

Critères de recherche

Les critères de recherche incluent :

— **Les plantes** : espèces végétales documentées au Burkina Faso, avec identification botanique (nom scientifique, famille, synonymes).

— **Les parties utilisées** : feuilles, racines, écorces, fruits, graines, fleurs, tiges, etc.

— **Les pathologies et usages médicinaux** : paludisme, infections respiratoires, digestives, diabète, hypertension, etc.

— **Les modes de préparation** : décoction, macération, infusion, poudre, extrait alcoolique, etc.

— **Les niveaux de preuve** : savoirs traditionnels, études in vitro, études in vivo, essais cliniques.

— **Les propriétés pharmacologiques** : antimicrobiennes, antipaludiques, anti-inflammatoires, antioxydantes, toxicité, etc.

— **La composition chimique** : alcaloïdes, flavonoïdes, tanins, saponines, huiles essentielles, etc.

Ces critères couvrent l'ensemble des dimensions des connaissances sur les plantes médicinales. Ils permettent de cibler les informations pertinentes pour notre recherche.

Critères de sélection des documents

Les critères de sélection des documents incluent :

— **Pertinence** : le document traite des plantes médicinales du Burkina Faso.

— **Identification de la plante** : le nom scientifique est précisé.

— **Disponibilité d'une référence scientifique** : le document est publié dans une revue à comité de lecture, une thèse, un mémoire ou un rapport de recherche.

— **Fiabilité** : les sources sont vérifiables et citées.

— **Actualité** : les documents récents seront privilégiés, sans exclure les travaux fondateurs.

Ces critères garantissent la qualité et la fiabilité des sources utilisées. Ils permettent d'écarter les documents non scientifiques ou non pertinents.

Cette phase permet de disposer d'un corpus fiable et cohérent, qui constituera la base documentaire de notre étude.

Livrable : Grille de critères de recherche et de sélection.

II.2.3 Phase 3 : Constitution du corpus scientifique

Objectif : Rassembler un corpus documentaire fiable et pertinent sur les plantes médicinales du Burkina Faso.

La constitution du corpus s'est déroulée en quatre phases. Premièrement, nous avons mené une recherche documentaire sur Google Scholar, PubMed et ResearchGate. Nous avons également consulté les bases burkinaherbiermed.org et INERA. Nous avons collecté des rapports de projets auprès d'institutions nationales.

Deuxièmement, nous avons appliqué les critères d'inclusion. Les documents devaient traiter des plantes médicinales du Burkina Faso. Ils devaient préciser le nom scientifique des plantes. Ils devaient être publiés ou validés par une institution scientifique. Leurs sources devaient être vérifiables et citées.

Troisièmement, nous avons appliqué les critères d'exclusion. Les documents non scientifiques (blogs, sites non référencés) ont été écartés. Les documents sans identification botanique ont été exclus. Les documents trop anciens ont été écartés, sauf les travaux fondateurs.

Quatrièmement, nous avons organisé le corpus. Les documents ont été classés par type (article, thèse, rapport). Ils ont été indexés par plante, pathologie et région. Ils ont été stockés dans un répertoire structuré.

Ce processus rigoureux a permis de constituer un corpus de 35 documents scientifiques, complété par les données de burkinaherbiermed.org et de l'INERA. Ce corpus couvre différentes régions du Burkina Faso, différentes pathologies et différentes approches méthodologiques. Il constitue une base solide pour l'extraction des connaissances.

Livrable : Un corpus de 35 documents scientifiques, complété par les données de burkinaherbiermed.org et de l'INERA.

II.2.4 Phase 4 : Adaptation de l'ontologie sélectionnée

Objectif : Adapter l'ontologie sélectionnée au contexte burkinabè.

L'adaptation de l'ontologie suit une démarche en cinq temps. Premièrement, nous analysons les concepts existants. Deuxièmement, nous ajoutons des classes. Troisièmement, nous ajoutons des propriétés. Quatrièmement, nous modifions les relations. Cinquièmement, nous documentons les adaptations.

Analyse des concepts existants

Nous étudions la structure de l'ontologie WATRIMed/HTM. Nous identifions les classes existantes : MedicinalPlant, Recipe, Disease/Symptom, PlantPart, PreparationMethod, AdministrationMode, Dosage, ChemicalCompound, ContraIndication, TherapeuticIndication, Source. Nous identifions les relations existantes : usesMedicinalPlant, treatsDisease/Symptom, hasPartPlantPart, hasPreparationMethod, hasAdministrationMode, hasDosage, containsChemicalCompound. Nous évaluons la couverture par rapport au contexte burkinabè.

Cette analyse révèle que l'ontologie WATRIMed/HTM couvre bien les concepts de base mais qu'elle nécessite des adaptations pour le contexte burkinabè. Les lacunes identifiées concernent principalement les noms vernaculaires en langues locales, les maladies spécifiques au Burkina Faso, les niveaux de preuve et la traçabilité des sources.

Ajout de classes

Nous ajoutons des classes pour les maladies spécifiques au Burkina Faso. Par exemple : paludisme, onchocercose, méningite. Nous ajoutons des classes pour les noms vernaculaires (mooré, dioula, fulfuldé). Nous ajoutons des classes pour les régions du Burkina Faso. Nous ajoutons des classes pour les niveaux de preuve (traditionnel, in vitro, in vivo, clinique). Nous ajoutons des classes pour les sources scientifiques (article, thèse, rapport).

Ces ajouts permettent de représenter les spécificités du contexte burkinabè. Ils facilitent l'intégration des connaissances locales et la traçabilité des sources.

Ajout de propriétés

Nous ajoutons des propriétés pour les noms vernaculaires (nomMooré, nomDioula, nomFulfuldé). Nous ajoutons des propriétés pour la localisation géographique (coordonnéesGPS, région, province). Nous ajoutons des propriétés pour les niveaux de preuve (niveauPreuve, typeEtude). Nous ajoutons des propriétés pour la traçabilité (source, DOI, page, section). Nous ajoutons des propriétés pour les dosages et toxicités.

Ces propriétés enrichissent l'ontologie et permettent de capturer des informations détaillées sur les plantes et leurs usages.

Modification de relations

Nous précisons la relation « traite » avec des attributs de niveau de preuve. Nous ajoutons la relation « provientDe » pour lier les connaissances aux sources. Nous ajoutons la relation « estDocumentéeDans » pour lier les plantes aux documents. Nous ajoutons la relation « aPourNomVernaculaire » pour lier les plantes aux noms locaux. Nous ajoutons la relation « estLocaliséeÀ » pour lier les plantes aux coordonnées géographiques.

Ces modifications permettent d'assurer la traçabilité des connaissances et de représenter les relations complexes entre les entités.

Documentation des adaptations

Nous tenons un journal des modifications. Nous justifions chaque ajout. Nous documentons les choix effectués. Nous documentons les classes ajoutées, modifiées ou supprimées. Nous documentons les propriétés ajoutées ou modifiées. Nous documentons les relations ajoutées ou modifiées.

Cette documentation est essentielle pour garantir la reproductibilité de notre démarche et faciliter les évolutions futures de l'ontologie.

Livrable : Une ontologie adaptée au contexte burkinabè.

II.2.5 Phase 5 : Enrichissement de l'ontologie à partir de la littérature scientifique

Objectif : Extraire les connaissances du corpus et enrichir l'ontologie.

L'enrichissement de l'ontologie suit une démarche en cinq temps. Premièrement, nous concevons les prompts d'extraction. Deuxièmement, nous exécutons l'extraction assistée par LLM. Troisièmement, nous validons les extractions. Quatrièmement, nous structurons les données. Cinquièmement, nous intégrons les données dans l'ontologie.

Conception des prompts d'extraction

Nous concevons des prompts pour extraire les informations du corpus. Chaque prompt cible un type d'information. Le prompt général demande d'extraire le nom scientifique, les noms vernaculaires, la famille botanique, les parties utilisées, les usages thérapeutiques, les modes de préparation, les activités pharmacologiques, le niveau de preuve et la source.

```
Tu es un assistant spécialisé dans l'extraction de connaissances
sur les plantes médicinales du Burkina Faso.

À partir du texte ci-dessous, extrais les informations suivantes :
- Nom scientifique de la plante
- Noms vernaculaires (mooré, dioula, fulfuldé)
- Famille botanique
- Parties utilisées
- Usages thérapeutiques
- Modes de préparation
- Activités pharmacologiques
- Niveau de preuve (traditionnel, in vitro, in vivo, clinique)
- Source (auteur, année, DOI)

Réponds au format JSON.

Texte :
[contenu du document]
```

Ce prompt est conçu pour guider le modèle de langage dans l'extraction structurée des informations. Il précise le format de sortie (JSON) et les champs à extraire. Il peut être adapté en fonction du type de document et des informations recherchées.

Exécution de l'extraction

Nous chargeons Llama 3 70B sur Google Colab. Nous exécutons les prompts sur chaque document. Nous sauvegardons les résultats en JSON.

L'exécution de l'extraction se fait de manière itérative. Nous traitons les documents un par un ou par lots. Nous vérifions la qualité des résultats au fur et à mesure. Nous ajustons les prompts si nécessaire.

Validation humaine

Nous vérifions les extractions. Un expert corrige les erreurs. Il valide les données. Cette étape est essentielle pour garantir la qualité.

La validation humaine permet de corriger les erreurs d'extraction, de compléter les informations manquantes et de vérifier la cohérence des données. Elle garantit que les connaissances intégrées dans l'ontologie sont fiables et exactes.

Structuration des données

Nous convertissons les données en CSV pour l'import Neo4j. Nous organisons les données selon le modèle de l'ontologie.

La structuration des données facilite leur import dans la base de connaissances. Elle permet de vérifier la conformité des données au modèle de l'ontologie.

Intégration dans l'ontologie

Nous ajoutons les instances (plantes, maladies, usages). Nous créons les relations entre instances. Nous associons les connaissances aux sources. Nous documentons les enrichissements.

L'intégration des données dans l'ontologie permet de peupler la base de connaissances et de créer les liens entre les entités.

Livrable : Un ensemble de données structurées (JSON, CSV) prêtes à être intégrées.

II.2.6 Phase 6 : Construction et interrogation de la base de connaissances

Objectif : Construire la base de connaissances orientée graphe.

La construction de la base Neo4j suit une démarche en trois temps. Premièrement, nous modélisons le graphe. Deuxièmement, nous importons les données. Troisièmement, nous testons les requêtes.

Modélisation du graphe

Nous définissons les nœuds : Plante, Maladie, Usage, Partie, Préparation, Source, ComposéChimique, Région. Nous définissons les relations : TRAITE, UTILISE, PROVIENT_DE, A_POUR_PARTIE, A_POUR_PREPARATION, CONTIENT, EST_LOCALISEE_A. Nous définissons les propriétés : nom, niveau de preuve, DOI, coordonnéesGPS.

Cette modélisation permet de représenter les connaissances de manière naturelle et intuitive. Les nœuds représentent les entités du domaine. Les relations représentent les liens entre ces entités. Les propriétés décrivent les caractéristiques des entités et des relations.

Import des données

Nous chargeons les fichiers CSV. Nous créons les nœuds et relations avec Cypher. Nous vérifions l'intégrité des données.

L'import des données se fait à l'aide de requêtes Cypher. Nous vérifions que toutes les données sont correctement importées. Nous contrôlons l'intégrité des relations et des propriétés.

Requêtes de test

Nous testons des requêtes simples (plantes par maladie). Nous testons des requêtes complexes (recettes multi-plantes). Nous testons des requêtes de traçabilité (source d'une information). Nous testons des requêtes spatiales (plantes par région).

Ces tests permettent de vérifier que la base de connaissances est fonctionnelle et que les requêtes retournent les résultats attendus.

Livrable : Une base Neo4j peuplée et interrogeable.

II.2.7 Phase 7 : Exploitation par IA et développement de l'application web

Objectif : Développer le système d'accès intelligent et l'interface utilisateur.

La mise en place du système RAG suit une démarche en trois temps. Premièrement, nous définissons l'architecture. Deuxièmement, nous construisons la chaîne de traitement. Troisièmement, nous intégrons les composants.

Architecture du système

L'architecture est la suivante : Utilisateur → Streamlit → LangChain → Neo4j → Llama 3 → Réponse.

Cette architecture permet de combiner la recherche d'informations dans la base de connaissances et la génération de réponses par le modèle de langage. Elle garantit la traçabilité des réponses en associant chaque information à sa source.

Chaîne de traitement

La chaîne de traitement comprend six étapes. Premièrement, l'interprétation de la requête en langage naturel. Deuxièmement, la génération de la requête Cypher par LangChain. Troisièmement, l'exécution sur Neo4j. Quatrièmement, la récupération des faits. Cinquièmement, la génération de la réponse par Llama 3. Sixièmement, l'affichage des sources.

Cette chaîne de traitement permet de transformer une question en langage naturel en une réponse précise et traçable.

Intégration des composants

Nous connectons LangChain à Neo4j. Nous connectons LangChain à Llama 3 via l'API ngrok. Nous configurons les prompts.

L'intégration des composants permet de faire fonctionner le système RAG de manière fluide et efficace.

Développement de l'application web

Nous concevons une page d'accueil avec chatbot. Nous concevons une page de recherche par plante. Nous concevons une page de recherche par pathologie. Nous concevons une page de fiches descriptives. Nous créons les composants (chat, recherche, fiches). Nous intégrons le système RAG. Nous gérons l'historique de conversation.

L'application web offre une interface intuitive et ergonomique pour interroger la base de connaissances. Elle permet aux utilisateurs de poser des questions en langage naturel et d'obtenir des réponses précises et traçables.

Tests et validation

Nous effectuons des tests fonctionnels. Nous effectuons des tests utilisateurs.

Les tests fonctionnels vérifient que l'application fonctionne correctement. Les tests utilisateurs évaluent la facilité d'utilisation et la pertinence des réponses.

Livrable : Un système RAG fonctionnel et une application web fonctionnelle.

II.2.8 Phase 8 : Évaluation et validation

Objectif : Évaluer la qualité de l'ontologie, du système RAG et de l'application web.

L'évaluation portera sur trois niveaux. Le premier niveau concerne l'ontologie. Le deuxième niveau concerne le système RAG. Le troisième niveau concerne l'application web.

Évaluation de l'ontologie

L'évaluation de l'ontologie portera sur quatre critères. Le tableau II.11 présente ces critères.

TABLE II.11 – Critères d'évaluation de l'ontologie

Critère	Description	Méthode
Couverture	Capacité à représenter les connaissances du corpus	Vérification manuelle
Cohérence	Absence de contradictions	Requêtes de test
Traçabilité	Association des connaissances aux sources	Vérification des relations
Extensibilité	Facilité d'ajout de nouvelles connaissances	Test d'ajout

Évaluation du système RAG

L'évaluation du système RAG portera sur quatre critères. Le tableau II.12 présente ces critères.

TABLE II.12 – Critères d'évaluation du système RAG

Critère	Description	Métrique
Pertinence	Les réponses répondent à la question	Précision
Fidélité	Les réponses sont fidèles aux sources	Rappel
Exactitude	Les réponses sont correctes	F1-score
Traçabilité	Les sources sont affichées	Taux de couverture

Nous constituerons un jeu de 50 questions de référence. Ces questions porteront sur les plantes, les usages et les propriétés. Les réponses seront comparées aux réponses attendues.

Évaluation de l'application web

L'évaluation de l'application web portera sur quatre critères. Le tableau II.13 présente ces critères.

Nous solliciterons 10 à 20 participants. Ils incluront des étudiants, des chercheurs et des tradipraticiens.

Livrable : Rapport d'évaluation et de validation.

TABLE II.13 – Critères d'évaluation de l'application web

Critère	Description	Méthode
Facilité d'utilisation	L'interface est intuitive	Questionnaire
Compréhension	Les réponses sont claires	Questionnaire
Utilité	L'application répond aux besoins	Questionnaire
Performance	Temps de réponse	Mesure

II.3 Synthèse et transition

Cette section présente une synthèse de la méthodologie et une transition vers le chapitre suivant.

II.3.1 Tableau de correspondance Phases - Livrables

Le tableau II.14 récapitule les phases, les objectifs et les livrables.

TABLE II.14 – Correspondance entre les phases, les objectifs et les livrables

Phase	Objectif	Livrable
Phase 1	Sélectionner l'ontologie la plus pertinente	Ontologie WATRIMed/HTM sélectionnée
Phase 2	Définir les critères de recherche et de sélection	Grille de critères
Phase 3	Rassembler un corpus fiable et pertinent	Corpus de 35 documents
Phase 4	Adapter l'ontologie au contexte burkinabè	Ontologie adaptée
Phase 5	Extraire les connaissances et enrichir l'ontologie	Données structurées (JSON, CSV)
Phase 6	Construire la base de connaissances graphe	Base Neo4j peuplée
Phase 7	Développer le système RAG et l'application web	Système RAG et application web
Phase 8	Évaluer la qualité du système	Rapport d'évaluation

Conclusion du chapitre

Ce chapitre a présenté le matériel et la méthodologie de notre recherche. Le matériel comprend un corpus de 35 documents scientifiques, les données de burkinaherbiermed.org et de l'INERA, cinq ontologies candidates et un environnement technique basé sur Llama 3 70B, Google Colab, Neo4j Desktop, LangChain et Streamlit.

La méthodologie est structurée en huit phases : identification et étude comparative des ontologies, définition des critères de recherche et de sélection des documents, constitution du corpus scientifique, adaptation de l'ontologie sélectionnée, enrichissement de l'ontologie à partir de la littérature scientifique, construction et interrogation de la base de connaissances, exploitation par l'intelligence artificielle et développement de l'application web, et évaluation et validation. Chaque phase est décrite avec ses actions concrètes et ses livrables.

L'ordre retenu pour ces phases est un choix méthodologique assumé. Commencer par l'identification et la sélection de l'ontologie avant la constitution du corpus garantit la cohérence entre le modèle conceptuel et les données collectées. Cette séquence facilite l'extraction des connaissances en ciblant les informations pertinentes dès la phase de collecte.

Les protocoles d'évaluation présentés dans la phase 8 seront appliqués dans le chapitre IV pour valider notre approche.

Le chapitre suivant présentera la conception et le développement du système. Nous y détaillerons l'ontologie adaptée, la base de connaissances construite, le système RAG implémenté et l'application web développée.

Chapitre III

Conception et développement du système

Chapitre IV

Résultats et discussion

Conclusion générale

Bibliographie

[1] AI4D. *Création d'une base de données sur les plantes médicinales pour faciliter l'exploitation des connaissances ethnopharmacologiques locales*. 2020. URL : https://www.ai4d.ai/fr/blog/building-a-medicinal-plant-database (visité le 26/09/2026).

[2] ARES. *Médecine traditionnelle et système de santé : vers une intégration durable*. 2018. URL : https://moove.ares-ac.be/actu/medecine-traditionnelle-et-systeme-de-sante-vers-une-integration-durable (visité le 26/09/2026).

[3] Armel AYIMDJI et al. « Towards A "Deep" Ontology for African Traditional Medicine ». en. In : *Intelligent Information Management* 3.6 (oct. 2011). Number : 6, p. 244-251. DOI : 10.4236/iim.2011.36030. URL : https://www.scirp.org/journal/paperinformation?paperid=8241 (visité le 12/06/2026).

[4] Ricardo BAEZA-YATES et Berthier RIBEIRO-NETO. *Modern Information Retrieval : The Concepts and Technology behind Search*. 2e éd. Harlow : Addison-Wesley, 2011. URL : https://books.google.com/books/about/Modern_Information_Retrieval.html?id=HbyAAAAACAAJ.

[5] Laurel COOPER et al. « The Plant Ontology as a Tool for Comparative Plant Anatomy and Genomic Analyses ». In : *Plant and Cell Physiology* 54.2 (2013), e1. DOI : 10.1093/pcp/pcs163.

[6] Fred D. DAVIS. « User acceptance of information technology : system characteristics, user perceptions and behavioral impacts ». In : *International Journal of Man-Machine Studies* 38.3 (mars 1993), p. 475-487. ISSN : 0020-7373. DOI : 10.1006/imms.1993.1022. URL : https://www.sciencedirect.com/science/article/pii/S0020737383710229 (visité le 29/09/2026).

[7] Jacob DEVLIN et al. « BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding ». In : *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*. 2019, p. 4171-4186. DOI : 10.18653/v1/N19-1423. URL : https://aclanthology.org/N19-1423/.

[8] Damion M. DOOLEY et al. « FoodOn : A Harmonized Food Ontology to Increase Global Food Traceability, Quality Control and Data Integration ». In : *npj Science of Food* 2 (2018), p. 23. DOI : 10.1038/s41538-018-0032-6. URL : https://www.nature.com/articles/s41538-018-0032-6.

[9] Jérôme EUZENAT et Pavel SHVAIKO. *Ontology Matching*. 2e éd. Springer, 2013. DOI : 10.1007/978-3-662-43550-9. URL : https://doi.org/10.1007/978-3-662-43550-9.

[10] Élisabeth FLAHAUT. « Pharmacopée et médecine traditionnelle dans l'Ouest du Burkina Faso : plantes médicinales et soins du couple mère-enfant ». 143 pages. Thèse de doctorat en pharmacie. Université de Lille II, 1999. URL : https://passioneuro.fr/wp-content/Documents/These_E-FLAHAUT_1999.pdf.

[11] Thomas R. GRUBER. « A Translation Approach to Portable Ontology Specifications ». In : *Knowledge Acquisition* 5.2 (1993), p. 199-220. DOI : 10.1006/knac.1993.1008. URL : https://doi.org/10.1006/knac.1993.1008.

[12] Sita GUINKO. « La végétation de la Haute-Volta ». Deux volumes, 394 pages. Thèse de doctorat ès sciences. Université de Bordeaux III, 1984. URL : https://www.scirp.org/reference/referencespapers?referenceid=3387847.

[13] John HANNA et al. « Building a Drug Ontology Based on RxNorm and Other Public Domain Drug Databases ». In : *Journal of Biomedical Semantics* 4 (2013), p. 44. DOI : 10.1186/2041-1480-4-44. URL : https://pubmed.ncbi.nlm.nih.gov/24345026/.

[14] Robert HOEHNDORF et al. « The Flora Phenotype Ontology (FLOPO) : Tool for Integrating Morphological Traits and Phenotypes of Vascular Plants ». In : *Journal of Biomedical Semantics* 7 (2016), p. 65. DOI : 10.1186/s13326-016-0107-8. URL : https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5109718/.

[15] Syed HUSSAIN et Gihan ATHULA. « Extending a Conventional Chatbot Knowledge Base to External Knowledge Source and Introducing User Based Sessions for Diabetes Education ». In : (2018), p. 698-703. URL : https://ieeexplore.ieee.org/abstract/document/8418155.

[16] Daniel JURAFSKY et James H. MARTIN. *Speech and Language Processing*. 3e éd. 2023. URL : https://web.stanford.edu/~jurafsky/slp3/ (visité le 26/09/2026).

[17] Appoh KOUAME. « Système de gestion de la médecine traditionnelle dans une plateforme web social et sémantique : une approche basée sur une ontologie visuelle ». fr. Thèse de doct. Université Gaston Berger de Saint-Louis (Sénégal), avr. 2018. URL : https://hal.science/tel-01842116 (visité le 12/06/2026).

[18] Patrick LEWIS et al. « Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks ». In : *Advances in Neural Information Processing Systems*. T. 33. 2020, p. 9459-9474. URL : https://arxiv.org/abs/2005.11401.

[19] Mariano FERNÁNDEZ-LÓPEZ et No AFFILIATION. « (PDF) Overview and analysis of methodologies for building ontologies ». en. In : *ResearchGate* (). DOI : 10.1017/S0269888902000462. URL : https://www.researchgate.net/publication/231908719_Overview_and_analysis_of_methodologies_for_building_ontologies (visité le 29/09/2026).

[20] Jeanne MILLOGO-RASOLODIMBY. « L'homme, le climat et les ressources alimentaires végétales en période de crises de subsistance au Burkina Faso ». Thèse de doctorat ès sciences naturelles. Université de Ouagadougou, 2001. URL : https://journals.openedition.org/vertigo/16758.

[21] Odile G. NACOULMA-OUEDRAOGO. « Plantes médicinales et pratiques médicales traditionnelles au Burkina Faso : cas du plateau central ». Thèse de doctorat d'État. Université de Ouagadougou, 1996. URL : https://publication.lecames.org/index.php/pharm/article/download/13/32.

[22] David NADEAU et Satoshi SEKINE. « A Survey of Named Entity Recognition and Classification ». In : *Lingvisticae Investigationes* 30.1 (2007), p. 3-26. DOI : 10.1075/li.30.1.02nad.

[23] Fnu NEHA, Deepshikha BHATI et Deepak Kumar SHUKLA. « Retrieval-Augmented Generation (RAG) in Healthcare : A Comprehensive Review ». en. In : *AI* 6.9 (sept. 2025), p. 226. ISSN : 2673-2688. DOI : 10.3390/ai6090226. URL : https://www.mdpi.com/2673-2688/6/9/226 (visité le 06/08/2026).

[24] L. OUÉDRAOGO et al. « Ethnobotanical Use and Conservation Assessment of Medicinal Plants Sold in Markets of Burkina Faso ». In : *Ethnobotany Research and Applications* 20 (2020), p. 1-25. DOI : 10.32859/era.20.39.1-25. URL : https://ethnobotanyjournal.org/index.php/era/article/view/2259.

[25] W Jedida Ouedraogo et al. « Revue des Plantes Médicinales à Potentiel Aromatique du Burkina Faso ». fr. In : 2 (2024).

[26] Colin Raffel et al. « Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer ». In : *Journal of Machine Learning Research* 21.140 (2020), p. 1-67. url : https://jmlr.csail.mit.edu/beta/papers/v21/20-074.html.

[27] D. L. Sackett et al. « Evidence based medicine : what it is and what it isn't ». eng. In : *BMJ* 312.7023 (jan. 1996), p. 71-72. issn : 0959-8138. doi : 10.1136/bmj.312.7023.71.

[28] Hassan Shojaee-Mend, Haleh Ayatollahi et Azam Abdolahadi. « Development and Evaluation of Ontologies in Traditional Medicine : A Review Study ». eng. In : *Methods of Information in Medicine* 58.6 (déc. 2019), p. 194-204. issn : 2511-705X. doi : 10.1055/s-0040-1702236.

[29] Abdoulaye Souley. « Trois entités hausa parentes : zahi, sanyi et shawara ». In : *La construction sociale des maladies : les entités nosologiques populaires en Afrique de l'Ouest*. Sous la dir. d'Yannick Jaffré et Jean-Pierre Olivier de Sardan. Presses Universitaires de France, 1999. url : https://horizon.documentation.ird.fr/exl-doc/pleins_textes/divers17-11/010050662.pdf.

[30] Rudi Studer, V. Richard Benjamins et Dieter Fensel. « Knowledge Engineering : Principles and Methods ». In : *Data & Knowledge Engineering* 25.1–2 (1998), p. 161-197. doi : 10.1016/S0169-023X(97)00056-6. url : https://doi.org/10.1016/S0169-023X(97)00056-6.

[31] Rudi Studer, V. Richard Benjamins et Dieter Fensel. « Knowledge engineering : Principles and methods ». In : *Data & Knowledge Engineering* 25.1 (mars 1998), p. 161-197. issn : 0169-023X. doi : 10.1016/S0169-023X(97)00056-6. url : https://www.sciencedirect.com/science/article/pii/S0169023X97000566 (visité le 29/09/2026).

[32] A. A. Tekemetieu, S. Koussoube et L. P. Fotso. « An Ontology-Based Computer-Aided Diagnosis System in African Traditional Medicine : At the Sorcerer's Stone ». In : *Kybernetes* 45.1 (2016), p. 30-50. url : https://www.ajol.info/index.php/jcmphc/article/download/252453/238490.

[33] André Tibiri et al. « Countrywide Survey of Plants Used for Liver Disease Management by Traditional Healers in Burkina Faso ». In : *Frontiers in Pharmacology* 11 (2020), p. 563751. doi : 10.3389/fphar.2020.563751. url : https://pmc.ncbi.nlm.nih.gov/articles/PMC7883685/.

[34] Mbih Jerome Tosam. « Metaphysical Issues in African Philosophy of Medicine ». In : *African Philosophy of Medicine*. Springer, 2024. doi : 10.1007/978-3-031-73963-7_12. url : https://link.springer.com/chapter/10.1007/978-3-031-73963-7_12.

[35] Safiatou Traoré et al. « Ethnobotanical Survey on Plants Used in the Treatment of Wounds by Traditional Health Practitioners in Burkina Faso ». In : *International Journal of Plant, Animal and Environmental Sciences* 15 (2025). url : https://www.progres.ujkz.gov.bf/publications/11832/details.

[36] Ashish Vaswani et al. « Attention Is All You Need ». In : *Advances in Neural Information Processing Systems*. T. 30. 2017. url : https://arxiv.org/abs/1706.03762.

[37] W3C. *OWL 2 Web Ontology Language Document Overview*. 2012. url : https://www.w3.org/TR/owl2-overview/ (visité le 26/09/2026).

[38] W3C. *RDF 1.1 Concepts and Abstract Syntax*. 2014. url : https://www.w3.org/TR/rdf11-concepts/ (visité le 26/09/2026).

[39] W3C. *SKOS Simple Knowledge Organization System Reference*. 2009. url : https://www.w3.org/TR/skos-reference/ (visité le 26/09/2026).

[40] Alain Wamba et al. « Enabling West African Herbal-Based Traditional Medicine Digitizing : The WATRIMed ». In : *Healthcare of the Future : Bridging the Information Gap*. IOS Press, 2019. doi : 10.3233/SHTI190528. url : https://ebooks.iospress.nl/pdf/doi/10.3233/SHTI190528.

[41] World Health Organization. *General Guidelines for Methodologies on Research and Evaluation of Traditional Medicine*. Geneva, 2000. url : https://iris.who.int/handle/10665/66783 (visité le 26/09/2026).

[42] World Health Organization. *WHO Monographs on Selected Medicinal Plants*. Geneva, 2002. url : https://iris.who.int/bitstream/handle/10665/42052/9789241547024_eng.pdf (visité le 26/09/2026).

[43] World Health Organization. *WHO Traditional Medicine Strategy 2014–2023*. Geneva, 2013. url : https://iris.who.int/bitstream/handle/10665/92455/9789241506090_eng.pdf (visité le 26/09/2026).

[44] Patrice Zerbo et al. « Plantes médicinales et pratiques médicales au Burkina Faso : cas des Sanan ». In : *BOIS & FORETS DES TROPIQUES* 307 (mars 2011), p. 41-53. issn : 1777-5760, 0006-579X. doi : 10.19182/bft2011.307.a20481. url : https://revues.cirad.fr/index.php/BFT/article/view/20481 (visité le 05/08/2026).

[45] Alexander Zizka et al. « Traditional plant use in Burkina Faso (West Africa) : a national-scale analysis with focus on traditional medicine ». en. In : *Journal of Ethnobiology and Ethnomedicine* 11.1 (déc. 2015), p. 9. issn : 1746-4269. doi : 10.1186/1746-4269-11-9. url : https://ethnobiomed.biomedcentral.com/articles/10.1186/1746-4269-11-9 (visité le 05/08/2026).

[46] Koudbi Jacob Zongo et al. « Ethnopharmacological Study on Medicinal Plants Used for Jaundice and Liver-Related Disorders Management in the Province of Kouritenga in the Central-Eastern of Burkina Faso ». In : *Journal of Advanced Translational and Preclinical Biomedicine* 4.1 (2025). doi : 10.57220/jatpb.v4i1.213. url : https://boa.unimib.it/retrieve/444bc5b3-4483-4e23-a45d-f0fe28fbb91a/Zongo%20et%20al-2025-JATPB-VoR.pdf.