Burkina Faso

La Patrie ou la Mort, nous Vaincrons

Ministère de l'Enseignement Supérieur
et de la Recherche Scientifique

Université Joseph Ki-Zerbo

Institut Burkinabè des Arts et Métiers

MÉMOIRE POUR L'OBTENTION DU MASTER II EN INFORMATIQUE

Option : Ingénierie des Systèmes d'Information en Entreprise

Par

Sanou Lougoudoro

Adaptation et enrichissement d'une ontologie pour un accès intelligent et traçable aux connaissances scientifiques sur les plantes médicinales du Burkina Faso

Encadreur : Dr. Belko Abdoul Aziz DIALLO **PhD**

Année Universitaire 2025 – 2026

Dédicace

À ma famille,
pour son soutien constant, sa patience
et ses encouragements tout au long de ce travail.

Remerciements

La réalisation de ce mémoire a bénéficié du soutien et de l'accompagnement de plusieurs personnes. Nous tenons à leur exprimer, par ces quelques lignes, notre profonde gratitude.

Nos remerciements vont particulièrement à l'endroit de :

- **Dr Belko Abdoul Aziz DIALLO**, notre encadreur, pour sa disponibilité, ses conseils et la rigueur avec laquelle il a suivi ce travail du début à la fin ;
- **Monsieur le Directeur de l'Institut Burkinabè des Arts et Métiers (IBAM)**, ainsi qu'à toute l'équipe pédagogique et administrative, pour la qualité de la formation reçue et leur accompagnement ;
- les chercheurs burkinabè dont les travaux sur les plantes médicinales constituent le corpus de cette étude, sans lesquels ce mémoire n'aurait pas pu voir le jour ;
- nos camarades de promotion et nos collègues, pour leur esprit d'entraide et les échanges qui ont enrichi ce travail ;
- notre famille, pour son soutien indéfectible depuis toujours, et particulièrement durant la préparation de ce mémoire ;
- tous nos amis et toutes les personnes qui, de près ou de loin, ont contribué à l'aboutissement de ce travail.

Résumé

Les connaissances scientifiques sur les plantes médicinales du Burkina Faso sont dispersées entre des articles, des thèses et des rapports dont les terminologies varient. Il est donc difficile de retrouver une information et de remonter à sa source. Ce mémoire propose un accès intelligent et traçable à ces connaissances.

Après avoir comparé cinq ontologies, nous avons retenu *ontoMEDTRAD* et adapté son modèle conceptuel au contexte burkinabè pour construire *OntoPlantMedBF*. Nous l'avons peuplée à partir de dix des 35 documents du corpus, au moyen d'une extraction assistée par un modèle de langue. L'ontologie compte 92 classes et 6 936 individus, dont 289 plantes et 1 676 usages thérapeutiques, tous reliés à une source. Importée dans Neo4j, elle alimente un système de génération augmentée par récupération (RAG) : Llama 3 traduit la question en requête Cypher, validée en lecture seule, puis rédige une réponse qui cite ses sources. Une application web développée avec Streamlit donne accès à l'ensemble ; elle n'a pas été évaluée auprès d'utilisateurs.

Sur un jeu de 50 questions, le système atteint un F1-score de 0,728 et produit 36 réponses conformes, contre 0,995 et 49 avec Gemini. Il refuse de répondre aux 5 questions hors corpus, mais aussi, à tort, à 6 questions dont la réponse figure dans le graphe ; pour 2 autres, il affirme à tort n'avoir rien trouvé. Ces mesures portent sur la restitution du contenu du graphe et non sur la justesse scientifique des faits, car les extractions n'ont pas été relues par un expert. Ce prototype est un outil de consultation : il ne pose aucun diagnostic et n'établit aucune prescription.

Mots-clés : plantes médicinales, Burkina Faso, ontologie, graphe de connaissances, Neo4j, génération augmentée par récupération, modèle de langue, traçabilité.

Abstract

Scientific knowledge about the medicinal plants of Burkina Faso is scattered across articles, theses and reports that use varying terminology. As a result, it is difficult to find a piece of information and trace it back to its source. This thesis proposes intelligent and traceable access to this knowledge.

After comparing five ontologies, we selected *ontoMEDTRAD* and adapted its conceptual model to the Burkinabè context to build *OntoPlantMedBF*. We populated it from ten of the 35 documents in the corpus, using extraction assisted by a language model. The ontology contains 92 classes and 6,936 individuals, including 289 plants and 1,676 therapeutic uses, all linked to a source. Imported into Neo4j, it feeds a Retrieval-Augmented Generation (RAG) system: Llama 3 translates the question into a Cypher query, validated as read-only, then writes an answer that cites its sources. A web application built with Streamlit provides access to the whole system; it has not been evaluated with users.

On a set of 50 questions, the system reaches an F1-score of 0.728 and produces 36 compliant answers, compared with 0.995 and 49 with Gemini. It declines to answer the 5 out-of-corpus questions, but also wrongly declines 6 questions whose answer is in the graph, and for 2 others it wrongly states that it found nothing. These measurements concern how well the content of the graph is restored, not the scientific accuracy of the facts, as the extractions were not reviewed by an expert. This prototype is a consultation tool: it does not make diagnoses or issue prescriptions.

Keywords: medicinal plants, Burkina Faso, ontology, knowledge graph, Neo4j, Retrieval-Augmented Generation, language model, traceability.

Table des figures

1 Dispersion des connaissances scientifiques 2
2 Démarche méthodologique adoptée 4

I.1 Hiérarchie des niveaux de preuve 11
I.2 Les langages du web sémantique 13

II.1 Constitution du corpus documentaire 31
II.2 Dispositif technique d'expérimentation 33
II.3 Démarche méthodologique détaillée 37

III.1 L'ontologie initiale ontoMEDTRAD reconstituée sous Protégé 5 (arbre des classes) . 49
III.2 Concepts d'ontoMEDTRAD conservés comme base d'OntoPlantMedBF 51
III.3 Modèle conceptuel adapté sous Protégé 5 (phase 3a) 52
III.4 Arborescence des propriétés de données dans Protégé 55
III.5 Arborescence des propriétés objet dans Protégé 57
III.6 Extrait du graphe peuplé dans Neo4j Browser : le sous-graphe de *Cochlospermum planchonii* 60
III.7 Chaîne de traitement du système RAG 64
III.8 L'assistant de l'application web : une réponse sourcée produite avec Llama 3 8B . . . 67
III.9 Fiche de *Cochlospermum planchonii* dans l'application web 67

Liste des tableaux

I.1 Synthèse comparative des ontologies de la littérature 27

II.1 Ontologies candidates pour la comparaison 33
II.2 Modèles de langage et modes d'accès 34
II.3 Caractéristiques de Neo4j Desktop 34
II.4 Composants LangChain utilisés 35
II.5 Bibliothèques Python utilisées 35
II.6 Récapitulatif du matériel 36
II.7 Correspondance entre le matériel et les phases 36
II.8 Grille de critères de comparaison 39
II.9 Notation des ontologies candidates 39
II.10 Critères d'évaluation de l'ontologie 45
II.11 Critères d'évaluation du système RAG 45
II.12 Critères d'évaluation de l'application web 46
II.13 Correspondance entre les phases, les objectifs et les livrables 46

III.1 Concepts retenus et écartés lors de l'adaptation 50
III.2 Statistiques de l'ontologie d'origine et du modèle conceptuel adapté 51
III.3 Classes ajoutées à l'ontologie 53
III.4 Propriétés ajoutées à l'ontologie 54
III.5 Relations ajoutées à l'ontologie 56
III.6 Correspondance entre les classes de l'ontologie et les nœuds du graphe 58
III.7 Relations du graphe de connaissances 59
III.8 Fonctionnalités de l'application web 66

IV.1 Résultats de l'évaluation de l'ontologie 71
IV.2 Résultats de l'évaluation du système RAG 72
IV.3 Résultats par famille de questions 72
IV.4 Comparaison de Llama 3 8B et de Gemini sur les 50 questions 72
IV.5 Volumes de résultats des quatre familles de requêtes 73
IV.6 Résultats de l'évaluation de l'application web 74

Liste des sigles et abréviations

Sigle ou abréviation	Signification
AI4D	Artificial Intelligence for Development
API	Application Programming Interface
BERT	Bidirectional Encoder Representations from Transformers
BFO	Basic Formal Ontology
CI50	Concentration Inhibitrice 50 %
CIM-10	Classification Internationale des Maladies, 10e révision
CNRST	Centre National de la Recherche Scientifique et Technologique
CSV	Comma-Separated Values
DL50	Dose Létale 50 %
DOI	Digital Object Identifier
DPPH	2,2-diphényl-1-picrylhydrazyle
DrOn	Drug Ontology
FLOPO	Flora Ontology
FOODON	Food Ontology
GC-MS	Gas Chromatography-Mass Spectrometry
GPT	Generative Pre-trained Transformer
GPU	Graphics Processing Unit
HNBU	Herbier National du Burkina
HPLC	High-Performance Liquid Chromatography
HTM	Herbal Traditional Medicine Ontology
IA	Intelligence Artificielle
IC50	Concentration Inhibitrice médiane de 50 %
IFAN	Institut Fondamental d'Afrique Noire
IHTSDO	International Health Terminology Standards Development Organisation
INERA	Institut de l'Environnement et de Recherches Agricoles
JSON	JavaScript Object Notation
LLM	Large Language Model
NER	Named Entity Recognition
NLP	Natural Language Processing
OCR	Optical Character Recognition
OMS	Organisation Mondiale de la Santé
OTM	Ontology of Traditional Medicine
OWL	Web Ontology Language
PNPMT	Programme National de Promotion de la Médecine Traditionnelle
PO	Plant Ontology
RAG	Retrieval-Augmented Generation
RDF	Resource Description Framework
RDFS	RDF Schema
SKOS	Simple Knowledge Organization System
SNOMED CT	Systematized Nomenclature of Medicine – Clinical Terms
SPARQL	SPARQL Protocol and RDF Query Language
T5	Text-to-Text Transfer Transformer
TALN	Traitement Automatique du Langage Naturel
TPU	Tensor Processing Unit
UICN	Union Internationale pour la Conservation de la Nature
W3C	World Wide Web Consortium
WATRIMed	West African Herbal-based Traditional Medicine
XML	Extensible Markup Language

Table des matières

Dédicace i

Remerciements ii

Résumé iii

Abstract iv

Table des figures v

Liste des tableaux vi

Liste des sigles et abréviations viii

Introduction générale 1

I Cadre théorique et revue de littérature 8
- I.1 Plantes médicinales et connaissances scientifiques au Burkina Faso . . . 8
  - I.1.1 Concepts fondamentaux . . . 8
  - I.1.2 Plantes médicinales documentées dans la littérature scientifique . . . 9
  - I.1.3 Types de connaissances et niveaux de preuve . . . 10
- I.2 Ingénierie des connaissances et ontologies . . . 12
  - I.2.1 Représentation des connaissances . . . 12
  - I.2.2 Ontologies et réutilisation d'ontologies existantes . . . 13
  - I.2.3 Adaptation, alignement et enrichissement ontologique . . . 14
  - I.2.4 Bases de connaissances et interrogation sémantique . . . 15
- I.3 Intelligence artificielle pour l'accès aux connaissances . . . 17
  - I.3.1 Traitement des requêtes en langage naturel . . . 17
  - I.3.2 Extraction et structuration assistées par des modèles de langue . . . 18
  - I.3.3 Recherche sémantique et génération de réponses . . . 19
  - I.3.4 Traçabilité et fiabilité des réponses . . . 20
- I.4 Travaux connexes et positionnement scientifique . . . 21
  - I.4.1 Ontologies dans le domaine des plantes médicinales . . . 21
  - I.4.2 Systèmes intelligents d'accès aux connaissances . . . 28
  - I.4.3 Positionnement de notre recherche . . . 29

Conclusion du chapitre . . . 29

II Matériel et méthodologie 31
- II.1 Matériel . . . 31
  - II.1.1 Corpus documentaire . . . 31
  - II.1.2 Ontologies candidates . . . 32
  - II.1.3 Outils et environnement technique . . . 33

II.1.4 Tableau récapitulatif du matériel . . . 36
II.1.5 Tableau de correspondance Matériel - Phases . . . 36
II.2 Méthodologie . . . 37
II.2.1 Phase 1 : Constitution du corpus . . . 37
II.2.2 Phase 2a : Étude comparative des ontologies . . . 38
II.2.3 Phase 3a : Adaptation du modèle conceptuel . . . 40
II.2.4 Phase 2b : Sélection des documents . . . 42
II.2.5 Phase 3b : Extraction des connaissances par modèle de langue . . . 42
II.2.6 Phase 4 : Peuplement de l'ontologie et construction de la base graphe . . . 43
II.2.7 Phase 5 : Dispositif numérique : système RAG et application web . . . 44
II.2.8 Phase 6 : Évaluation . . . 45
II.3 Synthèse et transition . . . 46
II.3.1 Tableau de correspondance Phases - Livrables . . . 46
Conclusion du chapitre . . . 47

III Conception et développement du système 48
III.1 Ontologie adaptée et enrichie . . . 48
III.1.1 Vue d'ensemble du modèle . . . 48
III.1.2 Classes ajoutées . . . 52
III.1.3 Propriétés ajoutées . . . 53
III.1.4 Relations ajoutées . . . 55
III.2 Base de connaissances orientée graphe . . . 57
III.2.1 Du modèle ontologique au graphe . . . 58
III.2.2 Import et peuplement . . . 59
III.2.3 Interrogation de la base . . . 60
III.3 Intégration de l'intelligence artificielle . . . 61
III.3.1 Extraction assistée des connaissances . . . 61
III.3.2 Système RAG d'accès aux connaissances . . . 63
III.3.3 Traçabilité des réponses . . . 65
III.4 Développement de l'application web . . . 65
III.4.1 Architecture de l'application . . . 65
III.4.2 Fonctionnalités . . . 65
III.4.3 Gestion de session et déploiement . . . 66
Conclusion du chapitre . . . 67

IV Résultats et discussion 69
IV.1 Évaluation de l'ontologie . . . 69
IV.1.1 Couverture . . . 69
IV.1.2 Cohérence . . . 69
IV.1.3 Traçabilité . . . 70
IV.1.4 Extensibilité . . . 70
IV.1.5 Synthèse de l'évaluation de l'ontologie . . . 70
IV.2 Évaluation du système RAG . . . 71
IV.2.1 Construction du jeu d'évaluation . . . 71
IV.2.2 Résultats quantitatifs . . . 72
IV.2.3 Volumes d'interrogation de la base . . . 73
IV.2.4 Observations qualitatives . . . 73
IV.3 Évaluation de l'application web . . . 74
IV.3.1 Performance . . . 74
IV.4 Discussion . . . 75

IV.4.1 Confrontation aux objectifs de la recherche 75
IV.4.2 Confrontation aux systèmes existants 75
IV.4.3 Limites 75
IV.4.4 Pistes de travail 76
Conclusion du chapitre 76

Conclusion générale **78**

Bibliographie **79**

Introduction générale

Contexte et justification du sujet

Au Burkina Faso, les plantes médicinales occupent une place centrale dans les pratiques de santé. L'Organisation mondiale de la santé rappelle que la médecine traditionnelle demeure, pour une large part des populations des pays en développement, le premier recours de soins [59]. Dans le pays, une grande partie de la population, majoritairement rurale, dépend fortement des produits végétaux locaux pour se soigner [62]. Cette importance est reconnue au niveau national, puisque le Ministère de la Santé a engagé un projet d'herbier national dédié aux plantes médicinales, couplé à une chimiothèque de marqueurs chimiques. Ces plantes font par ailleurs l'objet de nombreux travaux scientifiques [39], qui portent sur leurs identifications, leurs usages, leurs propriétés pharmacologiques et leurs toxicités.

Le problème ne vient pas d'un manque de connaissances, mais de leur dispersion. Les informations disponibles sont éparpillées dans la littérature scientifique [62], notamment dans les articles, les thèses, les mémoires et les rapports de recherche. Or ces documents n'emploient pas les mêmes terminologies. Une même plante y est souvent désignée par plusieurs synonymes ou noms vernaculaires. Il devient alors difficile de comparer les résultats d'une étude à l'autre, de retrouver une information précise sur une plante ou une maladie, et de remonter à la source qui la soutient.

Ce sont des personnes concrètes qui en pâtissent. Le chercheur y perd un temps précieux. L'étudiant ne sait pas toujours à quelle source se fier. Le tradipraticien, qui détient une part de ce savoir, dispose de peu d'outils pour le confronter aux travaux scientifiques. La communauté, qui détient et transmet ces savoirs, n'a pas non plus de moyen simple de les retrouver réunis. Or ces plantes ne sont pas anodines, puisque certaines sont toxiques à forte dose et que la posologie compte. Retrouver, pour chaque information, la source qui la fonde n'est donc pas un luxe de chercheur, mais une condition de confiance.

Les ontologies offrent un moyen de répondre à ce besoin. Elles donnent aux concepts d'un domaine une définition claire et des relations explicites. Les connaissances deviennent alors interopérables et interrogeables [48]. Dans cette perspective, nous reprendrons un modèle existant consacré aux plantes médicinales, que nous adapterons au contexte burkinabè et enrichirons à partir de la littérature scientifique. Nous utiliserons l'intelligence artificielle pour faciliter l'accès à ces connaissances. Le système interprétera les requêtes en langage naturel, recherchera l'information pertinente dans la base et présentera les résultats de manière accessible. Nous développerons une solution numérique pour servir d'interface entre l'utilisateur et le dispositif. Les réponses seront rattachées aux sources scientifiques correspondantes (figure 1).

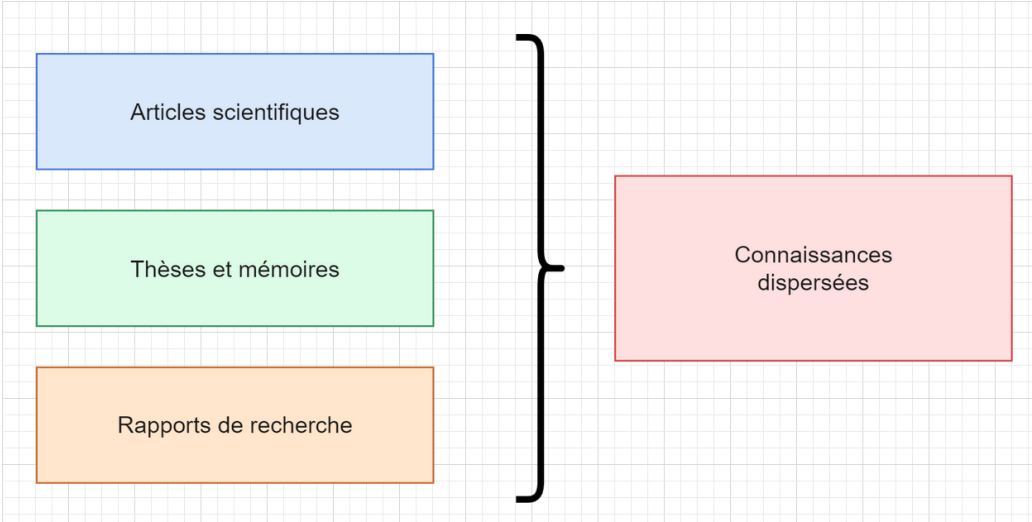


FIGURE 1 – Dispersion des connaissances scientifiques

Problématique de la recherche

Les connaissances scientifiques sur les plantes médicinales du Burkina Faso sont abondantes [39] et proviennent de sources variées, comme les articles, les thèses, les mémoires, les rapports de recherche et les bases de données institutionnelles [62]. Leur exploitation pose toutefois problème. Les ontologies peuvent aider à les structurer [43], en représentant les concepts d'un domaine et les relations entre eux, ce qui favorise l'interopérabilité et permet des interrogations plus précises. Comme aucune ontologie ne répond nécessairement aux besoins du contexte burkinabè, nous comparerons les modèles disponibles et retiendrons celui qui conviendra le mieux à l'étude. L'accès constitue une seconde difficulté, car une base structurée peut être riche sans être compréhensible. L'intelligence artificielle pourrait contribuer à réduire cet écart [37] en interprétant les requêtes en langage naturel, en recherchant les informations pertinentes et en les restituant sous une forme accessible.

Nous étudierons les connaissances issues de la littérature scientifique, leur organisation dans une ontologie adaptée et leur exploitation au moyen de l'intelligence artificielle dans une solution numérique. Notre question principale est la suivante :

> *Comment réajuster une ontologie existante à partir de la littérature scientifique sur les plantes médicinales du Burkina Faso, puis permettre son interrogation par l'intelligence artificielle afin d'obtenir, en langage naturel, des réponses pertinentes et traçables jusqu'aux sources ?*

Trois questions spécifiques guideront notre étude :

— Quelle ontologie existante convient le mieux pour représenter les connaissances sur les plantes médicinales du Burkina Faso, et quels réajustements faut-il lui apporter ?

— Dans quelle mesure l'intelligence artificielle peut-elle aider à extraire de la littérature scientifique des connaissances fidèles aux documents et rattachées à leurs sources ?

— Dans quelle mesure une solution numérique interrogeable en langage naturel facilite-t-elle l'accès à ces connaissances pour les chercheurs, les étudiants et les tradipraticiens ?

Objectif général et objectifs spécifiques

Pour répondre à cette problématique, nous poursuivrons un objectif général, décliné en objectifs spécifiques et en actions évaluables. Ces objectifs guideront notre démarche et nous permettront d'en apprécier les résultats.

Objectif général

Notre objectif général sera de réajuster une ontologie représentative afin de structurer les connaissances issues de la littérature scientifique sur les plantes médicinales du Burkina Faso, puis d'exploiter ces connaissances au moyen de l'intelligence artificielle et d'une solution numérique pour faciliter leur accès et leur diffusion.

Objectifs spécifiques

— Sélectionner, par une étude comparative, l'ontologie la plus adaptée au contexte burkinabè, puis réajuster son modèle conceptuel.

— Peupler l'ontologie avec des connaissances extraites de la littérature scientifique à l'aide de l'intelligence artificielle, tout en assurant leur traçabilité vers les sources.

— Développer une solution numérique permettant d'interroger ces connaissances en langage naturel, puis évaluer la qualité de ses réponses.

Hypothèses de recherche

Pour répondre aux questions posées et atteindre nos objectifs, nous formulerons trois hypothèses. La première portera sur le choix et le réajustement de l'ontologie, la deuxième sur l'extraction des connaissances et la troisième sur l'accès à ces connaissances. Nous les examinerons au cours de la recherche.

Hypothèse 1 : Une revue méthodique des ontologies existantes permet de sélectionner un modèle qui, après réajustement, représente les connaissances sur les plantes médicinales du Burkina Faso.

Hypothèse 2 : L'intelligence artificielle, associée à une vérification manuelle, permet d'extraire de la littérature scientifique des connaissances fidèles aux documents et traçables jusqu'à leurs sources.

Hypothèse 3 : Une solution numérique interrogeable en langage naturel devrait faciliter l'accès aux connaissances documentées sur les plantes médicinales du Burkina Faso, avec des réponses pertinentes et sourcées.

Démarche méthodologique adoptée

Nous suivrons une démarche en six phases, illustrée par la figure 2. Après la constitution du corpus, deux volets seront menés en parallèle. Le volet modèle conceptuel sélectionnera puis adaptera l'ontologie ; le volet modèle de données sélectionnera les documents puis en extraira les connaissances. Le modèle adapté fixera le schéma des fiches d'extraction. Les deux volets se rejoindront lors du peuplement de l'ontologie et de la construction de la base de connaissances, sur lesquels reposeront le dispositif numérique puis son évaluation. La démarche articulera la revue de littérature, la comparaison des ontologies, l'ingénierie des connaissances, l'intelligence artificielle et le développement logiciel. Chaque phase donnera lieu à un livrable utile à la suivante. Nous vérifierons les résultats à plusieurs étapes.

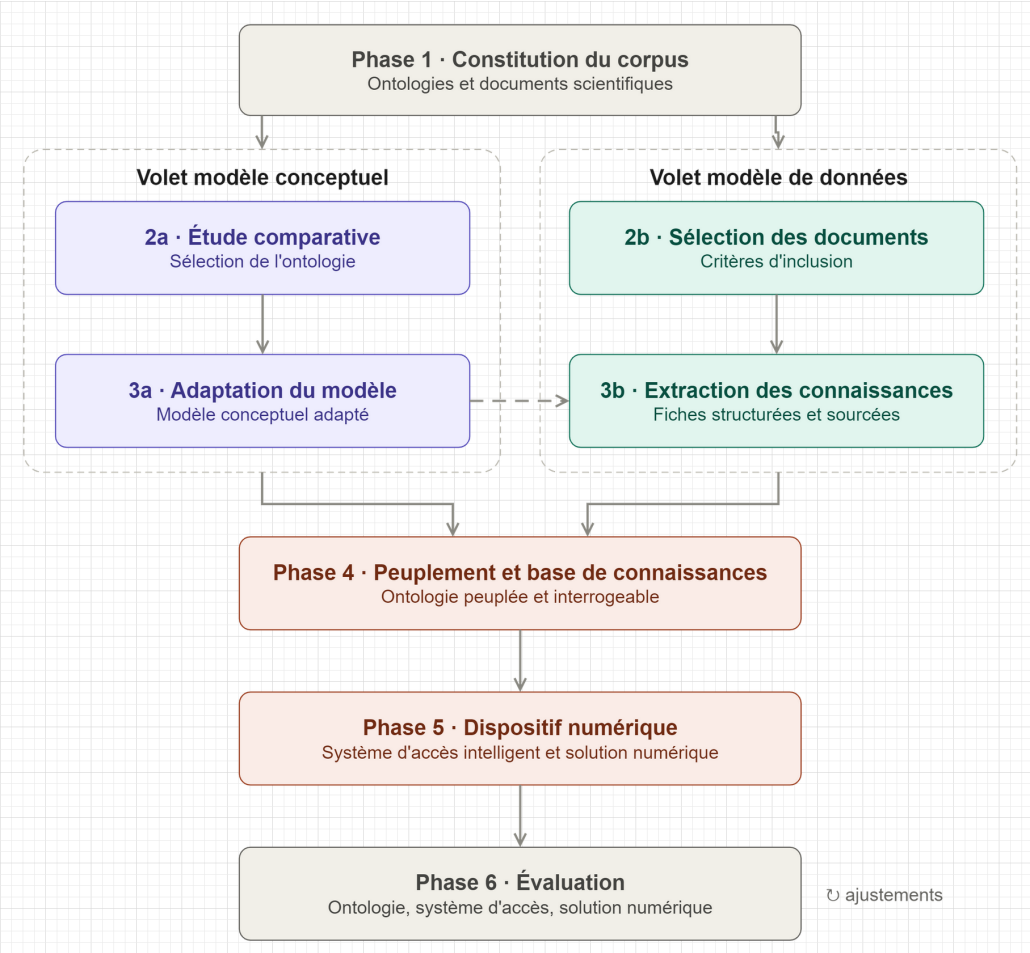


FIGURE 2 – Démarche méthodologique adoptée

Phase 1 : Constitution du corpus

Nous rechercherons les ontologies existantes sur les plantes médicinales dans la littérature scientifique et les bases spécialisées. Nous réunirons également les articles, thèses, mémoires et rapports de recherche sur les plantes médicinales du Burkina Faso. La recherche des documents portera sur les plantes, les parties utilisées, les pathologies et usages médicinaux, les modes de préparation, les niveaux de preuve, les propriétés pharmacologiques et la composition chimique. Le livrable sera un corpus réunissant les ontologies candidates et les documents scientifiques collectés.

Volet modèle conceptuel

Phase 2a : Étude comparative des ontologies

Nous comparerons les ontologies candidates au moyen d'une grille portant sur la couverture du domaine, la richesse sémantique, la disponibilité, la documentation, l'interopérabilité, l'adaptation au contexte burkinabè, la traçabilité et la prise en compte des savoirs locaux. Nous noterons chaque ontologie et retiendrons celle qui obtiendra le meilleur score. Ce choix déterminera le modèle conceptuel des phases suivantes. Le livrable sera l'ontologie sélectionnée.

Phase 3a : Adaptation du modèle conceptuel

Nous adapterons au contexte des plantes médicinales du Burkina Faso le modèle conceptuel de l'ontologie retenue. Nous distinguerons les concepts à conserver, à modifier et à ajouter, notamment pour les maladies, les noms vernaculaires, les régions et les niveaux de preuve, ainsi que les propriétés nécessaires à la localisation et à la traçabilité. Le livrable de cette phase sera le modèle conceptuel adapté, le schéma d'OntoPlantMedBF. Ce schéma fixera aussi les champs des fiches d'extraction de la phase 3b.

Volet modèle de données

Phase 2b : Sélection des documents

Nous appliquerons aux documents collectés des critères d'inclusion et d'exclusion afin d'en assurer la pertinence, la qualité et la cohérence. Nous examinerons la pertinence du document, l'identification botanique et la disponibilité de références scientifiques vérifiables, puis conserverons la provenance des informations. Nous organiserons et indexerons les documents retenus pour qu'ils servent de base documentaire à notre étude. Le livrable sera le corpus des documents retenus.

Phase 3b : Extraction des connaissances

À partir des documents retenus en phase 2b et selon le schéma défini en phase 3a, nous extrairons les connaissances nécessaires au peuplement de l'ontologie. Nous utiliserons l'intelligence artificielle pour repérer les plantes, leurs usages, les parties utilisées, les préparations et les propriétés pharmacologiques rapportées. Nous structurerons les résultats en fiches et conserverons les références bibliographiques ainsi que, lorsque cela sera possible, les pages ou sections correspondantes. Nous distinguerons les usages rapportés par les enquêtes ethnobotaniques des résultats expérimentaux. Nous reprendrons les niveaux de preuve indiqués par les sources, sans les réévaluer indépendamment. Nous examinerons la qualité des extractions selon le protocole de la phase 6. Le livrable sera un ensemble de fiches structurées et sourcées.

Phase 4 : Peuplement de l'ontologie et construction de la base de connaissances

Les deux volets se rejoindront dans cette phase. Nous transformerons les fiches en individus du modèle conceptuel adapté, ce qui produira l'ontologie peuplée OntoPlantMedBF. Nous construirons ensuite la base de connaissances en y important cette ontologie, de façon à rendre ses classes, ses propriétés et ses données interrogeables. Le livrable sera l'ontologie peuplée, importée dans une base de connaissances interrogeable.

Phase 5 : Dispositif numérique

Nous mettrons en place un système d'accès intelligent qui associera la recherche dans la base de connaissances à la génération de réponses par l'intelligence artificielle. Il interprétera les questions en langage naturel, interrogera la base et formulera des réponses accompagnées de leurs sources. Nous développerons une solution numérique proposant une recherche en langage naturel et des fiches sur les plantes, leurs usages, les parties utilisées, les modes de préparation et les références. Le système servira à consulter les connaissances ; il ne posera pas de diagnostic et n'établira pas de prescription. Les livrables seront le système d'accès intelligent et la solution numérique.

Phase 6 : Évaluation

Nous évaluerons l'approche à trois niveaux. Pour l'ontologie, nous examinerons la couverture, la cohérence, la traçabilité et l'extensibilité. Pour le système d'accès intelligent, nous mesurerons la pertinence, la fidélité, l'exactitude et la traçabilité. Pour la solution numérique, nous mesurerons les performances. Les résultats pourront conduire à des ajustements des phases précédentes, que nous déclarerons avec les mesures qu'ils concernent. Le livrable sera un rapport d'évaluation et de validation.

Délimitation du champ d'étude

Notre étude portera sur les plantes médicinales documentées au Burkina Faso et sur les connaissances relatives à leurs usages et à leurs propriétés biologiques rapportés dans les sources scientifiques. Nous nous appuierons sur la littérature accessible et vérifiable, sans mener d'enquête de terrain directe. Nous sélectionnerons une ontologie existante au moyen d'une étude comparative, puis l'adapterons au contexte burkinabè. Sur le plan technique, nous construirons une base de connaissances, mettrons en place un système d'intelligence artificielle pour en faciliter l'accès et développerons une solution numérique. Les consignes données aux outils d'intelligence artificielle faciliteront l'extraction sans constituer des sources scientifiques ; nous nous référerons aux documents eux-mêmes. Le système servira à consulter et à diffuser les connaissances scientifiques. Il ne remplacera pas l'avis d'un professionnel de santé et ne posera pas de diagnostic ni n'établira de prescription.

Résultats attendus

Au terme de la recherche, nous prévoyons les résultats suivants :

— La constitution d'un corpus scientifique organisé sur les plantes médicinales du Burkina Faso, avec les sources et les niveaux de preuve rapportés.

— La comparaison des ontologies existantes et la sélection de celle qui conviendra à notre étude.

— L'adaptation de cette ontologie à partir des connaissances issues de la littérature scientifique.

— La construction d'une base de connaissances et la mise en place d'un système d'accès associant l'intelligence artificielle à la recherche sémantique et à la génération de réponses.

— Le développement d'une solution numérique qui permettra de rechercher et de consulter les connaissances documentées sur les plantes médicinales du Burkina Faso.

Contribution attendue

Notre contribution consistera à adapter le modèle conceptuel d'une ontologie sur les plantes médicinales, à enrichir cette ontologie en données issues de la littérature scientifique, puis à importer OntoPlantMedBF dans une base de connaissances. Nous conserverons le lien entre chaque information et sa source. Ce dispositif, complété par un système d'accès intégré à une solution numérique, pourra aider les chercheurs, les étudiants et les autres utilisateurs à consulter les informations documentées, à effectuer des recherches bibliographiques et à explorer les relations entre les plantes et les connaissances scientifiques associées.

Structuration du mémoire

Le mémoire est organisé en quatre chapitres numérotés en chiffres romains, précédés de l'introduction générale et suivis de la conclusion générale.

— **Introduction générale (non numérotée).** Le contexte et la justification du sujet y sont exposés, puis la problématique, les questions de recherche, les objectifs et les hypothèses. Y figurent également la démarche méthodologique, la délimitation du champ d'étude et les résultats attendus.

— **Chapitre I :** Cadre théorique et revue de littérature. Les notions liées aux plantes médicinales et aux connaissances scientifiques sur le Burkina Faso y sont présentées, suivies de l'ingénierie des connaissances, des ontologies, des bases de connaissances et de l'intelligence artificielle. Les travaux connexes sont analysés en dernier.

— **Chapitre II :** Matériel et méthodologie. Le corpus scientifique, les critères de sélection et les méthodes d'analyse sont décrits. Les ontologies identifiées, les critères de comparaison, la méthode de sélection et le résultat de la comparaison sont présentés. Les étapes d'adaptation, d'enrichissement et de validation y sont détaillées.

— **Chapitre III :** Conception et développement du système. L'ontologie sélectionnée et les adaptations réalisées y sont présentées, suivies de la base de connaissances, puis de l'intégration de l'intelligence artificielle et du développement de la solution numérique.

— **Chapitre IV :** Résultats et discussion. Les résultats de l'évaluation d'OntoPlantMedBF, ontologie adaptée et peuplée, et de la base de connaissances y sont exposés. L'accès intelligent et les fonctionnalités de la solution numérique sont ensuite analysés, et les limites du système discutées.

La conclusion générale rappellera les principaux résultats, montrera dans quelle mesure les objectifs et les hypothèses auront été atteints, et présentera les limites du travail ainsi que les perspectives d'amélioration.

Chapitre I

Cadre théorique et revue de littérature

Introduction du chapitre

Toute recherche appliquée repose d'abord sur des notions clairement définies. Dans ce chapitre, nous présenterons les notions liées aux plantes médicinales et aux connaissances scientifiques accumulées sur le Burkina Faso, puis les principes de l'ingénierie des connaissances et des ontologies. Nous examinerons ensuite l'apport de l'intelligence artificielle à l'accès à ces connaissances, avant de passer en revue les travaux déjà consacrés au sujet et de situer notre recherche par rapport à eux. Le chapitre s'organisera en quatre sections, de la définition du domaine à la comparaison avec la littérature existante.

I.1 Plantes médicinales et connaissances scientifiques au Burkina Faso

I.1.1 Concepts fondamentaux

Définition des plantes médicinales Selon l'Organisation Mondiale de la Santé (OMS), une plante médicinale est toute plante dont une ou plusieurs parties contiennent des substances utilisables à des fins thérapeutiques [57]. Ces substances, dites principes actifs, exercent une action pharmacologique sur l'organisme. Elles peuvent prévenir, soulager ou guérir des affections.

L'Union Internationale pour la Conservation de la Nature (UICN) adopte une perspective plus large, qui présente les plantes médicinales à la fois comme des ressources végétales mobilisées par les systèmes de médecine traditionnelle et comme des matières premières pour l'industrie pharmaceutique. Elle souligne la nécessité d'en assurer une exploitation durable, sous peine de compromettre la biodiversité.

Médecine traditionnelle et pharmacopée L'OMS définit la médecine traditionnelle comme l'ensemble des connaissances, compétences et pratiques de soins [57]. Ces pratiques reposent sur des théories, des croyances et des expériences propres à chaque culture. Elles visent à maintenir la santé, mais aussi à prévenir, diagnostiquer et traiter les maladies [59].

La pharmacopée traditionnelle correspond à l'ensemble des remèdes et des préparations ainsi utilisés [57]. Elle décrit les recettes, précise les posologies et les modes d'administration, et signale les contre-indications et les précautions d'usage.

Ethnobotanique et ethnomédecine L'ethnobotanique étudie de façon scientifique les relations qui lient les plantes aux sociétés humaines [58]. Elle documente les usages traditionnels, recueille les savoirs locaux et analyse la manière dont les populations perçoivent, nomment, classifient et exploitent les végétaux.

L'ethnomédecine en constitue la branche médicale. Elle se penche sur les pratiques de soins, sur les systèmes traditionnels, sur les conceptions de la maladie et de la guérison, ainsi que sur les rituels et les actes thérapeutiques [58].

Contexte burkinabè Au Burkina Faso, la médecine traditionnelle couvre environ 80 % des besoins de santé primaire [4] et ne constitue pas une alternative marginale. Son accessibilité, son coût modique et son ancrage dans les habitudes culturelles en font le recours de premier choix, et les tradipraticiens en sont des acteurs centraux.

Les travaux de Zerbo et al. [61] ont appliqué cette lecture à un terrain précis, celui des Sanan, documentant 94 espèces utilisées en médecine traditionnelle, avec leurs modes de préparation et d'administration. Ouedraogo et al. [39] ont procédé de leur côté à une revue des plantes à potentiel aromatique du pays, recensant 42 espèces et en analysant les propriétés et les usages.

Or ces savoirs ne se présentent pas de façon homogène. Ils varient selon les ethnies, diffèrent selon les régions, et s'enrichissent des découvertes nouvelles. Une telle diversité rend leur documentation particulièrement complexe [33].

I.1.2 Plantes médicinales documentées dans la littérature scientifique

Inventaires et recensements La littérature scientifique burkinabè recense plusieurs centaines d'espèces médicinales. Guinko [20] a identifié 304 espèces utilisées en médecine traditionnelle, Nacoulma [34] en a documenté 280 avec leurs usages et Zerbo et al. [61] ont recensé 94 espèces chez les Sanan.

Ces plantes se répartissent dans des familles botaniques variées, les plus représentées étant les Fabacées, les Combretacées, les Rubiacées et les Euphorbiacées [34], une diversité qui reflète la richesse de la flore burkinabè.

Aspects botaniques et écologiques Les travaux sur ces plantes couvrent plusieurs aspects :

- **Identification botanique :** les plantes sont collectées et décrites, leurs caractéristiques morphologiques sont notées, les spécimens conservés en herbiers de référence et la taxonomie précisée.
- **Distribution géographique :** les zones de présence sont cartographiées, leur répartition étant liée aux conditions climatiques et édaphiques. Certaines espèces sont endémiques à une région [20].
- **Périodes de récolte :** les moments optimaux de collecte sont déterminés, la teneur en principes actifs variant selon la saison, ce qui pèse directement sur la qualité des remèdes.
- **Parties utilisées :** chez les Sanan, les feuilles dominent (31 % des cas), devant l'écorce du tronc (25 %), la racine (23 %) et les fruits (10 %) [61]. La partie retenue dépend de la plante et de l'usage visé.
- **Modes de préparation :** les décoctions, par ébullition dans l'eau, restent courantes. Les macérations (trempage à froid), les poudres obtenues par séchage et broyage, et plus rarement les extraits alcooliques sont également employés [34].

Usages thérapeutiques Le paludisme constitue une cible fréquente des études, aux côtés des infections respiratoires et digestives. Les pathologies chroniques, comme le diabète et l'hypertension, font également l'objet d'études spécifiques [39].

Propriétés pharmacologiques Les études expérimentales évaluent différentes activités pharmacologiques :

- **Activité antimicrobienne :** les extraits sont testés sur des bactéries et des champignons, notamment *Staphylococcus aureus*, *Escherichia coli* et *Candida albicans*, et les résultats se révèlent souvent prometteurs [34].
- **Activité antipaludique :** les extraits sont testés sur des souches de *Plasmodium falciparum*. Des plantes comme *Artemisia annua* ou *Cryptolepis sanguinolenta* sont étudiées, et certaines affichent une forte activité [39].
- **Activité anti-inflammatoire :** divers modèles d'inflammation sont mobilisés, au nombre desquels l'œdème de la patte du rat. Les plantes évaluées dans ces modèles peuvent présenter des effets significatifs.
- **Activité antioxydante :** le pouvoir piégeage des radicaux libres est mesuré par les méthodes DPPH et ABTS. Les polyphénols y sont le plus souvent impliqués.
- **Toxicité :** la toxicité aiguë et subchronique est évaluée par la détermination des doses létales (DL50). Certaines plantes s'avèrent toxiques à forte dose, information décisive pour la sécurité d'emploi [34].

Composition chimique Les analyses phytochimiques portent sur l'identification des métabolites secondaires :

- **Alcaloïdes :** composés azotés aux propriétés pharmacologiques variées, dont la quinine et la morphine.
- **Flavonoïdes :** composés phénoliques aux propriétés antioxydantes et anti-inflammatoires, tels que la quercétine et la rutine.
- **Tanins :** composés polyphénoliques à propriétés astringentes et antimicrobiennes.
- **Saponines :** composés aux propriétés moussantes et immunostimulantes.
- **Huiles essentielles :** mélanges complexes de terpènes aux propriétés variées [39].

I.1.3 Types de connaissances et niveaux de preuve

Typologie des connaissances Les connaissances relatives aux plantes médicinales sont de nature variée, et chaque type possède sa propre valeur comme ses propres limites.

Connaissances ethnobotaniques Issues des populations locales et recueillies par enquêtes et entretiens, elles reflètent le savoir traditionnel accumulé et décrivent usages, préparations et croyances. Elles orientent la recherche vers des plantes prometteuses et préservent un patrimoine culturel. Elles comportent toutefois des biais puisque un informateur peut fournir des informations incomplètes, un usage varier d'un guérisseur à l'autre, et la transmission n'est pas assurée.

Connaissances phytochimiques Elles portent sur la composition chimique des plantes, identifient les molécules actives, en précisent la concentration et comparent les profils chimiques entre espèces.

Connaissances pharmacologiques Les études expérimentales évaluent les effets biologiques des extraits à l'aide de modèles *in vitro*, sur des cellules ou des micro-organismes, et *in vivo*, sur des animaux de laboratoire [22]. Les résultats sont quantitatifs et portent notamment sur les concentrations efficaces (CI50), les comparaisons avec des témoins positifs et la toxicité. Les études animales ne permettent toutefois pas toujours de prévoir l'effet chez l'homme.

Connaissances cliniques Elles proviennent d'essais sur l'homme, rares pour les plantes médicinales, coûteuses et complexes, et supposent des autorisations éthiques ainsi que des essais rigoureux. Ces essais offrent le niveau de preuve le plus élevé. Ils mesurent l'efficacité réelle, évaluent les effets secondaires et comparent au traitement standard. Ils constituent la référence de la médecine fondée sur les preuves [42].

Hiérarchie des niveaux de preuve La médecine fondée sur les preuves (*evidence-based medicine*) distingue plusieurs niveaux :

1. **Méta-analyses et revues systématiques :** preuve la plus forte. Elles synthétisent plusieurs essais cliniques.
2. **Essais cliniques randomisés contrôlés :** preuve très forte. Ils comparent un traitement à un placebo ou à un standard.
3. **Études de cohorte :** preuve modérée. Elles suivent des groupes dans le temps.
4. **Études cas-témoins :** preuve modérée. Elles comparent des cas à des témoins.
5. **Études expérimentales animales :** preuve faible. Elles ne sont pas directement transposables à l'homme.
6. **Études *in vitro* :** preuve très faible. Elles sont éloignées des conditions réelles.
7. **Savoirs traditionnels et avis d'experts :** preuve anecdotique. Ils sont utiles pour générer des hypothèses mais non validés.

La figure I.1 résume cette hiérarchie. Dans notre modèle, la propriété *niveauPreuve* conserve la qualification indiquée par la source (section III.1.3 du chapitre III).

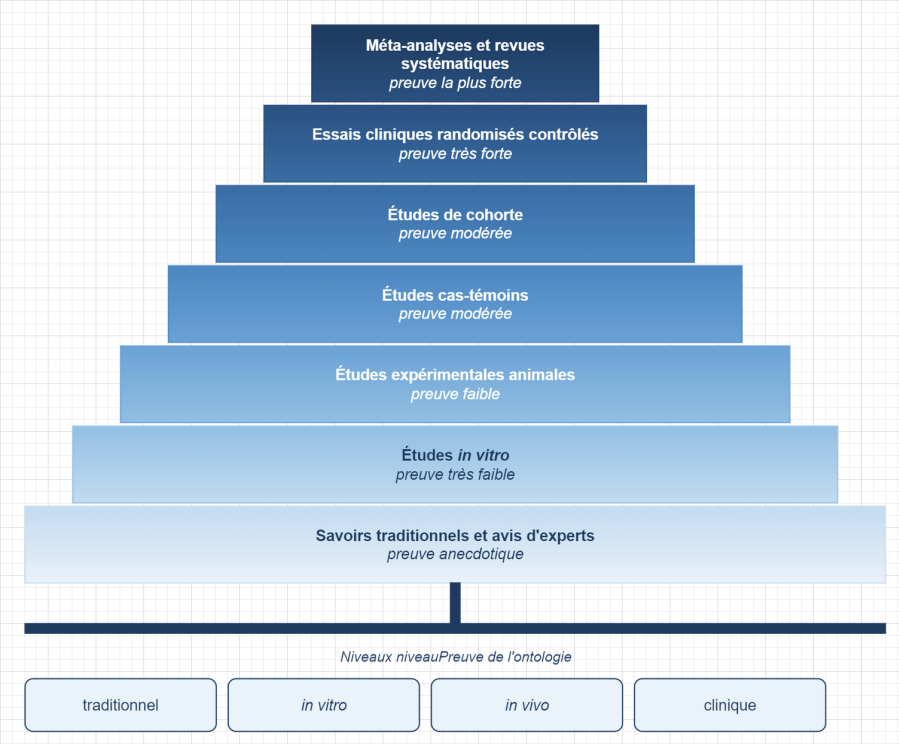


FIGURE I.1 – Hiérarchie des niveaux de preuve

I.2 Ingénierie des connaissances et ontologies

I.2.1 Représentation des connaissances

Définition et enjeux La représentation des connaissances est une discipline de l'intelligence artificielle qui formalise l'information pour la rendre exploitable par la machine [9]. Elle s'appuie sur des langages structurés et interprétables qui autorisent le raisonnement automatique et l'interrogation. Elle répond à quatre enjeux : capter la sémantique des connaissances, assurer leur interopérabilité, permettre leur réutilisation et faciliter leur évolution.

Principaux modèles de représentation

- **Les réseaux sémantiques :** des graphes de concepts reliés par des arcs, où les nœuds représentent des entités et les arcs des relations. Modèle simple et intuitif, il a servi aux premières bases de connaissances.
  Limites : ils n'ont pas de sémantique formelle, ils ne permettent pas le raisonnement complexe et ils sont difficiles à partager.
- **Les cadres (*frames*) :** des structures de données dans lesquelles chaque cadre possède des attributs (*slots*), éventuellement pourvus de valeurs par défaut, les cadres s'organisant en hiérarchies par héritage.
  Avantages : ils sont structurés, permettent l'héritage et sont faciles à implémenter.
  Limites : ils n'ont pas de sémantique formelle. L'héritage peut être ambigu.
- **Les règles :** des expressions logiques conditionnelles, de forme « SI condition ALORS conclusion », qui autorisent le raisonnement déductif et servent aux systèmes experts.
  Avantages : elles sont expressives, permettent le raisonnement et sont faciles à comprendre.
  Limites : elles peuvent être nombreuses, interagir de manière complexe et sont difficiles à maintenir.
- **Les ontologies :** des modèles formels d'un domaine [18], qui définissent classes et propriétés, précisent relations et axiomes, et dont l'expressivité élevée les adapte aux connaissances complexes.
  Avantages : elles ont une sémantique formelle, sont interopérables, permettent le raisonnement et sont réutilisables.

Notre recherche s'appuiera sur ce modèle pour structurer les connaissances scientifiques, les interroger et intégrer des sources multiples.

Ces modèles formels s'appuient aujourd'hui sur les langages du web sémantique, empilés du document à la donnée reliée puis au raisonnement (figure I.2).

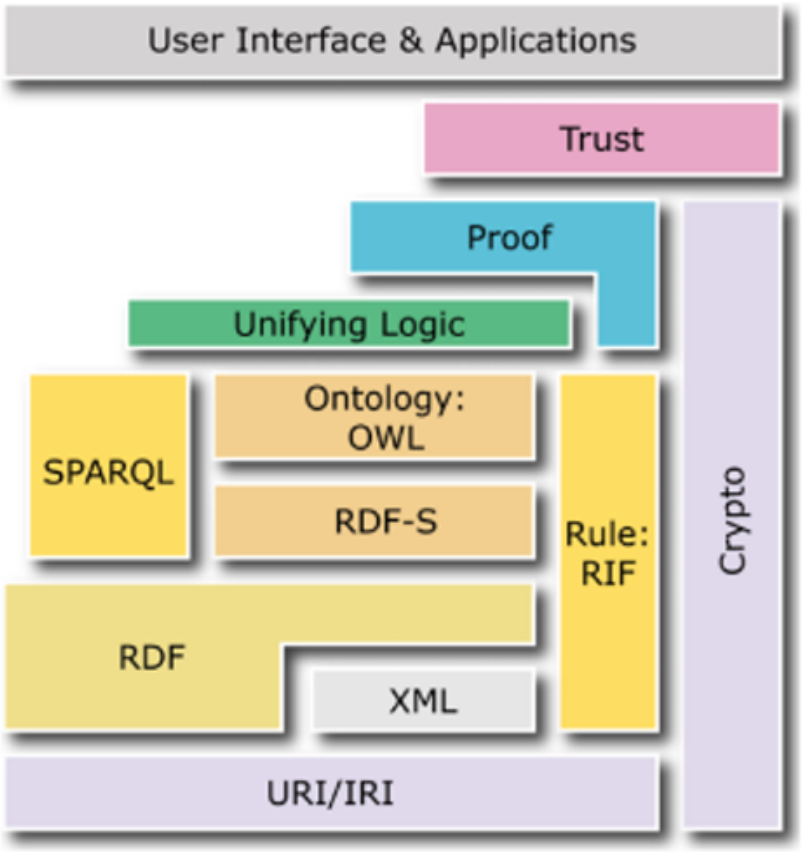


FIGURE I.2 – Les langages du web sémantique

I.2.2 Ontologies et réutilisation d'ontologies existantes

Définition formelle Une ontologie se définit comme « une spécification explicite et formelle d'une conceptualisation partagée » [18]. Chaque élément de cette formule compte :

- **Spécification explicite :** les concepts sont définis clairement, les termes précis, les définitions non ambiguës.
- **Spécification formelle :** l'ontologie est exprimée dans un langage logique, interprétable par la machine, ce qui autorise le raisonnement.
- **Conceptualisation :** l'ontologie représente une vision du monde, sélectionnant les concepts pertinents et laissant de côté les détails non pertinents.
- **Partagée :** l'ontologie est consensuelle, acceptée par une communauté, ce qui facilite la communication.

Composants d'une ontologie Les ontologies sont composées de plusieurs éléments [48] :

- **Classes (ou concepts) :** les entités du domaine, telles que Plante, Maladie, Substance active ou Mode de préparation, organisées en hiérarchies (taxonomies) [48].
- **Propriétés (ou attributs) :** les caractéristiques des classes, par exemple le nom scientifique, le nom vernaculaire, la partie utilisée ou le dosage, susceptibles de porter des valeurs (chaînes, nombres, dates) [48].
- **Relations :** les liens entre les classes, par exemple *« traite »* (une plante traite une maladie), *« contient »* (une plante contient une substance), *« est_préparée_par »* (une préparation utilise un mode) [48].

- **Axiomes :** des contraintes logiques qui assurent la cohérence de l'ontologie, par exemple « une plante peut avoir plusieurs usages » ou « une partie utilisée doit être une partie de la plante »[48].
- **Instances (ou individus) :** des exemples concrets, comme « Cassia alata », instance de Plante, ou « Paludisme », instance de Maladie.

Langages d'ontologies Plusieurs langages servent à représenter les ontologies :

- **RDF (Resource Description Framework) :** langage de base du Web sémantique. Il utilise des triplets (sujet-prédicat-objet). Il est simple mais peu expressif [55].
- **RDFS (RDF Schema) :** extension de RDF. Il permet de définir des classes et des propriétés. Il permet l'héritage. Il a une expressivité limitée [55].
- **OWL (Web Ontology Language) :** langage standard du W3C. Il est plus expressif que RDFS. Il permet des axiomes complexes. Il existe OWL-Lite, OWL-DL et OWL-Full, de complexité croissante [54].
- **SKOS (Simple Knowledge Organization System) :** langage pour les thésaurus et taxonomies. Il est adapté aux systèmes d'organisation des connaissances [56].

Réutilisation d'ontologies Réutiliser une ontologie existante est une pratique recommandée [31], et ce pour quatre raisons :

- **Économie de temps et de coûts :** la réutilisation évite de repartir de zéro et de refaire un travail déjà validé.
- **Fiabilité :** les ontologies existantes ont souvent été testées et corrigées. Elles sont éprouvées. Elles intègrent l'expertise de plusieurs chercheurs.
- **Interopérabilité :** l'utilisation d'ontologies standards facilite l'échange de données. Elle permet l'intégration avec d'autres systèmes. Elle favorise la réutilisation dans d'autres contextes.
- **Communauté :** les ontologies existantes ont souvent une communauté d'utilisateurs. Leur réutilisation permet de bénéficier de cette expertise et de contribuer à l'amélioration des modèles.

Plusieurs ontologies existent dans les domaines biomédicaux et pharmaceutiques. Certaines portent sur les plantes médicinales, d'autres sur la médecine traditionnelle [43]. Nous comparerons ces modèles afin de retenir celui qui conviendra à notre recherche.

I.2.3 Adaptation, alignement et enrichissement ontologique

Adaptation d'une ontologie L'adaptation modifie une ontologie pour un nouveau contexte [26]. Elle est nécessaire quand l'ontologie source ne couvre pas parfaitement le domaine visé. Elle est également nécessaire quand le contexte d'utilisation diffère.

L'adaptation peut inclure :

- **Ajout de classes :** pour couvrir des concepts absents. Par exemple, ajouter des classes pour les maladies spécifiques au Burkina Faso (paludisme, onchocercose, méningite).
- **Ajout de propriétés :** pour décrire des attributs non prévus. Par exemple, ajouter une propriété pour le nom vernaculaire en langue locale (mooré, dioula, fulfuldé).
- **Modification de relations :** pour adapter la sémantique. Par exemple, préciser la relation *« traite »* avec des attributs de niveau de preuve.
- **Suppression de classes :** lorsqu'elles ne sont pas pertinentes, elles peuvent être marquées comme obsolètes.
- **Redéfinition de restrictions :** pour adapter les contraintes logiques.

Alignement d'ontologies L'alignement établit des correspondances entre ontologies [14]. Il relie des concepts équivalents ou similaires. Il permet de fusionner des connaissances de sources différentes. Il facilite l'interopérabilité.

Les correspondances entre concepts comprennent :

- **Équivalence :** les concepts sont identiques (`owl:equivalentClass`).
- **Spécialisation :** un concept est un sous-concept de l'autre (`rdfs:subClassOf`).
- **Association :** les concepts sont liés par une relation.
- **Correspondance approximative :** les concepts sont similaires mais pas identiques.

Les méthodes d'alignement comprennent :

- **Manuelles :** un expert établit les correspondances. C'est précis mais coûteux.
- **Automatiques :** des algorithmes comparent les termes. Ils utilisent des mesures de similarité. Ils sont efficaces mais moins précis.
- **Semi-automatiques :** l'outil propose des correspondances. L'expert les vérifie et les corrige. C'est un bon compromis.

Enrichissement ontologique L'enrichissement ajoute de nouvelles connaissances à l'ontologie [36]. Il intègre des données issues de sources externes. Il peut être manuel ou assisté par des outils.

Les sources d'enrichissement comprennent notamment :

- Textes scientifiques : articles, thèses, rapports.
- Bases de données : bases de données botaniques, pharmacologiques.
- Ontologies tierces : pour aligner et intégrer.
- Connaissances d'experts : savoirs d'experts du domaine.

L'enrichissement comprend les étapes suivantes :

1. **Identification des sources :** sélectionner les sources pertinentes.
2. **Extraction des connaissances :** extraire les faits des sources.
3. **Transformation :** convertir les faits dans le format de l'ontologie.
4. **Intégration :** ajouter les faits à l'ontologie.
5. **Validation :** vérifier la cohérence et la correction.
6. **Documentation :** tracer les modifications.

Démarche pour notre recherche Dans notre démarche, nous adapterons une ontologie existante au contexte burkinabè en ajoutant les classes et les propriétés nécessaires, notamment pour les plantes locales et les noms vernaculaires. Nous modifierons les relations requises, puis organiserons les connaissances issues de la littérature selon le modèle. Nous documenterons les changements apportés au schéma et conserverons les faits extraits dans la base de connaissances.

I.2.4 Bases de connaissances et interrogation sémantique

Définition et structure Une base de connaissances est un système qui stocke des connaissances structurées [19]. Elle contient des instances (individus) et des faits. La base est typée par une ontologie. L'ontologie sert de schéma conceptuel.

Par exemple, l'ontologie définit la classe *« Plante »* et la propriété *« aPourUsage »*. La base de connaissances contient des instances comme *« Cassia alata »*. Elle contient des faits comme *« Cassia alata aPourUsage Paludisme »*.

Bases de connaissances orientées graphe Le choix d'une base orientée graphe (*graph database*) s'impose naturellement pour ce type de données, dont l'intérêt tient précisément à l'abondance des interconnexions. Plutôt que d'éparpiller l'information entre des tables, ce modèle organise les entités en nœuds et les liaisons en relations.

Ce choix présente quatre bénéfices convergents :

- **Performance :** le parcours du graphe est natif, les relations y sont des éléments à part entière, et non de simples clés étrangères.
- **Flexibilité :** le schéma n'est pas figé à l'avance, de nouveaux types de nœuds et de relations s'y intègrent sans migration lourde.
- **Expressivité :** les relations peuvent être typées, pondérées et parcourues, y compris lorsqu'elles sont profondément imbriquées.
- **Lecture intuitive :** le modèle représente les liens entre concepts, ce qui en facilite la lecture par un non-spécialiste.

Deux langages de requête dominent l'interrogation de ces graphes :

- **Cypher :** langage déclaratif de Neo4j, de loin le plus répandu, qui autorise des requêtes complexes sur les graphes.
- **Gremlin :** langage d'Apache TinkerPop, plus bas niveau, adopté par plusieurs autres bases de données graphe.

Interrogation avec Cypher Une requête Cypher typique se présente ainsi :

```
MATCH (p:Plante)-[:estRapportePour]->(:UsageTherapeutique)
  -[:aPourMaladieCible]->(m:Maladie {nom: "paludisme"})
            RETURN DISTINCT p.nomScientifique
```

Elle retourne le nom scientifique des plantes rapportées contre le paludisme.

Ses principales clauses répondent chacune à un besoin précis :

- `MATCH` : repérer des motifs dans le graphe.
- `WHERE` : filtrer les résultats.
- `RETURN` : désigner ce qui est renvoyé.
- `OPTIONAL MATCH` : établir une correspondance facultative sans perdre le reste des correspondances.
- `CREATE` : créer de nouveaux nœuds et relations.

Avantages des bases de connaissances graphe Pour notre usage, ces avantages se traduisent en cinq exigences :

- **Interrogation puissante :** formuler des requêtes combinant plusieurs critères et parcourant plusieurs relations à la fois.
- **Découverte de connaissances implicites :** laisser le parcours révéler des connexions non évidentes, par exemple des plantes partageant un usage ou une propriété.
- **Traçabilité :** associer chaque fait à sa source, de manière à pouvoir remonter à son origine et en contrôler la fiabilité.
- **Intégration :** réunir des données issues de sources diverses, l'ontologie servant de cadre unificateur.
- **Évolutivité :** enrichir la base de connaissances nouvelles sans avoir à tout reconstruire.

Application à notre recherche Nous construirons une base de connaissances orientée graphe à partir de l'ontologie réajustée. Nous y représenterons les plantes, leurs usages, leurs propriétés et leurs sources afin de permettre des requêtes depuis l'application.

I.3 Intelligence artificielle pour l'accès aux connaissances

I.3.1 Traitement des requêtes en langage naturel

Introduction au TALN Le traitement automatique du langage naturel (TALN) constitue l'une des branches de l'intelligence artificielle que nous mobiliserons dans notre projet. Il rend les textes interprétables par la machine en les analysant sur les plans syntaxique et sémantique, puis en convertissant les énoncés en formes exploitables [25]. Ces techniques permettront d'établir le dialogue entre l'utilisateur et le système.

Techniques fondamentales Les principales techniques de traitement automatique du langage naturel sont les suivantes :

- **Tokenisation :** découpage du texte en unités (mots, ponctuations). « Quelles plantes traitent le paludisme ? » devient ainsi `["Quelles", "plantes", "traitent", "le", "paludisme", "?"]`.
- **Analyse morphologique :** identification des racines des mots. « traitent » se ramène à « traiter », ce qui permet de normaliser les variantes (lemmatisation et *stemming*).
- **Étiquetage morphosyntaxique :** reconnaissance des catégories grammaticales (noms, verbes, adjectifs, etc.) (*part-of-speech tagging*).
- **Reconnaissance d'entités nommées (NER) :** détection des concepts clés, c'est-à-dire des plantes, des maladies, des parties de plantes et des modes de préparation [35].
- **Analyse de dépendances :** compréhension des relations entre mots, par identification du sujet, du verbe, de l'objet et des liens syntaxiques qui les unissent.
- **Analyse sémantique :** compréhension du sens des phrases, à l'aide de représentations vectorielles (*embeddings*) ou de graphes de connaissances.

Approches modernes : les transformers Les modèles récents reposent sur l'architecture *transformer* [53], fondée sur le mécanisme d'attention. Celui-ci prend en compte un contexte étendu, et ces modèles sont entraînés sur de grandes quantités de textes.

Trois familles font référence :

- **BERT (*Bidirectional Encoder Representations from Transformers*) :** modèle de Devlin et al. [11], bidirectionnel, qui exploite le contexte situé à la fois à gauche et à droite du mot et excelle dans les tâches de compréhension.
- **GPT (*Generative Pre-trained Transformer*) :** modèle autorégressif entraîné à prédire le prochain mot d'une séquence. Il est utilisé pour la génération de texte.
- **T5 (*Text-to-Text Transfer Transformer*) :** modèle de Raffel et al. [41], qui ramène toutes les tâches à des transformations texte-texte.

Ces modèles sont pré-entraînés sur des corpus généraux. Ils peuvent ensuite être affinés (*fine-tunés*) sur des données spécifiques afin de les adapter à des tâches particulières.

Application à notre recherche Dans notre étude, nous traiterons les requêtes en langage naturel à l'aide des méthodes de TALN. Nous en extrairons les entités et les relations pour les convertir en requêtes formelles adressées à la base de connaissances graphe. L'utilisateur pourra ainsi interroger le système en langage courant. Les exemples suivants illustrent des requêtes envisagées :

- « Quelles plantes sont utilisées contre le paludisme ? »
- « Comment prépare-t-on le remède contre la diarrhée ? »
- « La plante X a-t-elle des propriétés anti-inflammatoires ? »
- « Quelles études existent sur la toxicité de Y ? »
- « Quelles plantes du Burkina Faso sont utilisées pour le diabète et ont des études pharmacologiques ? »

I.3.2 Extraction et structuration assistées par des modèles de langue

Extraction d'information L'extraction d'information est une tâche de NLP [17] qui consiste à identifier des faits dans des textes non structurés, à en reconnaître les entités et les relations, puis à les convertir en données structurées exploitables.

Elle se déploie en quatre étapes successives :

1. **Reconnaissance des entités :** identifier les entités nommées.
2. **Reconnaissance des relations :** identifier les relations entre entités (*traite*, *contient*, *prévient*).
3. **Normalisation :** standardiser les entités.
4. **Structuration :** organiser les faits en format structuré.

Extraction à partir des textes Nous adresserons aux modèles de langue de grande taille des consignes précisant les informations à relever dans les documents.

Cette démarche comprendra quatre étapes :

- **Préparation de la consigne :** nous préciserons les informations, les entités et les relations à relever dans le texte.
- **Soumission :** nous fournirons le texte et la consigne au modèle, qui produira une réponse structurée.
- **Extraction :** nous récupérerons les informations produites et les convertirons dans le format souhaité.
- **Vérification :** nous contrôlerons la qualité de l'extraction et la corrigerons si nécessaire.

Cette approche présente plusieurs avantages :

- **Flexibilité :** les consignes peuvent être adaptées aux différents types de documents.
- **Rapidité :** la méthode convient au traitement de grands volumes de textes.
- **Adaptabilité :** les consignes peuvent être modifiées selon les informations recherchées.
- **Modèles pré-entraînés :** nous nous appuierons sur des modèles entraînés sur de grands corpus.

Cette méthode présente toutefois des limites :

- **Informations erronées :** le modèle peut produire des informations fausses ou absentes de la source.
- **Variabilité :** les réponses peuvent différer d'une exécution à l'autre.
- **Coût :** certains modèles peuvent entraîner des frais d'utilisation.

Dans notre étude, nous appliquerons ces consignes aux documents du corpus. Nous reprendrons les niveaux de preuve rapportés par les sources sans les réévaluer indépendamment. Nous examinerons la qualité des extractions selon le protocole d'évaluation du système, sans procéder à une relecture experte de chaque enregistrement.

Structuration des données La structuration convertit les faits extraits en formats standardisés. Pour notre base de connaissances orientée graphe, nous utiliserons les éléments suivants :

- **Format d'importation :** nous transformerons les données en individus de l'ontologie, au format Turtle, avant de les importer dans Neo4j.
- **Modèle de données :** nous structurerons les données selon l'ontologie, en définissant les nœuds et les relations correspondants.
- **Propriétés :** nous associerons aux nœuds et aux relations les propriétés nécessaires, notamment le type, la source et le niveau de preuve.

Application à notre recherche Nous utiliserons ces méthodes pour repérer les plantes, les usages, les parties utilisées et les propriétés rapportées, puis identifier les relations entre ces éléments. Nous organiserons les informations extraites dans un format structuré et rattacherons chaque fait à sa source.

I.3.3 Recherche sémantique et génération de réponses

Recherche sémantique La recherche sémantique dépasse la simple correspondance de mots [6] : elle s'appuie sur le sens des termes et sur l'ontologie sous-jacente pour retrouver une information pertinente, quelle que soit la formulation employée par l'utilisateur.

Dans le système prévu, le traitement comprendra six étapes :

1. **Analyse de la requête :** le NLP repère les concepts et les relations énoncés par l'utilisateur.
2. **Désambiguïsation :** lorsqu'un terme sera ambigu, le contexte aidera à déterminer le concept visé. « Paludisme » pourra, par exemple, être rapproché de « malaria » ou de « fièvre des marais ».
3. **Transformation en requête formelle :** l'énoncé naturel sera converti en requête Cypher destinée à la base de connaissances graphe, les concepts étant associés aux nœuds et aux relations.
4. **Exécution :** la requête sera exécutée sur la base de connaissances, puis les résultats seront récupérés.
5. **Filtrage et classement :** les résultats seront filtrés puis triés selon leur pertinence, leur niveau de preuve ou leur proximité sémantique.
6. **Génération de la réponse :** les résultats seront transformés en texte lisible.

Génération augmentée par récupération Pour faciliter l'accès aux connaissances, nous mettrons en place un système RAG (*Retrieval-Augmented Generation*) associant la recherche d'information à la génération de réponses [30].

Son fonctionnement comprendra cinq étapes :

- **Interprétation de la requête :** le système cernera la demande de l'utilisateur.
- **Recherche :** il interrogera la base de connaissances et en extraira les informations pertinentes (nœuds, relations, propriétés).
- **Contexte :** les informations retrouvées seront assemblées en un contexte, ensuite soumis au modèle de langue.
- **Génération :** le modèle formulera une réponse à partir du contexte fourni ; nous vérifierons que ses affirmations correspondent aux faits retrouvés.
- **Affichage des sources :** les sources accompagneront la réponse afin que l'utilisateur puisse vérifier l'origine de l'information.

Dans notre étude, le RAG présentera plusieurs caractéristiques utiles :

- **Appui sur les sources :** les réponses sont élaborées à partir des faits retrouvés dans la base.

- **Traçabilité :** le lien avec les sources permet de vérifier l'information.
- **Mise à jour :** l'ajout de données dans la base permettra de prendre en compte de nouvelles informations.
- **Adaptabilité :** la base peut être adaptée à des contextes différents.

Application à notre recherche Notre système interprétera les requêtes en langage naturel et interrogera la base de connaissances graphe. Il formulera ses réponses à partir des faits retrouvés et indiquera leurs sources ainsi que le niveau de preuve rapporté, afin que l'utilisateur puisse en vérifier l'origine.

I.3.4 Traçabilité et fiabilité des réponses

Importance de la traçabilité En contexte médical, la traçabilité conditionne la crédibilité d'un système [16]. En associant chaque information à sa source, nous pourrons en vérifier l'origine et aider les utilisateurs à en apprécier la fiabilité.

Sans traçabilité, une information peut être difficile à vérifier et l'utilisateur peut peiner à en apprécier la fiabilité.

Mécanismes de traçabilité Nous mettrons en œuvre cinq mécanismes :

- **Stockage des références :** nous stockerons chaque fait avec un identifiant de source, que nous décrirons.
- **Association information-source :** dans la base, nous relierons chaque information à sa source. Exemple : `(information)-[:PROVIENT_DE]->(source)`.
- **Affichage des sources :** nous accompagnerons les réponses de leurs références et des détails disponibles, comme la page, la section, le DOI ou l'URL.
- **Citations :** les renvois sont numérotés comme dans les articles scientifiques, avec appel à une bibliographie.
- **Lien vers les documents :** lorsque les documents sont disponibles en ligne, un lien est fourni.

Fiabilité des réponses La fiabilité des réponses dépendra d'abord de la qualité des sources. Nous privilégierons les sources scientifiques validées :

- **Articles évalués par les pairs :** publiés dans des revues scientifiques.
- **Thèses et mémoires :** validés par des jurys académiques.
- **Rapports de recherche :** produits par des institutions reconnues.
- **Livres et chapitres de livres :** publiés par des maisons d'édition scientifiques.

Distinction des niveaux de preuve Dans notre système, nous distinguerons les niveaux de preuve tels qu'ils seront rapportés par les sources :

- **Usage traditionnel :** nous indiquerons qu'il s'agit d'un usage rapporté, non démontré scientifiquement.
- **Activité *in vitro* :** nous préciserons que l'activité a été testée en laboratoire sur des cellules ou des micro-organismes.
- **Activité *in vivo* :** nous indiquerons que l'étude a évalué l'activité sur des animaux.
- **Essai clinique :** nous signalerons le niveau de preuve rapporté par la source.
- **Toxicité :** nous signalerons les informations rapportées sur la toxicité ou les effets secondaires.

Gestion des incertitudes Nous consignerons les contradictions relevées dans les documents sans les trancher. Chaque réponse renverra à sa source, dont l'année permet d'apprécier l'ancienneté de l'information, et le niveau de preuve rapporté rappellera qu'un usage traditionnel n'est pas une efficacité démontrée.

Limites du système Le système ne créera pas de connaissances thérapeutiques et ne remplacera pas l'expertise humaine. Il facilitera la consultation des connaissances existantes. L'utilisateur devra interpréter les informations en tenant compte de leurs sources et de leurs limites. Le système ne constituera ni un outil de diagnostic ni un outil de prescription.

I.4 Travaux connexes et positionnement scientifique

Nous examinerons dans cette section les travaux consacrés à la modélisation des connaissances en médecine traditionnelle à base de plantes. Nous distinguerons les ontologies développées en Afrique de celles qui concernent directement le Burkina Faso, puis situerons notre démarche par rapport à ces travaux.

I.4.1 Ontologies dans le domaine des plantes médicinales

Ontologies internationales

Plusieurs ontologies couvrent le domaine des plantes médicinales. Chacune a ses forces et ses limites.

- **Flora Ontology (FLOPO) :** elle décrit la structure botanique des plantes, parties et stades de développement compris [23]. Extrêmement complète pour la botanique, elle ignore en revanche les usages médicinaux et les connaissances ethnobotaniques.
- **Plant Ontology (PO) :** proche de FLOPO [8], elle porte sur l'anatomie et le développement des plantes et sert de référence pour l'annotation de données génomiques. Ni l'ethnobotanique ni la pharmacologie n'y figurent.
- **Ontology of Traditional Medicine (OTM) :** dédiée à la médecine traditionnelle [43], elle couvre maladies, traitements et remèdes, et intègre des notions issues de la médecine traditionnelle chinoise et de l'Ayurvéda. Prometteuse, elle demeure en cours de développement et n'est pas spécifique aux plantes d'Afrique.
- **Drug Ontology (DrOn) :** centrée sur les propriétés pharmaceutiques [21], elle décrit les médicaments, leurs ingrédients et leurs effets. Son utilité pharmacologique est réelle, mais son champ reste celui des médicaments modernes.
- **Food Ontology (FOODON) :** consacrée à la nutrition et aux aliments [13], elle intègre certaines plantes comestibles et peut être partiellement réutilisée sur le versant alimentaire, sans toutefois couvrir les usages médicinaux.
- **SNOMED CT :** cette terminologie clinique très large [44] couvre de nombreux domaines médicaux et inclut quelques concepts relatifs aux plantes, sans être pour autant structurée comme une ontologie formelle.

Ontologies de la médecine traditionnelle africaine

Plusieurs travaux récents ont développé des ontologies spécifiques à la médecine traditionnelle africaine. Ces travaux reconnaissent les particularités des systèmes de soins africains. Ils intègrent des dimensions culturelles, spirituelles et sociales.

WATRIMed, un graphe de connaissances pour la médecine traditionnelle ouest-africaine Deux publications complémentaires décrivent WATRIMed (West African Herbal based Traditional Medicine) [46, 45]. Elles présentent un modèle conçu pour structurer les connaissances sur les plantes médicinales, les recettes traditionnelles et les maladies traitées en Afrique de l'Ouest, et pour relier ces informations à des bases de données publiques. Le modèle est appelé HTM Ontology (Herbal Traditional Medicine Ontology).

Le noyau du modèle compte 556 concepts dans la version présentée à MEDINFO 2019 [46], dont 143 plantes médicinales ouest-africaines identifiées et 108 recettes employées par les tradipraticiens pour traiter 110 maladies et symptômes courants de la sous-région. La note de conception associée décrit un modèle de 472 concepts et de 75 propriétés, dont 57 propriétés objet et 18 propriétés de données [45]. Les classes principales qui y figurent sont :

- **Medicinal Plant** (plante médicinale) et **Plant Part** (partie de plante).
- **Recipe** (recette) et **Formulation** (forme galénique).
- **Chemical Component** (composé chimique) et **Therapeutic Action** (action thérapeutique).
- **Vernacular Name** et **Vocabulary** (noms vernaculaires et vocabulaires).
- **ContraIndication**, **Adverse Reaction** et **Usage Precaution** (contre-indications, réactions indésirables, précautions d'emploi).

Les relations principales associent la plante à ses composés chimiques, à ses actions thérapeutiques et à ses noms vernaculaires. Elles font également intervenir les contre-indications, les réactions indésirables, les formes galéniques et la dérivation d'une ressource à une autre.

Le projet s'inscrit dans un cadre sous-régional et bénéficie de l'expérience de l'Organisation ouest-africaine de la santé (WAHO), qui regroupe les États membres de la sous-région [45]. Le modèle est aligné sur l'ontologie fondationnelle BioTopLite2, et ses instances sont reliées à des ressources externes comme DBpedia, IPNI, Wikidata, PubChem et Yago. L'exemple donné par les auteurs porte sur le nom vernaculaire fulfuldé, au Burkina Faso, d'une espèce employée en médecine traditionnelle.

Ses apports tiennent à trois éléments : l'ampleur du modèle, son alignement avec des bases de connaissances existantes, et la perspective ouverte d'y détecter des interactions entre plantes et médicaments.

Ces deux publications n'exposent toutefois qu'un aperçu des classes supérieures et des relations principales. L'ontologie elle-même n'est pas téléchargeable, ce qui limite la réutilisation directe du modèle.

ontoMEDTRAD : ontologie visuelle pour l'Afrique de l'Ouest ontoMEDTRAD constitue une autre initiative notable, développée pour la médecine traditionnelle ouest-africaine [28]. Elle se distingue par une approche à la fois formelle et visuelle, l'ontologie étant répartie en deux modules complémentaires :

- **ontoCONCEPT-Term** : ontologie terminologique de domaine (plantes, recettes, maladies, préparations, etc.),
- **ontoICONE** : module iconique qui associe à ces concepts des représentations iconiques destinées à faciliter la compréhension par des tradipraticiens souvent illettrés dans les langues officielles.

Elle modélise explicitement le parcours de soin : le praticien de la médecine traditionnelle, le patient, les signes et les symptômes, les maladies, les ressources médicinales (plantes, animaux, minéraux), la recette, ses ingrédients et les parties de plantes employées, les modes de préparation et d'administration, ainsi que le remède et sa forme galénique. Elle distingue les cinq types de plante (arbre, arbuste, palme, herbe, liane) et les neuf parties de plantes utilisées (feuille, fruit, fleur, racine, tronc, écorce de tronc, écorce de racine, sève, plante entière).

Les relations de base y sont la subsomption (relation « est un ») et la partie-tout (relation « est une partie de »). 76 propriétés associatives et 16 propriétés de données complètent un modèle qui compte 144 concepts, 789 individus et 2 734 axiomes en logique de description ALCHOIQ.

Bien que conçue dans un contexte ouest-africain (Côte d'Ivoire, Sénégal, etc.), ontoMEDTRAD est théoriquement transposable au Burkina Faso. Elle met l'accent sur la représentation des recettes multi-plantes, en particulier antipaludéennes (son jeu de données compte 22 plantes et 31 remèdes antipaludéens [29]), et propose une méthode originale pour franchir les barrières linguistiques et l'illettrisme grâce à la dimension iconique.

ATHMed : un système à base de connaissances pour la médecine traditionnelle africaine Développée au Ghana, mais avec une vocation africaine, l'approche ATHMed (African Traditional Herbal Medicine) vise à construire un système à base de connaissances permettant la capture, le stockage, l'indexation et la recherche d'informations sur la médecine traditionnelle à base de plantes [10].

L'article qui la présente adopte une démarche de recherche en science du design et s'appuie sur des entretiens semi-directifs conduits auprès de vingt parties prenantes au Ghana : universités, organismes de recherche, tradipraticiens, cliniques, autorité de régulation et usagers. Il propose un cadre conceptuel articulé en trois couches. Une couche données capture et stocke les connaissances auprès des experts du domaine. Une couche logique assure le raisonnement à travers un raisonneur sémantique et un extracteur fondé sur le machine learning. Une couche présentation expose une interface permettant d'interroger la base en langage naturel.

Les connaissances sont attendues dans un corpus sémantiquement annoté, la recherche étant conçue comme contextuelle et multi-mots. L'originalité de l'approche tient à cette hybridation entre ontologie et techniques d'apprentissage automatique, destinée à extraire et à structurer les connaissances à partir de textes.

L'article reste toutefois au stade d'une proposition : l'ontologie ATHMed y est annoncée comme un modèle à dériver, et la mise en œuvre du système est explicitement renvoyée à des travaux ultérieurs. À ce stade, ATHMed est donc un cadre d'architecture plutôt qu'une ontologie réutilisable.

Travaux sur les « deep ontologies » de la médecine traditionnelle africaine Parallèlement à ces initiatives, plusieurs travaux conceptuels ont proposé des « deep ontologies » pour la médecine traditionnelle africaine. Au-delà des aspects cliniques et pharmacologiques (plantes, maladies, traitements), ces ontologies visent à intégrer des dimensions contextuelles, culturelles et symboliques propres à la médecine traditionnelle, telles que les rites et les croyances.

Ces modèles s'appuient sur des méthodologies d'ingénierie des connaissances comme METHONTOLOGY. Ils sont généralement implémentés dans des outils tels que Protégé (OWL). Ils mettent en avant la nécessité de modéliser des entités comme : TherapeuticRecipe, TherapeuticProcess, Ritual, Belief, en plus des classes plus classiques (Plant, Disease, Symptom).

Ayimdji et al. [5] proposent ainsi une première version d'une ontologie « profonde » pour la médecine traditionnelle africaine. Ce travail souligne la nécessité de prendre en compte les dimensions contextuelles et culturelles, au-delà des relations entre plante, maladie et traitement.

Ces travaux offrent une réflexion méthodologique précieuse sur la construction d'ontologies « profondes » capables de rendre compte de la complexité de la médecine traditionnelle africaine. Ils restent cependant majoritairement conceptuels : les déploiements opérationnels à grande échelle se comptent à peine, et les outils de consultation destinés aux acteurs de terrain sont rares.

Ontologie pour les tradipraticiens (bone-setters) en Afrique de l'Ouest (2024) Un travail récent (2024) propose une ontologie destinée aux tradipraticiens spécialisés dans le traitement des fractures. Dérivée du domaine des bone-setters en Afrique de l'Ouest, elle est appelée ontoFRACTURECARE [12].

Les auteurs constatent que les bone-setters restent le premier recours des populations rurales, leur pratique se révélant là où la médecine conventionnelle montre ses limites. La plupart des praticiens sont toutefois âgés et analphabètes, et l'intérêt des jeunes générations fait défaut.

L'ontologie vise à structurer, mettre en valeur et fournir une désignation consensuelle des concepts pertinents. Elle est destinée à servir de guide pour une prise de décision intelligente dans le processus de soins.

Modèle d'intégration des connaissances (Angole et al.) Angole et al. ont proposé un modèle fondé sur une ontologie, destiné à intégrer les connaissances de la médecine moderne et de la médecine traditionnelle africaine [2, 3].

Leur approche, présentée sous le nom d'ATMO (African Traditional Medicine Ontology), retient la Basic Formal Ontology comme ontologie supérieure standard et vise à s'articuler avec les ontologies de la médecine moderne, en particulier l'Ontologie de la Science Médicale Générale (OGMS), elle-même dérivée de la BFO.

L'objectif est de faire reconnaître la médecine traditionnelle africaine et de l'incorporer au système de santé : structurées, ses connaissances pourraient alors être mobilisées en parallèle de la médecine conventionnelle.

Ontologies nationales et ethniques Des ontologies ont été développées pour des contextes spécifiques : l'ontologie visuelle ontoMEDTRAD, par exemple, couvre l'Afrique de l'Ouest, principalement la Côte d'Ivoire et le Sénégal.

D'autres travaux documentent les systèmes nosologiques locaux. Souley [47], par exemple, a étudié les entités nosologiques populaires chez les Haoussa, faisant apparaître des concepts médicaux locaux tels que zahí, sanyi et shawara.

Particularités ontologiques de la médecine traditionnelle africaine L'étude de ces ontologies fait apparaître trois particularités récurrentes :

- **Holisme :** le corps est une entité interconnectée, faite de composantes naturelles et surnaturelles [51]. La santé désigne un bien-être physique, mental, spirituel, social et écologique à la fois.
- **Causalité surnaturelle :** la maladie n'est pas seulement un dysfonctionnement mécanique, elle peut résulter d'une rupture de l'harmonie entre l'homme et le cosmos.
- **Traitement magico-rationnel :** il articule les pouvoirs des plantes et ceux du guérisseur.

Inventaires et structuration de données ethnobotaniques au Burkina Faso

Au Burkina Faso, de nombreux travaux ont été consacrés au recensement des plantes médicinales et de leurs usages thérapeutiques. Ils relèvent principalement de :

- d'études ethnobotaniques publiées dans des revues scientifiques,
- de thèses et mémoires (pharmacie, biologie, médecine),
- de rapports de projets (AI4D, herbier national, chimiothèque, etc.).

Conduits dans différentes régions du pays (Hauts-Bassins, Sud-Ouest, Centre-Est, etc.), ces travaux ont produit des inventaires floristiques et des enquêtes auprès des tradipraticiens, documentant :

- les noms scientifiques et vernaculaires des plantes,
- les parties utilisées,
- les pathologies traitées,
- les modes de préparation et d'administration,
- parfois les dosages et les toxicités.

Exemples d'articles, thèses et rapports sur les plantes médicinales du Burkina Faso :

- **Tibiri A. et al. (2020)** [50]. « Countrywide Survey of Plants Used for Liver Disease Management by Traditional Healers in Burkina Faso », Frontiers in Pharmacology, 2020.

  Enquête à l'échelle nationale sur les plantes utilisées contre les maladies hépatiques. Plus de 2 000 entrées de plantes correspondant à 212 espèces. Géolocalisation des tradipraticiens. Analyse statistique sous R.

- **Ouédraogo L., Endl J., Sombié P. A. E. D., Schaefer H., Kiendrebeogo M. (2020)** [38]. « Ethnobotanical use and conservation assessment of medicinal plants sold in markets of Burkina Faso », Ethnobotany Research and Applications, 20 :1–25, 2020.

  Enquête auprès de 30 commerçants de plantes médicinales dans six grandes villes. Identification de 104 espèces utilisées pour diverses pathologies (troubles gastro-intestinaux, paludisme, etc.). Évaluation du statut de conservation.

- **Nadembega P. et al. (2026)** [40]. « An ethnobotanical survey of medicinal plants used for children's healthcare in Centre-Est Burkina Faso », Ethnobotany Research and Applications, 33, 2026.

  Enquête sur les plantes utilisées pour la santé des enfants dans la région du Centre-Est. Documentation de 185 espèces issues de 52 familles.

- **Zongo et al. (2025)** [63]. « Ethnopharmacological study on medicinal plants used for jaundice and liver-related disorders management in the Province of Kouritenga in the Central-Eastern of Burkina Faso », Journal of Advanced Translational and Preclinical Biomedicine, 2025.

  Étude ethnopharmacologique ciblée sur les plantes utilisées contre la jaunisse et les troubles hépatiques dans une province spécifique.

- **Traoré S., Diawara/Zimé H., Ouédraogo S., et al.** [52]. « Ethnobotanical Survey on Plants Used in the Treatment of Wounds by Traditional Health Practitioners in Burkina Faso », International Journal of Plant, Animal and Environmental Sciences, 15, 2025.

  Enquête sur les plantes utilisées par les tradipraticiens pour le traitement des plaies. Identification de 70 espèces.

- **Projet AI4D** [1]. « Création d'une base de données sur les plantes médicinales pour faciliter l'exploitation des connaissances ethnopharmacologiques locales ».

  Projet visant à construire une base de données ouverte et interrogeable sur les plantes médicinales du Burkina Faso. Champs standardisés : nom scientifique, famille, noms en mooré/dioula/fulfuldé, localisation spatiale, statut de conservation, usages médicaux.

- **Flahaut E.** [15]. « Pharmacopée et médecine traditionnelle dans l'ouest du Burkina Faso : plantes médicinales et soins du couple mère–enfant », Thèse de Doctorat en Pharmacie, Université de Lille II.

  Thèse ancienne mais souvent citée. Documente les plantes médicinales et les soins traditionnels dans l'ouest du Burkina Faso, en particulier pour la mère et l'enfant.

- **Zerbo P. et al. (2007)** [60]. « Contribution à la connaissance des plantes médicinales utilisées dans les soins infantiles en pays San, au Burkina Faso », International Journal of Biological and Chemical Sciences, 1(3), 2007.

  Recense 79 espèces médicinales utilisées dans les soins infantiles, avec 167 recettes médicamenteuses documentées.

L'Herbier National des Plantes Médicinales du Burkina Faso (projet « Herbier avec chimiothèque ») L'Herbier National des Plantes Médicinales du Burkina Faso, souvent désigné sous le nom de projet « Herbier avec chimiothèque », vise à créer un herbier national spécifiquement dédié aux plantes médicinales, couplé à une chimiothèque contenant les marqueurs chimiques des plantes répertoriées.

Ses objectifs principaux sont les suivants :

- réaliser des enquêtes ethnobotaniques régionales auprès des tradipraticiens de santé, en commençant par les régions du Centre et du Plateau central,
- établir un inventaire des plantes médicinales utilisées pour le traitement des dix pathologies prioritaires définies par le ministère de la Santé,
- identifier et géolocaliser ces plantes, et confectionner des spécimens d'herbier,
- procéder à l'identification botanique et au dosage de marqueurs chimiques pour les vingt plantes les plus couramment utilisées pour chaque pathologie,
- alimenter une base de données nationale sur les plantes médicinales, accessible via une application mobile et un site web.

Ce projet se veut la phase préliminaire d'une initiative plus ambitieuse qui étendrait les enquêtes ethnobotaniques à toutes les régions du pays. Il s'inscrit dans une dynamique plus large de valorisation de la pharmacopée traditionnelle, portée notamment par :

- la création de bosquets à plantes médicinales dans chaque province (annonce présidentielle de 2024–2025),
- l'approbation par le gouvernement de dizaines de produits issus de la pharmacopée traditionnelle,
- la mise en place de sites de conservation et de culture contrôlée des espèces médicinales.

Le projet « Herbier avec chimiothèque » se distingue des autres herbiers nationaux par sa focalisation explicite sur les plantes médicinales. Il associe trois dispositifs complémentaires :

- un herbier (spécimens botaniques identifiés et conservés),
- une chimiothèque (marqueurs chimiques identifiés et dosés),
- une base de données (informations ethnobotaniques, usages thérapeutiques, géolocalisation).

Il coexiste avec d'autres herbiers reconnus au Burkina Faso, notamment :

- l'Herbier National du Burkina (HNBU) du CNRST/INERA, héritier de la section de l'IFAN créée en 1954,
- l'herbier du Centre National de Semences Forestières (CNSF) (environ 15 000 spécimens),
- l'herbier de l'Université Joseph Ki-Zerbo (OUA).

Ces collections jouent un rôle important dans la conservation de la diversité végétale. Mais le projet « Herbier avec chimiothèque » est le seul à viser explicitement une base de données nationale structurée sur les plantes médicinales, avec une dimension ethnobotanique et chimique.

Ces travaux forment une base empirique essentielle et spécifiquement burkinabè. Ils fournissent des outils méthodologiques précieux et des données de terrain riches. Aucun ne propose cependant d'ontologie formelle explicite : les connaissances sont surtout organisées dans des tableaux, des bases relationnelles simples ou des documents PDF, sans modèle sémantique unifié. Les données demeurent dispersées entre études, bases locales et projets comme herbier national, chimiothèque.

Synthèse comparative des ontologies existantes

Cette lecture comparative fait apparaître des points communs et des écarts marquants.

Points communs

Les initiatives régionales (WATRIMed, ontoMEDTRAD, ATHMed) partagent une même ambition : formaliser les connaissances sur la médecine traditionnelle à base de plantes en Afrique. WATRIMed et ontoMEDTRAD modélisent explicitement les plantes, les recettes et les maladies traitées. Plusieurs y ajoutent les parties utilisées, les modes de préparation et d'administration, ainsi que le fait qu'une recette puisse combiner plusieurs plantes pour traiter une ou plusieurs pathologies. ATHMed, elle, en reste au stade d'un cadre proposé, où l'ontologie et le machine learning sont appelés à collaborer.

Différences

Elles diffèrent cependant sur plusieurs aspects :

- **Zone géographique de référence** : Afrique de l'Ouest vs Afrique générale.
- **Niveau de détail** : certaines incluent des composés chimiques, des rituels, des icônes. D'autres restent plus simples.
- **Degré de formalisation** : ontologies OWL riches vs modèles plus légers.
- **Volume de données modélisées** : de quelques dizaines à quelques centaines de plantes et recettes.
- **Existence d'applications web** : peu d'outils opérationnels et accessibles aux acteurs locaux.

Le tableau I.1 présente une synthèse comparative des ontologies identifiées dans la littérature.

TABLE I.1 – Synthèse comparative des ontologies de la littérature

Ontologie	Domaine	Couverture	Particularité	Limite principale
FLOPO [23]	Botanique	Structure des plantes	Très complète	Pas d'usages médicinaux
PO [8]	Botanique	Anatomie végétale	Standard génomique	Pas d'ethnobotanique
OTM [43]	Médecine trad.	Maladies, traitements	Intègre médecines asiatiques	Pas spécifique Afrique
DrOn [21]	Pharmacologie	Médicaments, effets	Standard pharmaceutique	Limitée aux médicaments modernes
FOODON [13]	Alimentation	Plantes comestibles	Couverture large	Pas d'usages médicinaux
SNOMED CT [44]	Clinique	Terminologie médicale	Large couverture	Structure non ontologique
WATRIMed [46, 45]	Med. trad. Ouest-Afr.	Plantes, recettes, maladies	Graphe relié à DBpedia, IPNI, Wikidata	Seules les classes supérieures sont publiées
ontoMEDTRAD [28]	Med. trad. Ouest-Afr.	Plantes, recettes	Approche visuelle iconique	Validation globale non faite ; 22 plantes
ATHMed [10]	Med. trad. Afr.	Plantes, traitements	Hybride ontologie/ML	Cadre proposé, Ghana
Deep Ontologies [5]	Med. trad. Afr.	Plantes, rituels, croyances	Intègre dimensions culturelles	Conceptuel, peu opérationnel
Angole et al. [3]	Intégration Med.	Maladies, traitements	Alignement BFO	Pas spécifique aux plantes médicinales
ontoFRACTURECARE [12]	Med. trad. (fractures)	Bone-setters	Structuration des connaissances	Limité au traitement des fractures

Analyse synthétique

Trois constats se dégagent du tableau. Les ontologies botaniques (FLOPO, PO) couvrent convenablement la plante mais ignorent les usages médicinaux. Les ontologies pharmaceutiques (DrOn) restent centrées sur les médicaments modernes. L'OTM, prometteuse, n'est pas spécifique à l'Afrique.

Pour l'Afrique, plusieurs initiatives se distinguent : celle de Tekemetieu [49] intègre les dimensions mystiques mais reste limitée au Gabon et au Cameroun. Celle d'Angole et al. [2, 3] apporte une intégration avec la médecine moderne tout en demeurant générale. OntoMEDTRAD [28] est la plus aboutie pour l'Afrique de l'Ouest grâce à son approche visuelle. WATRIMed [46, 45] couvre l'Afrique de l'Ouest, avec des exemples burkinabès, mais seules ses classes supérieures sont publiées.

Aucune de ces ontologies n'est spécifiquement consacrée aux plantes médicinales du Burkina Faso. La traçabilité systématique des sources et la restitution des niveaux de preuve attribués par ces sources restent également peu abordées. Notre recherche portera sur ces deux aspects.

Apports attendus par rapport aux travaux existants

Notre travail s'inscrit dans un paysage déjà dense, où coexistent des initiatives de recensement, de structuration et de modélisation des connaissances sur les plantes médicinales, en Afrique et plus particulièrement au Burkina Faso. D'un côté, des ontologies et systèmes à base de connaissances à vocation régionale ou continentale (WATRIMed, ontoMEDTRAD, ATHMed, deep ontologies de la médecine traditionnelle africaine). De l'autre, de nombreux inventaires ethnobotaniques, thèses, rapports et projets de bases de données burkinabès (enquêtes sur les plantes médicinales, projet AI4D, projet « Herbier avec chimiothèque », etc.).

Face à cet existant, notre travail apportera une contribution sur quatre plans.

Sur le plan scientifique, nous produirons une ontologie adaptée et une base de connaissances structurée à partir de la littérature scientifique burkinabè.

Sur le plan méthodologique, nous proposerons une méthode d'extraction assistée par des modèles de langue et un modèle conceptuel adapté au contexte burkinabè. Ce modèle intégrera les noms vernaculaires en mooré, dioula et fulfuldé, les recettes multi-plantes lorsqu'elles seront documentées et les localités rapportées par les sources. Nous rattacherons chaque information à sa source et conserverons le niveau de preuve que celle-ci lui attribue.

Sur le plan technologique, nous mettrons en place une base de connaissances orientée graphe et développerons une application web de consultation. Un système RAG permettra les requêtes en langage naturel. L'application proposera un chatbot, une recherche par plante ou par pathologie et des fiches descriptives accompagnées de leurs sources et de leurs niveaux de preuve.

Sur le plan sociétal, notre travail contribuera à la valorisation du patrimoine végétal thérapeutique burkinabè grâce à une base structurée et traçable, utile à la recherche, à la préservation des connaissances endogènes et à la diffusion scientifique.

Notre travail se positionnera comme un complément aux infrastructures existantes, notamment aux ontologies régionales, aux inventaires et à l'herbier national. Il proposera une modélisation sémantique centrée sur les usages thérapeutiques documentés au Burkina Faso et reliée aux sources scientifiques.

I.4.2 Systèmes intelligents d'accès aux connaissances

Typologie des systèmes Plusieurs familles de systèmes donnent accès aux connaissances médicinales, chacune adossée à une approche technique différente :

- **Systèmes experts :** ils modélisent l'expertise humaine par des règles logiques [7], comme dans MYCIN. Ils peuvent être difficiles à adapter aux connaissances traditionnelles et demander une maintenance importante.
- **Systèmes à base de cas :** ils réutilisent des cas similaires [27]. Ils supposent une base de cas étendue et peuvent être moins adaptés aux situations inédites.

- **Chatbots médicaux :** ils assurent une interaction en langage naturel [24], comme Ada ou Babylon Health. Leur base de connaissances et leur fiabilité peuvent varier.
- **Plateformes d'ontologies :** elles autorisent des requêtes sémantiques formelles [48]. Leurs interfaces peuvent être complexes et s'adresser surtout aux experts.

Systèmes RAG pour l'accès aux connaissances Les systèmes RAG (*Retrieval-Augmented Generation*) constituent une avancée plus récente [30], déjà déclinée dans plusieurs domaines : *HealthRAG* (médical), *BioRAG* (biologique), *LegalRAG* (juridique).

Limites communes des systèmes existants Quatre limites apparaissent dans plusieurs familles de systèmes :

- bases de connaissances incomplètes ou hétérogènes.
- absence de traçabilité systématique vers les sources d'origine.
- non-adaptation aux spécificités et aux langues locales.
- absence de pondération par niveaux de preuve scientifique.

Positionnement attendu de notre système Notre système associera l'adaptation au contexte burkinabè à l'exploitation de sources scientifiques, à la traçabilité et à la restitution des niveaux de preuve déclarés par les sources. Il s'appuiera sur une base orientée graphe et un système RAG pour l'accès en langage naturel.

I.4.3 Positionnement de notre recherche

Positionnement de notre recherche Notre démarche s'articulera autour de sept éléments :

1. **Réutilisation d'ontologie :** nous partirons d'un modèle existant pour favoriser la continuité avec les travaux antérieurs.
2. **Adaptation locale :** nous prendrons en compte le contexte burkinabè et les noms vernaculaires en *mooré*, *dioula* et *fulfuldé*.
3. **Enrichissement scientifique :** nous exploiterons des thèses, des articles et des travaux locaux documentés.
4. **Traçabilité des sources :** nous relierons chaque fait à sa référence scientifique.
5. **Accès par RAG :** nous permettrons des requêtes formulées en langage naturel.
6. **Base de connaissances graphe :** nous représenterons les entités et leurs relations dans Neo4j.
7. **Niveaux de preuve :** nous restituerons, pour chaque fait, la catégorie indiquée par la source, qu'il s'agisse d'un savoir traditionnel, d'une étude *in vitro*, d'une étude *in vivo* ou d'un essai clinique.

Conclusion du chapitre

Dans ce chapitre, nous avons présenté les concepts liés aux plantes médicinales et au patrimoine ethnobotanique, puis les principes de l'ingénierie des connaissances et des ontologies. Nous avons également examiné l'apport du traitement du langage naturel et des systèmes de génération augmentée par récupération à l'accès aux connaissances, avant d'analyser les travaux consacrés à la médecine traditionnelle africaine.

Cette revue de la littérature met en évidence plusieurs lacunes. Aucune ontologie n'est spécifiquement consacrée aux plantes médicinales du Burkina Faso. *ontoMEDTRAD* porte principalement sur la Côte

d'Ivoire et le Sénégal, tandis que *WATRIMed*, malgré des exemples burkinabè, n'en publie que les classes supérieures. La traçabilité des connaissances et l'intégration de sources scientifiques multiples restent également des enjeux.

Notre recherche cherchera à répondre à ces lacunes en adaptant une ontologie au contexte burkinabè et en structurant les connaissances issues de la littérature. Elle s'inscrira dans une démarche de valorisation et de préservation des savoirs locaux, tout en contribuant à l'étude de la médecine traditionnelle en Afrique.

Le chapitre suivant présentera le matériel mobilisé et la démarche méthodologique. Nous y décrirons le corpus, la comparaison des ontologies, l'adaptation de l'ontologie retenue et les phases de la démarche, jusqu'à l'évaluation du système.

Chapitre II

Matériel et méthodologie

Introduction du chapitre

Après avoir posé le cadre conceptuel et exposé l'état de l'art, nous présentons le matériel mobilisé et la démarche méthodologique suivie. Ce chapitre fait le lien entre la réflexion théorique et la mise en œuvre technique.

Nous présentons le matériel mobilisé, notamment le corpus documentaire, les ontologies candidates et l'environnement technique. Nous décrivons les six phases de la démarche suivie, de la constitution du corpus à l'évaluation du système, en passant par les deux volets menés en parallèle sur le modèle conceptuel et sur le modèle de données, puis en proposons une synthèse.

II.1 Matériel

Le matériel comprend le corpus documentaire, les ontologies candidates et l'environnement technique. Les deux tableaux qui suivent récapitulent ces ressources, réparties entre documentation, modèles conceptuels et outils techniques.

II.1.1 Corpus documentaire

Le corpus réunit les ontologies candidates, présentées à la section II.1.2, et les documents scientifiques. Pour ces derniers, nous avons réuni des publications scientifiques.

La figure II.1 résume le processus de constitution du corpus documentaire, de la recherche des documents (phase 1) à leur sélection (phase 2b).

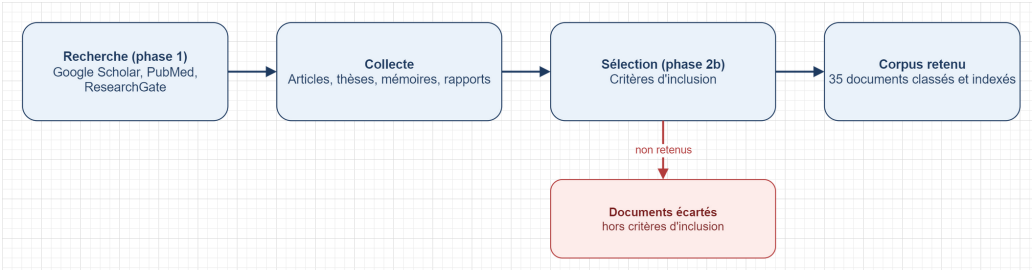


FIGURE II.1 – Constitution du corpus documentaire

Notre corpus scientifique comprend 35 rapports de recherche, articles, thèses et mémoires provenant de revues, d'universités et d'institutions de recherche burkinabè. Ces travaux ethnobotaniques, ethnopharmacologiques et phytochimiques documentent les noms scientifiques et vernaculaires, les

parties utilisées, les pathologies traitées, les modes de préparation et, pour les études qui les rapportent, les dosages et les données de toxicité.

Nous avons retenu ces travaux pour leur qualité et leur pertinence au contexte burkinabè, des publications fondatrices aux plus récentes. Cette diversité d'espèces, de pathologies et de pratiques thérapeutiques soutient l'extraction. Quatre travaux illustrent les types de données mobilisés dans le corpus :

— Zerbo et al. [61] ont étudié les plantes médicinales chez les Sanan du Burkina Faso. Leur travail documente 94 espèces utilisées pour combattre différentes pathologies.

— Ouédraogo et al. [39] ont dressé une revue des plantes médicinales à potentiel aromatique du pays, recensant 42 espèces et en caractérisant les propriétés et les usages.

— Tibiri et al. [50] ont mené une enquête à l'échelle nationale sur les plantes utilisées contre les maladies hépatiques, documentant plus de 2 000 entrées de plantes correspondant à 212 espèces.

— Ouédraogo et al. [38] ont enquêté auprès de 30 commerçants de plantes médicinales dans six grandes villes, identifiant 104 espèces utilisées pour diverses pathologies.

Ces travaux fournissent des méthodes réutilisables et des observations de terrain recueillies au Burkina Faso.

Les documents du corpus relèvent de types d'étude différents, et chacun est exploitable pour les informations qu'il rapporte. Trois profils se distinguent. Les enquêtes ethnobotaniques et ethnopharmacologiques, menées auprès de tradipraticiens ou dans les marchés, rapportent les noms vernaculaires, les parties utilisées, les modes de préparation et les pathologies traitées, souvent plante par plante. Les études expérimentales, notamment les essais *in vitro* et les travaux phytochimiques, mesurent des activités pharmacologiques, des concentrations, des niveaux de preuve et parfois les lieux de récolte. Elles renseignent moins sur les noms vernaculaires et les pratiques de préparation. Enfin, les revues de synthèse dressent des inventaires à grande échelle et servent surtout à repérer les sources primaires.

Nous avons appliqué quatre règles à l'extraction. Chaque source ne renseignait que les champs qu'elle mesurait. Nous avons laissé vides les champs non couverts, sans les compléter par déduction. Nous n'avons pas retenu comme fait établi un usage traditionnel rapporté dans un article expérimental sans référence ethnobotanique. Enfin, nous n'avons pas additionné les nombres d'espèces d'une source à l'autre, car une revue peut reprendre les espèces documentées dans les enquêtes qu'elle cite.

Ce corpus rassemble des études menées dans plusieurs régions du Burkina Faso, portant sur différentes pathologies et mobilisant des approches méthodologiques variées. Il a servi de base à l'extraction des connaissances et à l'enrichissement de l'ontologie. Le modèle conceptuel adapté a guidé l'extraction selon les concepts et les relations définis.

II.1.2 Ontologies candidates

Nous avons retenu cinq ontologies candidates pour l'étude comparative. Le chapitre I, aux sections I.4.1 et I.4.1, les présente. Parmi les ontologies du tableau I.1, nous avons retenu celles qui portent sur la médecine traditionnelle africaine, ainsi que FLOPO et PO comme référence pour la description botanique des plantes. Nous avons écarté celles dont le domaine s'éloigne des plantes médicinales (DrOn, FOODON, SNOMED CT, ontoFRACTURECARE), le modèle d'Angole et al., centré sur l'intégration avec la médecine moderne, ainsi que l'OTM, qui n'est pas spécifique à l'Afrique. Elles couvrent différents domaines, notamment la botanique, la médecine traditionnelle, la pharmacologie et l'ethnomédecine. Le tableau II.1 en présente les caractéristiques.

Nous les avons comparées à l'aide de la grille de critères présentée en phase 2a (section II.2.2). Nous avons sélectionné l'ontologie la plus adaptée à notre contexte afin de fixer le modèle conceptuel qui a guidé l'extraction.

TABLE II.1 – Ontologies candidates pour la comparaison

N°	Ontologie	Domaine	Zone géographique	Format	Source d'accès
1	WATRIMed	Médecine traditionnelle	Afrique de l'Ouest	OWL, graphe de connais-sances	IOS Press (2 articles)
2	ontoMEDTRAD	Médecine traditionnelle	Afrique de l'Ouest	OWL + iconique	Thèse A. Kouamé (UGB)
3	ATHMed	Médecine traditionnelle	Afrique (Ghana)	Cadre conceptuel	Frontiers in AI
4	Deep Ontologies	Médecine traditionnelle	Afrique	OWL (Protégé)	Intelligent Information Management
5	FLOPO, PO	Botanique	International	OWL	OBO Foundry

Chacune présente des acquis et des lacunes. Les ontologies botaniques (FLOPO, PO) décrivent bien la plante mais ne traitent pas des usages médicinaux. Les ontologies pharmaceutiques (DrOn) se resserrent sur les médicaments modernes. L'OTM, prometteuse, reste sans ancrage africain. Les initiatives africaines (WATRIMed, ontoMEDTRAD, ATHMed) s'intéressent en revanche à la médecine traditionnelle du terrain, avec ses dimensions culturelles et ses recettes multi-plantes, même si ATHMed en reste, elle, au stade d'un cadre proposé. La phase 2a en livre la comparaison détaillée.

II.1.3 Outils et environnement technique

Les outils techniques occupent une place importante dans notre démarche. Nous décrivons les phases concernées et les raisons de leur choix.

La figure II.2 résume l'environnement d'expérimentation, en précisant où chaque composant est exécuté et comment ils communiquent.

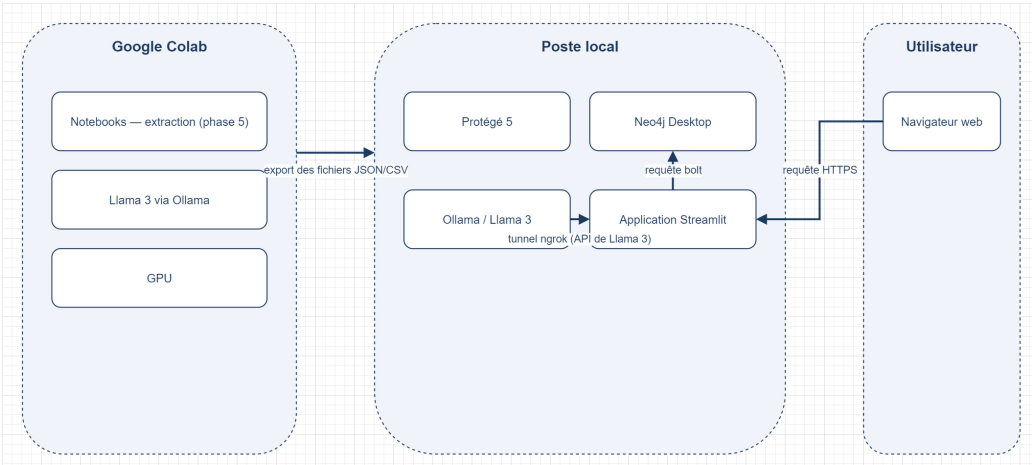


FIGURE II.2 – Dispositif technique d'expérimentation

Modèles de langage

Nous avons utilisé des modèles distincts selon l'étape. Pour l'extraction des connaissances (phase 3b), nous avons d'abord utilisé **gpt-6-luna** d'OpenAI, accessible par l'environnement OpenWork, puis

retenu une seconde extraction réalisée avec **Claude Opus 5.5** d'Anthropic, accessible par Claude Code. Pour la génération des réponses du système RAG (phase 5), nous avons utilisé **Llama 3 8B** [32], un modèle ouvert. Gemini (*gemini-3.5-flash-lite*) nous a servi de point de comparaison lors de l'évaluation.

Le tableau II.2 présente les modes d'accès à ces modèles.

TABLE II.2 – Modèles de langage et modes d'accès

Usage	**Modèle**	**Mode d'accès**
Première extraction (phase 3b)	gpt-6-luna	OpenWork
Extraction retenue (phase 3b)	Claude Opus 5.5	Claude Code
Génération RAG (phase 5)	Llama 3 8B	Ollama sur Google Colab, API exposée par ngrok
Comparaison (phase 6)	gemini-3.5-flash-lite	API de Google

Nous avons retenu Llama 3 pour la génération parce qu'il s'agit d'un modèle ouvert que nous pouvons exécuter sur une instance que nous contrôlons. La version 8B tient dans la mémoire d'un GPU accessible gratuitement sur Colab. Ollama sert le modèle et ngrok expose son API à l'application web, qui reste sur le poste local.

Plateforme d'exécution : Google Colab

Nous avons exécuté Llama 3 8B sur **Google Colab**, une plateforme de notebooks donnant accès à des GPU adaptés à l'inférence.

Phases d'utilisation : phases 5 et 6 pour la génération des réponses et l'évaluation du système RAG.

Cette plateforme nous a donné accès à un GPU sans nécessiter l'acquisition d'une infrastructure locale. La session reste cependant temporaire et l'adresse exposée par ngrok change à chaque lancement, ce qui convient à un prototype mais pas à un service pérenne.

Base de connaissances : Neo4j Desktop

Nous avons utilisé **Neo4j Desktop**, la version locale de Neo4j, pour créer, gérer et interroger la base de connaissances orientée graphe.

Phase d'utilisation : phase 4 pour la construction et l'interrogation de la base.

Le tableau II.3 présente les caractéristiques de Neo4j Desktop.

TABLE II.3 – Caractéristiques de Neo4j Desktop

Caractéristique	**Valeur**
Type	Base de données orientée graphe
Langage de requête	Cypher
Version	Desktop (locale)
Import réalisé	Fichier Turtle lu par un programme Python (`rdflib`)
Interface	Neo4j Browser, Bloom

Nous avons choisi Neo4j pour représenter les relations entre les plantes, les usages, les propriétés et les sources, interroger le graphe avec Cypher et assurer la traçabilité des connaissances. La base permet également d'ajouter des connaissances et de visualiser les liens entre les entités.

Orchestration RAG : LangChain

Nous avons utilisé **LangChain** pour définir les consignes et appeler les modèles de langage de façon uniforme. La recherche dans Neo4j passe par le pilote officiel et par les requêtes Cypher que le modèle génère et que nous validons.

Phase d'utilisation : phase 5 pour l'accès aux connaissances et le développement web.

Le tableau II.4 présente les composants LangChain utilisés.

TABLE II.4 – Composants LangChain utilisés

Composant	**Rôle**
PromptTemplate	Préparation des consignes de génération
ChatOpenAI	Appel de Llama 3 par l'API d'Ollama, compatible avec celle d'OpenAI
ChatGoogleGenerativeAI	Appel de Gemini pour la comparaison

Nous avons retenu LangChain parce qu'il permet de changer de modèle sans modifier le reste du système. Nous avons écrit notre propre chaîne de génération de Cypher, afin de contrôler chaque requête avant son exécution : le chapitre III justifie ce choix [30].

Interface web : Streamlit

Nous avons développé l'application web avec **Streamlit**, un framework Python qui permet de créer des applications web interactives.

Phase d'utilisation : phase 5 pour le développement de l'application web.

L'application propose un chatbot en langage naturel, des recherches par plante ou par pathologie, des fiches descriptives et l'affichage des sources et des niveaux de preuve. Nous avons également prévu une fonction de visualisation du graphe de connaissances.

Nous avons retenu Streamlit pour sa simplicité d'utilisation, sa gestion des sessions, son intégration avec LangChain et la rapidité de développement qu'il permet. Il facilite aussi le déploiement de l'application.

Bibliothèques Python

Nous avons mobilisé plusieurs bibliothèques Python au cours des phases 4 et 5. Le tableau II.5 en présente la liste et le rôle.

TABLE II.5 – Bibliothèques Python utilisées

Bibliothèque	**Version**	**Rôle**
`neo4j`	5.28	Pilote de connexion à Neo4j
`langchain`, `langchain-core`	0.3	Consignes et appel des modèles
`langchain-openai`	0.3	Accès à l'API d'Ollama
`langchain-google-genai`	2.1	Accès à Gemini
`streamlit`	1.64	Interface web
`plotly`	7.1	Visualisation du graphe
`rdflib`	7.6	Lecture du fichier Turtle
`pytest`	9.1	Tests logiciels
`pyngrok`	Sur Colab	Ouverture du tunnel ngrok

Ces bibliothèques couvrent les besoins de la recherche, notamment la connexion à la base, l'orchestration du système RAG, le développement de l'interface, le chargement du modèle, la manipulation de l'ontologie et le traitement des données.

II.1.4 Tableau récapitulatif du matériel

Le tableau II.6 rassemble l'ensemble du matériel mobilisé.

TABLE II.6 – Récapitulatif du matériel

Catégorie	**Élément**	**Spécification**
Corpus	Documents scientifiques	35 rapports, articles, thèses
Ontologies	WATRIMed	OWL, Afrique de l'Ouest
	ontoMEDTRAD	OWL + iconique, Afrique de l'Ouest
	ATHMed	Cadre proposé, Ghana
	Deep Ontologies	OWL, Afrique
	FLOPO, PO	OWL, botanique
Modèles de langage	gpt-6-luna ; Claude Opus 5.5 ; Llama 3 8B	OpenWork et Claude Code (extraction) ; Ollama sur Colab et ngrok (RAG)
Plateforme	Google Colab	GPU T4
Base de connaissances	Neo4j Desktop	Orientée graphe, Cypher
Orchestration RAG	LangChain	Consignes et appel des modèles
Interface web	Streamlit	Chatbot, recherche, fiches
Bibliothèques	Python	neo4j, langchain, streamlit, rdflib, etc.

II.1.5 Tableau de correspondance Matériel - Phases

Le tableau II.7 met en regard le matériel et les phases méthodologiques, et indique à quel moment et dans quel but chaque ressource entre en jeu.

TABLE II.7 – Correspondance entre le matériel et les phases

Matériel	**Phase**	**Utilisation**
Corpus documentaire	Phases 1, 2b	Collecte et sélection des documents
Ontologies candidates	Phases 1, 2a	Collecte, comparaison et sélection
gpt-6-luna	Phase 3b	Première extraction
Claude Opus 5.5	Phase 3b	Extraction retenue
Llama 3 8B	Phases 5, 6	Génération RAG, évaluation
Google Colab	Phases 5, 6	Exécution de Llama 3 8B
Neo4j Desktop	Phase 4	Base de connaissances
LangChain	Phase 5	Orchestration RAG
Streamlit	Phase 5	Interface web
Bibliothèques Python	Phases 4, 5	Développement

II.2 Méthodologie

Nous avons organisé la démarche en six phases, représentées par la figure II.3. La phase 1 a réuni le corpus, composé des ontologies candidates et des documents scientifiques. Deux volets ont ensuite été menés en parallèle. Le volet modèle conceptuel a comparé les ontologies (phase 2a), puis adapté l'ontologie retenue (phase 3a). Le volet modèle de données a sélectionné les documents selon des critères d'inclusion (phase 2b), puis en a extrait les connaissances au moyen de modèles de langue (phase 3b). Le modèle adapté en phase 3a a fixé le schéma des fiches produites en phase 3b, de sorte que l'extraction ciblait d'emblée les notions et les relations de l'ontologie.

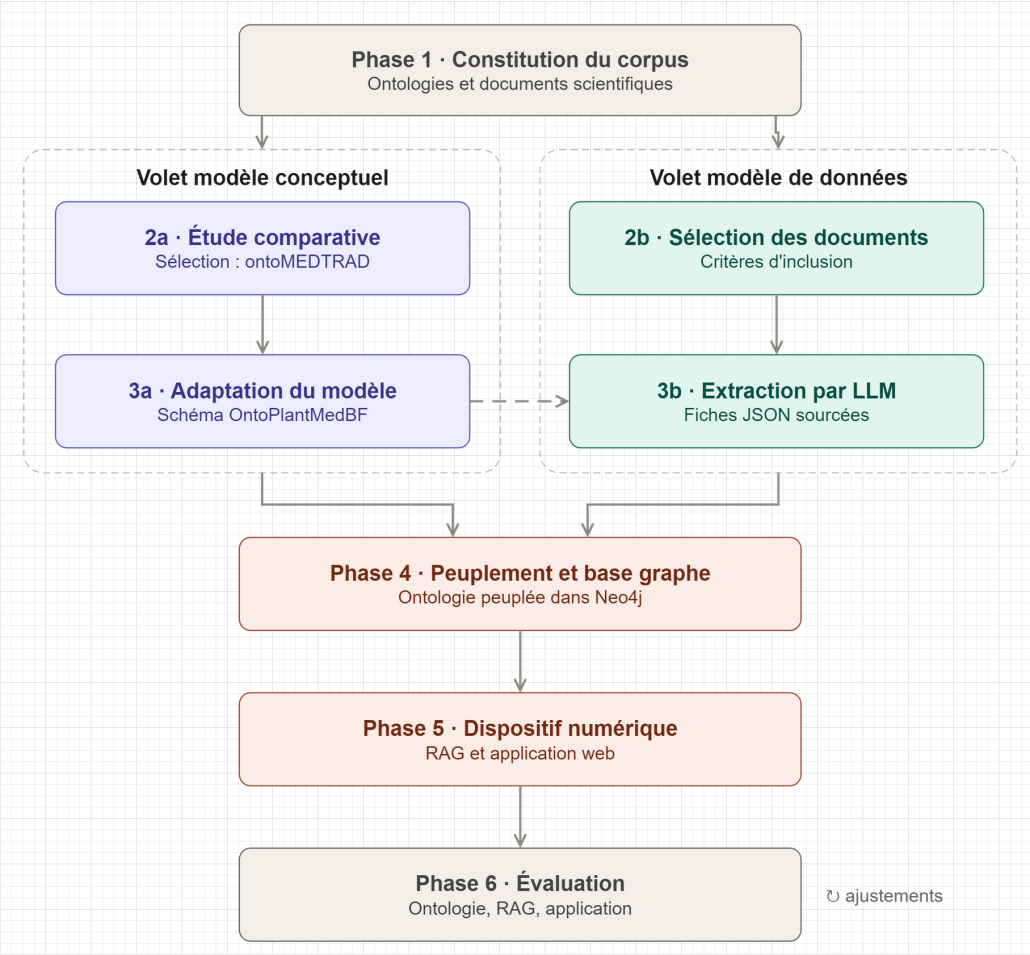


FIGURE II.3 – Démarche méthodologique détaillée

Les deux volets se rejoignent en phase 4, où les fiches extraites peuplent le modèle adapté et où l'ontologie peuplée est importée dans la base graphe. Nous avons ensuite développé le dispositif numérique, composé du système RAG et de l'application web (phase 5), puis évalué l'ensemble (phase 6). L'évaluation a conduit à des ajustements, que nous déclarons avec les résultats au chapitre IV.

II.2.1 Phase 1 : Constitution du corpus

Objectif : Réunir les ontologies candidates et les documents scientifiques sur les plantes médicinales du Burkina Faso.

Le corpus réunit deux types de ressources. Les ontologies candidates alimentent le volet modèle conceptuel ; les documents scientifiques alimentent le volet modèle de données.

Recherche des ontologies

Nous avons recherché les ontologies existantes sur les plantes médicinales dans la littérature scientifique et les bases spécialisées. Nous en avons retenu cinq comme candidates, présentées à la section II.1.2.

Recherche des documents scientifiques

Nous avons retenu les critères suivants pour guider la recherche :

— **Les plantes** : espèces végétales documentées au Burkina Faso, avec identification botanique (nom scientifique, famille, synonymes).

— **Les parties utilisées** : feuilles, racines, écorces, fruits, graines, fleurs, tiges, etc.

— **Les pathologies et usages médicinaux** : paludisme, infections respiratoires, digestives, diabète, hypertension, etc.

— **Les modes de préparation** : décoction, macération, infusion, poudre, extrait alcoolique, etc.

— **Les niveaux de preuve** : savoirs traditionnels, études in vitro, études in vivo, essais cliniques.

— **Les propriétés pharmacologiques** : antimicrobiennes, antipaludiques, anti-inflammatoires, antioxydantes, toxicité, etc.

— **La composition chimique** : alcaloïdes, flavonoïdes, tanins, saponines, huiles essentielles, etc.

Ils couvrent les principales dimensions des connaissances sur les plantes médicinales et ont permis de cibler les informations utiles à l'étude.

Nous avons recherché les documents dans Google Scholar, PubMed et ResearchGate.

Livrable : les cinq ontologies candidates et les documents scientifiques collectés.

II.2.2 Phase 2a : Étude comparative des ontologies

Objectif : Sélectionner l'ontologie la plus pertinente pour notre contexte.

Cette phase ouvre le volet modèle conceptuel. Nous avons comparé les ontologies en trois temps. Nous avons défini une grille de critères, attribué une note à chacune, puis retenu celle qui a obtenu le meilleur score. Ce choix a fixé le modèle conceptuel des étapes suivantes.

Définition de la grille de critères

Nous avons retenu huit critères adaptés à nos besoins : couverture du domaine, richesse sémantique, disponibilité, documentation, interopérabilité, adaptabilité au contexte burkinabè, traçabilité et prise en compte des savoirs locaux. Le tableau II.8 présente ces critères.

TABLE II.8 – Grille de critères de comparaison

N°	Critère	Description	Pondération
1	Couverture du domaine	Capacité à représenter plantes, usages, propriétés, maladies	Élevée (3)
2	Richesse sémantique	Nombre et qualité des classes, relations, axiomes	Élevée (3)
3	Disponibilité	Ontologie accessible : fichier téléchargeable ou structure complète publiée	Élevée (3)
4	Documentation	Qualité de la documentation et des exemples	Moyenne (2)
5	Interopérabilité	Compatibilité avec OWL, RDF, SPARQL	Moyenne (2)
6	Adaptabilité	Facilité d'adaptation au contexte burkinabè	Élevée (3)
7	Traçabilité	Capacité à associer les connaissances aux sources	Élevée (3)
8	Prise en compte des savoirs locaux	Intégration des noms vernaculaires, recettes multi-plantes	Élevée (3)

Nous avons attribué à chaque critère une pondération proportionnelle à son importance. Les critères fortement pondérés (3) étaient déterminants pour représenter le contexte burkinabè, tandis que les critères moyennement pondérés (2) autorisaient davantage de compromis. Nous avons calculé le score global en multipliant chaque note par la pondération correspondante, en additionnant les produits et en divisant cette somme par la somme des pondérations. Le résultat est rapporté sur 5.

Notation des ontologies

Nous avons noté chaque ontologie de 1 (très faible) à 5 (très élevé) pour chacun des critères. Le tableau II.9 présente les résultats.

TABLE II.9 – Notation des ontologies candidates

Ontologie	C1	C2	C3	C4	C5	C6	C7	C8	Score
WATRIMed	4	4	2	3	5	4	3	5	3.7
ontoMEDTRAD	5	5	5	4	4	5	4	5	4.7
ATHMed	4	4	3	3	4	3	2	3	3.2
Deep Ontologies	3	4	2	2	3	3	2	4	2.9
FLOPO / PO	2	3	5	4	5	2	1	1	2.7

Nous avons analysé les notes afin de comparer la couverture du domaine et la prise en compte des savoirs locaux par les ontologies africaines. Nous avons également examiné la disponibilité et l'interopérabilité des ontologies botaniques, ainsi que les différences entre WATRIMed et ontoMEDTRAD concernant la richesse du modèle et l'accessibilité de la documentation.

Nous avons accordé une attention particulière à la disponibilité (C3) et à la documentation (C4). Nous avons évalué les ressources effectivement accessibles. WATRIMed est décrite par deux articles de congrès, dont l'un compte deux pages, et seules ses classes supérieures et ses relations principales y sont décrites. Aucune des deux ontologies n'est téléchargeable, mais la thèse consacrée à ontoMEDTRAD fournit la liste des classes et des propriétés, les métriques ainsi que l'origine des concepts.

Sélection de l'ontologie

WATRIMed [46, 45] pourrait se distinguer par la richesse de son modèle documenté, qui compte 472 concepts et 75 propriétés, ainsi que par son alignement sur l'ontologie fondationnelle BioTopLite2. Toutefois, les deux publications n'en décrivent que les classes supérieures et les relations principales, ce qui ne suffit pas à reconstituer le modèle pour le réutiliser.

Nous avons retenu ontoMEDTRAD [28], qui a obtenu le meilleur score. Cette ontologie couvre l'Afrique de l'Ouest, représente les recettes multi-plantes, leurs ingrédients, les parties utilisées et les modes de préparation, et documente l'origine de ses concepts à partir de quinze ressources terminologiques et ontologiques. Sa thèse est accessible. Nous avons aussi pris en compte ses limites : sa validation globale reste annoncée comme perspective et son jeu de données comprend 22 plantes et 31 remèdes antipaludéens [29].

L'ontologie retenue fournit le cadre conceptuel pour extraire et organiser les connaissances. Nous l'avons adaptée au contexte burkinabè en phase 3a.

Livrable : Ontologie ontoMEDTRAD sélectionnée.

II.2.3 Phase 3a : Adaptation du modèle conceptuel

Objectif : Adapter le modèle conceptuel de l'ontologie sélectionnée au contexte burkinabè.

Cette phase clôt le volet modèle conceptuel. Nous avons examiné les concepts existants, ajouté des classes et des propriétés, modifié certaines relations et documenté les changements.

Analyse des concepts existants

Nous avons étudié la structure de l'ontologie ontoMEDTRAD telle qu'elle est décrite dans la thèse [28]. L'ontologie compte 144 concepts, 76 propriétés associatives, 16 propriétés de données, 789 individus et 2 734 axiomes. Elle est formalisée en logique de description ALCHOIQ, éditée sous Protégé 5 et vérifiée par les raisonneurs HermiT et Pellet.

Le fichier OWL de l'ontologie n'étant pas téléchargeable publiquement, nous avons reconstitué sa structure à partir de la thèse. Nous nous sommes appuyés sur les captures d'écran de Protégé (figures 5.15 à 5.20) et les tableaux récapitulatifs des concepts, propriétés et métriques (tableaux 5.5, 5.21 et 5.22). Cette reconstitution a servi de base à l'adaptation présentée au chapitre III.

Nous avons reconstitué la structure conceptuelle de l'ontologie, ses classes, propriétés et relations, mais pas ses instances d'origine. Nous n'avons pas réutilisé les 789 individus d'ontoMEDTRAD, liés au contexte et aux sources des travaux d'origine. Cette phase a produit le modèle conceptuel adapté ; le peuplement par les individus extraits de la littérature scientifique est intervenu en phase 4.

Ses concepts principaux décrivent le parcours de soin, du praticien et du patient aux symptômes, aux maladies, aux ressources médicinales, à l'examen clinique, aux recettes, aux ingrédients, aux parties utilisées, aux préparations et aux remèdes. L'ontologie distingue cinq types de plantes et neuf parties utilisées. Elle comprend aussi une classe pour les références scientifiques associées aux ressources, aux recettes et aux remèdes. Les concepts secondaires couvrent les contre-indications, les propriétés thérapeutiques, la toxicité, l'étiologie et la classification des maladies selon la CIM-10. Les relations de base expriment la subsomption et la relation partie-tout. Soixante-seize propriétés associatives complètent le modèle, dont la hiérarchie *aPourForme*, utilisée pour l'iconisation des plantes.

Nous avons ensuite évalué ce modèle au regard du contexte burkinabè. Il couvre les concepts de base et les raisonneurs testés n'y ont signalé aucune incohérence, mais il nécessitait des adaptations pour représenter les noms vernaculaires en langues locales, les maladies spécifiques, les niveaux de preuve, les dosages et la traçabilité détaillée des sources. Sa validation globale reste une perspective, et son jeu de données se limite à 22 plantes et 31 remèdes antipaludéens.

Ajout de classes

La comparaison des fichiers du modèle conceptuel adapté et du schéma conservé dénombre 40 classes ajoutées. Le modèle adapté déclare également 25 propriétés objet au total, dont 20 absentes du schéma conservé, et 20 propriétés de données, dont 15 ajoutées. Les classes ajoutées couvrent notamment les noms vernaculaires, les usages thérapeutiques, les niveaux de preuve, les sources, les préparations, des parties végétales complémentaires, les composés chimiques, les activités pharmacologiques et les effets toxicologiques. Ces ajouts définissent le modèle conceptuel ; les individus et données extraits sont intégrés lors de la phase 4.

Ces ajouts structurent des connaissances locales et scientifiques à différents niveaux. Ils ne préchargent pas les valeurs, comme les noms, pathologies, régions ou composés ; celles-ci proviennent des sources du corpus et sont enregistrées dans la base avec leur provenance.

Ajout de propriétés

Nous avons ajouté des propriétés de données pour les noms locaux, le niveau de preuve, le type d'étude, les références, le dosage et la toxicité, en complément de propriétés textuelles pour les noms vernaculaires et les descriptions d'activités ou d'effets. Des propriétés objet relient également l'usage à sa maladie cible, à la partie végétale utilisée, à la préparation et à la source ; d'autres décrivent les associations avec des composés, activités pharmacologiques, risques et localités. Les noms techniques exacts sont ceux déclarés dans la version courante du fichier Turtle.

L'enrichissement ainsi obtenu saisit des informations fines (noms vernaculaires, coordonnées, niveaux de preuve, références précises) que l'ontologie d'origine ne documentait pas pour le Burkina Faso.

Modification de relations

Nous avons structuré les liens entre plante, usage, maladie, partie utilisée et préparation, puis généralisé la traçabilité documentaire. La propriété objet *estDocumenteePar* relie les ressources du graphe à une source scientifique ; des sous-propriétés spécialisées permettent de préciser si la source documente une plante, un usage, un nom vernaculaire, une activité, un composé ou un effet toxicologique. *aPourNiveauDePreuve* rattache un usage au niveau déclaré par la source. Ces liens ne signifient pas que les usages ou activités constituent des recommandations thérapeutiques ni une validation clinique.

Ces modifications assurent la traçabilité des connaissances et permettent d'exprimer des relations que le modèle d'origine, fondé sur la relation « est un » et sur la relation partie-tout, ne couvrait pas.

Documentation des adaptations

Nous avons consigné toutes les modifications dans un journal : chaque ajout est justifié, chaque choix est explicité, et les classes, propriétés et relations ajoutées, modifiées ou supprimées y sont décrites une à une.

Cette documentation n'est pas une formalité. Elle rend la démarche reproductible par un tiers et facilite les évolutions ultérieures de l'ontologie.

Lien avec le volet modèle de données

Le modèle adapté a servi de schéma aux fiches d'extraction de la phase 3b. Les champs demandés au modèle de langue correspondent aux classes et aux propriétés du modèle : plante, nom vernaculaire, usage, maladie, partie utilisée, préparation, niveau de preuve, activité, composé, effet toxicologique, localité et source. Ce lien rend les fiches directement transformables en individus de l'ontologie lors de la phase 4.

Livrable : Le modèle conceptuel adapté de l'ontologie, schéma d'OntoPlantMedBF, sans les données instanciées.

II.2.4 Phase 2b : Sélection des documents

Objectif : Retenir, parmi les documents collectés, ceux qui satisfont aux critères d'inclusion.

Cette phase ouvre le volet modèle de données. Nous avons appliqué aux documents collectés en phase 1 des critères d'inclusion et d'exclusion visant à assurer la pertinence, la qualité et la cohérence des sources retenues.

Critères d'inclusion

Nous avons sélectionné les documents selon les critères suivants :

— **Pertinence** : le document traite des plantes médicinales du Burkina Faso.

— **Identification de la plante** : le nom scientifique est précisé.

— **Disponibilité d'une référence scientifique** : le document est publié dans une revue à comité de lecture, une thèse, un mémoire ou un rapport de recherche.

— **Fiabilité** : les sources sont vérifiables et citées.

— **Actualité** : les documents récents sont privilégiés, sans exclure les travaux fondateurs.

Application des critères et organisation du corpus

Nous avons inclus les documents portant sur les plantes médicinales du Burkina Faso, précisant le nom scientifique des plantes et publiés ou validés par une institution scientifique avec des sources vérifiables. Nous avons écarté les documents non scientifiques, ceux sans identification botanique et les documents anciens sans valeur de référence. Nous avons classé les documents par type, plante, pathologie et région et les avons enregistrés dans un répertoire structuré. Le corpus comprend 35 documents scientifiques.

Ces critères nous ont permis d'écarter les documents non scientifiques ou non pertinents et de constituer un corpus cohérent pour l'étude.

Livrable : un corpus de 35 documents scientifiques.

II.2.5 Phase 3b : Extraction des connaissances par modèle de langue

Objectif : Extraire des documents retenus des fiches structurées et sourcées, selon le schéma du modèle adapté.

Cette phase clôt le volet modèle de données. À partir des documents retenus en phase 2b et du schéma défini en phase 3a, nous avons conçu les consignes d'extraction, procédé à l'extraction assistée par modèle de langue, puis contrôlé les données obtenues.

Conception des prompts d'extraction

Nos consignes d'extraction ciblaient les noms scientifiques et vernaculaires, la famille botanique, les parties utilisées, les usages, les préparations, les activités pharmacologiques, le niveau de preuve et la source. Le chapitre III présente un exemple de consigne, avec le format JSON et les champs demandés.

Nous avons employé une même consigne pour les documents traités. Les champs absents reçoivent la valeur `null` ou une liste vide, et aucune valeur n'est complétée par déduction.

Exécution de l'extraction

Nous avons soumis les documents à gpt-6-luna dans l'environnement OpenWork, un par un, et enregistré les résultats en JSON. L'extraction a porté sur dix des 35 documents du corpus, principalement des enquêtes ethnobotaniques ; les 25 autres n'ont pas été extraits. Cette première extraction restant incomplète sur les grands tableaux, nous avons réalisé une seconde extraction des mêmes documents avec Claude Opus 5.5 dans Claude Code, selon le même schéma JSON, les 5 et 6 novembre 2026. Les tableaux y ont été relus en image, et le document numérisé de Ky et al. a en outre été comparé à une reconnaissance optique de caractères (Tesseract). Nous avons vérifié manuellement cette seconde extraction, puis l'avons retenue pour peupler l'ontologie.

Contrôle de la qualité des extractions

Nous avons repris le niveau de preuve indiqué par la source lorsqu'il était explicite, qu'il s'agisse d'un savoir traditionnel, d'une étude *in vitro*, d'une étude *in vivo* ou d'un essai clinique. Nous n'avons pas évalué indépendamment la solidité des faits et avons laissé le champ vide lorsque la source ne précisait pas ce niveau. Dans les dix documents extraits, tous les usages sont des usages traditionnels rapportés : aucun champ n'est resté vide, et le graphe ne compte que deux niveaux, l'usage rapporté par enquête et l'usage traditionnel rapporté (chapitre III). Un expert externe n'a pas relu les extractions. Nous avons contrôlé leur structure, puis comparé une partie des faits aux documents d'origine à la phase 6.

Livrable : dix fiches JSON sourcées, une par document extrait.

II.2.6 Phase 4 : Peuplement de l'ontologie et construction de la base graphe

Objectif : Peupler le modèle adapté avec les données extraites, puis importer et exploiter dans Neo4j l'ontologie réajustée *OntoPlantMedBF*.

Les deux volets se rejoignent dans cette phase : les fiches JSON de la phase 3b deviennent des individus du modèle conceptuel adapté en phase 3a. Nous avons ensuite importé dans Neo4j l'ontologie réajustée *OntoPlantMedBF* et ses données, en les représentant sous forme de nœuds, propriétés et relations du graphe. Nous avons vérifié la correspondance avec le modèle ontologique et testé les requêtes de la base.

Structuration des données

Nous avons organisé les données selon le modèle de l'ontologie, par type de connaissance (sources, plantes, noms vernaculaires, usages, préparations, maladies, activités, composés, toxicologie et localités), puis un programme les a transformées en individus au format Turtle. Lors de ce peuplement, nous avons complété le schéma pour représenter des informations rencontrées dans les sources, notamment les modes d'administration et de préparation, la posologie et certaines parties de plante ; le chapitre III en donne le détail.

Peuplement de l'ontologie

Le fichier OntoPlantMedBF-peuplee.ttl contient des individus extraits de dix documents scientifiques, en plus du schéma adapté. Ce fichier constitue l'ontologie enrichie importée dans Neo4j.

Import et ajustement du modèle dans le graphe

Nous avons importé les classes et propriétés d'OntoPlantMedBF dans Neo4j sous forme de labels, propriétés et relations. Les principaux nœuds représentent les plantes, maladies, usages, parties, préparations, sources, composés chimiques et régions. Les relations du graphe reprennent les liens du

modèle, avec des noms adaptés aux conventions Neo4j, et les propriétés conservent notamment les noms, niveaux de preuve, DOI et coordonnées géographiques.

Nous avons ainsi importé dans le graphe la structure réajustée d'OntoPlantMedBF et ses données. Les entités sont représentées par des nœuds, leurs liens par des relations et leurs caractéristiques par des propriétés, conformément au modèle ontologique.

Import des données

Nous avons chargé les données préparées, créé ou rapproché les nœuds et relations au moyen de requêtes Cypher, puis vérifié l'intégrité et la cohérence de l'import avec le modèle ontologique.

Après l'import, nous avons contrôlé que les données, les relations et les propriétés avaient été correctement reprises.

Requêtes de test

Nous avons testé quatre familles de requêtes : les requêtes simples sur les plantes associées à une maladie, les requêtes complexes sur les recettes multi-plantes, les requêtes de traçabilité et les requêtes spatiales par région.

Ces vérifications nous ont permis de contrôler le fonctionnement de la base et les résultats renvoyés par les requêtes.

Livrable : OntoPlantMedBF, ontologie enrichie avec les données extraites et leurs sources, et une base Neo4j peuplée et interrogeable, complémentaire d'OntoPlantMedBF.

II.2.7 Phase 5 : Dispositif numérique : système RAG et application web

Objectif : Développer le système d'accès intelligent et l'interface utilisateur.

Nous avons mis en place le système RAG en définissant son architecture, en construisant la chaîne de traitement et en intégrant ses composants.

Architecture du système

L'architecture relie l'utilisateur à Streamlit, LangChain, Neo4j et Llama 3 jusqu'à la réponse. Elle associe la recherche dans la base à la génération par le modèle de langue et conserve le lien entre les informations et leurs sources. Le chapitre III décrit la chaîne de traitement, de l'interprétation de la question à l'affichage des références.

Intégration des composants

Nous avons connecté l'application à Neo4j et au modèle de langue, puis configuré les consignes de génération des réponses. Cette intégration a réuni les composants du système RAG.

Développement de l'application web

Nous avons conçu l'application autour d'une page d'accueil avec chatbot, d'une recherche par plante, d'une recherche par pathologie et de fiches descriptives. Nous y avons intégré le système RAG et la gestion de l'historique. L'interface permet d'interroger la base en langage naturel et de recevoir des réponses reliées à leurs sources. Le chapitre III en décrit la conception et les composants.

Tests et validation

Nous avons mené des tests fonctionnels pour vérifier le fonctionnement de l'application. Des tests utilisateurs étaient prévus pour examiner sa facilité d'utilisation et la pertinence des réponses ; ils n'ont pas été menés.

Livrable : Un système RAG fonctionnel et une application web fonctionnelle.

II.2.8 Phase 6 : Évaluation

Objectif : Évaluer la qualité de l'ontologie, du système RAG et de l'application web.
Nous avons évalué trois composantes : l'ontologie, le système RAG et l'application web.

Évaluation de l'ontologie

Nous avons évalué l'ontologie selon les quatre critères présentés dans le tableau II.10.

TABLE II.10 – Critères d'évaluation de l'ontologie

Critère	Description	Méthode
Couverture	Capacité à représenter les connaissances du corpus	Vérification manuelle
Cohérence	Absence de contradictions	Requêtes de test
Traçabilité	Association des connaissances aux sources	Vérification des relations
Extensibilité	Facilité d'ajout de nouvelles connaissances	Test d'ajout

Évaluation du système RAG

Nous avons évalué le système RAG selon les quatre critères présentés dans le tableau II.11.

TABLE II.11 – Critères d'évaluation du système RAG

Critère	Description	Métrique
Pertinence	Les valeurs citées figurent parmi les valeurs attendues	Précision
Fidélité	Les valeurs attendues, tirées du graphe, sont restituées	Rappel
Exactitude	Synthèse de la précision et du rappel	F1-score
Traçabilité	Les sources sont affichées	Taux de couverture

Nous avons constitué un jeu de 50 questions de référence portant sur les plantes, les usages et leurs sources, puis comparé les réponses du système aux réponses attendues.

Évaluation de l'application web

Nous avons évalué l'application web selon les quatre critères présentés dans le tableau II.12.

TABLE II.12 – Critères d'évaluation de l'application web

Critère	Description	Méthode
Facilité d'utilisation	L'interface est intuitive	Questionnaire
Compréhension	Les réponses sont claires	Questionnaire
Utilité	L'application répond aux besoins	Questionnaire
Performance	Temps de réponse	Mesure

Nous avions prévu de soumettre ce questionnaire à des étudiants, des chercheurs et des tradipraticiens. Cette campagne n'a pas été menée ; seule la performance a été mesurée (chapitre IV).

Ajustements

L'évaluation n'est pas seulement une étape finale : ses résultats peuvent conduire à revenir sur une phase antérieure. Lorsqu'un ajustement a été fait après la lecture des résultats, nous l'avons déclaré et avons présenté les résultats obtenus avant et après cet ajustement. Le chapitre IV présente ces ajustements avec les résultats.

Livrable : Rapport d'évaluation et de validation.

II.3 Synthèse et transition

II.3.1 Tableau de correspondance Phases - Livrables

Le tableau II.13 récapitule les objectifs et les livrables des six phases et des deux volets.

TABLE II.13 – Correspondance entre les phases, les objectifs et les livrables

Phase	Objectif	Livrable
Phase 1	Réunir les ontologies candidates et les documents	Cinq ontologies candidates, documents collectés
Phase 2a	Sélectionner l'ontologie la plus pertinente	Ontologie ontoMEDTRAD sélectionnée
Phase 3a	Adapter le modèle conceptuel de l'ontologie	Modèle conceptuel adapté (schéma OntoPlantMedBF)
Phase 2b	Sélectionner les documents selon les critères d'inclusion	Corpus de 35 documents
Phase 3b	Extraire les connaissances par modèle de langue	Fiches JSON sourcées
Phase 4	Peupler l'ontologie et l'importer dans la base graphe	OntoPlantMedBF peuplée, intégrée à Neo4j, base interrogeable
Phase 5	Développer le système RAG et l'application web	Système RAG et application web
Phase 6	Évaluer la qualité du système	Rapport d'évaluation

Conclusion du chapitre

Ce chapitre a exposé le matériel et la méthodologie de notre recherche. Le matériel réunit un corpus de 35 documents scientifiques, cinq ontologies candidates et un environnement technique bâti sur gpt-6-luna puis Claude Opus 5.5 pour l'extraction, Llama 3 8B sur Google Colab pour le RAG, Neo4j Desktop, LangChain et Streamlit.

Nous avons suivi six phases : constitution du corpus, puis deux volets menés en parallèle, l'un sur le modèle conceptuel (comparaison et adaptation de l'ontologie), l'autre sur le modèle de données (sélection des documents et extraction des connaissances), peuplement de l'ontologie et construction de la base graphe, développement du dispositif numérique, puis évaluation. Nous avons décrit les actions menées et les livrables associés.

Le modèle adapté a fourni le schéma des fiches d'extraction, ce qui a assuré la cohérence entre le modèle et les données extraites ; il a ensuite été complété lors du peuplement, à partir des informations rencontrées dans les sources.

Nous signalons deux limites. Les niveaux de preuve associés aux connaissances proviennent des sources et n'ont pas fait l'objet d'une évaluation indépendante. De plus, un expert externe n'a pas validé les extractions. Ces limites sont à prendre en compte dans les travaux ultérieurs. Nous avons néanmoins conservé le lien entre chaque information et sa source.

Le chapitre IV présente les résultats de l'évaluation menée en phase 6.

Le chapitre suivant présente la conception et le développement du système, notamment l'ontologie adaptée, la base de connaissances, le système RAG et l'application web.

Chapitre III

Conception et développement du système

Introduction du chapitre

Dans les chapitres précédents, nous avons présenté le cadre théorique et la démarche méthodologique. Ce chapitre décrit le système conçu pour donner accès aux connaissances scientifiques sur les plantes médicinales du Burkina Faso. Il présente OntoPlantMedBF, l'ontologie adaptée et peuplée, la base de connaissances orientée graphe, l'extraction des données, leur interrogation par le système RAG et l'application web.

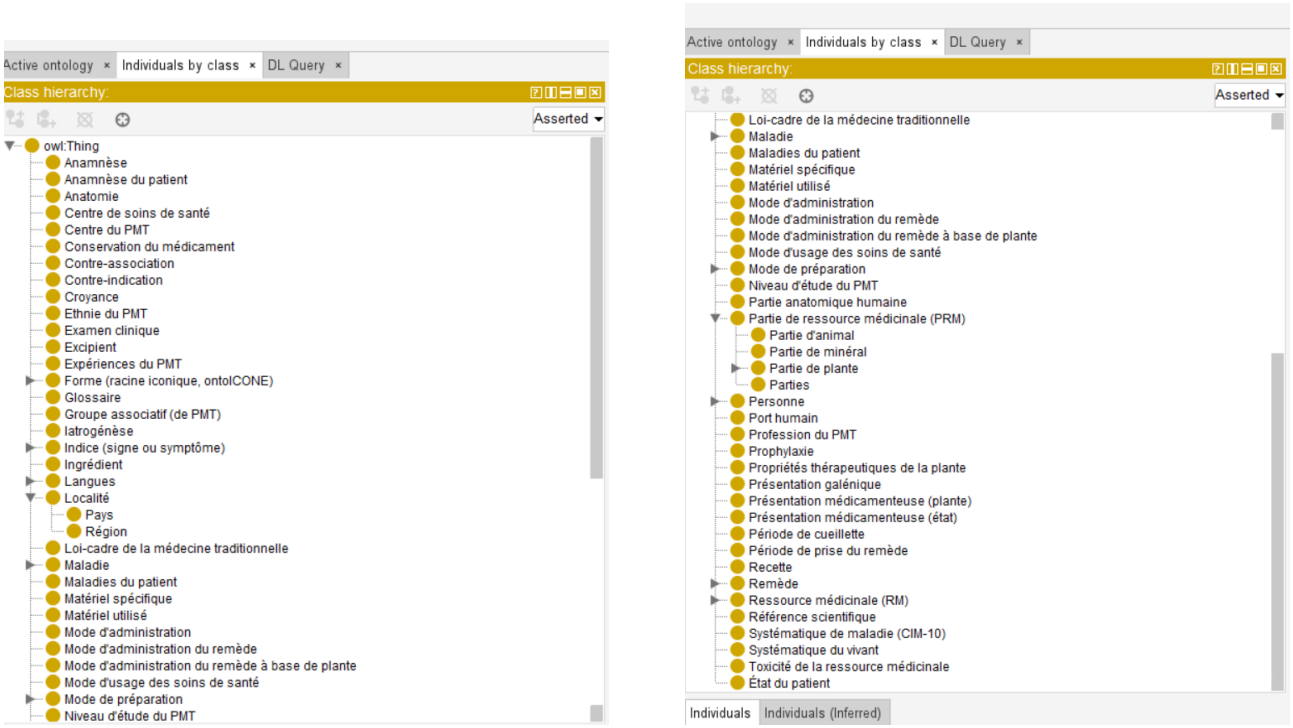
III.1 Ontologie adaptée et enrichie

En phase 2a, nous avons sélectionné l'ontologie *ontoMEDTRAD* [28] (section II.2.2 du chapitre II) comme point de départ. Ce modèle constituait une base solide, mais incomplète pour le contexte burkinabè : il ne représentait pas les noms vernaculaires locaux, les niveaux de preuve ni la traçabilité détaillée des sources. En phase 3a, nous en avons adapté le modèle conceptuel. En phase 4, nous avons enrichi l'ontologie avec les données et individus extraits de dix documents scientifiques en phase 3b. Enfin, au cours de la même phase, nous avons importé dans Neo4j l'ontologie réajustée *OntoPlantMedBF*.

III.1.1 Vue d'ensemble du modèle

L'ontologie d'origine comptait 144 concepts, 76 propriétés associatives, 16 propriétés de données, 789 individus et 2 734 axiomes. Elle était formalisée en logique de description *ALCHOIQ*, éditée sous Protégé 5 et vérifiée avec les raisonneurs HermiT et Pellet, qui n'y avaient signalé aucune incohérence. Nous en avons retenu une partie du schéma et l'avons étendue pour produire un modèle conceptuel adapté aux besoins de l'étude (phase 3a). Ce modèle a ensuite été enrichi par des données et individus extraits de dix documents scientifiques (phases 3b et 4), avant l'import et l'ajustement de cette représentation dans Neo4j (phase 4).

La figure III.1 présente la structure de l'ontologie initiale, reconstituée à partir de la thèse.



(a) Partie supérieure de la hiérarchie

(b) Partie inférieure de la hiérarchie

FIGURE III.1 – L'ontologie initiale ontoMEDTRAD reconstituée sous Protégé 5 (arbre des classes)

Nous avons retenu d'ontoMEDTRAD les concepts relatifs aux plantes médicinales, à leurs parties, aux modes de préparation, aux maladies, à la localisation et aux références scientifiques. Nous les avons complétés par les classes et relations nécessaires au périmètre de notre étude, notamment les usages thérapeutiques, les noms vernaculaires, les niveaux de preuve, la traçabilité documentaire, la phytochimie et la toxicologie. Nous avons écarté les modules hors périmètre, dont la couche d'iconisation ontoICONE et les concepts relatifs aux praticiens, aux patients, à l'examen clinique et à l'anamnèse. L'iconisation étant un choix de représentation visuelle, son retrait ne remet pas en cause la réutilisation du modèle conceptuel. Le tableau III.1 détaille ces choix.

Nous avons réutilisé la structure conceptuelle, mais pas les 789 individus d'ontoMEDTRAD, associés au contexte et aux sources des travaux d'origine. En phase 3a, nous avons défini le modèle conceptuel adapté et ses nouveaux éléments de schéma. En phase 4, nous avons enrichi l'ontologie avec les individus extraits de dix documents scientifiques en phase 3b et leurs liens aux sources, puis nous avons importé dans Neo4j l'ontologie réajustée OntoPlantMedBF.

TABLE III.1 – Concepts retenus et écartés lors de l'adaptation

Concepts retenus	**Concepts écartés**	**Justification**
Plante, types et parties de plante	Iconisation (ontoICONE : Forme, Silhouette, Couleur. . .)	Représentation visuelle des plantes, hors du périmètre du système
Maladie (catégories CIM-10)	Praticiens (PMT, professions, expériences)	Gestion de la pratique des tradipraticiens, non utilisée
Mode de préparation	Patient, état du patient, anamnèse, examen clinique	Suivi clinique des patients, hors du périmètre
Références scientifiques	Indices (signes, symptômes)	Diagnostic clinique, non exploité
Localité, Pays	Glossaire, croyances, loi-cadre	Dimensions culturelles et réglementaires, non exploitées
Noms vernaculaires en langues locales	Langues (LangueLocales, LangueOfficielle)	Dimension linguistique reprise par les noms vernaculaires

Nous n'avons pas repris tels quels les concepts de recette, d'ingrédient et de remède d'ontoMED-TRAD. Nous avons retenu les classes *UsageTherapeutique* et *Preparation* pour représenter les besoins correspondants sous une forme adaptée. Nous n'avons pas conservé la classe générale *Langues* comme axe autonome. Nous avons représenté la langue associée à un nom vernaculaire au moyen des propriétés de nom local et de code de langue. Ces concepts et relations structurent OntoPlantMedBF, dont la version peuplée contient les individus documentés dans les sources.

La figure III.2 présente le modèle réduit aux concepts retenus, importé dans Protégé 5. Cette étape intermédiaire a servi de base à la construction d'OntoPlantMedBF.

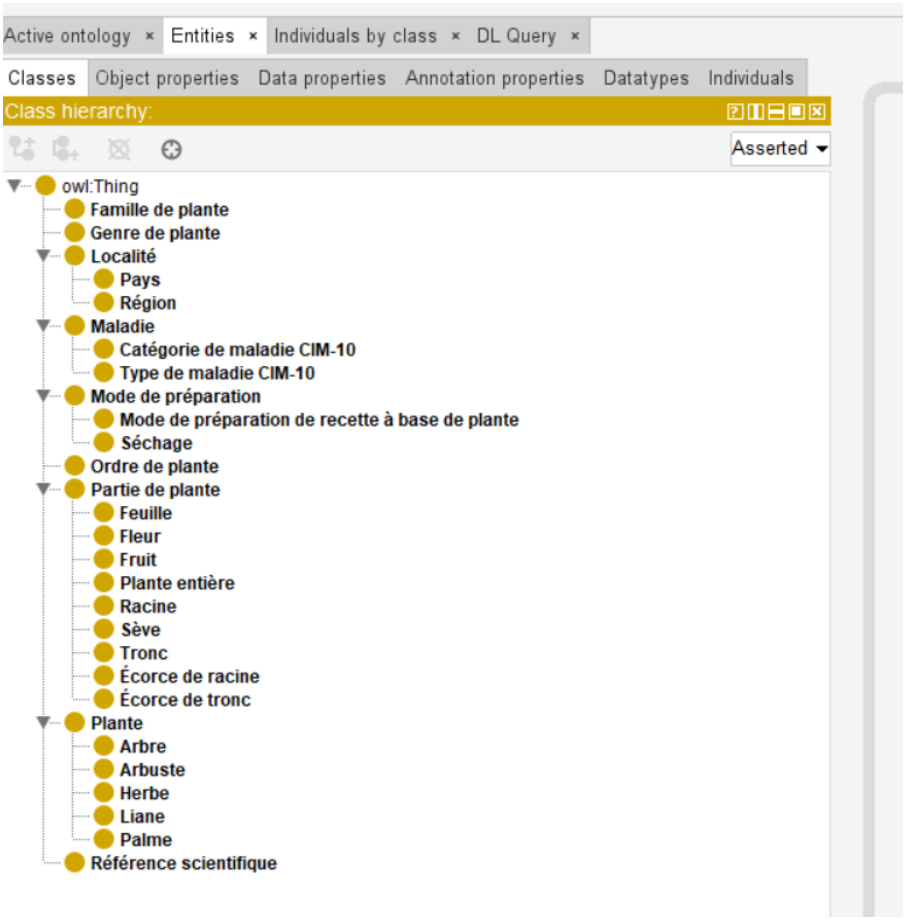


FIGURE III.2 – Concepts d'ontoMEDTRAD conservés comme base d'OntoPlantMedBF

Le tableau III.2 compare les métriques structurelles de l'ontologie d'origine à celles du modèle conceptuel adapté en phase 3a et de la version peuplée, dont le schéma a été complété lors de la phase 4 par des modes d'administration et de préparation, des propriétés de posologie et des parties de plante.

TABLE III.2 – Statistiques de l'ontologie d'origine et du modèle conceptuel adapté

Indicateur	**Ontologie d'origine**	**Modèle adapté (phase 3a)**	**Version peuplée (v4.0)**
Concepts (classes)	144	69 (40 ajoutées)	92
Propriétés objet	76	25 (20 ajoutées)	29
Propriétés de données	16	20 (15 ajoutées)	31
Individus	789	Sans objet	6 936
Axiomes	2 734	Non relevé	62 965

Nous n'avons pas repris les 789 individus de l'ontologie d'origine dans le modèle conceptuel adapté. Le fichier `OntoPlantMedBF-peuplee.ttl` correspond à l'étape suivante : il enrichit ce modèle avec des individus extraits de dix documents scientifiques. Ces données ont ensuite été importées et ajustées dans Neo4j.

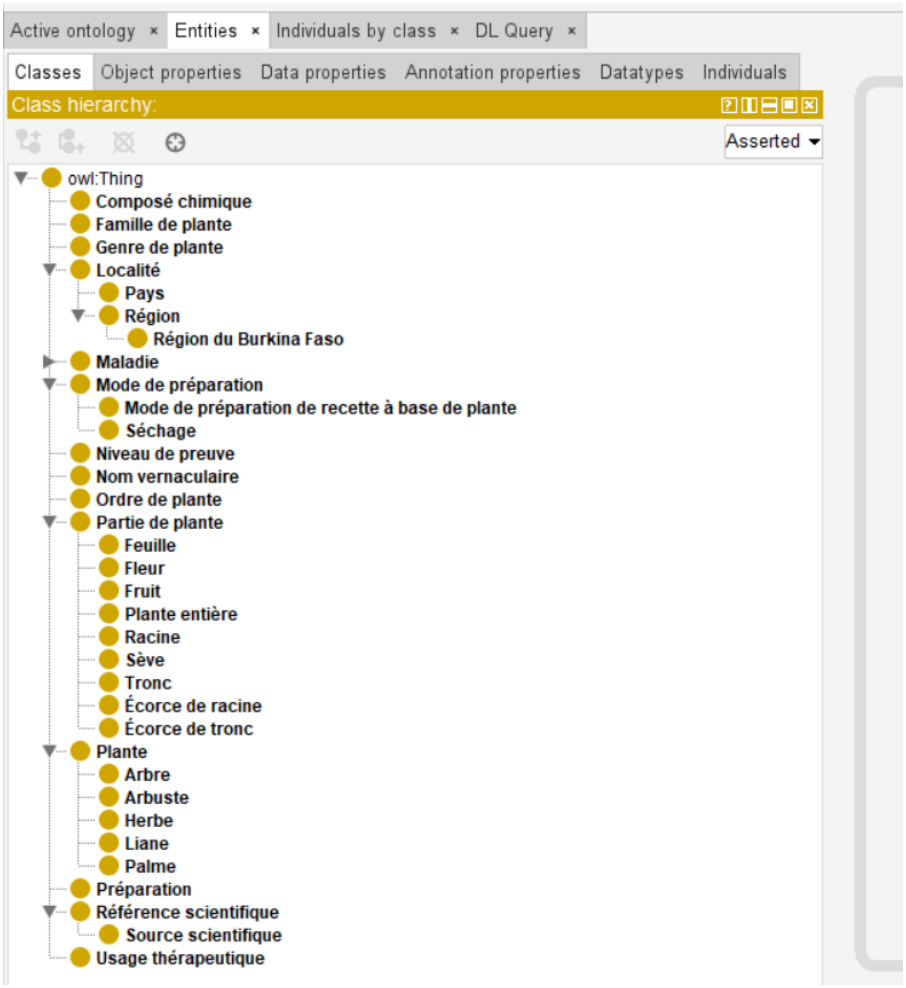


FIGURE III.3 – Modèle conceptuel adapté sous Protégé 5 (phase 3a)

III.1.2 Classes ajoutées

Nous avons construit OntoPlantMedBF en ajoutant au schéma initial des classes utiles à la représentation des connaissances ethnobotaniques et pharmacologiques étudiées. Ces ajouts complètent la sélection des concepts conservés. Le tableau III.3 en résume les principaux axes, sans lister toutes les classes.

TABLE III.3 – Classes ajoutées à l'ontologie

Ensemble de classes ajouté	**Ce qu'il représente**	**Exemples de concepts**
Maladies et indications thérapeutiques	Catégories et indications du domaine	Concepts définis dans le schéma ; données instanciées depuis les sources
Noms vernaculaires	Désignations locales et langue associée	Nom textuel et code de langue, si fournis
Localisation	Localités et régions pour structurer les données géographiques	Classes et individus issus des sources
Niveaux de preuve	Qualification telle que rapportée par la source	Traditionnel, *in vitro*, *in vivo*, clinique
Sources et traçabilité	Références et repères permettant de retrouver l'information	DOI, page, section et source
Préparations, parties et administration	Organes végétaux, procédés, formes et modes d'administration	Classes et individus selon les informations extraites
Phytochimie et sécurité	Composés, activités pharmacologiques et effets toxicologiques rapportés	Classes de composés et de risques ; faits sourcés

Nous avons inséré les classes ajoutées dans les hiérarchies existantes lorsque cela était pertinent. Les parties végétales spécialisent *PartieDePlante*, les formes galéniques et les procédés sont rattachés à *Preparation* ou à *ModeDePreparation*, et les catégories de métabolites spécialisent *ComposeChimique*. Les classes *NomVernaculaire*, *NiveauDePreuve*, *UsageTherapeutique* et *ActivitePharmacologique* structurent les désignations locales, la qualification rapportée par les sources, les usages et les résultats pharmacologiques. Le modèle de phase 3a déclare 69 classes, dont 29 conservées et 40 ajoutées ; la version peuplée en déclare 92 et inclut des individus issus des sources.

III.1.3 Propriétés ajoutées

Nous avons ajouté des propriétés de données pour décrire les noms vernaculaires, les usages, les niveaux de preuve, les activités pharmacologiques, les effets toxicologiques et les sources. La capture Protégé de la figure III.4 montre l'arborescence des propriétés de données. Elle comprend aussi des propriétés conservées de l'ontologie initiale ; le tableau III.4 présente des exemples d'ajouts.

TABLE III.4 – Propriétés ajoutées à l'ontologie

Propriété	**Rôle**
nomMoore, *nomDioula*, *nomFulfulde*	Noms vernaculaires de la plante dans les langues locales
estLocaliseeA	Localisation géographique de la plante (vers *Localite*)
nomVernaculaireTexte, *codeLangue*	Représentation structurée du nom local et de sa langue
niveauPreuve, *typeEtude*	Niveau de preuve rapporté par la source et type d'étude
source, *DOI*, page, section	Traçabilité documentaire de chaque connaissance
Dosage, toxicité	Précautions d'emploi documentées par les sources
descriptionActivite, *effetToxicologique*	Description des résultats rapportés

Les propriétés de données ajoutées sont des chaînes de caractères (*xsd :string*). Nous avons créé *nomMoore*, *nomDioula* et *nomFulfulde* pour décrire les noms locaux. Les propriétés *nomVernaculaire-Texte* et *codeLangue* associent un nom vernaculaire à sa langue. Dans la version peuplée, la langue est indiquée par *nomMoore*, *nomDioula* ou *nomFulfulde* lorsque la source la précise ; *codeLangue* n'est pas renseigné. *niveauPreuve*, *typeEtude*, *source* et *dosage* décrivent l'usage ; *doi*, *page* et *section* identifient la référence. La propriété *toxicite* consigne les précautions rapportées pour une plante. Les propriétés *descriptionActivite* et *effetToxicologique* décrivent les résultats rapportés. La localisation est décrite par *estLocaliseeA*, du domaine *Plante* à la classe *Localite*, en complément de *aCoordoneesGPS*, conservée de l'ontologie d'origine. Ces identifiants figurent dans le fichier Turtle.



FIGURE III.4 – Arborescence des propriétés de données dans Protégé

III.1.4 Relations ajoutées

Nous avons ajouté des propriétés objet pour relier les plantes à leurs usages, les usages aux maladies cibles, parties utilisées, préparations et niveaux de preuve, ainsi que les plantes aux composés, activités et effets toxicologiques rapportés. Nous avons aussi structuré la provenance documentaire autour de la relation générale *estDocumenteePar* et de ses sous-propriétés. La capture Protégé de la figure III.5 montre cette hiérarchie et comprend également des propriétés conservées. Le tableau III.5 présente les principales relations ajoutées.

TABLE III.5 – Relations ajoutées à l'ontologie

Relation	**Signification**
estDocumenteePar	Relation générique rattachant une ressource ou affirmation à sa source scientifique
estDocumenteeDans	Sous-propriété : relie une plante aux documents qui la décrivent
aPourNomVernaculaire	Rattache une plante à ses désignations locales
estLocaliseeA	Associe une plante à sa localisation géographique (*Localite*)
provientDe, *aPourNiveauDePreuve*	Rattachent un usage à sa source et au niveau déclaré
aPourPartieUtilisee, *aPourPreparation*	Relient un usage à la partie végétale et à la préparation rapportées
aPourMaladieCible, *estRapportePour*	Relient l'usage à la maladie cible et la plante à l'usage documenté
contientCompose, *presenteActivite*	Représentent les composés et activités rapportés par les sources
presenteEffetToxicologique	Relie une plante à un effet toxicologique rapporté

Nous avons associé le niveau de preuve à l'usage documenté, sans l'interpréter comme une validation indépendante de l'efficacité. La propriété textuelle *niveauPreuve* conserve la valeur rapportée, et la relation *aPourNiveauDePreuve* relie l'usage à la classe *NiveauDePreuve*. La relation générale *estDocumenteePar* rattache les ressources à une source scientifique. Nous l'avons spécialisée par *provientDe* pour les usages, *estDocumenteeDans* pour les plantes et des relations équivalentes pour les noms vernaculaires, les activités, les composés et les effets toxicologiques. Les individus n'emploient que deux niveaux de preuve, qui désignent des usages rapportés : nous les avons placés au rang 7 de l'échelle à sept niveaux, celui des savoirs traditionnels. Le modèle de phase 3a déclare 25 propriétés objet, dont 5 conservées et 20 ajoutées ; la version peuplée en déclare 29. Les relations *aPourPartieUtilisee*, *aPourPreparation* et *aPourMaladieCible* décrivent le contenu d'un usage ; *contientCompose*, *presenteActivite* et *presenteEffetToxicologique* décrivent les résultats rapportés. Ces liens structurent les informations, mais ne constituent pas une preuve d'efficacité clinique. La capture de la figure III.5 montre l'arborescence de provenance. Les domaines et portées sont déclarés dans le TTL et résumés au tableau III.5.

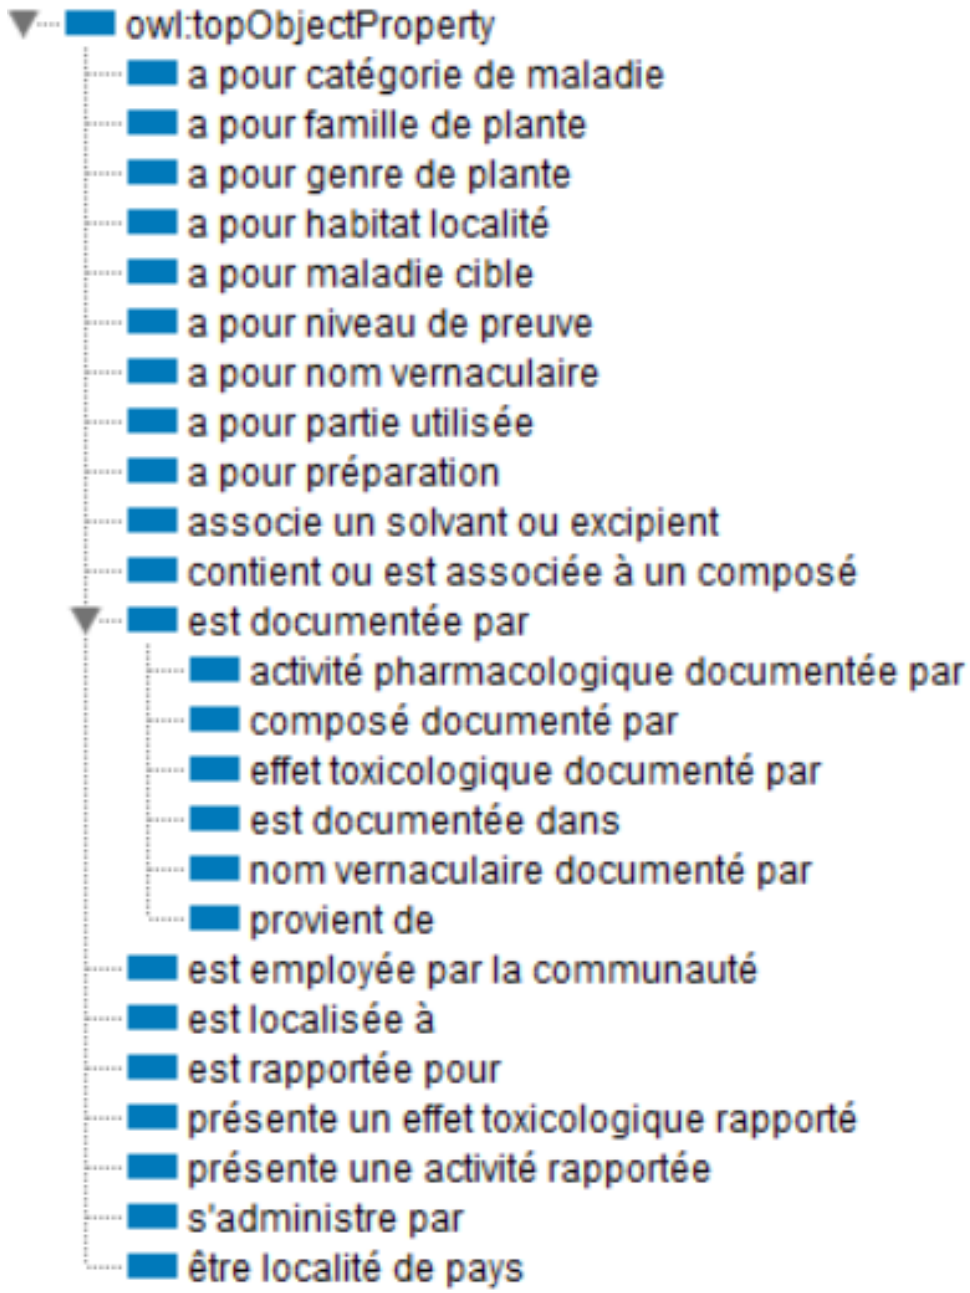


FIGURE III.5 – Arborescence des propriétés objet dans Protégé

III.2 Base de connaissances orientée graphe

Nous avons utilisé Neo4j Desktop pour stocker et interroger les connaissances extraites selon le schéma de l'ontologie. Cette base représente les liens entre plantes, usages, propriétés et sources, que nous avons parcourus au moyen de requêtes. Nous décrivons le passage du modèle ontologique au graphe, son import et son interrogation.

III.2.1 Du modèle ontologique au graphe

Nous avons importé dans Neo4j l'ontologie réajustée OntoPlantMedBF. Chaque individu devient un nœud portant sa classe et ses superclasses, et chaque propriété objet devient une relation du même nom, conformément à `OntoPlantMedBF-peuplee.ttl`. Les propriétés de données deviennent des propriétés du nœud. Nous recopions aussi quelques valeurs, comme le nom scientifique ou l'identifiant de source, sous des noms plus simples pour l'affichage. Les individus et faits extraits sont intégrés avec leurs liens vers les sources. Le tableau III.6 présente les principaux types de nœuds.

TABLE III.6 – Correspondance entre les classes de l'ontologie et les nœuds du graphe

Nœud	**Classe de l'ontologie**	**Propriétés principales**
Plante	*Plante*	Nom scientifique, famille, noms vernaculaires
Maladie	*Maladie*	Libellé repris de la source
UsageTherapeutique	*UsageTherapeutique*	Niveau de preuve rapporté, type d'étude, passage source, dosage
PartieDePlante	*PartieDePlante* et ses sous-classes	Partie utilisée
Preparation, *ModeDePreparation*	*Preparation*, *ModeDePreparation* et leurs sous-classes	Procédé, forme et ingrédients rapportés
SourceScientifique	*SourceScientifique* (classe ajoutée)	Titre, auteurs, année, DOI
ComposeChimique	*ComposeChimique* et ses sous-classes	Nom du composé
Localite	*Localite* et ses sous-classes, dont *RegionBF*	Nom et coordonnées, si rapportées

Nous avons aligné les noms des relations du graphe sur les propriétés objet d'OntoPlantMedBF, notamment *estRapportePour*, *aPourMaladieCible*, *aPourPartieUtilisee*, *aPourPreparation*, les sous-propriétés de *estDocumenteePar*, *aPourNiveauDePreuve*, *contientCompose*, *presenteActivite*, *presenteEffetToxicologique* et *estLocaliseeA*. Nous avons repris les propriétés de données du TTL pour décrire les entités. Les noms Neo4j étant les identifiants OWL, la correspondance préserve le domaine et la portée définis dans l'ontologie, que l'import contrôle pour chaque relation.

TABLE III.7 – Relations du graphe de connaissances

Relation	Sens retenu
estRapportePour	*Plante* → *UsageTherapeutique* : rattache une plante à un usage documenté
aPourMaladieCible	*UsageTherapeutique* → *Maladie* : maladie ou indication rapportée
aPourPartieUtilisee	*UsageTherapeutique* → *PartieDePlante* : partie explicitement rapportée
aPourPreparation	*UsageTherapeutique* → *Preparation* : préparation ou procédé documenté
provientDe	*UsageTherapeutique* → *SourceScientifique* : source du fait rapporté
aPourNiveauDePreuve	*UsageTherapeutique* → *NiveauDePreuve* : niveau déclaré par la source
contientCompose, *presenteActivite*, *presenteEffetToxicologique*	Liens vers les composés, activités et effets documentés

Ce mapping reprend les domaines et portées définis dans OntoPlantMedBF. Nous avons repris les noms OWL tels quels dans Neo4j afin de préserver cette équivalence lors du chargement et des requêtes.

III.2.2 Import et peuplement

Nous avons validé les extractions JSON en conservant les formulations et les références des sources, puis les avons intégrées à l'ontologie sous forme d'individus. Nous avons écarté du peuplement les usages répulsifs (25) et vétérinaires (33), qui ne sont pas des usages thérapeutiques humains, ainsi que 48 usages sans lien établi avec le Burkina Faso, issus de Karou et al. (38) et de Rouamba et al. (10). Nous avons regroupé 22 variantes d'orthographe de noms de plantes, sans fusionner les synonymes taxonomiques, ainsi que les formes équivalentes d'une même indication sous un libellé français ; les formes d'origine restent conservées. Nous avons ensuite écrit un programme d'import qui lit le fichier Turtle avec `rdflib`, contrôle les domaines et les portées, puis charge le graphe dans une transaction unique. Le chargement utilise `MERGE` sur l'URI de chaque individu : le relancer ne crée pas de doublon. Chaque fait reste relié à sa source et au passage d'origine. Les contradictions relevées dans les documents restent consignées dans les fichiers JSON, sans être tranchées. Nous n'avons ajouté au graphe aucune information absente des documents, à l'exception du rang attribué aux niveaux de preuve et de ces libellés de regroupement.

```
# Création des nœuds, regroupés par ensemble d'étiquettes
tx.run(
    f"UNWIND $lignes AS ligne "
    f"MERGE (n:{LABEL_COMMUN} {{uri: ligne.uri}}) "
    f"SET n += ligne.props, n:{etiquettes}",
    lignes=lot,
).consume()

# Création des relations, regroupées par propriété objet
tx.run(
    f"UNWIND $lignes AS ligne "
    f"MATCH (a:{LABEL_COMMUN} {{uri: ligne.de}}) "
```

```
        f"MATCH (b:{LABEL_COMMUN} {{uri: ligne.vers}}) "
        f"MERGE (a)-[:{_sur(nom)}]->(b)",
        lignes=lot,
    ).consume()
```

Après l'import, le programme relit le graphe et compare ses comptes à ceux du fichier ; tout écart est signalé comme une erreur. Les résultats sont les suivants :

Le fichier compte 62 981 triplets. Le graphe contient 6 936 nœuds et 25 321 relations, comme attendu, sans anomalie de domaine ou de portée.

— **Nœuds :** 2 822 préparations (dont 6 solvants ou excipients), 1 676 usages thérapeutiques, 722 noms vernaculaires, 554 composés chimiques, 289 plantes, 278 activités pharmacologiques, 238 maladies, 195 genres, 83 familles, 17 parties de plante, 14 localités, 13 effets toxicologiques, 11 modes d'administration, 10 modes de préparation, 10 sources, 2 ethnies et 2 niveaux de preuve.

— **Principales relations :** *aPourPartieUtilisee* (2 874), *aPourPreparation* et *estDocumenteePar* (2 816 chacune), *aPourModeDePreparation* (2 646), *estRapportePour*, *provientDe*, *aPourMaladieCible* et *aPourNiveauDePreuve* (1 676 chacune), *aPourModeAdministration* (1 471), *estLocaliseeA* (1 246), *estDocumenteeDans* (623).

La figure III.6 montre un extrait du graphe peuplé : le sous-graphe de *Cochlospermum planchonii*. La plante est reliée à trois usages, documentés par deux sources (Nadembega et al., 2026 ; Zongo et al., 2025). Chaque usage porte sa maladie cible (paludisme, ictère et affections hépatiques), la partie utilisée (le tubercule) et son niveau de preuve. La plante est aussi reliée à son nom vernaculaire en mooré et à ses localités.

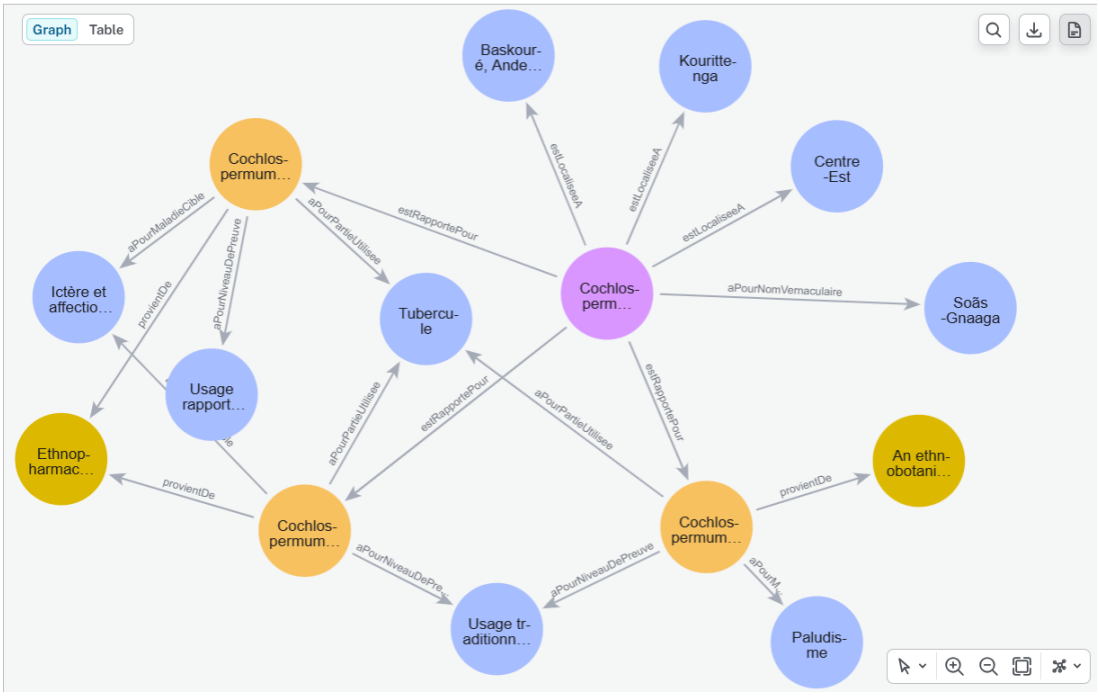


FIGURE III.6 – Extrait du graphe peuplé dans Neo4j Browser : le sous-graphe de *Cochlospermum planchonii*

III.2.3 Interrogation de la base

Nous avons défini quatre familles de requêtes en phase 4 (section II.2.6 du chapitre II) : requêtes simples, requêtes complexes, requêtes de traçabilité et requêtes spatiales. Nous en donnons des exemples ci-dessous.

```
// 1. Requête simple : plantes documentées contre le paludisme
MATCH (p:Plante)-[:estRapportePour]->(u:UsageTherapeutique)
      -[:aPourMaladieCible]->(m:Maladie)
WHERE toLower(m.nom) CONTAINS 'paludisme'
   OR toLower(m.nom) CONTAINS 'malaria'
RETURN DISTINCT p.nomScientifique AS plante, u.usageId AS usage

// 2. Requête complexe : recettes associant plusieurs plantes
MATCH (p:Plante)-[:estRapportePour]->(u:UsageTherapeutique)
      -[:aPourPreparation]->(:Preparation)
      -[:associePlante]->(a:Plante)
RETURN DISTINCT p.nomScientifique AS plante,
       a.nomScientifique AS associee, u.usageId AS usage

// 3. Requête de traçabilité : sources d'une plante
MATCH (:Plante {nomScientifique: 'Annona senegalensis'})
      -[:estDocumenteeDans]->(s:SourceScientifique)
RETURN s.sourceId AS source

// 4. Requête spatiale : plantes d'une localité
MATCH (p:Plante)-[:estLocaliseeA]->(:Localite {nom: 'Kourittenga'})
RETURN DISTINCT p.nomScientifique AS plante
```

Ces requêtes, exécutées sur la base peuplée, renvoient respectivement 136, 118, 7 et 194 lignes (tableau IV.5 du chapitre IV).

Pour répondre à la question « quelles plantes sont rapportées contre le paludisme au Kourittenga ? », une requête relie les nœuds *Plante*, *UsageTherapeutique*, *Maladie* et *Localite*, puis renvoie les noms scientifiques correspondants, ici 99 plantes. Nous avons vérifié le fonctionnement de la base et les résultats des requêtes avant d'intégrer le système d'accès en langage naturel.

III.3 Intégration de l'intelligence artificielle

Nous avons utilisé des modèles de langue à deux étapes. Nous les avons d'abord sollicités pour extraire et structurer les connaissances du corpus, puis mis en place un système RAG pour interroger le graphe en langage naturel. Cette section décrit l'extraction, le système d'accès et la traçabilité entre les sources et les réponses.

III.3.1 Extraction assistée des connaissances

Environnement d'extraction

Nous avons réalisé une première extraction avec le modèle **gpt-6-luna** d'OpenAI, accessible par l'environnement OpenWork, en soumettant les documents un par un. Elle a porté sur dix des 35 documents du corpus, les 19 et 20 octobre 2026. Le document de Ky et al., numérisé sans couche de texte, a dû passer par une reconnaissance optique de caractères, et son extraction restait partielle. Nous avons ensuite réalisé une seconde extraction des mêmes documents avec **Claude Opus 5.5** d'Anthropic, dans Claude Code, les 5 et 6 novembre 2026. Elle reprend le schéma de sortie et les règles de la première, relit les tableaux en image et couvre l'ensemble des lignes des tableaux, y compris pour Ky et al. Après notre vérification manuelle, c'est cette seconde extraction qui a peuplé l'ontologie.

Le prompt d'extraction

Pour la première extraction, nous avons adressé au modèle une même consigne pour chaque document. Longue d'environ 10 700 caractères, elle précise les règles à respecter, les éléments à extraire et le format de sortie. En voici le début :

```
Tu es un assistant d'extraction de connaissances scientifiques
spécialisé dans l'ethnobotanique, l'ethnopharmacologie et la
phytochimie des plantes médicinales du Burkina Faso.

OBJECTIF
À partir du document fourni, extrais les informations explicitement
présentes et organise-les selon le schéma de connaissances décrit
ci-dessous, compatible avec notre ontologie adaptée ontoMEDTRAD.

RÈGLES IMPÉRATIVES
1. Utilise uniquement les informations présentes dans le document.
2. N'invente, ne déduis et ne complète aucune valeur manquante.
3. Distingue strictement :
   - un usage traditionnel rapporté ;
   - une activité pharmacologique observée en laboratoire ;
   - un résultat sur un modèle animal ;
   - un résultat clinique chez l'humain.
[...]
```

Un champ absent du document reçoit la valeur `null`, ou une liste vide. La consigne interdit de compléter une valeur par déduction et demande de rattacher chaque fait à sa page, sa section ou son tableau, et de signaler les contradictions sans les trancher. Ces règles limitent l'ajout d'éléments non étayés dans les fiches.

Format de sortie

La sortie est un document JSON comprenant la description du document, les plantes, les contradictions relevées, les informations absentes et un contrôle de l'extraction. Voici un extrait réel, tiré de la fiche d'*Acacia albida* dans l'extraction de Ky et al. :

```
{
  "nom_scientifique_source": "Acacia albida Del.",
  "famille_botanique": "Mimosaceae",
  "synonymes": [],
  "noms_vernaculaires": [],
  "localisations": [{
    "localite": "Bissiga, Lalgaye et Tenkodogo",
    "province": null,
    "region": "Centre-Est",
    "coordonnees": null,
    "reference_passage": {
      "page": "1289",
      "section": "Results / Methodology",
      "citation_courte": "They were conducted in 8 villages
          from 3 municipalities (Bissiga, Lalgaye and Tenkodogo)"
    }
  }],
```

```
  "usages_therapeutiques": [{
    "indication_source": "Articular pains",
    "parties_utilisees": ["écorce"],
    ...
  }]
}
```

Déroulement et contrôle

Nous avons traité les documents un par un. Une première version de la consigne, jugée trop longue, a été raccourcie avant l'extraction. Un contrôle automatique en lecture seule a ensuite vérifié les fichiers : les 10 fichiers JSON sont valides et contiennent 230 fiches de plantes, 277 usages, 46 activités, 51 entrées de composés et 6 observations toxicologiques, sans aucun fait dépourvu de référence au passage source. La seconde extraction crée un usage par indication, ce qui rend ses effectifs non comparables un à un : elle compte 623 fiches de plantes, 1 734 usages après retrait des 48 usages sans lien établi avec le Burkina Faso, 278 activités, 554 entrées de composés et 13 observations toxicologiques. Pour les neuf documents dotés d'une couche de texte, chaque citation courte a été retrouvée dans le texte de la page annoncée. Le document de Ky et al. a été comparé à une reconnaissance optique de caractères : sur 1 158 champs, 19 écarts ont été relus en image et un seul a conduit à une correction. Nous n'avons pas chronométré l'extraction.

III.3.2 Système RAG d'accès aux connaissances

Nous avons mis en place un système de génération augmentée par récupération (RAG, *Retrieval-Augmented Generation*). Il associe la recherche dans le graphe à la génération de réponses par un modèle de langue [30]. Son architecture relie l'utilisateur, Streamlit, Neo4j et Llama 3 (figure III.7). Nous avons confié la sélection des données au modèle, selon une approche Text2Cypher : Llama 3 traduit la question en requête Cypher, puis rédige la réponse à partir des lignes obtenues. Des requêtes fixes auraient demandé d'écrire à la main une requête par type de question. Une requête générée peut en revanche se tromper sans que l'utilisateur le voie : le système la valide donc en lecture seule, exige ses sources et affiche la requête exécutée. Le chapitre IV mesure le coût de ce choix.

Une partie des questions ne passe pas par cette chaîne. Les questions qui portent sur le contenu de la base, sans critère scientifique, comme « Combien de plantes contient la base ? » ou « Cite 2 plantes documentées », sont reconnues par une liste fermée de mots, puis traitées par des requêtes fixes, sans appel au modèle. Cette voie donne des exemples, une liste d'au plus 20 éléments avec leur total, un décompte, un classement ou un aperçu, pour les plantes, les maladies, les composés, les familles, les localités et les sources. Chacune de ses réponses porte une mention fixe : elle décrit le contenu de la base et ne constitue ni un fait scientifique ni une recommandation d'usage. Dès qu'un mot n'appartient pas à cette liste, par exemple un nom de maladie ou de plante, la question est confiée à Text2Cypher.

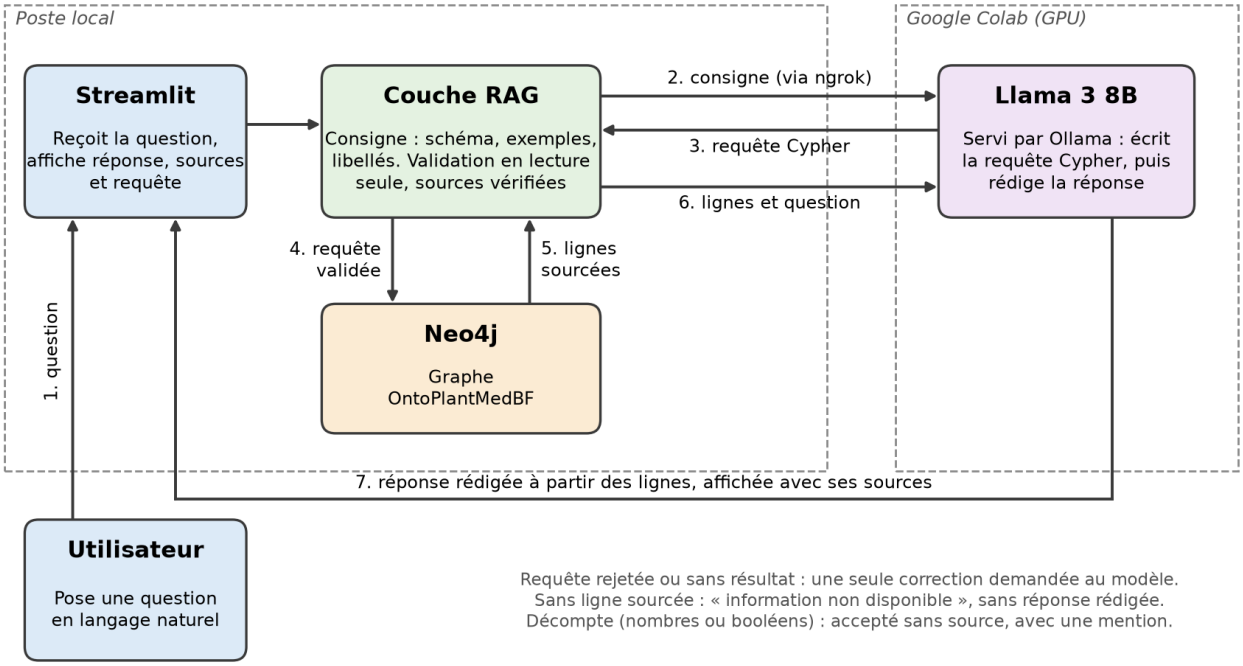


FIGURE III.7 – Chaîne de traitement du système RAG

Les six étapes de la chaîne de traitement

Nous avons organisé le traitement des requêtes en six étapes :

1. **Réception de la question.** L'utilisateur formule une question en langage naturel, par exemple « Quelles plantes sont utilisées contre le paludisme ? ». L'application la nettoie et la transmet à la couche RAG.
2. **Préparation de la consigne.** Le système réunit le schéma du graphe, des exemples de requêtes écrits à la main et les libellés réels du graphe proches de la question : maladies, plantes, noms vernaculaires et localités.
3. **Génération et exécution de la requête.** Llama 3 écrit une requête Cypher, que le système valide en lecture seule avant de l'exécuter. Les filtres sur le texte sont réécrits pour ignorer les accents. Si la requête est rejetée ou ne renvoie aucune ligne, le système demande une seule correction au modèle.
4. **Assemblage du contexte.** Les lignes obtenues sont réunies avec la requête qui les a produites. Le système vérifie dans le graphe les identifiants de sources renvoyés et refuse une requête sans source. Seule exception, une requête qui ne renvoie que des nombres ou des booléens est acceptée sans source : sa réponse porte une mention indiquant qu'il s'agit d'un décompte de la base, et non d'un fait scientifique.
5. **Génération de la réponse.** Llama 3 reçoit la question, les lignes retrouvées et l'historique récent, et rédige une réponse qui ne doit s'appuyer que sur eux. Si aucun fait n'est retrouvé, le système indique que l'information n'est pas disponible, sans demander de réponse au modèle.
6. **Affichage des sources.** L'interface présente la réponse, puis les références scientifiques correspondantes (auteur, année, DOI) et la requête Cypher exécutée.

Câblage des composants

Nous avons utilisé les composants LangChain présentés au tableau II.4 du chapitre II. `PromptTemplate` porte les consignes et `ChatOpenAI` appelle Llama 3 par l'API d'Ollama, exposée

par ngrok, comme indiqué au tableau II.2. Le pilote `neo4j` assure l'accès à la base. L'adresse du modèle est lue dans la configuration, et le fichier qui la contient n'est pas versionné. L'extrait suivant montre l'instanciation du modèle.

```
if config.utilise_ollama:
    from langchain_openai import ChatOpenAI

    # Ollama expose une API compatible OpenAI sur /v1 ;
    # sa clé est ignorée.
    return ChatOpenAI(
        model=modele,  # llama3:8b
        base_url=f"{config.ollama_url}/v1",
        api_key="ollama",
        temperature=config.temperature,  # 0
        timeout=180,
        max_retries=1,
    )
```

Le notebook Colab installe Ollama, télécharge le modèle, démarre le serveur avec un contexte de 8 192 jetons, puis ouvre le tunnel ngrok. Nous avons vérifié pendant l'évaluation que le modèle était entièrement chargé sur le GPU.

III.3.3 Traçabilité des réponses

Nous avons maintenu la traçabilité à chaque étape. L'extraction ne conservait que les informations rapportées par les sources et laissait vides les champs absents. Lors de l'import, chaque connaissance est restée reliée à un nœud *SourceScientifique*. Les requêtes générées doivent renvoyer ces références, vérifiées dans le graphe puis affichées avec les réponses. Nous avons repris les niveaux de preuve tels quels, sans évaluation indépendante, et aucun expert externe n'a relu les extractions. Ces limites sont discutées au chapitre IV.

III.4 Développement de l'application web

Nous avons développé une application web avec Streamlit pour donner accès au système. Elle recueille les questions, appelle la chaîne RAG et présente les réponses avec leurs sources. Les raisons du choix de Streamlit sont exposées au chapitre II, section II.1.3.

III.4.1 Architecture de l'application

Nous avons organisé l'application autour d'un point d'entrée, de huit écrans et d'un état de session partagé : accueil, assistant, recherche, plantes, pathologies, graphe, sources et à propos. Chaque question posée à l'assistant appelle la couche RAG, qui renvoie une réponse et les sources à afficher.

III.4.2 Fonctionnalités

Le tableau III.8 récapitule les fonctions définies en phase 5 (section II.2.7).

TABLE III.8 – Fonctionnalités de l'application web

Fonctionnalité	Description	État
Chatbot	Question en langage naturel, réponse générée par le système RAG, sources affichées	Terminé
Recherche par plante	Consultation d'une fiche à partir du nom scientifique ou vernaculaire	Terminé
Recherche par pathologie	Liste des plantes documentées contre une maladie donnée	Terminé
Fiches descriptives	Usages, parties utilisées, modes de préparation, niveaux de preuve et références	Terminé
Affichage des sources	Références complètes (auteur, année, DOI) sous chaque information	Partiel
Visualisation du graphe	Représentation des relations entourant une plante ou une maladie	Partiel

Deux fonctions restent partielles. Les références s'affichent sous la réponse et non sous chaque information, et la visualisation du graphe part d'une plante, pas d'une maladie.

Nous avons ajouté une alerte de toxicité à l'assistant. Lorsqu'une réponse cite une plante pour laquelle la base contient des données toxicologiques, un encadré les signale sous la réponse, chacune avec sa source. Neuf plantes sont concernées, pour les treize effets toxicologiques du graphe. L'alerte reprend les données rapportées sans les évaluer : certaines indiquent seulement qu'une étude de toxicité a été menée, ou que les répondants ne mentionnent pas de toxicité. Elle complète l'affichage des risques en tête de la fiche de chaque plante.

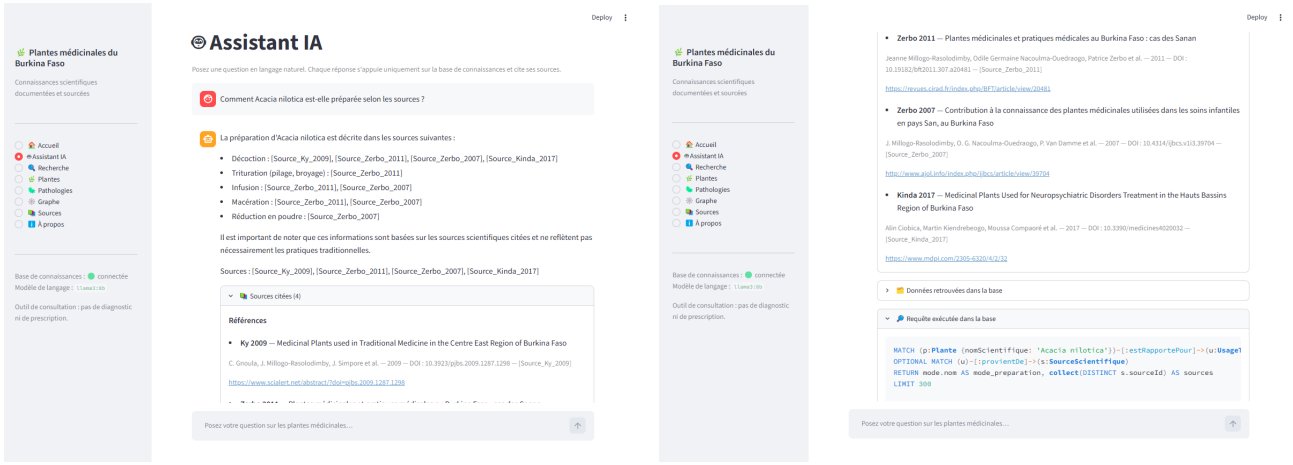
III.4.3 Gestion de session et déploiement

Nous avons conservé l'historique des échanges dans l'état de session de Streamlit et l'avons transmis au modèle dans la consigne de génération. L'historique sert à la rédaction, mais pas à la génération de la requête : une question de suivi qui ne nomme pas son sujet ne retrouve donc pas les bons faits. L'application fonctionne sur un poste local sous Windows 11 et accède au modèle par l'API exposée avec ngrok ; seule l'API du modèle est exposée, pas l'application.

```
python -m streamlit run application\app.py
```

L'application s'ouvre sur le port 8501. La session Colab n'est active que pendant son utilisation et son adresse change à chaque lancement. Il n'existe pas de mise en ligne pérenne.

La figure III.8 montre l'assistant avec Llama 3 8B, sur la question « Comment Acacia nilotica est-elle préparée selon les sources ? ». La réponse associe chaque mode de préparation aux sources qui le rapportent. Sous la réponse, l'utilisateur peut déplier les références complètes, avec leur DOI, puis la requête Cypher exécutée dans la base.



(a) Réponse et sources citées (b) Références complètes et requête exécutée

FIGURE III.8 – L'assistant de l'application web : une réponse sourcée produite avec Llama 3 8B

La figure III.9 montre la fiche de *Cochlospermum planchonii*, la plante de la figure III.6. La fiche réunit la famille, les noms vernaculaires et un tableau des usages documentés. Chaque ligne y indique la pathologie, l'indication telle qu'elle est écrite dans la source, la partie utilisée, la préparation, la plante éventuellement associée dans une recette, le niveau de preuve et la source de l'usage. Les références complètes figurent sous la fiche.

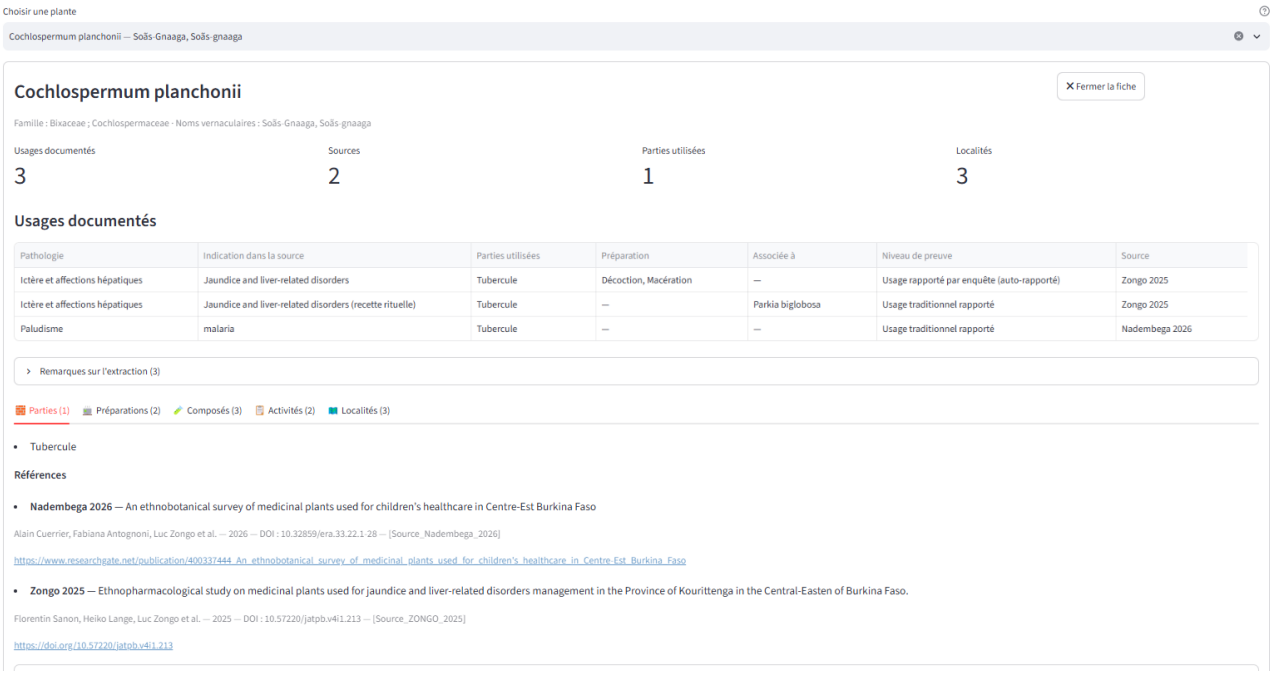


FIGURE III.9 – Fiche de *Cochlospermum planchonii* dans l'application web

Conclusion du chapitre

Ce chapitre a présenté le système issu de la démarche du chapitre II. Nous avons construit OntoPlantMedBF à partir d'ontoMEDTRAD, l'avons adaptée au contexte burkinabè et peuplée avec des connaissances sourcées ; son schéma organise également la base Neo4j. Nous avons décrit l'extraction assistée par modèle de langue, le système RAG qui interroge le graphe à partir des questions et l'application web qui présente les réponses. Nous avons rattaché les connaissances à leurs sources,

laissé vides les champs absents et repris les niveaux de preuve rapportés par les documents. Le chapitre IV évalue l'ontologie et les réponses du système, mesure les temps de réponse de l'application, puis discute les résultats et leurs limites.

Chapitre IV

Résultats et discussion

Introduction du chapitre

Les chapitres précédents ont présenté la démarche suivie et le système développé. Dans ce chapitre, nous exposons les résultats de l'évaluation de l'ontologie et du système RAG, ainsi que les temps de réponse de l'application web, dont l'évaluation auprès des utilisateurs n'a pas été menée. Nous en discutons la portée et les limites au regard des objectifs de la recherche et des systèmes existants.

IV.1 Évaluation de l'ontologie

Nous avons évalué l'ontologie selon les quatre critères retenus en phase 6 : couverture, cohérence, traçabilité et extensibilité (tableau II.10 du chapitre II). Nous décrivons la méthode employée et les résultats disponibles pour chacun.

IV.1.1 Couverture

Nous avons vérifié la couverture en confrontant l'ontologie peuplée aux extractions des dix documents traités. Nous avons examiné si les noms scientifiques et vernaculaires, les pathologies, les modes de préparation et les sources citées étaient représentés dans le modèle.

Le fichier peuplé contient 6 936 individus issus de dix des 35 documents du corpus (28,6 %), dont 289 plantes, 1 676 usages thérapeutiques, 238 maladies et 10 sources. Les extractions JSON comptent 623 fiches de plantes, à raison d'une fiche par plante et par document, regroupées en 289 plantes distinctes. Les effectifs d'individus correspondent à ceux des extractions pour les activités pharmacologiques (278) et les observations toxicologiques (13). Pour les usages, les 1 734 entrées des extractions donnent 1 676 individus après exclusion des 25 usages répulsifs et des 33 usages vétérinaires. Le modèle d'origine couvrait vingt-deux plantes et trente et un remèdes antipaludéens [29].

La couverture varie selon les connaissances disponibles dans le corpus. Celui-ci porte surtout sur certaines pathologies, notamment le paludisme, et sur un nombre restreint de régions. Le dosage et la toxicité sont peu représentés lorsque les documents ne les précisent pas. Nous avons limité l'extraction aux informations documentées (section III.3.1 du chapitre III).

IV.1.2 Cohérence

Nous avons contrôlé la cohérence avec HermiT dans Protégé 5 après les principales modifications de classes, propriétés et relations. Le raisonneur n'a signalé aucune incohérence. Nous avions également prévu des requêtes de test pour vérifier l'emploi des propriétés sur les domaines attendus et, après le peuplement et l'import de phase 4, le rattachement des instances à leurs classes. Sur la version

peuplée, HermiT (version 1.4.3 fournie avec Protégé 5.6.9) a traité l'ontologie en 1 550 ms sans signaler d'incohérence ni de classe insatisfiable. Après l'import, nous avons exécuté dans Neo4j les requêtes de contrôle suivantes, sur l'ensemble du graphe : usages sans source, 0 ; usages sans plante, 0 ; usages sans maladie cible, 0 ; plantes sans source, 0 ; composés sans source, 0 ; effets toxicologiques sans source, 0. L'import a aussi vérifié les domaines et les portées des propriétés sur les 25 321 relations, sans anomalie.

Ce résultat indique l'absence de contradiction dans le modèle, mais pas la justesse des connaissances qu'il contient. Une proposition erronée mais cohérente pourrait satisfaire ce contrôle.

IV.1.3 Traçabilité

Nous avons vérifié que les connaissances enregistrées restent rattachées aux sources correspondantes. L'extraction ne renseignait que les champs présents dans les documents et l'import associait les faits à une source (section III.3.3 du chapitre III).

Nous avons contrôlé sur l'ensemble du graphe le rattachement des faits à un nœud *SourceScientifique*. Toutes les plantes (289/289) et tous les usages (1 676/1 676) sont reliés à une source, et chaque usage conserve la référence de son passage. Tous les usages portent un niveau de preuve. Les 10 sources ont un titre et un DOI. Nous avons également contrôlé les usages dans les PDF d'origine. Le nom de la plante, sous sa forme retenue ou sous une graphie de la source, figure dans le texte du document pour 1 497 usages sur 1 501 contrôlables ; dans les quatre écarts, le nom est présent dans le document, mais la recherche automatique ne le retrouve pas, notamment lorsqu'il est coupé par une cellule de tableau. Les 175 autres usages proviennent d'un document numérisé sans couche de texte (Ky et al.) et n'ont pas été contrôlés de cette manière ; après reconnaissance optique de caractères, le nom exact y figure pour 93 d'entre eux. Sur un échantillon de 30 usages tirés au sort parmi les 1 501, une lecture assistée par un outil d'intelligence artificielle, appuyée sur les pages en image lorsque le texte des tableaux était désordonné, a retrouvé le fait principal, à savoir la plante et l'indication, pour les 30 et n'a relevé aucune contradiction. Cet outil étant celui qui a produit l'extraction, ce contrôle n'est pas indépendant et ne remplace pas une relecture par un spécialiste. L'import signale comme anomalie tout usage dépourvu de source ; aucun cas n'a été relevé.

IV.1.4 Extensibilité

Lors de la phase 3a, nous avons adapté le modèle conceptuel en ajoutant des classes et des propriétés relatives aux noms vernaculaires, aux usages, aux préparations, à la traçabilité documentaire, à la phytochimie et à la toxicologie. En phase 4, l'ontologie a été enrichie avec les individus et données extraits des sources en phase 3b, puis ce modèle enrichi a été importé et ajusté dans Neo4j. Nous n'avons pas réalisé de test d'ajout isolé en dehors des phases 3a et 4. Le passage à la version 4.0 du schéma, qui ajoute notamment les modes d'administration, les modes de préparation et les propriétés de posologie, a été importé sans anomalie de domaine ou de portée. Cela donne une indication sur l'extensibilité du modèle, sans en constituer une preuve.

IV.1.5 Synthèse de l'évaluation de l'ontologie

Le tableau IV.1 réunit les quatre critères et leurs résultats.

TABLE IV.1 – Résultats de l'évaluation de l'ontologie

Critère	Méthode	Résultat
Couverture	Comparaison aux extractions, sur les 35 documents du corpus	10/35 documents (28,6 %) peuplés ; 1 676 usages représentés sur 1 734 extraits (58 exclus)
Cohérence	Raisonneurs et requêtes de contrôle	Aucune incohérence signalée. Sur la version peuplée, 0 cas dans les six requêtes de contrôle et 0 anomalie de domaine ou de portée.
Traçabilité	Requêtes sur l'ensemble du graphe	Plantes 289/289 et usages 1 676/1 676 reliés à une source (100 %) ; niveau de preuve 1 676/1 676 (100 %)
Extensibilité	Ajouts en cours de phases 3a et 4	Pas de test isolé ; schéma v4.0 importé sans anomalie.

IV.2 Évaluation du système RAG

Nous avons évalué le système RAG sur quatre critères : pertinence, fidélité, exactitude et traçabilité. Le protocole de phase 6 prévoyait leur mesure au moyen d'un jeu de 50 questions de référence (tableau II.11 du chapitre II).

IV.2.1 Construction du jeu d'évaluation

Le jeu d'évaluation comprend 50 questions sur les plantes, les usages et leurs sources. La répartition compte 25 questions simples, 7 sur les recettes multi-plantes, 8 de traçabilité, 5 spatiales et 5 hors corpus, pour lesquelles un refus est attendu. Les réponses attendues sont calculées par des requêtes Cypher distinctes de la chaîne RAG. Le jeu mesure donc la restitution du contenu du graphe, et non l'exactitude des extractions. Nous avons préparé les questions et les scripts de calcul sans évaluateur extérieur et en connaissant le système, ce qui constitue un biais.

Nous avons utilisé la précision pour mesurer la pertinence, le rappel pour la fidélité, le F1-score pour l'exactitude et le taux de couverture des réponses sourcées pour la traçabilité. Pour chaque question, nous repérons automatiquement dans la réponse les valeurs du type attendu (plantes, parties, familles, modes de préparation ou sources). La précision est la part des valeurs citées qui sont attendues, $P = |C \cap A|/|C|$, et le rappel la part des valeurs attendues qui sont citées, $R = |C \cap A|/|A|$, où C désigne les valeurs citées et A les valeurs attendues. Le F1-score vaut $2PR/(P + R)$. Ces mesures sont calculées par question, puis moyennées sur les 45 questions dont la réponse attendue n'est pas vide. Une réponse est conforme si son F1-score atteint 0,8, seuil fixé avant la première exécution. Une question hors corpus est conforme si le système refuse de répondre sans citer de plante. La couverture compte les réponses comportant au moins une source. Une erreur de notre script de score, qui confondait les types d'écorce, a été corrigée après lecture des résultats ; la correction s'applique de la même façon aux deux modèles, sans nouvelle exécution.

IV.2.2 Résultats quantitatifs

Les mesures effectuées avec Llama 3 8B sur les 50 questions sont présentées au tableau IV.2.

TABLE IV.2 – Résultats de l'évaluation du système RAG

Critère	**Métrique**	**Résultat**
Pertinence	Précision	0,785
Fidélité	Rappel	0,746
Exactitude	F1-score	0,728
Traçabilité	Taux de couverture des réponses sourcées	39/45 réponses attendues non vides (86,7 %) ; aucune des 826 citations relevées ne désigne une source inexistante

Les scores globaux ne rendent pas compte des différences entre familles de questions. Le tableau IV.3 présente les résultats par famille.

TABLE IV.3 – Résultats par famille de questions

Famille de questions	**Effectif**	**Réponses conformes**	**Échecs**
Questions simples (plante, maladie, usage)	25	18	7
Recettes multi-plantes	7	5	2
Traçabilité (d'où vient l'information ?)	8	8	0
Questions spatiales (région, localisation)	5	0	5
Hors corpus (refus attendu)	5	5	0
Total	**50**	**36**	**14**

Nous avons posé les mêmes questions au système avec Gemini (*gemini-3.5-flash-lite*), qui remplace alors Llama 3 pour écrire la requête et rédiger la réponse. Le tableau IV.4 compare les deux exécutions. Gemini restitue davantage de valeurs, avec 49 réponses conformes contre 36, et Llama 3 présente un temps médian plus long. Llama 3 reste néanmoins un modèle ouvert, que nous avons pu exécuter sur une instance que nous contrôlions : c'est pour cette raison que nous l'avons conservé comme modèle du système, malgré son score plus bas. Cette comparaison repose sur une seule exécution de chaque modèle et ne permet pas de conclusion générale.

TABLE IV.4 – Comparaison de Llama 3 8B et de Gemini sur les 50 questions

Mesure	**Llama 3 8B**	**Gemini**
Précision	0,785	1,000
Rappel	0,746	0,992
F1-score	0,728	0,995
Réponses conformes	36/50	49/50
Temps médian	15,7 s	4,3 s
Temps moyen	21,8 s	7,3 s
Temps maximal	97,4 s	42,5 s

Ces résultats sont ceux de la version retenue de la consigne, ajustée une seule fois après lecture des échecs : correction des requêtes sans résultat, filtres insensibles aux accents, règles sur le sens des relations et sur les critères, et un exemple supplémentaire. La version précédente, évaluée sur le même graphe et les mêmes questions, donnait un F1-score de 0,780 avec Llama 3 (39 réponses conformes) et de 1,000 avec Gemini (50 réponses conformes). L'ajustement n'a donc pas amélioré le score sur ce jeu. Nous nous sommes arrêtés là pour ne pas adapter davantage la consigne à ces questions. Cette consigne avait elle-même été complétée après lecture d'essais antérieurs, et ses exemples portent sur les mêmes types de questions que le jeu d'évaluation, ce qui favorise le score.

Une première version du système, sur un graphe antérieur de 141 plantes, sélectionnait les faits par des requêtes fixes et atteignait un F1-score de 0,923 avec Llama 3 et de 0,966 avec Gemini, contre 0,607 et 0,842 en Text2Cypher sur ce même graphe. Ces chiffres ne sont pas directement comparables aux précédents, car le graphe et la consigne ont changé. Ils indiquent toutefois que le passage à Text2Cypher, retenu pour éviter d'écrire une requête par type de question, pèse sur la fiabilité.

IV.2.3 Volumes d'interrogation de la base

Nous avons relevé les volumes obtenus avec les quatre familles de requêtes définies en phase 4 (section II.2.6 du chapitre II). Le tableau IV.5 les présente.

TABLE IV.5 – Volumes de résultats des quatre familles de requêtes

Famille	**Exemple**	**Résultats renvoyés**
Requêtes simples	Plantes documentées contre une maladie	136
Requêtes complexes	Recette associant plusieurs plantes	118
Requêtes de traçabilité	Sources d'une plante donnée	7
Requêtes spatiales	Plantes d'une région donnée	194

IV.2.4 Observations qualitatives

Les métriques ne décrivent pas à elles seules le déroulement des tests. Nous les complétons par les observations qualitatives recueillies.

Les tests ont porté sur des questions simples, de traçabilité, spatiales, sur des recettes multi-plantes et sur des sujets absents du corpus. Sur les 14 réponses non conformes avec Llama 3, dix tiennent à la requête générée et quatre à la rédaction. Les 5 questions spatiales ont toutes échoué (Q41 à Q45) : le modèle écrit une requête mal formée, souvent en prolongeant le chemin au-delà de la localité, ce que le schéma ne permet pas, et le système répond à tort que l'information n'est pas disponible. La question Q19 aboutit au même refus, faute de source dans la requête. Le modèle ajoute une maladie non demandée dans Q03 et Q09, et ne cherche qu'une partie des libellés dans Q06 et Q10. Pour la rédaction, il omet des valeurs pourtant présentes dans le contexte (Q01, Q18) ou déclare à tort qu'il n'y a pas de réponse (Q30, Q31). La correction a été demandée pour 11 questions : les 5 questions hors corpus, de nouveau refusées, et 6 questions pour lesquelles elle n'a pas abouti. Elle n'a donc permis aucune réponse sur ce jeu. Lorsque l'information demandée est absente du graphe, le système doit éviter de produire une réponse non étayée. Les 5 questions hors corpus ont toutes reçu un refus, ce que nous comptons comme le comportement attendu. Mais 6 des 45 questions à réponse attendue ont reçu un refus à tort : avec Text2Cypher, un refus ne prouve pas que l'information est absente du graphe. Pour deux autres questions (Q30, Q31), le modèle répond lui-même, à tort, qu'il n'a rien trouvé : au total, 8 des 45 réponses attendues affirment à tort l'absence d'information.

Nous avons également posé 12 questions libres, écrites après avoir vu ces échecs et hors des types du jeu d'évaluation, comme « citer 2 plantes » ou « Quelles plantes sont utilisées à la fois contre le paludisme et contre la toux ? ». Jugées à la lecture, elles constituent un contrôle séparé, qui ne s'ajoute pas au score. Llama 3 a produit 2 réponses correctes, 8 refus à tort et 2 réponses à côté de la question, tandis que les 12 réponses de Gemini étaient utilisables, certaines listes restant incomplètes. Nous avons ensuite accepté sans source les requêtes ne renvoyant que des nombres ou des booléens, ce qui permet à Llama 3 de répondre à « Combien de plantes contient la base ? ». Le score du jeu d'évaluation n'en dépend pas : aucune de ses requêtes finales n'est un décompte, et aucune n'a été rejetée pour ce motif. Après l'évaluation, nous avons aussi ajouté une voie à requêtes fixes pour les questions portant sur le contenu de la base (section III.3.2 du chapitre III). Un test automatique vérifie qu'aucune des 50 questions n'emprunte cette voie : les scores restent inchangés. En revanche, 3 des 12 questions libres, dont « citer 2 plantes » et « Combien de plantes contient la base ? », y passent désormais ; les résultats ci-dessus décrivent la version antérieure et n'ont pas été recalculés.

Le temps total, mesuré par le script d'évaluation pour chaque question, s'élève en moyenne à 21,8 s (médiane 15,7 s, maximum 97,4 s). Treize questions ont dépassé 20 s et quatre ont dépassé 60 s. Nous n'avions pas fixé de seuil au préalable.

IV.3 Évaluation de l'application web

Le protocole prévoyait quatre critères : facilité d'utilisation, compréhension des réponses, utilité perçue et performance (tableau II.12 du chapitre II). Les trois premiers devaient être mesurés par un questionnaire, auprès d'étudiants, de chercheurs et de tradipraticiens. Cette campagne de tests n'a pas été menée dans le temps imparti au mémoire. Nous ne disposons donc d'aucun résultat pour ces trois critères et nous ne les estimons pas. Seule la performance a été mesurée. Le tableau IV.6 récapitule cette situation.

TABLE IV.6 – Résultats de l'évaluation de l'application web

Critère	**Méthode prévue**	**Résultat**
Facilité d'utilisation	Questionnaire	Non mesurée : campagne non menée
Compréhension des réponses	Questionnaire	Non mesurée : campagne non menée
Utilité perçue	Questionnaire	Non mesurée : campagne non menée
Performance	Mesure du temps de réponse	21,8 s en moyenne (médiane 15,7 s ; maximum 97,4 s), sur les 50 questions

IV.3.1 Performance

Nous avons séparé le temps d'interrogation de Neo4j du temps restant, qui regroupe la génération par Llama 3 et le délai du tunnel ngrok. En réexécutant après l'évaluation les requêtes générées, l'interrogation de Neo4j prend en moyenne 0,02 s (maximum 0,15 s). L'essentiel du temps tient donc à la génération et au tunnel, soit environ 21,8 s en moyenne ; notre mesure ne permet pas de séparer ces deux composantes.

IV.4 Discussion

Nous avons examiné les résultats au regard des questions de recherche et des systèmes existants, puis précisé les limites de l'étude et les pistes de travail qu'elles suggèrent.

IV.4.1 Confrontation aux objectifs de la recherche

La première question de recherche portait sur le choix d'une ontologie adaptée au contexte burkinabè et sur les réajustements qu'elle demandait. Nous avons comparé cinq ontologies à l'aide d'une grille commune au chapitre II. *ontoMEDTRAD* a obtenu le score le plus élevé, 4,7 contre 3,7 pour *WATRIMed*. Nous l'avons retenue comme base conceptuelle, en tenant compte des limites du modèle d'origine. Nous avons étendu le schéma par des classes et des relations relatives aux noms vernaculaires, aux usages, aux parties utilisées, aux préparations, aux niveaux de preuve, aux sources, à la localisation, à la phytochimie et à la toxicologie.

La deuxième question portait sur l'extraction des connaissances et leur traçabilité. Les connaissances de dix documents ont été extraites avec l'aide de l'intelligence artificielle, puis vérifiées manuellement avant le peuplement de l'ontologie et son import dans Neo4j. Le rattachement aux sources est complet pour les usages et les plantes (section IV.1.3). Le nom de la plante figure dans le document d'origine pour 1 497 usages sur 1 501 contrôlables, mais l'exactitude de chaque information n'a été contrôlée que partiellement. Nous n'avons pas comparé cette méthode à une extraction manuelle.

La troisième question concernait l'accès en langage naturel au moyen d'une solution numérique, qui associe un système RAG à une application web. Le modèle traduit la question en requête Cypher, validée en lecture seule, puis produit une réponse accompagnée de sources. Les métriques du tableau IV.2 indiquent une restitution partielle du graphe avec Llama 3 (F1-score de 0,728), bien meilleure avec Gemini (0,995), sans renseigner sur l'exactitude scientifique des faits. L'accès en langage naturel fonctionne donc, mais sa fiabilité dépend fortement du modèle qui écrit la requête. Nous avons développé l'application et défini les fonctions présentées au tableau III.8. La campagne de tests auprès des utilisateurs n'ayant pas été menée, nous ne pouvons pas dire dans quelle mesure l'application facilite leur accès aux connaissances : la réponse à la troisième question reste partielle.

IV.4.2 Confrontation aux systèmes existants

Le modèle d'origine *ontoMEDTRAD* couvrait vingt-deux plantes et trente et un remèdes antipaludéens [29]. Notre base compte 289 plantes et 1 676 usages issus de dix documents. Ces chiffres ne sont pas directement comparables, car les deux travaux n'ont pas le même périmètre et notre décompte ne distingue pas les remèdes de la même façon.

Par rapport à *WATRIMed*, dont les publications ne décrivent que les classes supérieures, notre travail relie le schéma à une base interrogeable et à une application qui présente les réponses avec leurs sources.

L'apport du travail tient à la chaîne qui relie les sources scientifiques à l'ontologie, au graphe et aux réponses de l'application. Les contrôles chiffrés établissent la présence de ces liens ; leur exactitude n'est vérifiée que sur une partie des documents.

IV.4.3 Limites

Six limites encadrent les résultats qui précèdent et déterminent leur portée.

1. **L'évaluation a été conduite par nous-mêmes, les concepteurs du système.** Aucun évaluateur extérieur n'a participé aux tests, et la campagne prévue auprès des utilisateurs n'a pas été menée.

2. **Le jeu de 50 questions provient du corpus utilisé pour construire le système.** Il mesure donc principalement les réponses du système sur les documents qui ont alimenté la base. Des questions formulées par d'autres utilisateurs à partir de documents différents pourraient produire d'autres résultats.
3. **Les niveaux de preuve proviennent des sources.** Nous les avons repris tels quels, sans réévaluation indépendante, comme indiqué en phase 3b et au chapitre III. Un usage classé « traditionnel » par sa source conserve cette qualification dans la base.
4. **Les extractions n'ont pas été relues par un expert.** L'absence d'ajout d'informations non rapportées par les sources limite certains risques, mais une fiche peut malgré tout déformer le propos. Aucune relecture systématique par un ethnobotaniste ou un pharmacologue n'a eu lieu ; seul le contrôle sur échantillon de la section IV.1.3 a été réalisé.
5. **L'échelle reste celle d'un prototype.** Le corpus comprend 35 documents et dix ont été extraits, soit 623 fiches de plantes et 1 734 usages, dont 1 676 retenus dans le graphe. L'application a fonctionné sur un poste local, le modèle sur une session Google Colab jointe par un tunnel ngrok ; nous n'avons pas étudié son usage soutenu par un large public ni son déploiement pérenne.
6. **Le périmètre reste celui d'un outil de consultation.** Le système aide à rechercher et à vérifier des informations documentées. Il ne pose pas de diagnostic et n'établit pas de prescription. Les résultats ne constituent pas une validation clinique.

Trois réserves s'y ajoutent. Les réponses attendues provenant du graphe, nos métriques ne mesurent pas la justesse des faits. Le jeu de 50 questions reprend les types illustrés par les exemples de la consigne, ce que les questions libres montrent : Llama 3 y réussit nettement moins bien. Enfin, 175 usages sur 1 676 proviennent d'un document numérisé, contrôlé seulement à partir d'une reconnaissance optique de caractères.

Nous n'avons pas testé par comparaison contrôlée l'hypothèse selon laquelle l'extraction assistée par modèle de langue serait meilleure qu'une extraction manuelle. Une telle comparaison nécessiterait un protocole distinct appliqué dans les mêmes conditions aux deux méthodes.

IV.4.4 Pistes de travail

Les limites observées ouvrent plusieurs pistes de travail. Une évaluation des extractions avec un spécialiste, des tests auprès d'utilisateurs, dont des tradipraticiens, et l'intégration de thèses et de rapports non numérisés permettraient d'étudier le système sur un corpus plus large. Une relecture experte d'un échantillon et des questions formulées par des utilisateurs compléteraient l'évaluation. Un déploiement pérenne et une collecte discrète des données d'usage permettraient également d'étudier le système en conditions réelles.

Conclusion du chapitre

Ce chapitre présente l'évaluation de l'ontologie et du système RAG, ainsi que les temps de réponse de l'application web, qui n'a pas été évaluée auprès de ses utilisateurs. Le système restitue en partie le contenu du graphe sur les 50 questions, avec un F1-score de 0,728 pour Llama 3 8B et de 0,995 pour Gemini, et un refus pour toutes les questions hors corpus. L'ontologie couvre dix des 35 documents du corpus, et l'exactitude des faits n'a été contrôlée que partiellement.

Nous avons replacé ces résultats au regard des questions de recherche et des systèmes existants. Le travail met en place une chaîne reliant les sources scientifiques à l'ontologie, au graphe et aux réponses de l'application. Les résultats restent toutefois encadrés par les limites méthodologiques présentées dans ce chapitre.

La conclusion générale reprend les résultats disponibles, les limites de l'étude et les travaux qui pourraient prolonger ce prototype.

Conclusion générale

Notre recherche répond à une difficulté d'accès aux connaissances scientifiques sur les plantes médicinales du Burkina Faso. Ces connaissances sont dispersées entre des articles, des thèses, des mémoires et des rapports dont les terminologies et les noms de plantes varient. Il est donc difficile de retrouver une information sur une plante, une pathologie ou une recette et de remonter à sa source. Pour répondre à cette difficulté, nous avons adapté le modèle conceptuel d'une ontologie existante, enrichi l'ontologie en données issues de la littérature scientifique, puis importé et ajusté cette représentation dans une base orientée graphe exploitée par un système d'accès intelligent et une application web. La démarche a suivi six phases, de la constitution du corpus à l'évaluation du dispositif, avec deux volets menés en parallèle sur le modèle conceptuel et sur le modèle de données.

Nous avons comparé les ontologies du domaine au moyen d'une grille commune et retenu *ontoMEDTRAD*, qui a obtenu le score le plus élevé devant *WATRIMed*, comme base conceptuelle. En phase 3a, nous avons adapté son modèle conceptuel au contexte burkinabè ; en phase 3b, nous avons extrait les connaissances de dix documents scientifiques, puis, en phase 4, enrichi l'ontologie avec ces individus associés à leurs sources. Au cours de la même phase, nous avons importé dans Neo4j l'ontologie réajustée *OntoPlantMedBF*, afin d'exploiter son modèle et ses données dans la base graphe. La comparaison des schémas montre 40 classes ajoutées, 20 propriétés objet ajoutées et 15 propriétés de données ajoutées par rapport au schéma conservé. Ces ajouts portent notamment sur les noms vernaculaires, les usages et maladies cibles, les parties et préparations, les niveaux de preuve, la provenance, la localisation, les composés chimiques, les activités pharmacologiques et les effets toxicologiques rapportés. Nous avons mis en place un système RAG associant Neo4j et Llama 3 8B, exécuté sur Google Colab. Le modèle traduit les questions en langage naturel en requêtes Cypher, validées en lecture seule, et produit des réponses à partir des faits retrouvés. Une application web fournit une interface de recherche et de consultation. Nous avons évalué l'ontologie et le système RAG ; l'application n'a pas été évaluée auprès de ses utilisateurs.

Nous avons examiné les hypothèses à partir des résultats présentés aux chapitres III et IV. Faute de campagne de tests auprès des utilisateurs, nos conclusions sur l'application web se limitent à ses fonctions et à ses temps de réponse.

Hypothèse 1. Une revue méthodique des ontologies existantes devait permettre de sélectionner un modèle capable, après réajustement, de représenter les connaissances sur les plantes médicinales du Burkina Faso. Les travaux réalisés étayent cette hypothèse. Nous avons comparé plusieurs modèles, puis construit et peuplé OntoPlantMedBF à partir de l'ontologie retenue, afin de représenter les plantes, leurs usages, leurs parties utilisées, leurs préparations, leurs propriétés et leurs sources. HermiT n'a signalé aucune incohérence dans les vérifications rapportées.

Hypothèse 2. L'intelligence artificielle, associée à une vérification manuelle, devait permettre d'extraire de la littérature scientifique des connaissances fidèles aux documents et traçables jusqu'à leurs sources. Les résultats du tableau IV.1 étayent cette hypothèse : les 289 plantes et les 1 676 usages sont reliés à une source, sur dix des 35 documents du corpus, et le nom de la plante figure dans le document d'origine pour 1 497 usages sur 1 501 contrôlables. La présence de ces liens ne garantit pas l'exactitude des faits, contrôlée seulement sur une partie des documents. Nous n'avons pas non plus comparé cette méthode à une extraction manuelle dans des conditions contrôlées ; nous ne pouvons donc pas conclure qu'elle lui soit supérieure.

Hypothèse 3. Une solution numérique interrogeable en langage naturel devait faciliter l'accès aux connaissances documentées. Nous avons testé le système RAG sur un jeu de 50 questions : avec Llama 3 8B, le F1-score atteint 0,728, 36 réponses sont conformes, et les 5 questions hors corpus reçoivent un refus. Le système restitue donc en partie le contenu du graphe et refuse à tort 6 questions, tandis que pour 2 autres le modèle affirme à tort n'avoir rien trouvé ; Gemini atteint 0,995 sur le même jeu. Ces mesures ne renseignent pas sur la justesse scientifique des faits. Le jeu de questions provient en outre du corpus utilisé pour construire le système, et l'évaluation a été menée par ses concepteurs. L'application a été développée, mais elle n'a pas été évaluée auprès de ses utilisateurs : son apport pour la consultation des connaissances reste à mesurer. Avec le modèle ouvert retenu, l'hypothèse n'est donc que partiellement étayée.

Six limites encadrent ce bilan. L'évaluation a été conduite par nous-mêmes, les concepteurs du système, sans regard extérieur. Le jeu de questions provient du même corpus que celui utilisé pour construire la base et mesure donc surtout les capacités du système sur ces données. Les niveaux de preuve sont repris des sources sans réévaluation indépendante, et les extractions n'ont pas été relues par un expert. Le système reste un prototype déployé localement, dont l'utilisation à grande échelle n'a pas été étudiée. Enfin, il s'agit d'un outil de consultation. Il ne pose pas de diagnostic et n'établit pas de prescription ; les résultats ne constituent pas une validation clinique.

Ces limites indiquent plusieurs prolongements possibles : faire évaluer les extractions par un spécialiste, tester l'application auprès d'utilisateurs, dont des tradipraticiens, élargir le corpus aux thèses et rapports non numérisés, puis mesurer l'effet de ces ajouts sur la couverture. Une relecture experte d'un échantillon et des questions formulées par des utilisateurs compléteraient l'évaluation. Un déploiement pérenne et une collecte discrète des données d'usage permettraient aussi d'étudier le système en conditions réelles.

L'apport du travail tient à l'organisation des connaissances et au lien établi entre les sources, l'ontologie, le graphe et les réponses présentées à l'utilisateur. La base reste de taille modeste, et l'évaluation par les utilisateurs reste à mener. La traçabilité est vérifiée dans le graphe ; des contrôles dans les documents et des évaluations plus larges seront nécessaires pour en établir la portée.

Bibliographie

[1] AI4D. *Création d'une base de données sur les plantes médicinales pour faciliter l'exploitation des connaissances ethnopharmacologiques locales*. 2020. URL : https://www.ai4d.ai/fr/blog/building-a-medicinal-plant-database (visité le 26/09/2026).

[2] Richard O. ANGOLE et al. « Towards an Ontology Model for African Traditional Medicine ». In : *Advances in Knowledge-Based and Intelligent Information and Engineering Systems*. T. 243. Frontiers in Artificial Intelligence and Applications. IOS Press, 2012, p. 386-395. DOI : 10.3233/978-1-61499-105-2-386.

[3] Richard Okelo ANGOLE, Peter JEHOPIO et Gilbert MAIGA. « Ontology model : Towards bridging the gap between African traditional medicine and conventional medicine ». In : *International Journal of Knowledge-Based and Intelligent Engineering Systems* 17.1 (2013), p. 37-43. DOI : 10.3233/KES-130263.

[4] ARES. *Médecine traditionnelle et système de santé : vers une intégration durable*. 2018. URL : https://moove.ares-ac.be/actu/medecine-traditionnelle-et-systeme-de-sante-vers-une-integration-durable (visité le 26/09/2026).

[5] Armel AYIMDJI et al. « Towards A "Deep" Ontology for African Traditional Medicine ». en. In : *Intelligent Information Management* 3.6 (oct. 2011). Number : 6, p. 244-251. DOI : 10.4236/iim.2011.36030. URL : https://www.scirp.org/journal/paperinformation?paperid=8241 (visité le 12/06/2026).

[6] Ricardo BAEZA-YATES et Berthier RIBEIRO-NETO. *Modern Information Retrieval : The Concepts and Technology behind Search*. 2e éd. Harlow : Addison-Wesley, 2011. URL : https://books.google.com/books/about/Modern_Information_Retrieval.html?id=HbyAAAAACAAJ.

[7] Bruce G. BUCHANAN et Edward H. SHORTLIFFE, éd. *Rule-Based Expert Systems : The MYCIN Experiments of the Stanford Heuristic Programming Project*. Reading, MA, USA : Addison-Wesley, 1984. ISBN : 0-201-10172-6.

[8] Laurel COOPER et al. « The Plant Ontology as a Tool for Comparative Plant Anatomy and Genomic Analyses ». In : *Plant and Cell Physiology* 54.2 (2013), e1. DOI : 10.1093/pcp/pcs163.

[9] Fred D. DAVIS. « User acceptance of information technology : system characteristics, user perceptions and behavioral impacts ». In : *International Journal of Man-Machine Studies* 38.3 (mars 1993), p. 475-487. ISSN : 0020-7373. DOI : 10.1006/imms.1993.1022. URL : https://www.sciencedirect.com/science/article/pii/S0020737383710229 (visité le 29/09/2026).

[10] Samuel Nii Odoi DEVINE, Emmanuel Awuni KOLOG et Roger ATINGA. « Toward a Knowledge-Based System for African Traditional Herbal Medicine : A Design Science Research Approach ». In : *Frontiers in Artificial Intelligence* 5 (2022). PMC8959699, p. 856705. DOI : 10.3389/frai.2022.856705. URL : https://doi.org/10.3389/frai.2022.856705.

[11] Jacob Devlin et al. « BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding ». In : *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*. 2019, p. 4171-4186. doi : 10.18653/v1/N19-1423. url : https://aclanthology.org/N19-1423/.

[12] Keffa Denis Diomande et al. « Traditional Medicinal Practices of African Bone-Setters : Aspects of an Ontology of the Field ». In : *International Journal of Advanced Research* 12.5 (2024), p. 773-786. url : https://www.journalijar.com/article/48743/traditional-medicinal-practices-of-african-bone-setters:-aspects-of-an-ontology-of-the-field/.

[13] Damion M. Dooley et al. « FoodOn : A Harmonized Food Ontology to Increase Global Food Traceability, Quality Control and Data Integration ». In : *npj Science of Food* 2 (2018), p. 23. doi : 10.1038/s41538-018-0032-6. url : https://www.nature.com/articles/s41538-018-0032-6.

[14] Jérôme Euzenat et Pavel Shvaiko. *Ontology Matching*. 2e éd. Springer, 2013. doi : 10.1007/978-3-662-43550-9. url : https://doi.org/10.1007/978-3-662-43550-9.

[15] Élisabeth Flahaut. « Pharmacopée et médecine traditionnelle dans l'Ouest du Burkina Faso : plantes médicinales et soins du couple mère-enfant ». 143 pages. Thèse de doctorat en pharmacie. Université de Lille II, 1999. url : https://passioneuro.fr/wp-content/Documents/These_E-FLAHAUT_1999.pdf.

[16] Luciano Floridi et al. « AI4People—An Ethical Framework for a Good AI Society : Opportunities, Risks, Principles, and Recommendations ». In : *Minds and Machines* 28.4 (2018), p. 689-707. doi : 10.1007/s11023-018-9482-5.

[17] Ralph Grishman. « Twenty-five Years of Information Extraction ». In : *Natural Language Engineering* 25.6 (2019), p. 677-692. doi : 10.1017/S1351324919000512.

[18] Thomas R. Gruber. « A Translation Approach to Portable Ontology Specifications ». In : *Knowledge Acquisition* 5.2 (1993), p. 199-220. doi : 10.1006/knac.1993.1008. url : https://doi.org/10.1006/knac.1993.1008.

[19] Nicola Guarino. « Formal Ontology, Conceptual Analysis and Knowledge Representation ». In : *International Journal of Human-Computer Studies* 43.5–6 (1995), p. 625-640. doi : 10.1006/ijhc.1995.1066.

[20] Sita Guinko. « La végétation de la Haute-Volta ». Deux volumes, 394 pages. Thèse de doctorat ès sciences. Université de Bordeaux III, 1984. url : https://www.scirp.org/reference/referencespapers?referenceid=3387847.

[21] John Hanna et al. « Building a Drug Ontology Based on RxNorm and Other Public Domain Drug Databases ». In : *Journal of Biomedical Semantics* 4 (2013), p. 44. doi : 10.1186/2041-1480-4-44. url : https://pubmed.ncbi.nlm.nih.gov/24345026/.

[22] Michael Heinrich et al. *Fundamentals of Pharmacognosy and Phytotherapy*. Edinburgh : Churchill Livingstone, 2004. isbn : 978-0-443-07132-4.

[23] Robert Hoehndorf et al. « The Flora Phenotype Ontology (FLOPO) : Tool for Integrating Morphological Traits and Phenotypes of Vascular Plants ». In : *Journal of Biomedical Semantics* 7 (2016), p. 65. doi : 10.1186/s13326-016-0107-8. url : https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5109718/.

[24] Syed Hussain et Gihan Athula. « Extending a Conventional Chatbot Knowledge Base to External Knowledge Source and Introducing User Based Sessions for Diabetes Education ». In : (2018), p. 698-703. url : https://ieeexplore.ieee.org/abstract/document/8418155.

[25] Daniel Jurafsky et James H. Martin. *Speech and Language Processing*. 3e éd. 2023. url : https://web.stanford.edu/~jurafsky/slp3/ (visité le 26/09/2026).

[26] Michel C. A. Klein et Dieter Fensel. « Ontology Versioning on the Semantic Web ». In : *Proceedings of the First International Semantic Web Working Symposium (SWWS)*. Stanford, CA, USA, 2001, p. 75-91.

[27] Janet L. Kolodner. *Case-Based Reasoning*. San Mateo, CA, USA : Morgan Kaufmann, 1993. isbn : 1-55860-237-2.

[28] Appoh Kouamé. « Système de gestion de la médecine traditionnelle dans une plateforme web social et sémantique : une approche basée sur une ontologie visuelle ». fr. Thèse de doct. Université Gaston Berger de Saint-Louis (Sénégal), avr. 2018. url : https://hal.science/tel-01842116 (visité le 12/06/2026).

[29] Appoh Kouamé et al. « Visual Representation of African Traditional Medicine Recipes Using Icons and a Formal Ontology, ontoMEDTRAD ». In : *Digital Personalized Health and Medicine – Proceedings of MIE 2020*. T. 270. Studies in Health Technology and Informatics. IOS Press, 2020, p. 791-795. doi : 10.3233/SHTI200269. url : https://ebooks.iospress.nl/doi/10.3233/SHTI200269.

[30] Patrick Lewis et al. « Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks ». In : *Advances in Neural Information Processing Systems*. T. 33. 2020, p. 9459-9474. url : https://arxiv.org/abs/2005.11401.

[31] Mariano Fernández-López et No affiliation. « (PDF) Overview and analysis of methodologies for building ontologies ». en. In : *ResearchGate* (). doi : 10.1017/S0269888902000462. url : https://www.researchgate.net/publication/231908719_Overview_and_analysis_of_methodologies_for_building_ontologies (visité le 29/09/2026).

[32] Meta AI. *Introducing Meta Llama 3 : The Most Capable Openly Available LLM to Date*. Meta AI Blog. Avr. 2024. url : https://ai.meta.com/blog/meta-llama-3/.

[33] Jeanne Millogo-Rasolodimby. « L'homme, le climat et les ressources alimentaires végétales en période de crises de subsistance au Burkina Faso ». Thèse de doctorat ès sciences naturelles. Université de Ouagadougou, 2001. url : https://journals.openedition.org/vertigo/16758.

[34] Odile G. Nacoulma-Ouedraogo. « Plantes médicinales et pratiques médicales traditionnelles au Burkina Faso : cas du plateau central ». Thèse de doctorat d'État. Université de Ouagadougou, 1996. url : https://publication.lecames.org/index.php/pharm/article/download/13/32.

[35] David Nadeau et Satoshi Sekine. « A Survey of Named Entity Recognition and Classification ». In : *Lingvisticae Investigationes* 30.1 (2007), p. 3-26. doi : 10.1075/li.30.1.02nad.

[36] Roberto Navigli, Paola Velardi et Aldo Gangemi. « Ontology Learning and Its Application to Automated Terminology Translation ». In : *IEEE Intelligent Systems* 18.1 (2003), p. 22-31. doi : 10.1109/MIS.2003.1179190.

[37] Fnu Neha, Deepshikha Bhati et Deepak Kumar Shukla. « Retrieval-Augmented Generation (RAG) in Healthcare : A Comprehensive Review ». en. In : *AI* 6.9 (sept. 2025), p. 226. issn : 2673-2688. doi : 10.3390/ai6090226. url : https://www.mdpi.com/2673-2688/6/9/226 (visité le 06/08/2026).

[38] L. Ouédraogo et al. « Ethnobotanical Use and Conservation Assessment of Medicinal Plants Sold in Markets of Burkina Faso ». In : *Ethnobotany Research and Applications* 20 (2020), p. 1-25. doi : 10.32859/era.20.39.1-25. url : https://ethnobotanyjournal.org/index.php/era/article/view/2259.

[39] W Jedida Ouedraogo et al. « Revue des Plantes Médicinales à Potentiel Aromatique du Burkina Faso ». fr. In : 2 (2024).

[40] Pascal Nadembega et al. « An ethnobotanical survey of medicinal plants used for children's healthcare in Centre-Est Burkina Faso ». en. In : *ResearchGate* (sept. 2026). doi : 10.32859/era.33.22.1-28. url : https://www.researchgate.net/publication/400337444_An_ethnobotanical_survey_of_medicinal_plants_used_for_children's_healthcare_in_Centre-Est_Burkina_Faso.

[41] Colin Raffel et al. « Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer ». In : *Journal of Machine Learning Research* 21.140 (2020), p. 1-67. url : https://jmlr.csail.mit.edu/beta/papers/v21/20-074.html.

[42] D. L. Sackett et al. « Evidence based medicine : what it is and what it isn't ». eng. In : *BMJ* 312.7023 (jan. 1996), p. 71-72. issn : 0959-8138. doi : 10.1136/bmj.312.7023.71.

[43] Hassan Shojaee-Mend, Haleh Ayatollahi et Azam Abdolahadi. « Development and Evaluation of Ontologies in Traditional Medicine : A Review Study ». eng. In : *Methods of Information in Medicine* 58.6 (déc. 2019), p. 194-204. issn : 2511-705X. doi : 10.1055/s-0040-1702236.

[44] SNOMED International. *SNOMED CT : Systematized Nomenclature of Medicine – Clinical Terms*. International Health Terminology Standards Development Organisation (IHTSDO). 2020. url : https://www.snomed.org/.

[45] Borlli Michel Jonas Somé et al. « Design Considerations for a Knowledge Graph : The WATRIMed Use Case ». In : *Healthcare of the Future : Bridging the Information Gap*. T. 259. Studies in Health Technology and Informatics. IOS Press, 2019, p. 59-64. url : https://healthcareofthefuture.ch/wp-content/uploads/2022/03/proceedings_HoF_2019.pdf.

[46] Borlli Michel Jonas Somé et al. « Enabling West African Herbal-Based Traditional Medicine Digitizing : The WATRIMed Knowledge Graph ». In : *MEDINFO 2019 : Health and Wellbeing e-Networks for All*. T. 264. Studies in Health Technology and Informatics. IOS Press, 2019, p. 1548-1549. doi : 10.3233/SHTI190528. url : https://ebooks.iospress.nl/doi/10.3233/SHTI190528.

[47] Abdoulaye Souley. « Trois entités hausa parentes : zahi, sanyi et shawara ». In : *La construction sociale des maladies : les entités nosologiques populaires en Afrique de l'Ouest*. Sous la dir. d'Yannick Jaffré et Jean-Pierre Olivier de Sardan. Presses Universitaires de France, 1999. url : https://horizon.documentation.ird.fr/exl-doc/pleins_textes/divers17-11/010050662.pdf.

[48] Rudi Studer, V. Richard Benjamins et Dieter Fensel. « Knowledge Engineering : Principles and Methods ». In : *Data & Knowledge Engineering* 25.1–2 (1998), p. 161-197. doi : 10.1016/S0169-023X(97)00056-6. url : https://doi.org/10.1016/S0169-023X(97)00056-6.

[49] A. A. Tekemetieu, S. Koussoube et L. P. Fotso. « An Ontology-Based Computer-Aided Diagnosis System in African Traditional Medicine : At the Sorcerer's Stone ». In : *Kybernetes* 45.1 (2016), p. 30-50. url : https://www.ajol.info/index.php/jcmphc/article/download/252453/238490.

[50] André Tibiri et al. « Countrywide Survey of Plants Used for Liver Disease Management by Traditional Healers in Burkina Faso ». In : *Frontiers in Pharmacology* 11 (2020), p. 563751. doi : 10.3389/fphar.2020.563751. url : https://pmc.ncbi.nlm.nih.gov/articles/PMC7883685/.

[51] Mbih Jerome Tosam. « Metaphysical Issues in African Philosophy of Medicine ». In : *African Philosophy of Medicine*. Springer, 2024. doi : 10.1007/978-3-031-73963-7_12. url : https://link.springer.com/chapter/10.1007/978-3-031-73963-7_12.

[52] Safiatou Traoré et al. « Ethnobotanical Survey on Plants Used in the Treatment of Wounds by Traditional Health Practitioners in Burkina Faso ». In : *International Journal of Plant, Animal and Environmental Sciences* 15 (2025). URL : https://www.progres.ujkz.gov.bf/publications/11832/details.

[53] Ashish Vaswani et al. « Attention Is All You Need ». In : *Advances in Neural Information Processing Systems*. T. 30. 2017. URL : https://arxiv.org/abs/1706.03762.

[54] W3C. *OWL 2 Web Ontology Language Document Overview*. 2012. URL : https://www.w3.org/TR/owl2-overview/ (visité le 26/09/2026).

[55] W3C. *RDF 1.1 Concepts and Abstract Syntax*. 2014. URL : https://www.w3.org/TR/rdf11-concepts/ (visité le 26/09/2026).

[56] W3C. *SKOS Simple Knowledge Organization System Reference*. 2009. URL : https://www.w3.org/TR/skos-reference/ (visité le 26/09/2026).

[57] World Health Organization. *General Guidelines for Methodologies on Research and Evaluation of Traditional Medicine*. Geneva, 2000. URL : https://iris.who.int/handle/10665/66783 (visité le 26/09/2026).

[58] World Health Organization. *WHO Monographs on Selected Medicinal Plants*. Geneva, 2002. URL : https://iris.who.int/bitstream/handle/10665/42052/9789241547024_eng.pdf (visité le 26/09/2026).

[59] World Health Organization. *WHO Traditional Medicine Strategy 2014–2023*. Geneva, 2013. URL : https://iris.who.int/bitstream/handle/10665/92455/9789241506090_eng.pdf (visité le 26/09/2026).

[60] P Zerbo et al. « Contribution à la connaissance des plantes médicinales utilisées dans les soins infantiles en pays San, au Burkina Faso ». In : *International Journal of Biological and Chemical Sciences* 1.3 (jan. 2007), p. 262-274. ISSN : 1991-8631. DOI : 10.4314/ijbcs.v1i3.39704. URL : http://www.ajol.info/index.php/ijbcs/article/view/39704 (visité le 05/08/2026).

[61] Patrice Zerbo et al. « Plantes médicinales et pratiques médicales au Burkina Faso : cas des Sanan ». In : *BOIS & FORETS DES TROPIQUES* 307 (mars 2011), p. 41-53. ISSN : 1777-5760, 0006-579X. DOI : 10.19182/bft2011.307.a20481. URL : https://revues.cirad.fr/index.php/BFT/article/view/20481 (visité le 05/08/2026).

[62] Alexander Zizka et al. « Traditional plant use in Burkina Faso (West Africa) : a national-scale analysis with focus on traditional medicine ». en. In : *Journal of Ethnobiology and Ethnomedicine* 11.1 (déc. 2015), p. 9. ISSN : 1746-4269. DOI : 10.1186/1746-4269-11-9. URL : https://ethnobiomed.biomedcentral.com/articles/10.1186/1746-4269-11-9 (visité le 05/08/2026).

[63] Koudbi Jacob Zongo et al. « Ethnopharmacological Study on Medicinal Plants Used for Jaundice and Liver-Related Disorders Management in the Province of Kouritenga in the Central-Eastern of Burkina Faso ». In : *Journal of Advanced Translational and Preclinical Biomedicine* 4.1 (2025). DOI : 10.57220/jatpb.v4i1.213. URL : https://boa.unimib.it/retrieve/444bc5b3-4483-4e23-a45d-f0fe28fbb91a/Zongo%20et%20al-2025-JATPB-VoR.pdf.