Burkina Faso

La Patrie ou la Mort, nous Vaicrons

Ministère de l'Enseignement Supérieur
et de la Recherche Scientifique

Université Joseph Ki-Zerbo

Institut Burkinabè des Arts et Métiers

MÉMOIRE POUR L'OBTENTION DU MASTER II EN INFORMATIQUE

Option : Ingénierie des Systèmes d'Information en Entreprise

Par

Sanou Lougoudoro

Adaptation et enrichissement d'une ontologie pour un accès intelligent et traçable aux connaissances scientifiques sur les plantes médicinales du Burkina Faso

Encadreur : Dr. Belko Abdoul Aziz DIALLO **PhD**

Annee Universitaire 2025 – 2026

Dédicace

Remerciements

Resumé

Abstract

Table des figures

1 Dispersion des connaissances scientifiques 2
2 Démarche méthodologique adoptée 4

I.1 Hiérarchie des niveaux de preuve 11
I.2 Les langages du web sémantique 13

II.1 Constitution du corpus documentaire 32
II.2 Dispositif technique d'expérimentation 35

Liste des tableaux

I.1 Synthèse comparative des ontologies de la littérature 28

II.1 Sources du corpus documentaire 33
II.2 Ontologies candidates pour la comparaison 34
II.3 Modes d'accès à Llama 3 70B 35
II.4 Caractéristiques de Neo4j Desktop 36
II.5 Composants LangChain utilisés 36
II.6 Bibliothèques Python utilisées 37
II.7 Récapitulatif du matériel 38
II.8 Correspondance entre le matériel et les phases 38
II.9 Grille de critères de comparaison 39
II.10 Notation des ontologies candidates 40
II.11 Critères d'évaluation de l'ontologie 46
II.12 Critères d'évaluation du système RAG 46
II.13 Critères d'évaluation de l'application web 47
II.14 Correspondance entre les phases, les objectifs et les livrables 47

Liste des sigles et abréviations

Sigle ou abréviation	Signification
API	Application Programming Interface
BERT	Bidirectional Encoder Representations from Transformers
BFO	Basic Formal Ontology
CI50	Concentration Inhibitrice 50 %
CSV	Comma-Separated Values
DL50	Dose Létale 50 %
DOI	Digital Object Identifier
DPPH	2,2-diphényl-1-picrylhydrazyle
DrOn	Drug Ontology
FLOPO	Flora Ontology
FOODON	Food Ontology
GC-MS	Gas Chromatography-Mass Spectrometry
GPT	Generative Pre-trained Transformer
GPU	Graphics Processing Unit
HPLC	High-Performance Liquid Chromatography
HTM	Herbal Traditional Medicine Ontology
IA	Intelligence Artificielle
IC50	Concentration Inhibitrice médiane de 50 %
IHTSDO	International Health Terminology Standards Development Organisation
INERA	Institut National de l'Environnement et de la Recherche Appliquée
JSON	JavaScript Object Notation
LLM	Large Language Model
NER	Named Entity Recognition
NLP	Natural Language Processing
OCR	Optical Character Recognition
OMS	Organisation Mondiale de la Santé
OTM	Ontology of Traditional Medicine
OWL	Web Ontology Language
PNPMT	Programme National de Promotion de la Médecine Traditionnelle
PO	Plant Ontology
RAG	Retrieval-Augmented Generation
RDF	Resource Description Framework
RDFS	RDF Schema
SKOS	Simple Knowledge Organization System
SNOMED CT	Systematized Nomenclature of Medicine – Clinical Terms
SPARQL	SPARQL Protocol and RDF Query Language
T5	Text-to-Text Transfer Transformer
TALN	Traitement Automatique du Langage Naturel
TPU	Tensor Processing Unit
UICN	Union Internationale pour la Conservation de la Nature
W3C	World Wide Web Consortium
WATRIMed	West African Herbal-based Traditional Medicine
XML	Extensible Markup Language

Table des matières

Dédicace i

Remerciements ii

Resumé iii

Abstract iv

Table des figures v

Liste des tableaux vi

Liste des sigles et abréviations vii

Introduction générale 1

I Cadre théorique et revue de littérature 8
- I.1 Plantes médicinales et connaissances scientifiques au Burkina Faso . . . 8
  - I.1.1 Concepts fondamentaux . . . 8
  - I.1.2 Plantes médicinales documentées dans la littérature scientifique . . . 9
  - I.1.3 Types de connaissances et niveaux de preuve . . . 10
- I.2 Ingénierie des connaissances et ontologies . . . 12
  - I.2.1 Représentation des connaissances . . . 12
  - I.2.2 Ontologies et réutilisation d'ontologies existantes . . . 13
  - I.2.3 Adaptation, alignement et enrichissement ontologique . . . 14
  - I.2.4 Bases de connaissances et interrogation sémantique . . . 15
- I.3 Intelligence artificielle pour l'accès aux connaissances . . . 17
  - I.3.1 Traitement des requêtes en langage naturel . . . 17
  - I.3.2 Extraction et structuration assistées par IA . . . 18
  - I.3.3 Recherche sémantique et génération de réponses . . . 19
  - I.3.4 Traçabilité et fiabilité des réponses . . . 20
- I.4 Travaux connexes et positionnement scientifique . . . 21
  - I.4.1 Ontologies dans le domaine des plantes médicinales . . . 21
  - I.4.2 Systèmes intelligents d'accès aux connaissances . . . 29
  - I.4.3 Positionnement de notre recherche . . . 30

Conclusion du chapitre . . . 30

II Matériel et méthodologie 31
- II.1 Matériel . . . 31
  - II.1.1 Corpus documentaire . . . 31
  - II.1.2 Ontologies candidates . . . 34
  - II.1.3 Outils et environnement technique . . . 34

II.1.4 Tableau récapitulatif du matériel 37
II.1.5 Tableau de correspondance Matériel - Phases 38
II.2 Méthodologie 38
II.2.1 Phase 1 : Identification et étude comparative des ontologies 39
II.2.2 Phase 2 : Définition des critères de recherche et de sélection des documents . 40
II.2.3 Phase 3 : Constitution du corpus scientifique 41
II.2.4 Phase 4 : Adaptation de l'ontologie sélectionnée 42
II.2.5 Phase 5 : Enrichissement des connaissances à partir de la littérature scientifique 43
II.2.6 Phase 6 : Construction et interrogation de la base de connaissances 44
II.2.7 Phase 7 : Exploitation par IA et développement de l'application web 45
II.2.8 Phase 8 : Évaluation et validation 46
II.3 Synthèse et transition 47
II.3.1 Tableau de correspondance Phases - Livrables 47
Conclusion du chapitre 47

Bibliographie **48**

Introduction générale

Contexte et justification du sujet

Au Burkina Faso, les plantes médicinales occupent une place centrale dans les pratiques de santé. L'Organisation mondiale de la santé rappelle que la médecine traditionnelle demeure, pour une large part des populations des pays en développement, le premier recours de soins [57]. Dans le pays, une grande partie de la population, majoritairement rurale, dépend fortement des produits végétaux locaux pour se soigner [59]. Cette importance est reconnue au niveau national, puisque le Ministère de la Santé a engagé un projet d'herbier national dédié aux plantes médicinales, couplé à une chimiothèque de marqueurs chimiques. Ces plantes font par ailleurs l'objet de nombreux travaux scientifiques [38], qui portent sur leurs identifications, leurs usages, leurs propriétés pharmacologiques et leurs toxicités.

Le problème ne vient pas d'un manque de connaissances, mais de leur dispersion. Les informations disponibles sont éparpillées dans la littérature scientifique [59] : articles, thèses, mémoires, rapports de recherche, inventaires ethnobotaniques et plateformes numériques. S'y ajoutent les données institutionnelles, comme celles de l'Herbier National des Plantes Médicinales ou de l'INERA. Or ces documents n'emploient pas les mêmes terminologies. Une même plante y est souvent désignée par plusieurs synonymes ou noms vernaculaires. Il devient alors difficile de comparer les résultats d'une étude à l'autre, de retrouver une information précise sur une plante ou une maladie, et de remonter à la source qui la soutient.

Ce sont des personnes concrètes qui en pâtissent. Le chercheur y perd un temps précieux. L'étudiant ne sait pas toujours à quelle source se fier. Le tradipraticien, qui détient une part de ce savoir, dispose de peu d'outils pour le confronter aux travaux scientifiques. Le patient, au bout de la chaîne, reçoit parfois des conseils dont personne ne peut vérifier l'origine. La communauté, qui détient et transmet ces savoirs, n'a pas non plus de moyen simple de les retrouver réunis. Or ces plantes ne sont pas anodines : certaines sont toxiques à forte dose, et la posologie compte. Retrouver, pour chaque information, la source qui la fonde n'est donc pas un luxe de chercheur. C'est une condition de confiance.

Les ontologies offrent un moyen de répondre à ce désordre. Elles donnent aux concepts d'un domaine, une définition claire et des relations explicites. Les connaissances deviennent alors interopérables et interrogeables [58].

C'est dans cette perspective que s'inscrit notre travail, sans prétendre construire une ontologie entièrement nouvelle. Plutôt que de partir de zéro, nous reprendrons un modèle existant consacré aux plantes médicinales pour l'adapter au contexte burkinabè et l'enrichir à partir de la littérature scientifique. L'intelligence artificielle interviendra ensuite pour faciliter l'accès à ces connaissances : interpréter des requêtes formulées en langage naturel, retrouver l'information pertinente dans la base de connaissances, et présenter le résultat de manière accessible. Une application web assurera l'interface entre l'utilisateur et notre dispositif. Chaque réponse restera rattachée aux sources scientifiques qui l'ont fondée.

Trois éléments sont ainsi rapprochés dans notre recherche : une ontologie existante, les connaissances scientifiques sur les plantes médicinales du Burkina Faso, et des mécanismes d'accès intelligent fondés sur l'intelligence artificielle (figure 1).

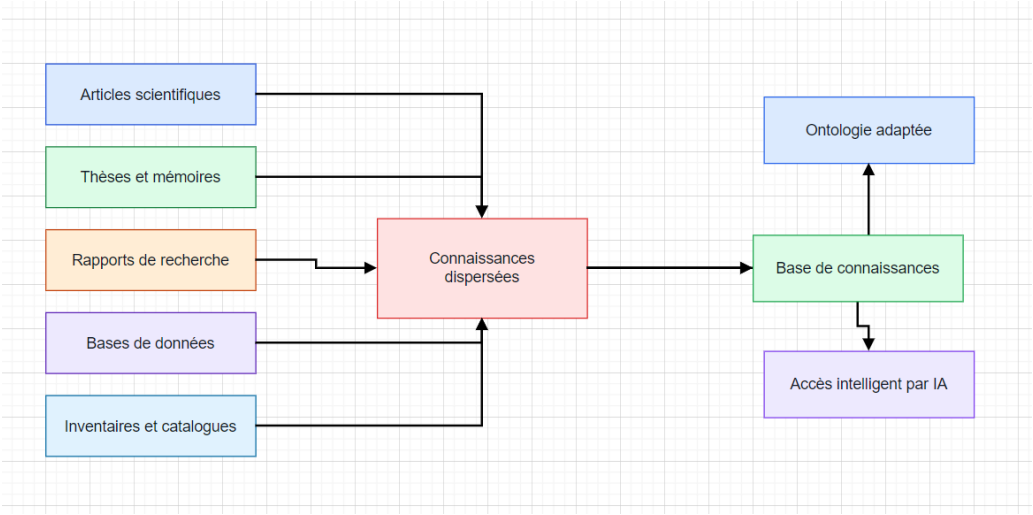


FIGURE 1 – Dispersion des connaissances scientifiques

Problématique de la recherche

Les connaissances scientifiques sur les plantes médicinales du Burkina Faso sont abondantes [38] et proviennent de sources aussi variées que des articles, des thèses, des mémoires, des rapports de recherche et des bases de données institutionnelles [59]. Leur exploitation, en revanche, pose problème. Les ontologies apparaissent comme un moyen de les structurer [41], en représentant les concepts d'un domaine et les relations entre ces concepts, ce qui ouvre la voie à l'interopérabilité et à une interrogation plus fine. Mais aucune ne répond nécessairement aux besoins du contexte burkinabè : nous devons donc identifier les modèles disponibles, juger de leur pertinence, et n'en retenir qu'un. À cela s'ajoute une seconde difficulté, qui concerne l'accès. Une base structurée peut être riche sans être compréhensible. L'intelligence artificielle est précisément susceptible de remédier à cet écart [36], en acceptant des requêtes en langage naturel, en allant chercher les informations pertinentes et en les restituant sous une forme accessible.

L'étude qui suit cherche donc à relier trois dimensions : des connaissances issues de la littérature scientifique, leur organisation dans une ontologie adaptée et enrichie, et leur exploitation par l'intelligence artificielle au moyen d'une application web. La question principale se presente ainsi :

> *Comment enrichir une ontologie existante à partir de la littérature scientifique sur les plantes médicinales du Burkina Faso, puis utiliser l'intelligence artificielle pour l'interroger et obtenir des réponses pertinentes, traçables, en langage naturel et fidèles aux sources scientifiques ?*

Quatre questions spécifiques en découlent :

— Quelles ontologies existantes peuvent représenter les connaissances sur les plantes médicinales, et sur quels critères les comparer afin de retenir la plus adaptée au contexte burkinabè ?

— Quelles adaptations et quels enrichissements sont nécessaires pour intégrer les connaissances issues de la littérature scientifique sur les plantes médicinales du Burkina Faso, tout en garantissant la traçabilité vers les sources ?

— Comment exploiter l'ontologie adaptée et enrichie avec l'intelligence artificielle (LLM, RAG) pour faciliter l'accès aux connaissances en langage naturel ?

— Comment concevoir une application web permettant la consultation, la recherche et la compréhension des connaissances documentées sur les plantes médicinales du Burkina Faso ?

Objectif général et objectifs spécifiques

De cette problématique découlent un objectif général, qui énonce la finalité du travail, et des objectifs spécifiques, qui la décomposent en actions concrètes et évaluables. Ils guideront la démarche méthodologique et permettront d'apprécier ce que la recherche apporte effectivement.

Objectif général

Notre objectif général est d'adapter et d'enrichir une ontologie existante afin de représenter les connaissances issues de la littérature scientifique sur les plantes médicinales du Burkina Faso, puis d'exploiter ces connaissances par l'intelligence artificielle au moyen d'une application web pour faciliter leur accès et leur diffusion.

Objectifs spécifiques

— Identifier et comparer les ontologies existantes dans le domaine des plantes médicinales afin de sélectionner la plus pertinente pour le contexte burkinabè.

— Adapter et enrichir l'ontologie sélectionnée à partir de la littérature scientifique sur les plantes médicinales du Burkina Faso, en assurant la traçabilité des connaissances vers leurs sources.

— Construire une base de connaissances orientée graphe et mettre en place un système d'accès intelligent (RAG) exploitant l'ontologie enrichie.

— Développer une application web permettant la recherche, la consultation et la compréhension des connaissances documentées sur les plantes médicinales du Burkina Faso.

Hypothèses de recherche

Pour répondre aux questions posées et atteindre les objectifs fixés, notre étude repose sur cinq hypothèses. La première porte sur la démarche ontologique, la deuxième sur la méthodologie d'extraction, la troisième sur l'adaptation et l'enrichissement, la quatrième sur l'accès intelligent et la cinquième sur la diffusion. Chacune sera vérifiée au fil de la recherche.

1. **Hypothèse 1 :** Une revue méthodique et systématique de la littérature scientifique permet d'identifier et d'enrichir un modèle ontologique capable de représenter les connaissances sur les plantes médicinales du Burkina Faso
2. **Hypothèse 2 :** L'utilisation de modèles de langue de grande taille (LLM) améliore l'extraction automatique des connaissances à partir de la littérature scientifique, comparativement aux méthodes manuelles.
3. **Hypothèse 3 :** L'adaptation et l'enrichissement de l'ontologie sélectionnée permettent de mieux représenter les connaissances documentées dans la littérature scientifique sur les plantes médicinales du Burkina Faso, tout en assurant leur traçabilité.
4. **Hypothèse 4 :** L'exploitation de l'ontologie enrichie par un système RAG facilite la recherche et la compréhension des connaissances en langage naturel.
5. **Hypothèse 5 :** Une application web intégrant le système RAG permet de mieux vulgariser et diffuser les connaissances scientifiques documentées sur les plantes médicinales du Burkina Faso.

Démarche méthodologique adoptée

La démarche adoptée est progressive. Elle articule une revue de littérature, une étude comparative des ontologies, l'ingénierie des connaissances, l'intelligence artificielle et le développement logiciel, selon les huit phases de la figure 2. Chaque phase produit des livrables qui servent la suivante, et la validation intervient à plusieurs étapes pour sécuriser la qualité des résultats.

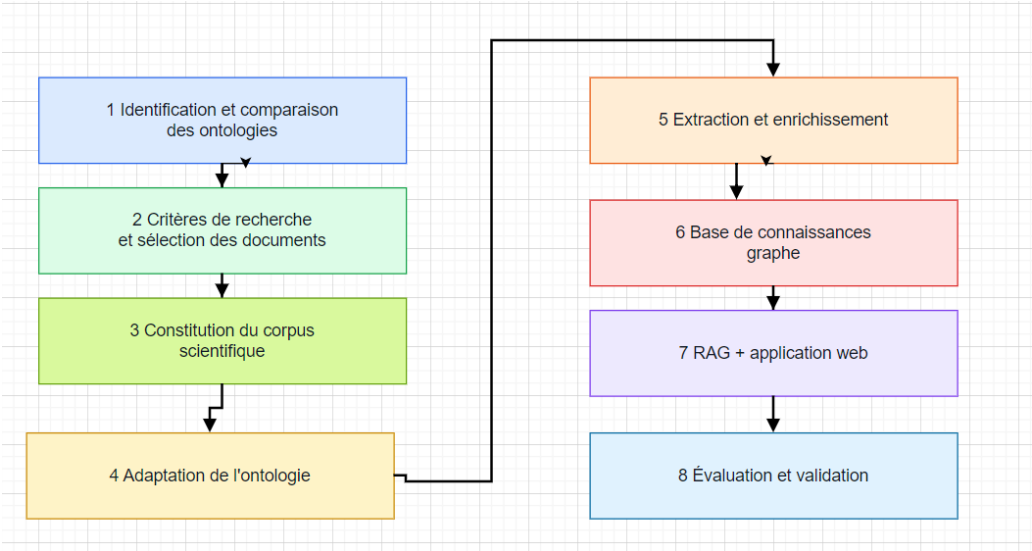


FIGURE 2 – Démarche méthodologique adoptée

Phase 1 : Identification et étude comparative des ontologies

La première phase identifie les ontologies existantes du domaine des plantes médicinales, en les recherchant dans la littérature scientifique et dans les bases de données spécialisées. Nous les comparerons à l'aide d'une grille de critères portant sur la couverture du domaine, la richesse sémantique, la disponibilité, la documentation, l'interopérabilité, l'adaptabilité au contexte burkinabè, la traçabilité et la prise en compte des savoirs locaux. Chacune sera notée sur cette grille, et celle qui obtiendra le score le plus élevé sera retenue. Cette phase conditionne la suite du travail, puisqu'elle détermine le modèle conceptuel qui guidera l'ensemble des étapes ultérieures. Son livrable est l'ontologie sélectionnée.

Phase 2 : Définition des critères de collection des documents

La deuxième phase fixe les critères qui encadreront la recherche et la sélection des documents scientifiques, de manière à garantir la pertinence, la qualité et la cohérence des sources mobilisées. Les critères de recherche portent sur les plantes, les parties utilisées, les pathologies et usages médicinaux, les modes de préparation, les niveaux de preuve, les propriétés pharmacologiques et la composition chimique. Ceux de sélection tiennent à la pertinence du document, à l'identification de la plante, à la disponibilité d'une référence scientifique, à la fiabilité et à l'actualité. De ce corpus sûr et cohérent dépendra la suite des travaux. Le livrable est la grille de critères de recherche et de sélection.

Phase 3 : Constitution du corpus scientifique

La troisième phase réunit les documents scientifiques portant sur les plantes médicinales du Burkina Faso : articles, thèses, mémoires et rapports de recherche. Les critères d'inclusion et d'exclusion définis précédemment s'appliquent, avec une vérification systématique de la pertinence du document,

de l'identification de la plante et de l'existence d'une référence scientifique. Chaque information retenue est conservée avec sa provenance. Le corpus ainsi constitué, organisé et indexé, forme la base documentaire de notre étude.

Phase 4 : Adaptation de l'ontologie sélectionnée

La quatrième phase adapte l'ontologie retenue au contexte des plantes médicinales du Burkina Faso. L'analyse des concepts existants conduit à distinguer ceux que nous conservons, ceux que nous modifions et ceux que nous ajoutons. Nous ajouterons des classes pour les maladies spécifiques au pays, les noms vernaculaires en langues locales, les régions et les niveaux de preuve, ainsi que des propriétés pour les noms vernaculaires, la localisation géographique, les niveaux de preuve et la traçabilité. Nous modifierons les relations pour préciser leur sémantique et garantir la traçabilité, en préservant autant que possible la compatibilité avec la structure initiale. Nous documenterons chaque adaptation. Le livrable est une ontologie adaptée au contexte burkinabè.

Phase 5 : Enrichissement des connaissances à partir de la littérature scientifique

La cinquième phase enrichit l'ontologie à partir du corpus constitué en phase 3 et filtré selon les critères de la phase 2. L'extraction est assistée par l'intelligence artificielle, au moyen de prompts adressés à des modèles de langue de grande taille (LLM) pour identifier les plantes, leurs usages, les parties utilisées, les modes de préparation et les propriétés pharmacologiques, tels que documentés dans les sources. Les résultats sont produits dans des formats structurés (JSON, CSV). Nous conserverons les références bibliographiques et, lorsque cela est possible, la page ou la section dont proviennent les informations, en distinguant les usages rapportés par les études ethnobotaniques des résultats issus d'études expérimentales. Nous retiendrons les niveaux de preuve associés aux connaissances tels que les rapportent les sources, sans réévaluation indépendante, et la qualité des extractions sera appréciée par le protocole d'évaluation de la phase 8. Le livrable est un ensemble de données structurées prêtes à être intégrées dans la base de connaissances orientée graphe. Ces données ne sont pas versées dans l'ontologie, qui n'en fournit que le schéma.

Phase 6 : Construction et interrogation de la base de connaissances

La sixième phase construit la base de connaissances orientée graphe, dont l'ontologie adaptée et enrichie fournit la structure. Les données extraites deviennent des instances correspondant aux concepts définis. Le choix du graphe se justifie par sa capacité à modéliser naturellement les relations complexes entre plantes, usages, propriétés et sources. Nous rattacherons chaque connaissance importante à sa source, de sorte qu'il soit toujours possible de retrouver l'origine d'une information. L'interrogation s'effectuera en Cypher ou en SPARQL, et nous définirons des scénarios de recherche portant sur une plante, un usage médicinal, une partie utilisée ou une source scientifique. Le livrable est une base Neo4j peuplée et interrogeable.

Phase 7 : Exploitation par IA et développement de l'application web

La septième phase constitue le cœur de l'objectif d'accès intelligent. L'accès est assuré par un système RAG (Retrieval-Augmented Generation), qui combine recherche d'informations dans la base de connaissances et génération de réponses par un modèle de langage. Le système interprète la requête en langage naturel, interroge la base pour retrouver les informations pertinentes, puis formule une réponse fondée sur les faits retrouvés. La traçabilité en découle, chaque information étant liée à sa source scientifique. L'application web qui nous servira d'interface proposera une recherche en langage naturel et des fiches sur les plantes, leurs usages documentés, les parties utilisées, les modes de préparation

et les références correspondantes. Les réponses resteront liées aux sources disponibles. Précisons qu'il s'agit d'un outil de consultation : il ne constitue ni un dispositif de diagnostic, ni un système de prescription. Le livrable est un système RAG fonctionnel et une application web fonctionnelle.

Phase 8 : Évaluation et validation

La huitième phase évalue et valide l'approche, à trois niveaux. L'ontologie d'abord, dont nous vérifierons la couverture, la cohérence, la traçabilité et l'extensibilité. Le système RAG ensuite, dont nous mesurerons la pertinence, la fidélité, l'exactitude et la traçabilité. L'application web enfin, évaluée sur sa facilité d'utilisation, sa compréhension, son utilité et ses performances. L'évaluation sollicitera des participants : étudiants, chercheurs et tradipraticiens. Le livrable est un rapport d'évaluation et de validation.

Délimitation du champ d'étude

Notre étude porte sur les plantes médicinales documentées au Burkina Faso, et sur les connaissances relatives à leurs usages médicinaux et à leurs propriétés biologiques lorsqu'une source scientifique les rapporte. Ces connaissances proviendront de la littérature accessible et vérifiable. Aucune enquête de terrain directe n'est prévue dans le cadre de notre travail.

Le travail consiste à sélectionner une ontologie existante, puis à l'adapter et à l'enrichir, ce choix étant précédé d'une étude comparative.

Sur le plan technique, il comprendra une base de connaissances orientée graphe, un système RAG pour l'accès intelligent et une application web. L'extraction des connaissances s'appuiera sur des prompts d'IA, qui facilitent l'accès aux connaissances structurées sans être pour autant une source scientifique autonome : les documents scientifiques restent la référence.

Le système s'adresse donc à la consultation, à la vulgarisation et à la diffusion scientifique. Il ne remplace pas l'avis d'un professionnel de santé et ne sert ni à poser un diagnostic, ni à établir une prescription.

Résultats attendus

Au terme de notre recherche, nous attendons :

— La constitution d'un corpus scientifique organisé sur les plantes médicinales du Burkina Faso, avec des connaissances rattachées à leurs sources et au niveau de preuve qu'elles y déclarent.

— La réalisation d'une étude comparative des ontologies existantes afin de sélectionner celle qui nous semble la plus pertinente.

— L'adaptation et l'enrichissement de cette ontologie avec les connaissances issues de la littérature scientifique.

— La mise en place d'une base de connaissances graphe traçable, exploitée par le système RAG qui combine la recherche sémantique et la génération de réponses.

— Le développement d'une application web permettant de rechercher, consulter et comprendre les connaissances documentées sur les plantes médicinales du Burkina Faso.

L'intelligence artificielle facilitera l'interprétation des requêtes et l'accès aux informations pertinentes. Les résultats proposés resteront fondés sur les données de la base et sur les références scientifiques associées.

Contribution attendue

La contribution principale de notre recherche sera de réutiliser une ontologie existante et de l'adapter au contexte des plantes médicinales du Burkina Faso, en l'enrichissant à partir des connaissances issues de la littérature scientifique.

Sur le plan scientifique, le travail contribuera à mieux structurer des connaissances dispersées dans plusieurs publications, et à conserver le lien qui unit chaque information à sa source.

Sur le plan technique, la recherche aboutira à une ontologie enrichie, une base de connaissances et un mécanisme d'accès intelligent, l'intelligence artificielle facilitant l'interrogation des connaissances via une application web.

Sur le plan pratique, le système pourra aider les chercheurs, les étudiants et les autres utilisateurs autorisés à accéder plus facilement aux informations documentées. Il facilitera également la recherche bibliographique et l'exploration des relations entre les plantes et les connaissances scientifiques associées.

Structuration du mémoire

Le mémoire est organisé en quatre chapitres numérotés en chiffres romains, précédés de l'introduction générale et suivis de la conclusion générale.

— **Introduction générale (non numérotée).** Le contexte et la justification du sujet y sont exposés, puis la problématique, les questions de recherche, les objectifs et les hypothèses. Y figurent également la démarche méthodologique, la délimitation du champ d'étude et les résultats attendus.

— **Chapitre I :** Cadre théorique et revue de littérature. Les notions liées aux plantes médicinales et aux connaissances scientifiques sur le Burkina Faso y sont présentées, suivies de l'ingénierie des connaissances, des ontologies, des bases de connaissances et de l'intelligence artificielle. Les travaux connexes sont analysés en dernier.

— **Chapitre II :** Matériel et méthodologie. Le corpus scientifique, les critères de sélection et les méthodes d'analyse sont décrits. Les ontologies identifiées, les critères de comparaison et la méthode de sélection sont présentés. Les étapes d'adaptation, d'enrichissement et de validation y sont détaillées.

— **Chapitre III :** Conception et développement du système. L'ontologie sélectionnée et les adaptations réalisées y sont présentées, suivies de la base de connaissances, puis de l'intégration de l'intelligence artificielle et du développement de l'application web.

— **Chapitre IV :** Résultats et discussion. Les résultats de l'étude comparative des ontologies y sont exposés, avec l'ontologie adaptée et enrichie ainsi que la base de connaissances. L'accès intelligent et les fonctionnalités de l'application web sont ensuite analysés, et les limites du système discutées.

La conclusion générale rappelle les principaux résultats, montre dans quelle mesure les objectifs et les hypothèses ont été atteints, et présente enfin les limites du travail comme ses perspectives d'amélioration.

Chapitre I

Cadre théorique et revue de littérature

Introduction du chapitre

Toute recherche appliquée repose d'abord sur des notions clairement définies. Ce chapitre a pour objet de poser d'abord les notions liées aux plantes médicinales et aux connaissances scientifiques accumulées sur le Burkina Faso, puis les principes de l'ingénierie des connaissances et des ontologies, avant d'examiner ce que l'intelligence artificielle peut apporter à l'accès à ces connaissances. Il passe enfin en revue les travaux déjà consacrés au sujet et situe la présente recherche par rapport à eux. Quatre sections s'articulent ainsi, de la définition du domaine à la confrontation avec la littérature existante.

I.1 Plantes médicinales et connaissances scientifiques au Burkina Faso

I.1.1 Concepts fondamentaux

Définition des plantes médicinales Selon l'Organisation Mondiale de la Santé (OMS), une plante médicinale est toute plante dont une ou plusieurs parties contiennent des substances utilisables à des fins thérapeutiques [55]. Ces substances, dites principes actifs, exercent une action pharmacologique sur l'organisme : elles peuvent prévenir, soulager ou guérir des affections.

L'Union Internationale pour la Conservation de la Nature (UICN) adopte une perspective plus large, qui présente les plantes médicinales à la fois comme des ressources végétales mobilisées par les systèmes de médecine traditionnelle et comme des matières premières pour l'industrie pharmaceutique. Elle souligne la nécessité d'en assurer une exploitation durable, sous peine de compromettre la biodiversité.

Médecine traditionnelle et pharmacopée L'OMS définit la médecine traditionnelle comme l'ensemble des connaissances, compétences et pratiques de soins [55]. Ces pratiques reposent sur des théories, des croyances et des expériences propres à chaque culture. Elles visent à maintenir la santé, mais aussi à prévenir, diagnostiquer et traiter les maladies [57].

La pharmacopée traditionnelle correspond à l'ensemble des remèdes et des préparations ainsi utilisés [55]. Elle décrit les recettes, précise les posologies et les modes d'administration, et signale les contre-indications et les précautions d'usage.

Ethnobotanique et ethnomédecine L'ethnobotanique étudie de façon scientifique les relations qui lient les plantes aux sociétés humaines [56]. Elle documente les usages traditionnels, recueille les savoirs locaux et analyse la manière dont les populations perçoivent, nomment, classifient et exploitent les végétaux.

L'ethnomédecine en constitue la branche médicale : elle se penche sur les pratiques de soins, sur les systèmes traditionnels, sur les conceptions de la maladie et de la guérison, ainsi que sur les rituels et les actes thérapeutiques [56].

Contexte burkinabè Au Burkina Faso, la médecine traditionnelle couvre environ 80 % des besoins de santé primaire [4] et ne constitue pas une alternative marginale. Son accessibilité, son coût modique et son ancrage dans les habitudes culturelles en font le recours de premier choix, et les tradipraticiens en sont des acteurs centraux.

Les travaux de Zerbo et al. [58] ont appliqué cette lecture à un terrain précis, celui des Sanan, documentant 85 espèces utilisées et 63 affections traitées, avec leurs modes de préparation et d'administration. Ouedraogo et al. [38] ont procédé de leur côté à une revue des plantes à potentiel aromatique du pays, recensant 42 espèces et en analysant les propriétés et les usages.

Or ces savoirs ne se présentent pas de façon homogène. Ils varient selon les ethnies, diffèrent selon les régions, évoluent dans le temps et s'enrichissent des découvertes nouvelles. Une telle diversité rend leur documentation particulièrement complexe [32].

I.1.2 Plantes médicinales documentées dans la littérature scientifique

Inventaires et recensements La littérature scientifique burkinabè est fournie : elle recense plusieurs centaines d'espèces médicinales. Les travaux de Guinko [19] ont identifié 304 espèces utilisées en médecine traditionnelle, tandis que Nacoulma [33] en a documenté 280 avec leurs usages, et que Zerbo et al. [58] ont recensé 85 espèces chez les Sanan.

Ces plantes se répartissent dans des familles botaniques variées, les plus représentées étant les Fabacées, les Combretacées, les Rubiacées et les Euphorbiacées [33], une diversité qui reflète la richesse de la flore burkinabè.

Aspects botaniques et écologiques La recherche couvre plusieurs aspects :

- **Identification botanique :** les plantes sont collectées et décrites, leurs caractéristiques morphologiques sont notées, les spécimens conservés en herbiers de référence et la taxonomie précisée.
- **Distribution géographique :** les zones de présence sont cartographiées, leur répartition étant liée aux conditions climatiques et édaphiques. Certaines espèces sont endémiques à une région [19].
- **Périodes de récolte :** les moments optimaux de collecte sont déterminés, la teneur en principes actifs variant selon la saison, ce qui pèse directement sur la qualité des remèdes.
- **Parties utilisées :** les feuilles dominent (45 % des cas)[58], devant les racines (25 %), les écorces (15 %), les fruits (10 %) et les graines (5 %) [58]. La partie retenue dépend de la plante et de l'usage visé.
- **Modes de préparation :** les décoctions, par ébullition dans l'eau, restent courantes. Les macérations (trempage à froid), les poudres obtenues par séchage et broyage, et plus rarement les extraits alcooliques sont également employés [33].

Usages thérapeutiques Les affections traitées sont principalement courantes : le paludisme en constitue une cible fréquente, aux côtés des infections respiratoires et digestives, tandis que les pathologies chroniques (diabète, hypertension) font l'objet d'études spécifiques [38].

Propriétés pharmacologiques Les études expérimentales évaluent les activités pharmacologiques :

- **Activité antimicrobienne :** les extraits sont testés sur des bactéries et des champignons, notamment *Staphylococcus aureus*, *Escherichia coli* et *Candida albicans*, et les résultats se révèlent souvent prometteurs [33].
- **Activité antipaludique :** les extraits sont testés sur des souches de *Plasmodium falciparum*. Des plantes comme *Artemisia annua* ou *Cryptolepis sanguinolenta* sont étudiées, et certaines affichent une forte activité [38].
- **Activité anti-inflammatoire :** divers modèles d'inflammation sont mobilisés, au nombre desquels l'œdème de la patte du rat. Les plantes évaluées dans ces modèles peuvent présenter des effets significatifs.
- **Activité antioxydante :** le pouvoir piégeage des radicaux libres est mesuré par les méthodes DPPH et ABTS. Les polyphénols y sont le plus souvent impliqués.
- **Toxicité :** la toxicité aiguë et subchronique est évaluée par la détermination des doses létales (DL50). Certaines plantes s'avèrent toxiques à forte dose, information décisive pour la sécurité d'emploi [33].

Composition chimique Les analyses phytochimiques identifient les métabolites secondaires :

- **Alcaloïdes :** composés azotés aux propriétés pharmacologiques variées, dont la quinine et la morphine.
- **Flavonoïdes :** composés phénoliques aux propriétés antioxydantes et anti-inflammatoires, tels que la quercétine et la rutine.
- **Tanins :** composés polyphénoliques à propriétés astringentes et antimicrobiennes.
- **Saponines :** composés aux propriétés moussantes et immunostimulantes.
- **Huiles essentielles :** mélanges complexes de terpènes aux propriétés variées [38].

I.1.3 Types de connaissances et niveaux de preuve

Typologie des connaissances Les connaissances relatives aux plantes médicinales sont de nature variée, et chaque type possède sa propre valeur comme ses propres limites.

Connaissances ethnobotaniques Issues des populations locales et recueillies par enquêtes et entretiens, elles reflètent le savoir traditionnel accumulé et décrivent usages, préparations et croyances. Leur valeur est double : elles orientent la recherche vers des plantes prometteuses et préservent un patrimoine culturel. Elles comportent toutefois des biais : un informateur peut fournir des informations incomplètes, un usage varier d'un guérisseur à l'autre, et la transmission n'est pas assurée.

Connaissances phytochimiques Elles portent sur la composition chimique des plantes, identifient les molécules actives, en précisent la concentration et comparent les profils chimiques entre espèces.

Connaissances pharmacologiques Provenant d'études expérimentales, ces connaissances testent les effets biologiques des extraits, à l'aide de modèles *in vitro* (cellules, micro-organismes) ou *in vivo* (animaux de laboratoire) [21]. Les résultats sont quantitatifs : ils mesurent la concentration efficace (CI50), comparent à des témoins positifs et évaluent la toxicité. Une réserve demeure : les études animales ne prédisent pas toujours l'effet chez l'homme.

Connaissances cliniques Elles proviennent d'essais sur l'homme, rares pour les plantes médicinales, coûteuses et complexes, et supposent des autorisations éthiques ainsi que des essais rigoureux. Ces essais offrent le niveau de preuve le plus élevé : ils mesurent l'efficacité réelle, évaluent les effets secondaires et comparent au placebo ou au traitement standard. Ils constituent la référence de la médecine fondée sur les preuves [40].

Hiérarchie des niveaux de preuve La médecine fondée sur les preuves (*evidence-based medicine*) établit une hiérarchie :

1. **Méta-analyses et revues systématiques :** preuve la plus forte. Elles synthétisent plusieurs essais cliniques.
2. **Essais cliniques randomisés contrôlés :** preuve très forte. Ils comparent un traitement à un placebo ou à un standard.
3. **Études de cohorte :** preuve modérée. Elles suivent des groupes dans le temps.
4. **Études cas-témoins :** preuve modérée. Elles comparent des cas à des témoins.
5. **Études expérimentales animales :** preuve faible. Elles ne sont pas directement transposables à l'homme.
6. **Études *in vitro* :** preuve très faible. Elles sont éloignées des conditions réelles.
7. **Savoirs traditionnels et avis d'experts :** preuve anecdotique. Ils sont utiles pour générer des hypothèses mais non validés.

Cette hiérarchie est résumée dans la figure I.1. Elle commande la fiabilité de chaque connaissance : l'ontologie la traduira en propriété *niveauPreuve* (section **??** du chapitre **??**).

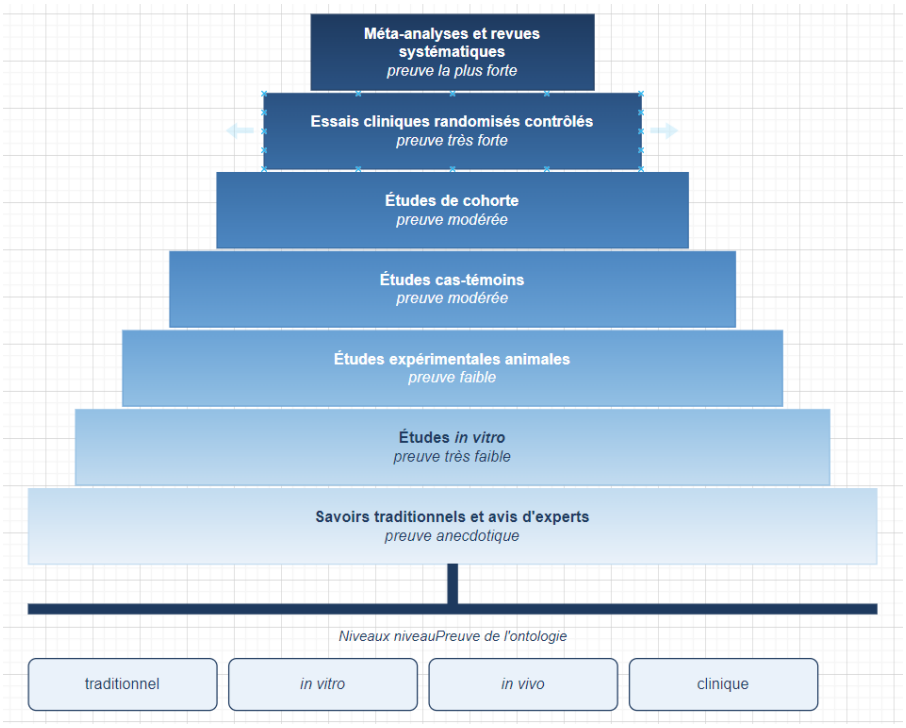


FIGURE I.1 – Hiérarchie des niveaux de preuve

I.2 Ingénierie des connaissances et ontologies

I.2.1 Représentation des connaissances

Définition et enjeux La représentation des connaissances est une discipline de l'intelligence artificielle dont l'objet est de formaliser l'information pour la rendre exploitable par la machine [9]. Elle s'appuie sur des langages structurés et interprétables, et permet en retour le raisonnement automatique et l'interrogation. Quatre enjeux la caractérisent : capter la sémantique des connaissances, les rendre interopérables, permettre leur réutilisation et faciliter leur évolution.

Principaux modèles de représentation

- **Les réseaux sémantiques :** des graphes de concepts reliés par des arcs, où les nœuds représentent des entités et les arcs des relations. Modèle simple et intuitif, il a servi aux premières bases de connaissances.
  Limites : ils n'ont pas de sémantique formelle, ils ne permettent pas le raisonnement complexe et ils sont difficiles à partager.
- **Les cadres (*frames*) :** des structures de données dans lesquelles chaque cadre possède des attributs (*slots*), éventuellement pourvus de valeurs par défaut, les cadres s'organisant en hiérarchies par héritage.
  Avantages : ils sont structurés, permettent l'héritage et sont faciles à implémenter.
  Limites : ils n'ont pas de sémantique formelle. L'héritage peut être ambigu.
- **Les règles :** des expressions logiques conditionnelles, de forme « SI condition ALORS conclusion », qui autorisent le raisonnement déductif et servent aux systèmes experts.
  Avantages : elles sont expressives, permettent le raisonnement et sont faciles à comprendre.
  Limites : elles peuvent être nombreuses, interagir de manière complexe et sont difficiles à maintenir.
- **Les ontologies :** des modèles formels d'un domaine [17], qui définissent classes et propriétés, précisent relations et axiomes, et dont l'expressivité élevée les adapte aux connaissances complexes.
  Avantages : elles ont une sémantique formelle, sont interopérables, permettent le raisonnement et sont réutilisables.

C'est vers ce dernier modèle que se porte notre recherche. Les ontologies sont les plus adaptées à la structuration des connaissances scientifiques : elles autorisent une interrogation fine et facilitent l'intégration de sources multiples.

Ces modèles formels s'appuient aujourd'hui sur les langages du web sémantique, empilés du document à la donnée reliée puis au raisonnement (figure I.2).

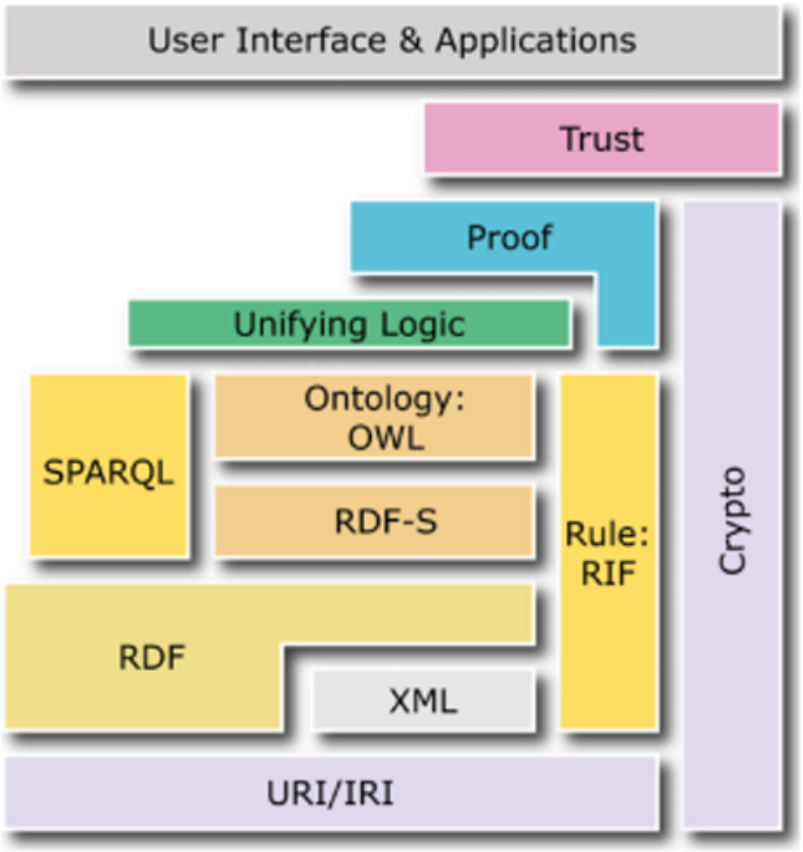


FIGURE I.2 – Les langages du web sémantique

I.2.2 Ontologies et réutilisation d'ontologies existantes

Définition formelle Une ontologie se définit comme « une spécification explicite et formelle d'une conceptualisation partagée » [17]. Chaque élément de cette formule compte :

- **Spécification explicite :** les concepts sont définis clairement, les termes précis, les définitions non ambiguës.
- **Spécification formelle :** l'ontologie est exprimée dans un langage logique, interprétable par la machine, ce qui autorise le raisonnement.
- **Conceptualisation :** l'ontologie représente une vision du monde, sélectionnant les concepts pertinents et laissant de côté les détails non pertinents.
- **Partagée :** l'ontologie est consensuelle, acceptée par une communauté, ce qui facilite la communication.

Composants d'une ontologie Les ontologies sont composées de plusieurs éléments [46] :

- **Classes (ou concepts) :** les entités du domaine, telles que Plante, Maladie, Substance active ou Mode de préparation, organisées en hiérarchies (taxonomies) [46].
- **Propriétés (ou attributs) :** les caractéristiques des classes, par exemple le nom scientifique, le nom vernaculaire, la partie utilisée ou le dosage, susceptibles de porter des valeurs (chaînes, nombres, dates) [46].
- **Relations :** les liens entre les classes, par exemple *« traite »* (une plante traite une maladie), *« contient »* (une plante contient une substance), *« est_préparée_par »* (une préparation utilise un mode) [46].

- **Axiomes :** des contraintes logiques qui assurent la cohérence de l'ontologie, par exemple « une plante peut avoir plusieurs usages » ou « une partie utilisée doit être une partie de la plante »[46].
- **Instances (ou individus) :** les exemples concrets : « Cassia alata » est une instance de Plante, « Paludisme » une instance de Maladie.

Langages d'ontologies Plusieurs langages servent à représenter les ontologies :

- **RDF (Resource Description Framework) :** langage de base du Web sémantique. Il utilise des triplets (sujet-prédicat-objet). Il est simple mais peu expressif [53].
- **RDFS (RDF Schema) :** extension de RDF. Il permet de définir des classes et des propriétés. Il permet l'héritage. Il a une expressivité limitée [53].
- **OWL (Web Ontology Language) :** langage standard du W3C. Il est plus expressif que RDFS. Il permet des axiomes complexes. Il existe OWL-Lite, OWL-DL et OWL-Full, de complexité croissante [52].
- **SKOS (Simple Knowledge Organization System) :** langage pour les thésaurus et taxonomies. Il est adapté aux systèmes d'organisation des connaissances [54].

Réutilisation d'ontologies Réutiliser une ontologie existante est une pratique recommandée [30], et ce pour quatre raisons :

- **Économie de temps et de coûts :** nous ne repartons pas de zéro. Nous nous appuyons sur un travail déjà validé. Nous évitons de « réinventer la roue ».
- **Fiabilité :** les ontologies existantes ont souvent été testées et corrigées. Elles sont éprouvées. Elles intègrent l'expertise de plusieurs chercheurs.
- **Interopérabilité :** l'utilisation d'ontologies standards facilite l'échange de données. Elle permet l'intégration avec d'autres systèmes. Elle favorise la réutilisation dans d'autres contextes.
- **Communauté :** les ontologies existantes ont souvent une communauté d'utilisateurs. Nous pouvons bénéficier de leur expertise. Nous pouvons contribuer à leur amélioration.

Plusieurs ontologies sont disponibles dans les domaines biomédicaux et pharmaceutiques. Certaines portent spécifiquement sur les plantes médicinales. D'autres couvrent la médecine traditionnelle [41]. Notre travail partira d'une de ces ontologies.

I.2.3 Adaptation, alignement et enrichissement ontologique

Adaptation d'une ontologie L'adaptation modifie une ontologie pour un nouveau contexte [25]. Elle est nécessaire quand l'ontologie source ne couvre pas parfaitement le domaine visé. Elle est également nécessaire quand le contexte d'utilisation diffère.

L'adaptation peut inclure :

- **Ajout de classes :** pour couvrir des concepts absents. Par exemple, ajouter des classes pour les maladies spécifiques au Burkina Faso (paludisme, onchocercose, méningite).
- **Ajout de propriétés :** pour décrire des attributs non prévus. Par exemple, ajouter une propriété pour le nom vernaculaire en langue locale (mooré, dioula, fulfuldé).
- **Modification de relations :** pour adapter la sémantique. Par exemple, préciser la relation *« traite »* avec des attributs de niveau de preuve.
- **Suppression de classes :** si elles ne sont pas pertinentes. Mais nous évitons de supprimer pour préserver la compatibilité. Nous pouvons les marquer comme obsolètes.
- **Redéfinition de restrictions :** pour adapter les contraintes logiques.

Alignement d'ontologies L'alignement établit des correspondances entre ontologies [13]. Il relie des concepts équivalents ou similaires. Il permet de fusionner des connaissances de sources différentes. Il facilite l'interopérabilité.

Les correspondances peuvent être :

- **Équivalence :** les concepts sont identiques (`owl:equivalentClass`).
- **Spécialisation :** un concept est un sous-concept de l'autre (`rdfs:subClassOf`).
- **Association :** les concepts sont liés par une relation.
- **Correspondance approximative :** les concepts sont similaires mais pas identiques.

Les méthodes d'alignement peuvent être :

- **Manuelles :** un expert établit les correspondances. C'est précis mais coûteux.
- **Automatiques :** des algorithmes comparent les termes. Ils utilisent des mesures de similarité. Ils sont efficaces mais moins précis.
- **Semi-automatiques :** l'outil propose des correspondances. L'expert les vérifie et les corrige. C'est un bon compromis.

Enrichissement ontologique L'enrichissement ajoute de nouvelles connaissances à l'ontologie [35]. Il intègre des données issues de sources externes. Il peut être manuel (expert humain) ou assisté par des outils.

Les sources d'enrichissement peuvent être :

- Textes scientifiques : articles, thèses, rapports.
- Bases de données : bases de données botaniques, pharmacologiques.
- Ontologies tierces : pour aligner et intégrer.
- Connaissances d'experts : savoirs d'experts du domaine.

Les étapes de l'enrichissement sont :

1. **Identification des sources :** sélectionner les sources pertinentes.
2. **Extraction des connaissances :** extraire les faits des sources.
3. **Transformation :** convertir les faits dans le format de l'ontologie.
4. **Intégration :** ajouter les faits à l'ontologie.
5. **Validation :** vérifier la cohérence et la correction.
6. **Documentation :** tracer les modifications.

Démarche pour notre recherche Notre démarche combinera adaptation et enrichissement. Nous partirons d'une ontologie existante, que nous adapterons au contexte burkinabè en ajoutant des classes pour les plantes locales et des propriétés pour les noms vernaculaires. Les relations seront modifiées si nécessaire. Nous enrichirons ensuite cette ontologie avec les données de la littérature, en documentant l'ensemble des modifications apportées.

I.2.4 Bases de connaissances et interrogation sémantique

Définition et structure Une base de connaissances est un système qui stocke des connaissances structurées [18]. Elle contient des instances (individus) et des faits. La base est typée par une ontologie. L'ontologie sert de schéma conceptuel.

Par exemple, l'ontologie définit la classe *« Plante »* et la propriété *« aPourUsage »*. La base de connaissances contient des instances comme *« Cassia alata »*. Elle contient des faits comme *« Cassia alata aPourUsage Paludisme »*.

Bases de connaissances orientées graphe Le choix d'une base orientée graphe (*graph database*) s'impose naturellement pour ce type de données, dont l'intérêt tient précisément à l'abondance des interconnexions : plutôt que d'éparpiller l'information entre des tables, ce modèle organise les entités en nœuds et les liaisons en relations.

Ce choix présente quatre bénéfices convergents :

- **Performance :** le parcours du graphe est natif, les relations y sont des éléments à part entière, et non de simples clés étrangères.
- **Flexibilité :** le schéma n'est pas figé à l'avance, de nouveaux types de nœuds et de relations s'y intègrent sans migration lourde.
- **Expressivité :** les relations peuvent être typées, pondérées et parcourues, y compris lorsqu'elles sont profondément imbriquées.
- **Lecture intuitive :** le modèle reproduit la façon dont nous lions naturellement les concepts, ce qui en facilite la lecture par un non-spécialiste.

Deux langages de requête dominent l'interrogation de ces graphes :

- **Cypher :** langage déclaratif de Neo4j, de loin le plus répandu, qui autorise des requêtes complexes sur les graphes.
- **Gremlin :** langage d'Apache TinkerPop, plus bas niveau, adopté par plusieurs autres bases de données graphe.

Interrogation avec Cypher Une requête Cypher typique se présente ainsi :

```
MATCH (p:Plante {nomVernaculaire: "Néré"}) RETURN p.nomScientifique,
                                p.usages
```

Elle retourne le nom scientifique et les usages de la plante appelée « Néré ».

Ses principales clauses répondent chacune à un besoin précis :

- `MATCH` : repérer des motifs dans le graphe.
- `WHERE` : filtrer les résultats.
- `RETURN` : désigner ce qui est renvoyé.
- `OPTIONAL MATCH` : établir une correspondance facultative sans perdre le reste des correspondances.
- `CREATE` : créer de nouveaux nœuds et relations.

Avantages des bases de connaissances graphe Pour notre usage, ces avantages se traduisent en cinq exigences :

- **Interrogation puissante :** formuler des requêtes combinant plusieurs critères et parcourant plusieurs relations à la fois.
- **Découverte de connaissances implicites :** laisser le parcours révéler des connexions non évidentes, par exemple des plantes partageant un usage ou une propriété.
- **Traçabilité :** associer chaque fait à sa source, de manière à pouvoir remonter à son origine et en contrôler la fiabilité.
- **Intégration :** réunir des données issues de sources diverses, l'ontologie servant de cadre unificateur.
- **Évolutivité :** enrichir la base de connaissances nouvelles sans avoir à tout reconstruire.

Application à notre recherche Notre base de connaissances dériverait de l'ontologie adaptée selon un modèle orienté graphe. Elle hébergerait les informations relatives aux plantes, à leurs usages, à leurs propriétés et à leurs sources, rendant ainsi possibles des requêtes sémantiques riches, interrogeables depuis l'application web.

I.3 Intelligence artificielle pour l'accès aux connaissances

I.3.1 Traitement des requêtes en langage naturel

Introduction au TALN Le traitement automatique du langage naturel (TALN) constitue l'une des branches de l'intelligence artificielle les plus directement mobilisables dans notre projet. Il s'agit de rendre les textes humains interprétables par la machine, en les analysant sur les plans syntaxique et sémantique, puis en convertissant les énoncés en formes exploitables par la machine [24]. C'est cette propriété qui permet d'établir le dialogue entre l'utilisateur et le système.

Techniques fondamentales Les techniques de Traitement Automatique du Langage Naturel (NLP) mobilisables ici sont les suivantes :

- **Tokenisation :** découpage du texte en unités (mots, ponctuations). « Quelles plantes traitent le paludisme ? » devient ainsi `["Quelles", "plantes", "traitent", "le", "paludisme", "?"]`.
- **Analyse morphologique :** identification des racines des mots. « traitent » se ramène à « traiter », ce qui permet de normaliser les variantes (lemmatisation et *stemming*).
- **Étiquetage morphosyntaxique :** reconnaissance des catégories grammaticales (noms, verbes, adjectifs, etc.) (*part-of-speech tagging*).
- **Reconnaissance d'entités nommées (NER) :** détection des concepts clés, c'est-à-dire des plantes, des maladies, des parties de plantes et des modes de préparation [34].
- **Analyse de dépendances :** compréhension des relations entre mots, par identification du sujet, du verbe, de l'objet et des liens syntaxiques qui les unissent.
- **Analyse sémantique :** compréhension du sens des phrases, à l'aide de représentations vectorielles (*embeddings*) ou de graphes de connaissances.

Approches modernes : les transformers Les modèles récents reposent sur l'architecture *transformer* [51], fondée sur le mécanisme d'attention : celui-ci permet de prendre en compte un contexte étendu, les modèles étant entraînés sur de très grandes quantités de textes.

Trois familles font référence :

- **BERT (*Bidirectional Encoder Representations from Transformers*) :** modèle de Devlin et al. [11], bidirectionnel, qui exploite le contexte situé à la fois à gauche et à droite du mot et excelle dans les tâches de compréhension.
- **GPT (*Generative Pre-trained Transformer*) :** modèle de Radford et al. [39], unidirectionnel, particulièrement performant pour la génération de texte et utilisé dans ChatGPT.
- **T5 (*Text-to-Text Transfer Transformer*) :** modèle de Raffel et al. [39], qui ramène toutes les tâches à des transformations texte-texte.

Ces modèles sont pré-entraînés sur des corpus généraux. Ils peuvent ensuite être affinés (*fine-tunés*) sur des données spécifiques, ce qui leur confère des performances supérieures à celles des approches traditionnelles.

Application à notre recherche Notre système interprêterait ainsi des requêtes variées, à l'aide de modèles NLP, en en extrayant entités et relations pour les traduire en requêtes formelles adressées à la base de connaissances graphe. L'utilisateur dialoguerait avec le système en langage courant. Quelques requêtes attendues illustrent cette exigence :

- « Quelles plantes sont utilisées contre le paludisme ? »
- « Comment prépare-t-on le remède contre la diarrhée ? »
- « La plante X a-t-elle des propriétés anti-inflammatoires ? »
- « Quelles études existent sur la toxicité de Y ? »
- « Quelles plantes du Burkina Faso sont utilisées pour le diabète et ont des études pharmacologiques ? »

I.3.2 Extraction et structuration assistées par IA

Extraction d'information L'extraction d'information est une tâche de NLP [16] qui consiste à identifier des faits dans des textes non structurés, à en reconnaître les entités et les relations, puis à les convertir en données structurées exploitables.

Elle se déploie en quatre étapes successives :

1. **Reconnaissance des entités :** identifier les entités nommées (plantes, maladies, substances).
2. **Reconnaissance des relations :** identifier les relations entre entités (*traite*, *contient*, *prévient*).
3. **Normalisation :** standardiser les entités (synonymes, variantes orthographiques).
4. **Structuration :** organiser les faits en format structuré.

Approche par prompts d'IA Notre recherche s'appuiera sur une approche par *prompts* d'IA, c'est-à-dire sur l'interrogation de modèles de langage de grande taille (LLM) tels que GPT, Claude ou des modèles *open source*.

Le principe repose sur quatre phases :

- **Préparation du prompt :** nous concevons un *prompt* qui demande au modèle d'extraire des informations spécifiques d'un texte. Le *prompt* précise les entités et les relations à extraire.
- **Soumission au modèle :** nous envoyons le texte et le *prompt* au modèle, qui produit une réponse structurée.
- **Extraction :** nous extrayons les informations de la réponse, puis nous les convertissons dans le format souhaité.
- **Validation :** nous vérifions la qualité de l'extraction, et nous corrigeons si nécessaire.

Cette approche présente des avantages réels :

- **Flexibilité :** le *prompt* s'adapte à différents types de documents.
- **Rapidité :** l'extraction reste rapide même sur de grands volumes de textes.
- **Adaptabilité :** modifier le *prompt* suffit à changer la nature des informations extraites.
- **Utilisation de modèles pré-entraînés :** nous bénéficions des connaissances générales du modèle.

Elle n'est toutefois pas exempte de limites :

- **Hallucinations :** le modèle peut générer des informations fausses.
- **Incohérence :** le modèle peut donner des réponses variables.
- **Coût :** l'utilisation de modèles commerciaux peut être coûteuse.

Dans notre recherche, nous utiliserons des *prompts* d'IA pour l'extraction. Les niveaux de preuve associés aux faits extraits seront ceux que rapporte la source, sans réévaluation indépendante, et la qualité des extractions sera appréciée par le protocole d'évaluation prévu pour le système, plutôt que par une relecture individuelle de chaque enregistrement.

Structuration des données La structuration convertit les faits extraits en formats standardisés. Pour notre base de connaissances graphe, nous utiliserons :

- **Format d'importation :** les données seront préparées en JSON ou CSV, formats compatibles avec les outils d'importation de Neo4j.
- **Modèle de données :** les données seront structurées selon l'ontologie, nœuds et relations étant définis en conséquence.
- **Propriétés :** chaque nœud sera porteur de propriétés (nom, type, etc.) et chaque relation de propriétés propres (type, source, niveau de preuve).

Application à notre recherche Dans notre recherche, l'IA assistera l'extraction via des *prompts*. Elle repérera les mentions de plantes, usages, parties et propriétés. Elle identifiera les relations entre ces entités. Elle produira des données structurées, chaque fait étant rattaché à sa source de manière à pouvoir être retracé jusqu'à lui.

I.3.3 Recherche sémantique et génération de réponses

Recherche sémantique La recherche sémantique dépasse la simple correspondance de mots [6] : elle s'appuie sur le sens des termes et sur l'ontologie sous-jacente pour retrouver une information pertinente, quelle que soit la formulation employée par l'utilisateur.

Le processus se déroule en six temps :

1. **Analyse de la requête :** le NLP repère les concepts et les relations énoncés par l'utilisateur.
2. **Désambiguïsation :** lorsqu'un terme est ambigu, le contexte permet de trancher. « Paludisme », par exemple, peut être rapproché de « malaria » ou de « fièvre des marais ». Le système retient le concept approprié.
3. **Transformation en requête formelle :** l'énoncé naturel est converti en requête destinée à la base de connaissances graphe (Cypher), les concepts étant mappés sur les nœuds et les relations.
4. **Exécution :** la requête est exécutée sur la base de connaissances, et les résultats récupérés.
5. **Filtrage et classement :** les résultats sont filtrés puis triés par pertinence, selon des critères de fiabilité (niveau de preuve) ou de proximité sémantique.
6. **Génération de la réponse :** les résultats sont enfin transformés en texte lisible.

Système RAG (*Retrieval-Augmented Generation*) Pour l'accès intelligent aux connaissances, notre recherche s'appuiera sur un système RAG (*Retrieval-Augmented Generation*), qui articule recherche d'information et génération de réponses [29].

Son fonctionnement s'articule en cinq étapes :

- **Interprétation de la requête :** le système cerne la demande de l'utilisateur.
- **Recherche :** il interroge la base de connaissances et en extrait les informations pertinentes (nœuds, relations, propriétés).
- **Contexte :** les informations retrouvées sont assemblées en un contexte, ensuite soumis au modèle de langage.
- **Génération :** le modèle produit une réponse fondée sur ce contexte, et non sur ses seules connaissances, ce qui la rend factuelle et traçable.
- **Affichage des sources :** les sources accompagnent la réponse, permettant à l'utilisateur de vérifier l'origine de l'information.

Les avantages du RAG sont multiples :

- **Fiabilité :** les réponses sont ancrées dans des faits de la base, ce qui réduit les hallucinations.
- **Traçabilité :** nous pouvons remonter aux sources et vérifier l'information.
- **Actualisation :** la base étant mise à jour, les réponses le sont automatiquement.
- **Adaptabilité :** la base peut être adaptée à des contextes différents.

Application à notre recherche Notre système suivra une architecture RAG : il interprétera les requêtes en langage naturel, interrogera la base de connaissances graphe et générera des réponses construites à partir des faits retrouvés. Chacune d'elles inclura ses sources et son niveau de preuve, de sorte que l'utilisateur puisse remonter à l'origine de l'information.

I.3.4 Traçabilité et fiabilité des réponses

Importance de la traçabilité En contexte médical, la traçabilité conditionne la crédibilité d'un système [15]. En associant chaque information à sa source, elle permet d'en vérifier l'origine et renforce d'autant la confiance que lui accordent les utilisateurs.

Sans traçabilité, l'information reste difficile à vérifier : elle peut être erronée ou obsolète, et l'utilisateur est dans l'impossibilité d'en apprécier la fiabilité.

Mécanismes de traçabilité Trois mécanismes seront mis en œuvre :

- **Stockage des références :** chaque fait est stocké avec un identifiant de source, celle-ci étant décrite (titre, auteur, année, éditeur, DOI).
- **Association information-source :** dans la base, l'information est liée à sa source par une relation. Exemple : `(information)-[:PROVIENT_DE]->(source)`.
- **Affichage des sources :** les réponses affichent leurs sources, sur lesquelles un clic ouvre le détail : page ou section exacte, DOI ou URL.
- **Citations :** les renvois sont numérotés comme dans les articles scientifiques, avec appel à une bibliographie.
- **Lien vers les documents :** lorsque les documents sont disponibles en ligne, un lien est fourni.

Fiabilité des réponses La fiabilité des réponses tient d'abord à la qualité des sources. Nous nous limiterons donc à des sources scientifiques validées :

- **Articles évalués par les pairs :** publiés dans des revues scientifiques.
- **Thèses et mémoires :** validés par des jurys académiques.
- **Rapports de recherche :** produits par des institutions reconnues.
- **Livres et chapitres de livres :** publiés par des maisons d'édition scientifiques.

Nous éviterons les sources non vérifiées (sites web non référencés, articles de vulgarisation non validés, témoignages non vérifiés, informations sans attribution).

Distinction des niveaux de preuve Nous distinguerons clairement les niveaux de preuve, tels qu'ils sont rapportés par les sources :

- **Usage traditionnel :** nous indiquons que c'est un usage rapporté, non démontré scientifiquement.
- **Activité *in vitro* :** nous mentionnons que l'activité a été testée en laboratoire sur des cellules ou des micro-organismes.
- **Activité *in vivo* :** nous précisons que l'efficacité a été démontrée sur des animaux.
- **Essai clinique :** nous mettons en avant le niveau de preuve le plus élevé.
- **Toxicité :** nous signalons toute information sur la toxicité ou les effets secondaires.

Gestion des incertitudes Nous ne passerons pas sous silence les incertitudes, et notamment :

- toute information contestée ou non confirmée sera signalée comme telle.
- les données contradictoires seront présentées toutes, sans en cacher aucune.
- le caractère limité de certaines études sera mentionné.
- l'ancienneté d'une information sera indiquée par sa date.

Limites de l'IA Rappelons enfin ce que l'IA ne fera pas : elle ne créera pas de nouvelles connaissances thérapeutiques et ne remplacera pas l'expertise humaine. Son rôle se limite à faciliter l'accès aux connaissances existantes. La responsabilité de l'interprétation demeure celle de l'utilisateur. Le système constitue ainsi un outil d'aide à la consultation, et non un outil de diagnostic ou de prescription.

I.4 Travaux connexes et positionnement scientifique

Pour achever ce cadrage, il nous reste à examiner ce qui a déjà été fait. Cette section passe en revue les travaux consacrés à la modélisation des connaissances en médecine traditionnelle à base de plantes, en distinguant les ontologies développées en Afrique de celles qui nouent un lien direct avec le Burkina Faso, avant de situer notre propre démarche parmi elles.

I.4.1 Ontologies dans le domaine des plantes médicinales

Ontologies internationales

Plusieurs ontologies couvrent le domaine des plantes médicinales. Chacune a ses forces et ses limites.

- **Flora Ontology (FLOPO) :** elle décrit la structure botanique des plantes, parties et stades de développement compris [22]. Extrêmement complète pour la botanique, elle ignore en revanche les usages médicinaux et les connaissances ethnobotaniques.
- **Plant Ontology (PO) :** proche de FLOPO [8], elle porte sur l'anatomie et le développement des plantes et sert de référence pour l'annotation de données génomiques. Ni l'ethnobotanique ni la pharmacologie n'y figurent.
- **Ontology of Traditional Medicine (OTM) :** dédiée à la médecine traditionnelle [41], elle couvre maladies, traitements et remèdes, et intègre des notions issues de la médecine traditionnelle chinoise et de l'Ayurvéda. Prometteuse, elle demeure en cours de développement et n'est pas spécifique aux plantes d'Afrique.
- **Drug Ontology (DrOn) :** centrée sur les propriétés pharmaceutiques [20], elle décrit les médicaments, leurs ingrédients et leurs effets. Son utilité pharmacologique est réelle, mais son champ reste celui des médicaments modernes.
- **Food Ontology (FOODON) :** consacrée à la nutrition et aux aliments [12], elle intègre certaines plantes comestibles et peut être partiellement réutilisée sur le versant alimentaire, sans toutefois couvrir les usages médicinaux.
- **SNOMED CT :** cette terminologie clinique très large [42] couvre de nombreux domaines médicaux et inclut quelques concepts relatifs aux plantes, sans être pour autant structurée comme une ontologie formelle.

Ontologies de la médecine traditionnelle africaine

Plusieurs travaux récents ont développé des ontologies spécifiques à la médecine traditionnelle africaine. Ces travaux reconnaissent les particularités des systèmes de soins africains. Ils intègrent des dimensions culturelles, spirituelles et sociales.

WATRIMed : un graphe de connaissances pour la médecine traditionnelle ouest-africaine Le projet WATRIMed (West African Herbal based Traditional Medicine) fait l'objet de deux publications complémentaires [44, 43]. Leur objectif est de structurer les connaissances sur les plantes médicinales, les recettes traditionnelles et les maladies traitées en Afrique de l'Ouest, et de relier ces connaissances à des bases de données publiques. Le modèle décrit porte le nom de HTM Ontology (Herbal Traditional Medicine Ontology).

Le noyau du modèle compte 556 concepts dans la version présentée à MEDINFO 2019 [44], dont 143 plantes médicinales ouest-africaines identifiées et 108 recettes employées par les tradipraticiens pour traiter 110 maladies et symptômes courants de la sous-région. La note de conception associée décrit un modèle de 472 concepts et de 75 propriétés, dont 57 propriétés objet et 18 propriétés de données [43]. Les classes principales qui y figurent sont :

- **Medicinal Plant** (plante médicinale) et **Plant Part** (partie de plante).
- **Recipe** (recette) et **Formulation** (forme galénique).
- **Chemical Component** (composé chimique) et **Therapeutic Action** (action thérapeutique).
- **Vernacular Name** et **Vocabulary** (noms vernaculaires et vocabulaires).
- **ContraIndication**, **Adverse Reaction** et **Usage Precaution** (contre-indications, réactions indésirables, précautions d'emploi).

Les relations principales associent la plante à ses composés chimiques, à ses actions thérapeutiques et à ses noms vernaculaires. Elles font également intervenir les contre-indications, les réactions indésirables, les formes galéniques et la dérivation d'une ressource à une autre.

Le projet s'inscrit dans un cadre sous-régional et bénéficie de l'expérience de l'Organisation ouest-africaine de la santé (WAHO), qui regroupe les États membres de la sous-région [43]. Le modèle est aligné sur l'ontologie fondationnelle BioTopLite2, et ses instances sont reliées à des ressources externes comme DBpedia, IPNI, Wikidata, PubChem et Yago. L'exemple donné par les auteurs porte sur le nom vernaculaire fulfuldé, au Burkina Faso, d'une espèce employée en médecine traditionnelle.

Ses apports tiennent à trois éléments : l'ampleur du modèle, son alignement avec des bases de connaissances existantes, et la perspective ouverte d'y détecter des interactions entre plantes et médicaments.

Ces deux publications n'exposent toutefois qu'un aperçu des classes supérieures et des relations principales. L'ontologie elle-même n'est pas téléchargeable, ce qui limite la réutilisation directe du modèle.

Sources principales :

- « Enabling West African Herbal-Based Traditional Medicine Digitizing : The WATRIMed Knowledge Graph », actes de MEDINFO 2019, IOS Press, *Studies in Health Technology and Informatics*, vol. 264, p. 1548–1549, 2019.
- « Design Considerations for a Knowledge Graph : The WATRIMed Use Case », conférence Healthcare of the Future, IOS Press, *Studies in Health Technology and Informatics*, vol. 259, p. 59–64, 2019.

ontoMEDTRAD : ontologie visuelle pour l'Afrique de l'Ouest ontoMEDTRAD constitue une autre initiative notable, développée pour la médecine traditionnelle ouest-africaine [27]. Elle se distingue par une approche à la fois formelle et visuelle, l'ontologie étant répartie en deux modules complémentaires :

- **ontoCONCEPT-Term** : ontologie terminologique de domaine (plantes, recettes, maladies, préparations, etc.),
- **ontoICONE** : module iconique qui associe à ces concepts des représentations iconiques destinées à faciliter la compréhension par des tradipraticiens souvent illettrés dans les langues officielles.

Elle modélise explicitement le parcours de soin : le praticien de la médecine traditionnelle, le patient, les signes et les symptômes, les maladies, les ressources médicinales (plantes, animaux, minéraux), la recette, ses ingrédients et les parties de plantes employées, les modes de préparation et d'administration, ainsi que le remède et sa forme galénique. Elle distingue les cinq types de plante (arbre, arbuste, palme, herbe, liane) et les neuf parties de plantes utilisées (feuille, fruit, fleur, racine, tronc, écorce de tronc, écorce de racine, sève, plante entière).

Les relations de base y sont la subsomption (relation « est un ») et la partie-tout (relation « est une partie de »). 76 propriétés associatives et 16 propriétés de données complètent un modèle qui compte 144 concepts, 789 individus et 2 734 axiomes en logique de description ALCHOIQ.

Bien que conçue dans un contexte ouest-africain (Côte d'Ivoire, Sénégal, etc.), ontoMEDTRAD est théoriquement transposable au Burkina Faso. Elle met l'accent sur la représentation des recettes multi-plantes, en particulier antipaludéennes (son jeu de données compte 22 plantes et 31 remèdes antipaludéens [28]), et propose une méthode originale pour franchir les barrières linguistiques et l'illettrisme grâce à la dimension iconique.

Sources principales :

- Thèse : « Système de gestion de la médecine traditionnelle dans une plateforme web social et sémantique : une approche basée sur une ontologie visuelle », Appoh Kouamé, Université Gaston Berger de Saint-Louis (Sénégal), soutenue le 14 avril 2018 (HAL : tel-01842116).
- Article : « Visual Representation of African Traditional Medicine Recipes Using Icons and a Formal Ontology, ontoMEDTRAD », actes de MIE 2020, IOS Press, *Studies in Health Technology and Informatics*, vol. 270, p. 791–795, 2020.

ATHMed : un système à base de connaissances pour la médecine traditionnelle africaine Développée au Ghana, mais avec une vocation africaine, l'approche ATHMed (African Traditional Herbal Medicine) vise à construire un système à base de connaissances permettant la capture, le stockage, l'indexation et la recherche d'informations sur la médecine traditionnelle à base de plantes [10].

L'article qui la présente adopte une démarche de recherche en science du design et s'appuie sur des entretiens semi-directifs conduits auprès de vingt parties prenantes au Ghana : universités, organismes de recherche, tradipraticiens, cliniques, autorité de régulation et usagers. Il propose un cadre conceptuel articulé en trois couches. Une couche données capture et stocke les connaissances auprès des experts du domaine. Une couche logique assure le raisonnement à travers un raisonneur sémantique et un extracteur fondé sur le machine learning. Une couche présentation expose une interface permettant d'interroger la base en langage naturel.

Les connaissances sont attendues dans un corpus sémantiquement annoté, la recherche étant conçue comme contextuelle et multi-mots. L'originalité de l'approche tient à cette hybridation entre ontologie et techniques d'apprentissage automatique, destinée à extraire et à structurer les connaissances à partir de textes.

L'article reste toutefois au stade d'une proposition : l'ontologie ATHMed y est annoncée comme un modèle à dériver, et la mise en œuvre du système est explicitement renvoyée à des travaux ultérieurs. À ce stade, ATHMed est donc un cadre d'architecture plutôt qu'une ontologie réutilisable.

Source principale :

- Article : « Toward a Knowledge-Based System for African Traditional Herbal Medicine : A Design Science Research Approach », Devine S. N. O., Kolog E. A., Atinga R., *Frontiers in Artificial Intelligence*, vol. 5, article 856705, 2022, doi : 10.3389/frai.2022.856705 (PMC8959699).

Travaux sur les « deep ontologies » de la médecine traditionnelle africaine Parallèlement à ces initiatives, plusieurs travaux conceptuels ont proposé des « deep ontologies » pour la médecine traditionnelle africaine. Au-delà des aspects cliniques et pharmacologiques (plantes, maladies, traitements), ces ontologies visent à intégrer des dimensions contextuelles, culturelles et symboliques propres à la médecine traditionnelle, telles que les rites et les croyances.

Ces modèles s'appuient sur des méthodologies d'ingénierie des connaissances comme METHONTOLOGY. Ils sont généralement implémentés dans des outils tels que Protégé (OWL). Ils mettent en avant la nécessité de modéliser des entités comme : TherapeuticRecipe, TherapeuticProcess, Ritual, Belief, en plus des classes plus classiques (Plant, Disease, Symptom).

Exemples concrets d'articles :

- Ayimdji A., Koussoubé S., Fotso L. P., Konfé B. O. (2011). « Towards a "Deep" Ontology for African Traditional Medicine » [5], Intelligent Information Management, vol. 3, n° 6, p. 244–251.

  Cet article propose une première version d'une ontologie « profonde » pour la médecine traditionnelle africaine. Il insiste sur la nécessité de prendre en compte des aspects contextuels et culturels au-delà des simples relations plante–maladie–traitement.
- Ayimdji A., Koussoubé S., Fotso L. P., Konfé B. O. (2012). « Using METHONTOLOGY to Build a Deep Ontology for African Traditional Medicine : First Steps », ARIMA, p. 1–12.

  Ce travail décrit les premières étapes de construction d'une ontologie profonde en appliquant la méthodologie METHONTOLOGY. Il présente une implémentation dans Protégé et une réflexion sur l'intégration des dimensions rituelles et symboliques.

Ces travaux offrent une réflexion méthodologique précieuse sur la construction d'ontologies « profondes » capables de rendre compte de la complexité de la médecine traditionnelle africaine. Ils restent cependant majoritairement conceptuels : les déploiements opérationnels à grande échelle se comptent à peine, et les outils de consultation destinés aux acteurs de terrain sont rares.

Ontologie pour les tradipraticiens (bone-setters) en Afrique de l'Ouest (2024) Un travail récent (2024) propose une ontologie destinée aux tradipraticiens spécialisés dans le traitement des fractures. Dérivée du domaine des bone-setters en Afrique de l'Ouest, elle est appelée ontoFRACTURECARE.

Les auteurs constatent que les bone-setters restent le premier recours des populations rurales, leur pratique se révélant là où la médecine conventionnelle montre ses limites. La plupart des praticiens sont toutefois âgés et analphabètes, et l'intérêt des jeunes générations fait défaut.

L'ontologie vise à structurer, mettre en valeur et fournir une désignation consensuelle des concepts pertinents. Elle est destinée à servir de guide pour une prise de décision intelligente dans le processus de soins.

Modèle d'intégration des connaissances (Angole et al.) Angole et al. ont proposé un modèle fondé sur une ontologie, destiné à intégrer les connaissances de la médecine moderne et de la médecine traditionnelle africaine [2, 3].

Leur approche, présentée sous le nom d'ATMO (African Traditional Medicine Ontology), retient la Basic Formal Ontology comme ontologie supérieure standard et vise à s'articuler avec les ontologies de la médecine moderne, en particulier l'Ontologie de la Science Médicale Générale (OGMS), elle-même dérivée de la BFO.

L'objectif est de faire reconnaître la médecine traditionnelle africaine et de l'incorporer au système de santé : structurées, ses connaissances pourraient alors être mobilisées en parallèle de la médecine conventionnelle.

Ontologies nationales et ethniques Des ontologies ont été développées pour des contextes spécifiques : l'ontologie visuelle ontoMEDTRAD, par exemple, couvre l'Afrique de l'Ouest, principalement la Côte d'Ivoire et le Sénégal.

D'autres travaux documentent les systèmes nosologiques locaux. Souley [45], par exemple, a étudié les entités nosologiques populaires chez les Haoussa, faisant apparaître des concepts médicaux locaux tels que zahí, sanyi et shawara.

Particularités ontologiques de la médecine traditionnelle africaine L'étude de ces ontologies fait apparaître trois particularités récurrentes :

- **Holisme :** le corps est une entité interconnectée, faite de composantes naturelles et surnaturelles [49]. La santé désigne un bien-être physique, mental, spirituel, social et écologique à la fois.
- **Causalité surnaturelle :** la maladie n'est pas seulement un dysfonctionnement mécanique, elle peut résulter d'une rupture de l'harmonie entre l'homme et le cosmos.
- **Traitement magico-rationnel :** il articule les pouvoirs des plantes et ceux du guérisseur.

Inventaires et structuration de données ethnobotaniques au Burkina Faso

Au Burkina Faso, de nombreux travaux ont été consacrés au recensement des plantes médicinales et de leurs usages thérapeutiques. Ils relèvent principalement de :

- d'études ethnobotaniques publiées dans des revues scientifiques,
- de thèses et mémoires (pharmacie, biologie, médecine),
- de rapports de projets (AI4D, herbier national, chimiothèque, etc.).

Conduits dans différentes régions du pays (Hauts-Bassins, Sud-Ouest, Centre-Est, etc.), ces travaux ont produit des inventaires floristiques et des enquêtes auprès des tradipraticiens, documentant :

- les noms scientifiques et vernaculaires des plantes,
- les parties utilisées,
- les pathologies traitées,
- les modes de préparation et d'administration,
- parfois les dosages et les toxicités.

Exemples d'articles, thèses et rapports sur les plantes médicinales du Burkina Faso :

- **Tibiri A. et al. (2020)** [48]. « Countrywide Survey of Plants Used for Liver Disease Management by Traditional Healers in Burkina Faso », Frontiers in Pharmacology, 2020.
  Enquête à l'échelle nationale sur les plantes utilisées contre les maladies hépatiques. Plus de 2 000 entrées de plantes correspondant à 212 espèces. Géolocalisation des tradipraticiens. Analyse statistique sous R.
- **Ouédraogo L., Endl J., Sombié P. A. E. D., Schaefer H., Kiendrebeogo M. (2020)** [37]. « Ethnobotanical use and conservation assessment of medicinal plants sold in markets of Burkina Faso », Ethnobotany Research and Applications, 20 :1–25, 2020.
  Enquête auprès de 30 commerçants de plantes médicinales dans six grandes villes. Identification de 104 espèces utilisées pour diverses pathologies (troubles gastro-intestinaux, paludisme, etc.). Évaluation du statut de conservation.
- **Nadembega P. et al. (2025)**. « An ethnobotanical survey of medicinal plants used for children's healthcare in Centre-Est Burkina Faso », Ethnobotany Research and Applications, 33, 2025.
  Enquête sur les plantes utilisées pour la santé des enfants dans la région du Centre-Est. Documentation de 185 espèces issues de 52 familles.
- **Zongo et al. (2025)** [60]. « Ethnopharmacological study on medicinal plants used for jaundice and liver-related disorders management in the Province of Kouritenga in the Central-Eastern of Burkina Faso », Journal of Advanced Translational and Preclinical Biomedicine, 2025.
  Étude ethnopharmacologique ciblée sur les plantes utilisées contre la jaunisse et les troubles hépatiques dans une province spécifique.

- **Traoré S., Diawara/Zimé H., Ouédraogo S., et al.** [50]. « Ethnobotanical Survey on Plants Used in the Treatment of Wounds by Traditional Health Practitioners in Burkina Faso », International Journal of Plant, Animal and Environmental Sciences, 15, 2025.

  Enquête sur les plantes utilisées par les tradipraticiens pour le traitement des plaies. Identification de 70 espèces.

- **Projet AI4D** [1]. « Création d'une base de données sur les plantes médicinales pour faciliter l'exploitation des connaissances ethnopharmacologiques locales ».

  Projet visant à construire une base de données ouverte et interrogeable sur les plantes médicinales du Burkina Faso. Champs standardisés : nom scientifique, famille, noms en mooré/dioula/fulfuldé, localisation spatiale, statut de conservation, usages médicaux.

- **Flahaut E.** [14]. « Pharmacopée et médecine traditionnelle dans l'ouest du Burkina Faso : plantes médicinales et soins du couple mère–enfant », Thèse de Doctorat en Pharmacie, Université de Lille II.

  Thèse ancienne mais souvent citée. Documente les plantes médicinales et les soins traditionnels dans l'ouest du Burkina Faso, en particulier pour la mère et l'enfant.

- **Étude synthétique sur les soins infantiles (2010)**. « Contribution à l'étude des plantes médicinales et des recettes médicamenteuses utilisées dans les soins infantiles au Burkina Faso », publication synthétique (13 pages, 4 tableaux, 42 références).

  Recense 79 espèces médicinales utilisées dans les soins infantiles, avec 167 recettes médicamenteuses documentées.

L'Herbier National des Plantes Médicinales du Burkina Faso (projet « Herbier avec chimiothèque ») L'Herbier National des Plantes Médicinales du Burkina Faso, souvent désigné sous le nom de projet « Herbier avec chimiothèque », vise à créer un herbier national spécifiquement dédié aux plantes médicinales, couplé à une chimiothèque contenant les marqueurs chimiques des plantes répertoriées.

Ses objectifs principaux sont les suivants :

- réaliser des enquêtes ethnobotaniques régionales auprès des tradipraticiens de santé, en commençant par les régions du Centre et du Plateau central,
- établir un inventaire des plantes médicinales utilisées pour le traitement des dix pathologies prioritaires définies par le ministère de la Santé,
- identifier et géolocaliser ces plantes, et confectionner des spécimens d'herbier,
- procéder à l'identification botanique et au dosage de marqueurs chimiques pour les vingt plantes les plus couramment utilisées pour chaque pathologie,
- alimenter une base de données nationale sur les plantes médicinales, accessible via une application mobile et un site web.

Ce projet se veut la phase préliminaire d'une initiative plus ambitieuse qui étendrait les enquêtes ethnobotaniques à toutes les régions du pays. Il s'inscrit dans une dynamique plus large de valorisation de la pharmacopée traditionnelle, portée notamment par :

- la création de bosquets à plantes médicinales dans chaque province (annonce présidentielle de 2024–2025),
- l'approbation par le gouvernement de dizaines de produits issus de la pharmacopée traditionnelle,
- la mise en place de sites de conservation et de culture contrôlée des espèces médicinales.

Le projet « Herbier avec chimiothèque » se distingue des autres herbiers nationaux par sa focalisation explicite sur les plantes médicinales. Il associe trois dispositifs complémentaires :

- un herbier (spécimens botaniques identifiés et conservés),

- une chimiothèque (marqueurs chimiques identifiés et dosés),
- une base de données (informations ethnobotaniques, usages thérapeutiques, géolocalisation).

Il coexiste avec d'autres herbiers reconnus au Burkina Faso, notamment :

- l'Herbier National du Burkina (HNBU) du CNRST/INERA, héritier de la section de l'IFAN créée en 1954,
- l'herbier du Centre National de Semences Forestières (CNSF) (environ 15 000 spécimens),
- l'herbier de l'Université Joseph Ki-Zerbo (OUA).

Ces collections jouent un rôle important dans la conservation de la diversité végétale. Mais le projet « Herbier avec chimiothèque » est le seul à viser explicitement une base de données nationale structurée sur les plantes médicinales, avec une dimension ethnobotanique et chimique.

Ces travaux forment une base empirique essentielle et spécifiquement burkinabè. Ils fournissent des outils méthodologiques précieux (questionnaires, grilles de saisie) et des données de terrain riches. Aucun ne propose cependant d'ontologie formelle explicite : les connaissances sont surtout organisées dans des tableaux, des bases relationnelles simples ou des documents PDF, sans modèle sémantique unifié. Les données demeurent dispersées entre études, bases locales et projets (AI4D, herbier national, chimiothèque, etc.), et il n'existe pas encore d'application web centralisée permettant d'en consulter l'ensemble, dans une perspective de recherche et de modélisation sémantique.

Synthèse comparative des ontologies existantes

Cette lecture comparative fait apparaître des points communs et des écarts marquants.

Points communs

Les initiatives régionales (WATRIMed, ontoMEDTRAD, ATHMed) partagent une même ambition : formaliser les connaissances sur la médecine traditionnelle à base de plantes en Afrique. WATRIMed et ontoMEDTRAD modélisent explicitement les plantes, les recettes et les maladies traitées. Plusieurs y ajoutent les parties utilisées, les modes de préparation et d'administration, ainsi que le fait qu'une recette puisse combiner plusieurs plantes pour traiter une ou plusieurs pathologies. ATHMed, elle, en reste au stade d'un cadre proposé, où l'ontologie et le machine learning sont appelés à collaborer.

Différences

Elles diffèrent cependant sur plusieurs aspects :

- **Zone géographique de référence** : Afrique de l'Ouest vs Afrique générale.
- **Niveau de détail** : certaines incluent des composés chimiques, des rituels, des icônes. D'autres restent plus simples.
- **Degré de formalisation** : ontologies OWL riches vs modèles plus légers.
- **Volume de données modélisées** : de quelques dizaines à quelques centaines de plantes et recettes.
- **Existence d'applications web** : peu d'outils opérationnels et accessibles aux acteurs locaux.

Le tableau I.1 présente une synthèse comparative des ontologies identifiées dans la littérature.

TABLE I.1 – Synthèse comparative des ontologies de la littérature

Ontologie	Domaine	Couverture	Particularité	Limite principale
FLOPO	Botanique	Structure des plantes	Très complète	Pas d'usages médicinaux
PO	Botanique	Anatomie végétale	Standard génomique	Pas d'ethnobotanique
OTM	Médecine trad.	Maladies, traitements	Intègre médecines asiatiques	Pas spécifique Afrique
DrOn	Pharmacologie	Médicaments, effets	Standard pharmaceutique	Pas de préparations trad.
FOODON	Alimentation	Plantes comestibles	Couverture large	Pas d'usages médicinaux
SNOMED CT	Clinique	Terminologie médicale	Large couverture	Structure non ontologique
WATRIMed (2019)	Med. trad. Ouest-Afr.	Plantes, recettes, maladies	Graphe relié à DBpedia, IPNI, Wikidata	Ontologie non téléchargeable
ontoMEDTRAD (2018)	Med. trad. Ouest-Afr.	Plantes, recettes	Approche visuelle iconique	Côte d'Ivoire / Sénégal
ATHMed (2022)	Med. trad. Afr.	Plantes, traitements	Hybride ontologie/ML	Cadre proposé, Ghana
Deep Ontologies	Med. trad. Afr.	Plantes, rituels, croyances	Intègre dimensions culturelles	Conceptuel, peu opérationnel
Angole et al. (2013)	Intégration Med.	Maladies, traitements	Alignement BFO	Général Afrique
ontoFRACTURECARE (2024)	Med. trad. (fractures)	Bone-setters	Structuration des connaissances	Domaine spécifique

Analyse synthétique

Trois constats se dégagent du tableau. Les ontologies botaniques (FLOPO, PO) couvrent convenablement la plante mais ignorent les usages médicinaux. Les ontologies pharmaceutiques (DrOn) restent centrées sur les médicaments modernes. L'OTM, prometteuse, n'est pas spécifique à l'Afrique.

Pour l'Afrique, plusieurs initiatives se distinguent : celle de Tekemetieu [47] intègre les dimensions mystiques mais reste limitée au Gabon et au Cameroun. Celle d'Angole et al. [2, 3] apporte une intégration avec la médecine moderne tout en demeurant générale. OntoMEDTRAD [27] est la plus aboutie pour l'Afrique de l'Ouest grâce à son approche visuelle. WATRIMed [44, 43] couvre l'Afrique de l'Ouest, avec des exemples burkinabès, mais son ontologie n'est pas téléchargeable.

Aucune de ces ontologies n'est spécifiquement dédiée aux plantes médicinales du Burkina Faso, et aucune n'intègre systématiquement la traçabilité des sources ni les niveaux de preuve. C'est précisément ce double manque que notre recherche entend combler : liaison complète de chaque fait à sa source, et

restitution du niveau de preuve que cette source lui attribue.

Apports de notre travail par rapport aux travaux existants

Notre travail s'inscrit dans un paysage déjà dense, où coexistent des initiatives de recensement, de structuration et de modélisation des connaissances sur les plantes médicinales, en Afrique et plus particulièrement au Burkina Faso. D'un côté, des ontologies et systèmes à base de connaissances à vocation régionale ou continentale (WATRIMed, ontoMEDTRAD, ATHMed, deep ontologies de la médecine traditionnelle africaine). De l'autre, de nombreux inventaires ethnobotaniques, thèses, rapports et projets de bases de données burkinabès (enquêtes sur les plantes médicinales, projet AI4D, projet « Herbier avec chimiothèque », etc.).

Face à cet existant, notre travail apporte une valeur ajoutée sur quatre plans.

Sur le plan scientifique, nous produisons une ontologie enrichie et une base de connaissances structurée, issues de la littérature scientifique burkinabè, en mettant en évidence les plantes, les pathologies et les régions les plus étudiées, ainsi que les principales lacunes (dosages, toxicités, zones sous-documentées).

Sur le plan méthodologique, nous proposons une méthode d'extraction assistée par IA (*prompts* adressés à des LLM) et un modèle conceptuel adapté au contexte burkinabè. Ce modèle intègre les noms vernaculaires (mooré, dioula, fulfuldé), les recettes multi-plantes lorsqu'elles sont documentées et les coordonnées géographiques issues de l'INERA. Chaque information y reste rattachée à sa source, avec le niveau de preuve que celle-ci lui attribue.

Sur le plan technologique, nous implémentons une base de connaissances orientée graphe (Neo4j) et développons une application web de consultation (Streamlit) permettant des requêtes en langage naturel via un système RAG (Llama 3 + LangChain). L'application propose un chatbot, une recherche par plante ou par pathologie, ainsi que des fiches descriptives accompagnées de leurs sources et de leurs niveaux de preuve.

Sur le plan sociétal, nous contribuons à la valorisation du patrimoine végétal thérapeutique burkinabè en fournissant une base structurée et traçable, utile à la recherche, à la préservation des connaissances endogènes et à la diffusion scientifique.

Notre travail se positionne ainsi comme une couche complémentaire aux infrastructures existantes (ontologies régionales, inventaires, herbier national), en apportant une modélisation sémantique centrée sur les usages thérapeutiques documentés, propre au Burkina Faso et adossée à une traçabilité systématique vers les sources scientifiques.

I.4.2 Systèmes intelligents d'accès aux connaissances

Typologie des systèmes Plusieurs familles de systèmes donnent accès aux connaissances médicinales, chacune adossée à une approche technique différente :

- **Systèmes experts :** ils modélisent l'expertise humaine par des règles logiques [7], comme dans MYCIN. *Limites :* difficiles à adapter aux connaissances traditionnelles, maintenance lourde.
- **Systèmes à base de cas :** ils réutilisent des cas similaires [26]. *Limites :* supposent une base de cas très riche et peinent face aux situations inédites.
- **Chatbots médicaux :** ils assurent une interaction en langage naturel [23], comme Ada ou Babylon Health. *Limites :* bases parfois limitées, fiabilité variable.
- **Plateformes d'ontologies :** elles autorisent des requêtes sémantiques formelles [46]. *Limites :* interfaces souvent complexes, réservées aux experts.

Systèmes RAG pour l'accès aux connaissances Les systèmes RAG (*Retrieval-Augmented Generation*) constituent une avancée plus récente [29], déjà déclinée dans plusieurs domaines : *HealthRAG* (médical), *BioRAG* (biologique), *LegalRAG* (juridique).

Limites communes des systèmes existants Quatre insuffisances reviennent cependant d'une famille à l'autre :

- bases de connaissances incomplètes ou hétérogènes.
- absence de traçabilité systématique vers les sources d'origine.
- non-adaptation aux spécificités et aux langues locales.
- absence de pondération par niveaux de preuve scientifique.

Positionnement de notre système Notre système entend répondre à ces quatre insuffisances, en conjuguant adaptation locale (Burkina Faso), enrichissement scientifique, traçabilité systématique, intégration explicite des niveaux de preuve déclarés par les sources et accès naturel assuré par un RAG couplé à une base de données graphe (Neo4j).

I.4.3 Positionnement de notre recherche

Originalité de notre recherche L'originalité de notre recherche tient à la réunion de sept éléments :

1. **Réutilisation d'ontologie :** Gain de temps et garantie d'interopérabilité.
2. **Adaptation locale :** Prise en compte du contexte burkinabè et des noms vernaculaires locales (*mooré*, *dioula*, *fulfuldé*).
3. **Enrichissement scientifique :** Exploitation des thèses, articles et travaux locaux validés.
4. **Traçabilité des sources :** Chaque fait est lié à sa référence scientifique.
5. **Accès intelligent par RAG :** Requêtes formulées en langage naturel.
6. **Base de connaissances graphe :** Flexibilité de modélisation orientée graphe.
7. **Niveaux de preuve :** Restitution, pour chaque fait, de la catégorie déclarée par sa source : savoir traditionnel, étude *in vitro*, étude *in vivo* ou essai clinique.

Conclusion du chapitre

Ce chapitre a posé les fondements théoriques de notre recherche. Nous y avons défini les concepts clés liés aux plantes médicinales et au patrimoine ethnobotanique, puis exposé les principes de l'ingénierie des connaissances et des ontologies. Nous avons également examiné les apports de l'intelligence artificielle à l'accès aux connaissances, à travers le traitement du langage naturel et les architectures de génération augmentée par récupération (*Retrieval-Augmented Generation*, RAG), avant d'analyser les travaux connexes, en particulier les ontologies développées pour la médecine traditionnelle africaine.

Cette revue de la littérature met en évidence des lacunes substantielles. Aucune ontologie n'est spécifiquement dédiée aux plantes médicinales du Burkina Faso : *ontoMEDTRAD* couvre principalement la Côte d'Ivoire et le Sénégal, et *WATRIMed*, bien qu'elle s'appuie sur des exemples burkinabès, ne fournit pas d'ontologie téléchargeable. S'y ajoutent deux défis, majoritairement laissés ouverts : la traçabilité des connaissances et l'intégration systématique de sources scientifiques multiples.

Notre recherche entend combler ces lacunes en proposant un modèle structuré, tracé et accessible en langage naturel, qui apporte des contributions à la fois scientifiques, techniques et pratiques. Elle s'inscrit ainsi pleinement dans une démarche de valorisation et de préservation des savoirs locaux, tout en contribuant à l'essor et à l'intégration de la médecine traditionnelle en Afrique.

Le chapitre suivant présentera la démarche méthodologique adoptée pour mener à bien notre recherche. Nous y décrirons la constitution du corpus d'études, l'analyse comparative des ontologies existantes, la démarche d'adaptation et d'enrichissement de l'ontologie retenue, ainsi que la conception et le développement de notre système intelligent d'accès aux connaissances.

Chapitre II

Matériel et méthodologie

Introduction du chapitre

Après avoir posé le cadre conceptuel et balisé l'état de l'art, il nous reste à dire comment ce cadre a été mis à l'épreuve des faits. Le présent chapitre expose le matériel mobilisé et la démarche méthodologique suivie. Il fait le lien entre la réflexion théorique et la mise en œuvre technique.

Trois mouvements structurent son propos. Le premier porte sur le matériel, c'est-à-dire sur le corpus documentaire, les ontologies candidates et l'environnement technique. Le deuxième détaille la méthodologie, décomposée en huit phases allant de l'identification comparée des ontologies jusqu'à l'évaluation du système. Le troisième rassemble la démarche dans une synthèse et ouvre la voie au chapitre suivant.

Chaque phase est exposée selon un format constant : objectif poursuivi, actions concrètes, méthodes, outils mobilisés et livrables produits. Cette uniformité, un peu austère, a une raison d'être : elle rend la démarche reproductible par un tiers et permet d'en apprécier la contribution.

II.1 Matériel

Rassembler les ressources mobilisées est la première exigence de ce type de recherche : sans inventaire clair, aucune étape ultérieure ne peut être évaluée. Nous présentons donc successivement le corpus documentaire, les ontologies candidates, puis l'environnement technique, avant de proposer deux tableaux récapitulatifs.

Ces ressources sont de trois ordres : documentaires (articles, thèses, rapports, bases de données), conceptuelles (les ontologies existantes dont nous avons évalué l'usage) et techniques (modèles de langage, base de données, frameworks et bibliothèques). Chacune est présentée avec la précision nécessaire pour que son rôle dans la démarche soit sans ambiguïté.

II.1.1 Corpus documentaire

Point de départ inhabituel : nous n'avons pas choisi l'ontologie après le corpus, mais avant. Nous l'avons identifiée et sélectionnée en amont, afin de savoir quelles notions et quelles relations guideront l'extraction. Les documents entrent ainsi dès la collecte dans une structure conceptuelle précise, plutôt que d'être fouillés après coup.

Le corpus réunit des documents scientifiques et techniques consacrés aux plantes médicinales du Burkina Faso, répartis en deux ensembles : les publications scientifiques, d'une part, les données de l'Herbier National des Plantes Médicinales (burkinaherbiermed.org) et celles de l'INERA, d'autre part.

La figure II.1 résume le cheminement suivi, de l'ontologie sélectionnée en amont au corpus final.

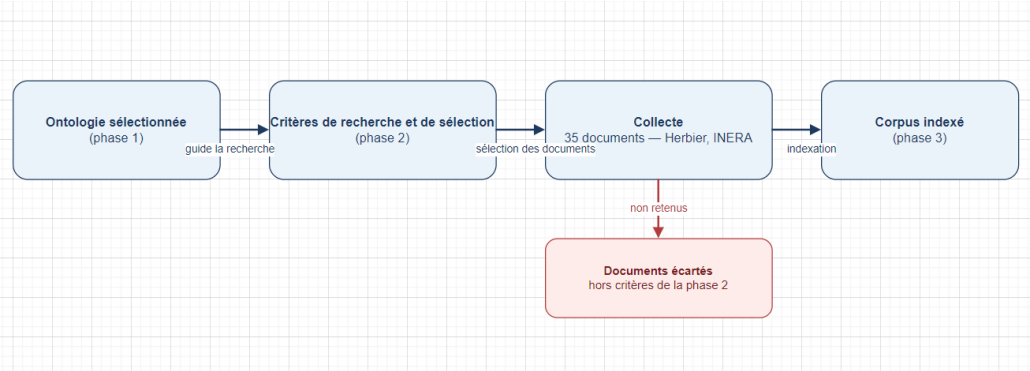


FIGURE II.1 – Constitution du corpus documentaire

Sources scientifiques publiées

Le corpus scientifique repose sur 35 rapports de recherche, articles, thèses et mémoires, issus de revues, d'universités et d'institutions de recherche burkinabè. Les études ethnobotaniques, ethnopharmacologiques et phytochimiques qu'ils rassemblent portent sur les noms scientifiques et vernaculaires, les parties utilisées, les pathologies traitées et les modes de préparation, sans oublier, pour les plus récentes, les dosages et les données de toxicité.

Ces travaux forment le socle du corpus. Nous les avons retenus pour leur rigueur et pour leur pertinence au contexte burkinabè, sur une période allant des fondements du domaine aux publications les plus actuelles. Un tel étagement permet de couvrir un large éventail d'espèces, de pathologies et de pratiques thérapeutiques : c'est de cette diversité, plus que du volume, que dépend la qualité de l'extraction.

Quatre travaux illustrent la variété des données mobilisées :

— Zerbo et al. [58] ont étudié les plantes médicinales chez les Sanan du Burkina Faso. Leur travail documente 85 espèces utilisées pour traiter 63 affections.

— Ouédraogo et al. [38] ont dressé une revue des plantes médicinales à potentiel aromatique du pays, recensant 42 espèces et en caractérisant les propriétés et les usages.

— Tibiri et al. [48] ont mené une enquête à l'échelle nationale sur les plantes utilisées contre les maladies hépatiques, documentant plus de 2 000 entrées de plantes correspondant à 212 espèces.

— Ouédraogo et al. [37] ont enquêté auprès de 30 commerçants de plantes médicinales dans six grandes villes, identifiant 104 espèces utilisées pour diverses pathologies.

Réunis, ces travaux forment une base empirique solidement burkinabè : ils fournissent à la fois des protocoles méthodologiques réutilisables et des observations de terrain très riches.

Données de l'Herbier National des Plantes Médicinales du Burkina Faso

Le site burkinaherbiermed.org diffuse des données sur les plantes médicinales du pays : informations botaniques, usages thérapeutiques et références bibliographiques. Elles proviennent du projet « Herbier avec chimiothèque », piloté par le Ministère de la Santé.

Ce projet vise à bâtir un herbier national dédié aux plantes médicinales, accouplé à une chimiothèque de marqueurs chimiques. Il documente les plantes utilisées contre les dix pathologies prioritaires définies par le ministère, géolocalise les stations et constitue des spécimens conservés, le tout alimentant une base de données nationale accessible par application mobile et par site web.

Là où les herbiers nationaux s'arrêtent à la conservation de spécimens, celui-ci articule trois registres : un herbier (spécimens identifiés et conservés), une chimiothèque (marqueurs chimiques identifiés et dosés) et une base de données (informations ethnobotaniques, usages thérapeutiques, géolocalisation). Il ne se substitue pas aux autres herbiers burkinabè (HNBU du CNRST/INERA,

Centre National de Semences Forestières, Université Joseph Ki-Zerbo). Il s'y articule par la spécificité de son objet : les plantes médicinales.

Données de l'INERA

L'Institut de l'Environnement et de Recherches Agricoles (INERA) tient une base de données de plus de 7 000 espèces végétales, assorties des coordonnées géographiques des stations où elles peuvent être observées. Ces données ouvrent la voie à une analyse spatiale de la distribution des espèces et complètent les données ethnobotaniques par une dimension géographique.

Leur apport se révèle décisif pour notre recherche : elles localisent les plantes sur le territoire burkinabè, autorisent l'étude de leur répartition et enrichissent la base de connaissances en informations spatiales. Le croisement des usages traditionnels avec la distribution géographique des espèces laisse par ailleurs entrevoir des régularités régionales dignes d'être vérifiées.

Le tableau II.1 récapitule les sources du corpus.

TABLE II.1 – Sources du corpus documentaire

Source	**Type**	**Volume estimé**	**Contenu principal**
Articles et thèses	Publications scientifiques	35 documents	Études ethnobotaniques, pharmacologiques
burkinaherbiermed.org	Base de données en ligne	Plusieurs centaines de plantes	Données botaniques, usages, références
INERA	Base de données institutionnelle	> 7 000 espèces	Coordonnées géographiques, identification

Ce corpus ne se lit pas d'un seul tenant : les documents qui le composent relèvent de types d'étude différents, et chacun n'est exploitable que pour ce qu'il mesure. Trois profils s'y distinguent. Les enquêtes ethnobotaniques et ethnopharmacologiques (enquêtes auprès de tradipraticiens, recensements de marchés) livrent les noms vernaculaires, les parties utilisées, les modes de préparation et les pathologies traitées, souvent espèce par espèce. Les études expérimentales, qu'il s'agisse d'essais *in vitro* ou de travaux phytochimiques, apportent en revanche les activités pharmacologiques mesurées, les concentrations testées, le niveau de preuve et le lieu de récolte, mais ne renseignent ni sur les noms vernaculaires ni sur les pratiques de préparation. Les revues de synthèse dressent enfin des inventaires à grande échelle dont la provenance est diluée : elles servent à repérer les sources primaires plutôt qu'à alimenter directement la base de connaissances.

Trois règles découlent de cette typologie pour l'extraction. Une source ne remplit que les champs qu'elle a effectivement mesurés. Un champ qu'elle ne couvre pas reste vide et n'est pas comblé par déduction. Une affirmation d'usage traditionnel portée par un article expérimental, lorsqu'elle n'est appuyée d'aucune référence ethnobotanique, n'est pas enregistrée comme connaissance : elle est écartée ou conservée à titre indicatif, sans être rattachée à la base. Enfin, les comptes d'espèces ne se somment pas d'un type de source à l'autre : les 42 espèces d'une revue [38] peuvent recouper pour l'essentiel celles des enquêtes qu'elle reprend, et les additionner reviendrait à compter plusieurs fois la même observation. Le corpus s'énonce donc document par document, comme le fait le tableau II.1, sans agrégation des volumes.

Ce corpus se distingue par sa richesse et sa diversité : il embrasse plusieurs régions du Burkina Faso, un éventail de pathologies et des approches méthodologiques d'une variété appréciable. Il offre une base sérieuse pour l'extraction des connaissances et l'enrichissement de l'ontologie. Le choix de l'ontologie en amont a joué un rôle déterminant : il a permis de cibler les informations à extraire et d'organiser le corpus selon les concepts et relations définis, garantissant ainsi la cohérence entre le modèle conceptuel et les données collectées.

II.1.2 Ontologies candidates

Nous avons retenu cinq ontologies candidates pour l'étude comparative. Nous les avons présentées au chapitre I, aux sections I.4.1 et I.4.1, et couvrent des domaines variés : botanique, médecine traditionnelle, pharmacologie, ethnomédecine. Le tableau II.2 en donne les caractéristiques descriptives.

Nous les confronterons à une grille de critères définie en phase 1 (section II.2.1), opération qui doit désigner l'ontologie la plus adaptée à notre contexte. Cette sélection précède la constitution du corpus et détermine le modèle conceptuel qui guidera l'extraction.

TABLE II.2 – Ontologies candidates pour la comparaison

N°	Ontologie	Domaine	Zone géographique	Format	Source d'accès
1	WATRIMed	Médecine traditionnelle	Afrique de l'Ouest	OWL, graphe de connais-sances	IOS Press (2 articles)
2	ontoMEDTRAD	Médecine traditionnelle	Afrique de l'Ouest	OWL + iconique	Thèse A. Kouamé (UGB)
3	ATHMed	Médecine traditionnelle	Afrique (Ghana)	Cadre conceptuel	Frontiers in AI
4	Deep Ontologies	Médecine traditionnelle	Afrique	OWL (Protégé)	Articles ARIMA
5	FLOPO, PO	Botanique	International	OWL	OBO Foundry

Chacune présente des acquis et des lacunes. Les ontologies botaniques (FLOPO, PO) décrivent bien la plante mais ne traitent pas des usages médicinaux. Les ontologies pharmaceutiques (DrOn) se resserrent sur les médicaments modernes. L'OTM, prometteuse, reste sans ancrage africain. Les initiatives africaines (WATRIMed, ontoMEDTRAD, ATHMed) s'intéressent en revanche à la médecine traditionnelle du terrain, avec ses dimensions culturelles et ses recettes multi-plantes, même si ATHMed en reste, elle, au stade d'un cadre proposé. La phase 1 en livre la comparaison détaillée.

II.1.3 Outils et environnement technique

Les outils techniques occupent une place à part entière dans notre recherche : ils ne se contentent pas d'exécuter, ils orientent. Pour chacun, nous précisons les phases concernées et les raisons de son choix.

Le dispositif d'expérimentation qui les accueille est résumé dans la figure II.2 : où chaque composant est exécuté, et comment ils communiquent.

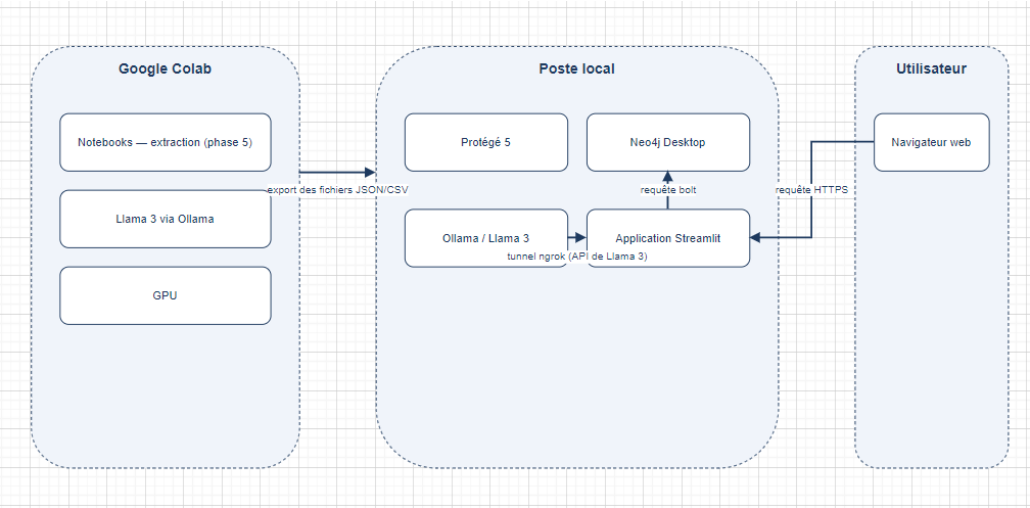


FIGURE II.2 – Dispositif technique d'expérimentation

Modèle de langage : Llama 3

Notre modèle de langage est **Llama 3 70B** [31], un modèle ouvert de grande taille dont les performances en compréhension et en génération de texte justifient le choix. Deux propriétés ont été déterminantes : la maîtrise du français, indispensable au traitement de documents scientifiques burkinabè, et la capacité à suivre des instructions complexes, requise pour une extraction structurée.

Phases d'utilisation : Phase 5 (Extraction des connaissances) et Phase 7 (Génération de réponses RAG).

Le tableau II.3 présente les modes d'accès à Llama 3.

TABLE II.3 – Modes d'accès à Llama 3 70B

Usage	**Mode d'accès**	**Environnement**
Extraction	Ollama + Google Colab	Notebooks Colab avec GPU
Génération RAG	API via ngrok	Serveur local exposé

Cinq raisons ont motivé ce choix. Ses performances dépassent celles des modèles de plus petite taille sur les tâches complexes. Il est open source, donc utilisable sans contrainte de licence. Il maîtrise le français et peut être adapté aux langues locales. Ollama en autorise l'exécution locale, tandis que ngrok en expose une API distante à l'application web. Enfin, ses 70 milliards de paramètres lui permettent de saisir des nuances sémantiques fines, qualité décisive pour l'extraction de connaissances spécialisées.

Plateforme d'exécution : Google Colab

Les expériences d'extraction se déroulent sur **Google Colab**, plateforme de notebooks hébergée par Google qui donne accès à des GPU (T4, V100, A100) adaptés à l'inférence de Llama 3 70B.

Phase d'utilisation : Phase 5 (Extraction des connaissances).

La plateforme présente une série d'avantages décisifs pour ce type de travail : elle épargne l'acquisition d'infrastructure locale coûteuse, donne accès à des GPU performants, autorise une exécution interactive et itérative, et facilite la reproductibilité des expériences. Son intégration avec Google Drive simplifie le stockage des données et des résultats, et le partage des notebooks avec d'autres chercheurs favorise la collaboration et la validation.

Base de connaissances : Neo4j Desktop

La base de connaissances est tenue par **Neo4j Desktop**, version locale de Neo4j qui permet de créer, de gérer et d'interroger des graphes de connaissances.

Phase d'utilisation : Phase 6 (Construction et interrogation de la base).

Le tableau II.4 présente les caractéristiques de Neo4j Desktop.

TABLE II.4 – Caractéristiques de Neo4j Desktop

Caractéristique	**Valeur**
Type	Base de données orientée graphe
Langage de requête	Cypher
Version	Desktop (locale)
Format d'import	CSV, JSON
Interface	Neo4j Browser, Bloom

Neo4j convient particulièrement à notre projet. Il autorise une modélisation naturelle des relations complexes entre plantes, usages, propriétés et sources. Il offre une interrogation puissante par Cypher. Il rend la traçabilité explicite par le seul jeu des relations. Il reste extensible (de nouvelles connaissances s'y ajoutent sans reconstruire la base) et sa visualisation du graphe facilite la compréhension des liens entre entités.

Orchestration RAG : LangChain

L'orchestration du système RAG est confiée à **LangChain**, framework qui permet d'enchaîner les composants du traitement : interprétation de la requête, recherche dans Neo4j, génération de la réponse.

Phase d'utilisation : Phase 7 (Exploitation par l'IA et développement web).

Le tableau II.5 présente les composants LangChain utilisés.

TABLE II.5 – Composants LangChain utilisés

Composant	**Rôle**
GraphCypherQAChain	Génération de requêtes Cypher à partir de questions naturelles
Neo4jGraph	Connexion à la base Neo4j
ChatOpenAI / Ollama	Intégration du modèle Llama 3
PromptTemplate	Construction des prompts
Memory	Gestion de l'historique de conversation

Plusieurs raisons ont conduit à retenir LangChain : c'est aujourd'hui l'un des frameworks les plus aboutis pour les systèmes RAG [29], il propose une intégration native de Neo4j via `GraphCypherQAChain`, gère l'historique de conversation, reste extensible et bien documenté, s'intègre sans effort à Streamlit et autorise la définition de chaînes de traitement complexes sans sacrifier la lisibilité du code.

Interface web : Streamlit

L'application web est développée avec **Streamlit**, framework Python qui permet de construire rapidement des applications web interactives.

Phase d'utilisation : Phase 7 (Exploitation par l'IA et développement web).

L'application offrira un ensemble de fonctionnalités : un chatbot en langage naturel pour poser des questions, des recherches par plante, par pathologie ou par région, des fiches descriptives présentant les

plantes et leurs usages, l'affichage des sources et des niveaux de preuve, ainsi qu'une visualisation du graphe de connaissances.

Nous avons retenu Streamlit pour sa simplicité d'usage et la rapidité de développement qu'il autorise, pour la gestion de l'état de session propre aux conversations, pour son intégration immédiate avec LangChain, et parce qu'il produit une interface professionnelle sans investissement lourd. Le déploiement sur un serveur ou une plateforme cloud en est également direct.

Bibliothèques Python

Les bibliothèques Python sont utilisées dans les phases 5, 6 et 7. Le tableau II.6 liste les bibliothèques Python utilisées.

TABLE II.6 – Bibliothèques Python utilisées

Bibliothèque	**Version**	**Rôle**
`neo4j`	5.x	Driver de connexion à Neo4j
`langchain`	0.1.x	Orchestration RAG
`langchain-community`	0.0.x	Intégrations Neo4j, Ollama
`streamlit`	1.30+	Interface web
`transformers`	4.40+	Chargement de Llama 3
`ollama`	0.1.x	Client Ollama
`sentence-transformers`	2.5+	Embeddings
`owlready2`	0.45+	Manipulation ontologies OWL
`rdflib`	7.0+	Format RDF/OWL
`pandas`	2.0+	Manipulation de données
`plotly`	5.18+	Visualisation

Ces bibliothèques couvrent l'ensemble des besoins techniques de la recherche : connexion à la base de données, orchestration du système RAG, développement de l'interface web, chargement du modèle de langage, manipulation des ontologies, traitement des données et visualisation.

II.1.4 Tableau récapitulatif du matériel

Le tableau II.7 rassemble l'ensemble du matériel mobilisé.

TABLE II.7 – Récapitulatif du matériel

Catégorie	Élément	Spécification
Corpus	Documents scientifiques	35 rapports, articles, thèses
	Base burkinaherbiermed.org	Plusieurs centaines de plantes
	Base INERA	> 7 000 espèces géolocalisées
Ontologies	WATRIMed	OWL, Afrique de l'Ouest
	ontoMEDTRAD	OWL + iconique, Afrique de l'Ouest
	ATHMed	Cadre proposé, Ghana
	Deep Ontologies	OWL, Afrique
	FLOPO, PO	OWL, botanique
Modèle de langage	Llama 3 70B	Via Ollama + Colab (extraction), API ngrok (RAG)
Plateforme	Google Colab	GPU T4/V100/A100
Base de connaissances	Neo4j Desktop	Orientée graphe, Cypher
Orchestration RAG	LangChain	GraphCypherQAChain
Interface web	Streamlit	Chatbot, recherche, fiches
Bibliothèques	Python	neo4j, langchain, streamlit, transformers, etc.

II.1.5 Tableau de correspondance Matériel - Phases

Le tableau II.8 met en regard le matériel et les phases méthodologiques, et indique à quel moment et dans quel but chaque ressource entre en jeu.

TABLE II.8 – Correspondance entre le matériel et les phases

Matériel	Phase	Utilisation
Corpus documentaire	Phase 3	Constitution du corpus
Ontologies candidates	Phase 1	Comparaison et sélection
Llama 3 70B	Phase 5, Phase 7	Extraction, génération RAG
Google Colab	Phase 5	Exécution de l'extraction
Neo4j Desktop	Phase 6	Base de connaissances
LangChain	Phase 7	Orchestration RAG
Streamlit	Phase 7	Interface web
Bibliothèques Python	Phase 5, 6, 7	Développement

II.2 Méthodologie

La démarche se décompose en huit phases opérationnelles. Chacune est décrite avec ses actions concrètes, ses méthodes et le livrable qu'elle produit. L'enchaînement suit une progression qui va de l'identification et de la comparaison des ontologies à la définition des critères de recherche, puis à la constitution du corpus, à l'adaptation et à l'enrichissement de l'ontologie, à la construction de la base de connaissances, à l'exploitation par l'intelligence artificielle et au développement de l'application web, et se referme sur l'évaluation et la validation.

L'ordre retenu n'est pas fortuit. Commencer par le choix de l'ontologie revient à fixer un cadre conceptuel avant même de collecter la moindre donnée : les documents sont alors recueillis dans une structure cohérente, et l'extraction peut cibler d'emblée les informations pertinentes. C'est cette discipline d'amont qui écarte la dérive la plus coûteuse : collecter abondamment pour découvrir trop tard que nous avons collecté les mauvaises choses.

II.2.1 Phase 1 : Identification et étude comparative des ontologies

Objectif : Sélectionner l'ontologie la plus pertinente pour notre contexte.

La comparaison des ontologies procède en trois temps : définir une grille de critères, noter chaque ontologie selon cette grille, puis retenir celle qui obtient le score le plus élevé. Cette phase conditionne l'ensemble de la suite, puisque c'est elle qui fixe le modèle conceptuel.

Définition de la grille de critères

Nous avons retenu huit critères, choisis en fonction de nos besoins propres : représenter les connaissances sur les plantes médicinales du Burkina Faso, intégrer les savoirs locaux, assurer la traçabilité des sources et permettre l'adaptation au contexte burkinabè. Le tableau II.9 les présente.

TABLE II.9 – Grille de critères de comparaison

N°	Critère	Description	Pondération
1	Couverture du domaine	Capacité à représenter plantes, usages, propriétés, maladies	Élevée (3)
2	Richesse sémantique	Nombre et qualité des classes, relations, axiomes	Élevée (3)
3	Disponibilité	Ontologie accessible et téléchargeable	Élevée (3)
4	Documentation	Qualité de la documentation et des exemples	Moyenne (2)
5	Interopérabilité	Compatibilité avec OWL, RDF, SPARQL	Moyenne (2)
6	Adaptabilité	Facilité d'adaptation au contexte burkinabè	Élevée (3)
7	Traçabilité	Capacité à associer les connaissances aux sources	Élevée (3)
8	Prise en compte des savoirs locaux	Intégration des noms vernaculaires, recettes multi-plantes	Élevée (3)

Chaque critère reçoit une pondération proportionnelle à son importance. Les critères de pondération élevée (3) sont ceux sans lesquels le contexte burkinabè ne serait pas représenté. Les critères de pondération moyenne (2) comptent mais peuvent s'accommoder d'un compromis. Le score global est ensuite obtenu en multipliant chaque note par la pondération de son critère, en sommant les produits et en divisant par la somme des pondérations : la pondération rend ainsi la comparaison quantitative et permet d'aboutir à un score global rapporté sur 5.

Notation des ontologies

Chaque ontologie est notée de 1 (très faible) à 5 (très élevé) pour chaque critère. Les résultats figurent dans le tableau II.10.

TABLE II.10 – Notation des ontologies candidates

Ontologie	C1	C2	C3	C4	C5	C6	C7	C8	Score
WATRIMed	4	4	2	3	5	4	3	5	3.7
ontoMEDTRAD	5	5	5	4	4	5	4	5	4.7
ATHMed	4	4	3	3	4	3	2	3	3.2
Deep Ontologies	3	4	2	2	3	3	2	4	2.9
FLOPO / PO	2	3	5	4	5	2	1	1	2.7

La lecture de ce tableau fait apparaître plusieurs tendances. Les ontologies africaines (WATRIMed, ontoMEDTRAD, ATHMed) dominent, grâce à la couverture du domaine et à la prise en compte des savoirs locaux. Les ontologies botaniques (FLOPO, PO) obtiennent de bons résultats en disponibilité et en interopérabilité, mais des scores très faibles sur la couverture des usages médicinaux et sur les savoirs locaux. WATRIMed et ontoMEDTRAD se détachent du lot, mais pour des raisons différentes : la première par l'ampleur de son modèle, la seconde par la complétude de ce qui en est accessible.

Les écarts se creusent en particulier sur la disponibilité (C3) et la documentation (C4), deux critères pondérés à 3 et à 2. Leur notation ne retient que ce que nous avons réellement en main : WATRIMed est décrit par deux articles de congrès, dont un qui tient en deux pages, et son fichier d'ontologie n'est pas téléchargeable. OntoMEDTRAD est décrite par une thèse intégralement accessible, qui livre sa liste de classes, ses propriétés, ses métriques et l'origine de ses concepts.

Sélection de l'ontologie

WATRIMed [44, 43] se classe seconde (3.7). Son modèle est riche (472 concepts et 75 propriétés dans la version documentée) et aligné sur une ontologie fondationnelle, BioTopLite2. Mais les deux publications qui le décrivent ne donnent qu'un aperçu des classes supérieures et des relations principales, et aucun moyen de réutiliser l'ontologie : le score baisse dès que la question de l'accès est posée.

ontoMEDTRAD [27] obtient le score le plus élevé (4.7). Elle couvre l'Afrique de l'Ouest, modélise explicitement les recettes multi-plantes (ingrédients, parties de plantes, modes de préparation et d'administration), trace l'origine de ses concepts et de ses relations à quinze ressources terminologiques et ontologiques existantes, et est intégralement accessible à travers la thèse qui la présente. Deux limites sont assumées : la validation définitive et globale de l'ontologie est annoncée comme une perspective, et son peuplement reste restreint à un jeu de données de 22 plantes et de 31 remèdes antipaludéens [28]. Nous l'avons retenue pour notre étude.

Ce choix nous dote d'un cadre conceptuel solide pour l'extraction et l'organisation des connaissances. Il guidera la constitution du corpus documentaire et l'adaptation de l'ontologie au contexte burkinabè.

Livrable : Ontologie ontoMEDTRAD sélectionnée.

II.2.2 Phase 2 : Définition des critères de recherche et de sélection des documents

Objectif : Définir les critères qui guideront la recherche et la sélection des documents scientifiques.

La définition des critères procède en deux temps : fixer d'abord les critères de recherche, puis les critères de sélection des documents. Ensemble, ils doivent garantir la pertinence, la qualité et la cohérence des sources retenues.

Critères de recherche

Les critères de recherche incluent :

— **Les plantes** : espèces végétales documentées au Burkina Faso, avec identification botanique (nom scientifique, famille, synonymes).

— **Les parties utilisées** : feuilles, racines, écorces, fruits, graines, fleurs, tiges, etc.

— **Les pathologies et usages médicinaux** : paludisme, infections respiratoires, digestives, diabète, hypertension, etc.

— **Les modes de préparation** : décoction, macération, infusion, poudre, extrait alcoolique, etc.

— **Les niveaux de preuve** : savoirs traditionnels, études in vitro, études in vivo, essais cliniques.

— **Les propriétés pharmacologiques** : antimicrobiennes, antipaludiques, anti-inflammatoires, antioxydantes, toxicité, etc.

— **La composition chimique** : alcaloïdes, flavonoïdes, tanins, saponines, huiles essentielles, etc.

Ces critères couvrent les principales dimensions des connaissances sur les plantes médicinales, et permettent ainsi de cibler les informations utiles à la recherche.

Critères de sélection des documents

Les critères de sélection des documents incluent :

— **Pertinence** : le document traite des plantes médicinales du Burkina Faso.

— **Identification de la plante** : le nom scientifique est précisé.

— **Disponibilité d'une référence scientifique** : le document est publié dans une revue à comité de lecture, une thèse, un mémoire ou un rapport de recherche.

— **Fiabilité** : les sources sont vérifiables et citées.

— **Actualité** : les documents récents sont privilégiés, sans exclure les travaux fondateurs.

Ces critères sauvegardent la qualité et la fiabilité des sources, et permettent d'écarter les documents non scientifiques ou non pertinents. Nous disposons ainsi d'un corpus fiable et cohérent, qui constituera la base documentaire de l'étude.

Livrable : Grille de critères de recherche et de sélection.

II.2.3 Phase 3 : Constitution du corpus scientifique

Objectif : Rassembler un corpus documentaire fiable et pertinent sur les plantes médicinales du Burkina Faso.

La constitution du corpus s'est déroulée en quatre temps. Nous avons d'abord mené une recherche documentaire sur Google Scholar, PubMed et ResearchGate, et consulté les bases burkinaherbiermed.org et INERA.

Nous avons ensuite appliqué les critères d'inclusion : le document devait traiter des plantes médicinales du Burkina Faso, préciser le nom scientifique des plantes, être publié ou validé par une institution scientifique, et s'appuyer sur des sources vérifiables et citées.

Puis sont venus les critères d'exclusion : nous avons écarté les documents non scientifiques (blogs, sites non référencés), ceux qui ne comportent pas d'identification botanique, et les documents trop anciens, sauf lorsqu'ils font référence.

Enfin, nous avons organisé le corpus, en classant les documents par type (article, thèse, rapport), en les indexant par plante, par pathologie et par région, et en les stockant dans un répertoire structuré.

Au terme de ce processus, le corpus compte 35 documents scientifiques, complétés par les données de burkinaherbiermed.org et de l'INERA. Il couvre les différentes régions du pays, un éventail de pathologies et des approches méthodologiques variées, et constitue une base solide pour l'extraction des connaissances.

Livrable : Un corpus de 35 documents scientifiques, complété par les données de burkinaherbiermed.org et de l'INERA.

II.2.4 Phase 4 : Adaptation de l'ontologie sélectionnée

Objectif : Adapter l'ontologie sélectionnée au contexte burkinabè.

L'adaptation de l'ontologie suit cinq temps : analyser les concepts existants, ajouter des classes, ajouter des propriétés, modifier les relations, puis documenter les adaptations.

Analyse des concepts existants

Nous avons étudié la structure de l'ontologie ontoMEDTRAD telle qu'elle est décrite dans la thèse [27]. L'ontologie compte 144 concepts, 76 propriétés associatives, 16 propriétés de données, 789 individus et 2 734 axiomes. Elle est formalisée en logique de description ALCHOIQ, éditée sous Protégé 5 et vérifiée par les raisonneurs HermiT et Pellet.

Le fichier OWL de l'ontologie n'étant pas téléchargeable publiquement, nous avons reconstitué sa structure à partir de la documentation publiée dans la thèse : captures d'écran Protégé (figures 5.15 à 5.20) et tableaux récapitulatifs des concepts, des propriétés et de la métrique (tableaux 5.5, 5.21 et 5.22). Cette reconstitution, aussi fidèle et complète que le permet la documentation publiée, a servi de base à l'adaptation présentée au chapitre **??**.

Cette reconstitution porte sur la structure conceptuelle de l'ontologie, c'est-à-dire ses classes, ses propriétés et ses relations, et non sur ses instances. Les 789 individus d'ontoMEDTRAD n'ont pas été réutilisés : ils relèvent du contexte et des sources propres aux travaux d'origine, tandis que notre base de connaissances orientée graphe (Neo4j) est peuplée à partir de la littérature scientifique sur les plantes médicinales du Burkina Faso. Les instances de notre modèle sont donc entièrement nouvelles, insérées dans le graphe et rattachées à leurs sources.

Ses concepts majeurs couvrent le parcours de soin complet : le praticien de la médecine traditionnelle, le patient, les indices (signes et symptômes), les maladies, les ressources médicinales (plantes, animaux, minéraux), l'examen clinique, la recette, l'ingrédient, la partie de ressource médicinale, le mode de préparation, le remède, sa forme galénique et son mode d'administration. Deux points méritent d'être relevés pour notre contexte : l'ontologie distingue explicitement les types de plante (arbre, arbuste, palme, herbe, liane) et les neuf parties de plantes utilisées (feuille, fruit, fleur, racine, tronc, écorce de tronc, écorce de racine, sève, plante entière), et elle réserve une classe aux références scientifiques des ressources médicinales, des recettes et des remèdes. Les concepts secondaires ajoutent les contre-indications, les contre-associations, les propriétés thérapeutiques, la toxicité, l'étiologie et la systématique des maladies (CIM-10). Les relations de base sont la subsomption (« est un ») et la partie-tout (« est une partie de »), complétées par 76 propriétés associatives, dont la hiérarchie *aPourForme* qui servira à l'iconisation des plantes.

Nous avons ensuite évalué cette couverture au regard du contexte burkinabè.

Le constat est mitigé. Les concepts de base sont bien couverts et l'ontologie est cohérente (aucun des raisonneurs testés ne signale d'incohérence), mais elle exige des adaptations pour le Burkina Faso. Les lacunes principales concernent les noms vernaculaires en langues locales du pays, les maladies spécifiques, les niveaux de preuve, le dosage et la traçabilité fine des sources scientifiques. S'y ajoute une limite que la thèse elle-même assume : la validation définitive et globale de l'ontologie reste une perspective, et son peuplement se limite à un jeu de données de 22 plantes et de 31 remèdes antipaludéens.

Ajout de classes

Nous avons ajouté des classes pour les maladies spécifiques au Burkina Faso (paludisme, onchocercose, méningite), pour les noms vernaculaires en mooré, dioula et fulfuldé, pour les régions du pays, pour les niveaux de preuve (traditionnel, *in vitro*, *in vivo*, clinique) et pour les sources scientifiques (article, thèse, rapport).

Ces ajouts permettent de représenter les spécificités du contexte burkinabè, d'intégrer les connaissances locales et d'assurer la traçabilité des sources.

Ajout de propriétés

Nous avons ajouté des propriétés pour les noms vernaculaires (*nomMooré*, *nomDioula* et *nomFulfuldé*), pour la localisation géographique (*coordonnéesGPS*, région et province), pour le niveau de preuve (*niveauPreuve* et *typeEtude*) et pour la traçabilité (*source*, *DOI*, page et section). Enfin, nous avons ajouté des propriétés de dosage et de toxicité.

L'enrichissement ainsi obtenu saisit des informations fines (noms vernaculaires, coordonnées, niveaux de preuve, références précises) que l'ontologie d'origine ne documentait pas pour le Burkina Faso.

Modification de relations

Nous avons précisé la relation entre remède et maladie par des attributs de niveau de preuve. Cinq relations nouvelles complètent le modèle. « aPourNiveauDePreuve » rattache un usage au niveau de preuve déclaré par sa source. « provientDe » relie une connaissance à sa source. « estDocumentéeDans » relie une plante aux documents. « aPourNomVernaculaire » rattache une plante à ses noms locaux. Enfin, « estLocaliséeÀ » l'associe à ses coordonnées géographiques.

Ces modifications assurent la traçabilité des connaissances et permettent d'exprimer des relations que le modèle d'origine, fondé sur la relation « est un » et sur la relation partie-tout, ne couvrait pas.

Documentation des adaptations

Nous avons consigné toutes les modifications dans un journal : chaque ajout est justifié, chaque choix est explicité, et les classes, propriétés et relations ajoutées, modifiées ou supprimées y sont décrites une à une.

Cette documentation n'est pas une formalité. Elle rend la démarche reproductible par un tiers et facilite les évolutions ultérieures de l'ontologie.

Livrable : Une ontologie adaptée au contexte burkinabè.

II.2.5 Phase 5 : Enrichissement des connaissances à partir de la littérature scientifique

Objectif : Extraire les connaissances du corpus et enrichir l'ontologie.

L'enrichissement ne consiste pas à ajouter les instances à l'ontologie : l'ontologie fournit le schéma, et les connaissances extraites sont destinées à la base de connaissances orientée graphe (Neo4j).

L'enrichissement procède en cinq temps : concevoir les prompts d'extraction, exécuter l'extraction assistée par LLM, contrôler la qualité des extractions, structurer les données, puis les préparer pour l'intégration dans la base de connaissances.

Conception des prompts d'extraction

Les prompts d'extraction ciblent chaque type d'information. Le prompt général demande le nom scientifique, les noms vernaculaires, la famille botanique, les parties utilisées, les usages thérapeutiques, les modes de préparation, les activités pharmacologiques, le niveau de preuve et la source.

Le prompt complet est reproduit au chapitre **??**. Il impose le format de sortie (JSON) et la liste exhaustive des champs à renseigner.

Il est ajusté selon le type de document, la typologie des sources présentée en section II.1.1 indiquant à l'avance les champs qu'un document est en mesure de renseigner. Les champs absents d'un document

restent vides dans la sortie : aucune valeur n'est comblée par déduction, ni laissée au modèle le soin de la produire.

Exécution de l'extraction

Nous avons chargé Llama 3 70B sur Google Colab, exécuté les prompts sur chaque document et sauvegardé les résultats en JSON.

L'extraction procède de manière itérative : les documents sont traités un par un ou par lots, la qualité des résultats est vérifiée au fur et à mesure, et les prompts sont ajustés lorsqu'il le faut.

Contrôle de la qualité des extractions

Deux précisions s'imposent sur la manière dont la qualité des extractions est assurée.

Le niveau de preuve associé à chaque connaissance est un attribut *rapporté* depuis la source : il reprend la caractérisation qu'en fait le document d'origine, lorsque celle-ci y est explicite (savoir traditionnel, étude *in vitro*, étude *in vivo*, essai clinique). Aucune évaluation indépendante de notre part n'y est ajoutée. Nous ne jugeons pas la solidité d'un fait. Nous conservons la valeur que lui attribue sa source et nous la relions à cette source. À défaut d'indication, l'attribut reste vide plutôt que d'être comblé par déduction. C'est au lecteur qu'il revient d'en apprécier la portée.

Par ailleurs, les extractions n'ont pas été validées par un expert externe : une relecture individuelle de chaque enregistrement n'a pas été intégrée au protocole et relève de perspectives de travail ultérieurs. La qualité n'est donc pas certifiée en amont. Elle sera mesurée en aval par le protocole d'évaluation de la phase 8, où les réponses produites seront confrontées aux réponses attendues sur un jeu de 50 questions de référence.

Structuration des données

Nous avons converti les données en CSV pour l'import dans Neo4j et les avons organisées selon le modèle de l'ontologie.

Cette structuration facilite l'import dans la base de connaissances et permet de vérifier la conformité des données au modèle.

Préparation de l'intégration dans la base de connaissances

Les instances (plantes, maladies, usages) et les relations entre instances ne sont pas ajoutées à l'ontologie elle-même : l'ontologie n'en fournit que le schéma. Les données extraites sont préparées pour être insérées dans la base de connaissances orientée graphe (Neo4j), où les connaissances seront associées à leurs sources et où les enrichissements seront documentés.

L'intégration peuple la base de connaissances et établit les liens entre les entités.

Livrable : Un ensemble de données structurées (JSON, CSV) prêtes à être intégrées.

II.2.6 Phase 6 : Construction et interrogation de la base de connaissances

Objectif : Construire la base de connaissances orientée graphe.

La construction de la base Neo4j suit trois temps : modéliser le graphe, importer les données, tester les requêtes.

Modélisation du graphe

Les nœuds définis sont *Plante*, *Maladie*, *Usage*, *Partie*, *Préparation*, *Source*, *Composé-Chimique* et *Région*. Les relations sont `TRAITE`, `UTILISE`, `PROVIENT_DE`, `A_POUR_PARTIE`,

`A_POUR_PREPARATION`, `CONTIENT` et `EST_LOCALISEE_A`. Les propriétés retenues sont le nom, le niveau de preuve, le DOI et les *coordonnéesGPS*.

Cette modélisation rend les connaissances lisibles parce qu'elle les représente comme elles sont : les nœuds sont les entités du domaine, les relations sont les liens entre ces entités, les propriétés décrivent leurs caractéristiques.

Import des données

Nous avons chargé les fichiers CSV, créé les nœuds et les relations par des requêtes Cypher, et vérifié l'intégrité des données au passage.

L'import terminé, nous avons contrôlé que toutes les données ont été correctement reprises et que les relations et les propriétés sont intactes.

Requêtes de test

Nous avons testé quatre familles de requêtes : des requêtes simples (plantes par maladie), des requêtes complexes (recettes multi-plantes), des requêtes de traçabilité (source d'une information) et des requêtes spatiales (plantes par région).

Ces vérifications établissent que la base est fonctionnelle et que les requêtes renvoient les résultats attendus.

Livrable : Une base Neo4j peuplée et interrogeable.

II.2.7 Phase 7 : Exploitation par IA et développement de l'application web

Objectif : Développer le système d'accès intelligent et l'interface utilisateur.

La mise en place du système RAG suit trois temps : définir l'architecture, construire la chaîne de traitement, intégrer les composants.

Architecture du système

L'architecture est la suivante : Utilisateur → Streamlit → LangChain → Neo4j → Llama 3 → Réponse.

Cette architecture associe la recherche d'information dans la base de connaissances à la génération de réponses par le modèle de langage. Elle préserve la traçabilité, chaque information restant rattachée à sa source. La chaîne de traitement qui relie ces maillons, de l'interprétation de la requête en langage naturel à l'affichage des sources, fait l'objet d'un détail au chapitre **??**.

Intégration des composants

Nous avons connecté LangChain à Neo4j puis au modèle de langage, et configuré les prompts pour orienter la génération des réponses. L'intégration a permis d'assembler les composants en un système RAG opérationnel.

Développement de l'application web

Nous avons conçu l'application autour de quatre fonctions : une page d'accueil avec chatbot, une recherche par plante, une recherche par pathologie et des fiches descriptives. Nous y avons intégré le système RAG et géré l'historique de conversation.

L'interface obtenue permet d'interroger la base de connaissances en langage naturel et de recevoir des réponses traçables. Sa conception détaillée et ses composants sont présentés au chapitre **??**.

Tests et validation

Deux campagnes de tests sont prévues : des tests fonctionnels et des tests utilisateurs. Les premiers vérifient que l'application fonctionne correctement. Les seconds évaluent la facilité d'utilisation et la pertinence des réponses.

Livrable : Un système RAG fonctionnel et une application web fonctionnelle.

II.2.8 Phase 8 : Évaluation et validation

Objectif : Évaluer la qualité de l'ontologie, du système RAG et de l'application web.

L'évaluation se fait à trois niveaux : l'ontologie, le système RAG, puis l'application web.

Évaluation de l'ontologie

Nous évaluerons l'ontologie sur quatre critères, présentés dans le tableau II.11.

TABLE II.11 – Critères d'évaluation de l'ontologie

Critère	**Description**	**Méthode**
Couverture	Capacité à représenter les connaissances du corpus	Vérification manuelle
Cohérence	Absence de contradictions	Requêtes de test
Traçabilité	Association des connaissances aux sources	Vérification des relations
Extensibilité	Facilité d'ajout de nouvelles connaissances	Test d'ajout

Évaluation du système RAG

Nous évaluerons le système RAG sur les quatre critères du tableau II.12.

TABLE II.12 – Critères d'évaluation du système RAG

Critère	**Description**	**Métrique**
Pertinence	Les réponses répondent à la question	Précision
Fidélité	Les réponses sont fidèles aux sources	Rappel
Exactitude	Les réponses sont correctes	F1-score
Traçabilité	Les sources sont affichées	Taux de couverture

Nous constituerons un jeu de 50 questions de référence, portant sur les plantes, les usages et les propriétés. Les réponses produites seront confrontées aux réponses attendues.

Évaluation de l'application web

Nous évaluerons l'application web sur les quatre critères du tableau II.13.

TABLE II.13 – Critères d'évaluation de l'application web

Critère	Description	Méthode
Facilité d'utilisation	L'interface est intuitive	Questionnaire
Compréhension	Les réponses sont claires	Questionnaire
Utilité	L'application répond aux besoins	Questionnaire
Performance	Temps de réponse	Mesure

Nous solliciterons 10 à 20 participants : étudiants, chercheurs et tradipraticiens.
Livrable : Rapport d'évaluation et de validation.

II.3 Synthèse et transition

II.3.1 Tableau de correspondance Phases - Livrables

Reste à réunir le parcours et à ouvrir sur le chapitre suivant. Le tableau II.14 récapitule, pour chacune des huit phases, son objectif et son livrable.

TABLE II.14 – Correspondance entre les phases, les objectifs et les livrables

Phase	Objectif	Livrable
Phase 1	Sélectionner l'ontologie la plus pertinente	Ontologie ontoMEDTRAD sélectionnée
Phase 2	Définir les critères de recherche et de sélection	Grille de critères
Phase 3	Rassembler un corpus fiable et pertinent	Corpus de 35 documents
Phase 4	Adapter l'ontologie au contexte burkinabè	Ontologie adaptée
Phase 5	Extraire les connaissances et enrichir l'ontologie	Données structurées (JSON, CSV)
Phase 6	Construire la base de connaissances graphe	Base Neo4j peuplée
Phase 7	Développer le système RAG et l'application web	Système RAG et application web
Phase 8	Évaluer la qualité du système	Rapport d'évaluation

Conclusion du chapitre

Ce chapitre a exposé le matériel et la méthodologie de notre recherche. Le matériel réunit un corpus de 35 documents scientifiques, les données de burkinaherbiermed.org et de l'INERA, cinq ontologies candidates et un environnement technique bâti sur Llama 3 70B, Google Colab, Neo4j Desktop, LangChain et Streamlit.

La méthodologie se décompose en huit phases : identification et étude comparative des ontologies, définition des critères de recherche et de sélection des documents, constitution du corpus scientifique, adaptation de l'ontologie sélectionnée, enrichissement à partir de la littérature scientifique, construction et interrogation de la base de connaissances, exploitation par l'intelligence artificielle et développement

de l'application web, évaluation et validation. Chaque phase a été décrite avec ses actions concrètes et son livrable.

L'ordre de ces phases est un choix assumé. Faire précéder la constitution du corpus par le choix de l'ontologie garantit la cohérence entre le modèle conceptuel et les données collectées, et facilite l'extraction en ciblant les informations pertinentes dès la collecte.

Deux limites méritent d'être signalées. Premièrement, les niveaux de preuve associés aux connaissances sont hérités des sources et n'ont pas fait l'objet d'une évaluation indépendante. Deuxièmement, les extractions n'ont pas été validées par un expert externe. Ces deux points relèvent de perspectives de travail et n'altèrent pas la traçabilité, qui demeure garantie par la liaison systématique de chaque information à sa source.

Les protocoles d'évaluation de la phase 8 seront appliqués au chapitre **??**, où notre approche sera mise à l'épreuve des résultats.

Le chapitre suivant portera sur la conception et le développement du système : l'ontologie adaptée, la base de connaissances construite, le système RAG implémenté et l'application web développée.

Chapitre III

Conception et développement du système

Introduction du chapitre

Les chapitres précédents ont posé, tour à tour, le cadre théorique de la recherche et la démarche méthodologique suivie pour la mener à bien. Il nous reste à montrer ce que notre démarche a effectivement produit. Le présent chapitre a pour objet de présenter le système conçu et développé pour mettre à disposition des connaissances sur les plantes médicinales du Burkina Faso, depuis le modèle conceptuel jusqu'à l'interface accessible à l'utilisateur final.

Quatre sections suivent, dans l'ordre où nous avons construit les composants. La première présente l'ontologie adaptée et enrichie, c'est-à-dire le modèle dont découle tout le reste. La seconde décrit la base de connaissances orientée graphe qui matérialise ce modèle et reçoit les connaissances extraites. La troisième expose l'intégration de l'intelligence artificielle, tant pour l'extraction assistée que pour l'accès en langage naturel fondé sur le système RAG. La quatrième enfin relate le développement de l'application web qui ouvre l'ensemble de ces composants à l'utilisateur.

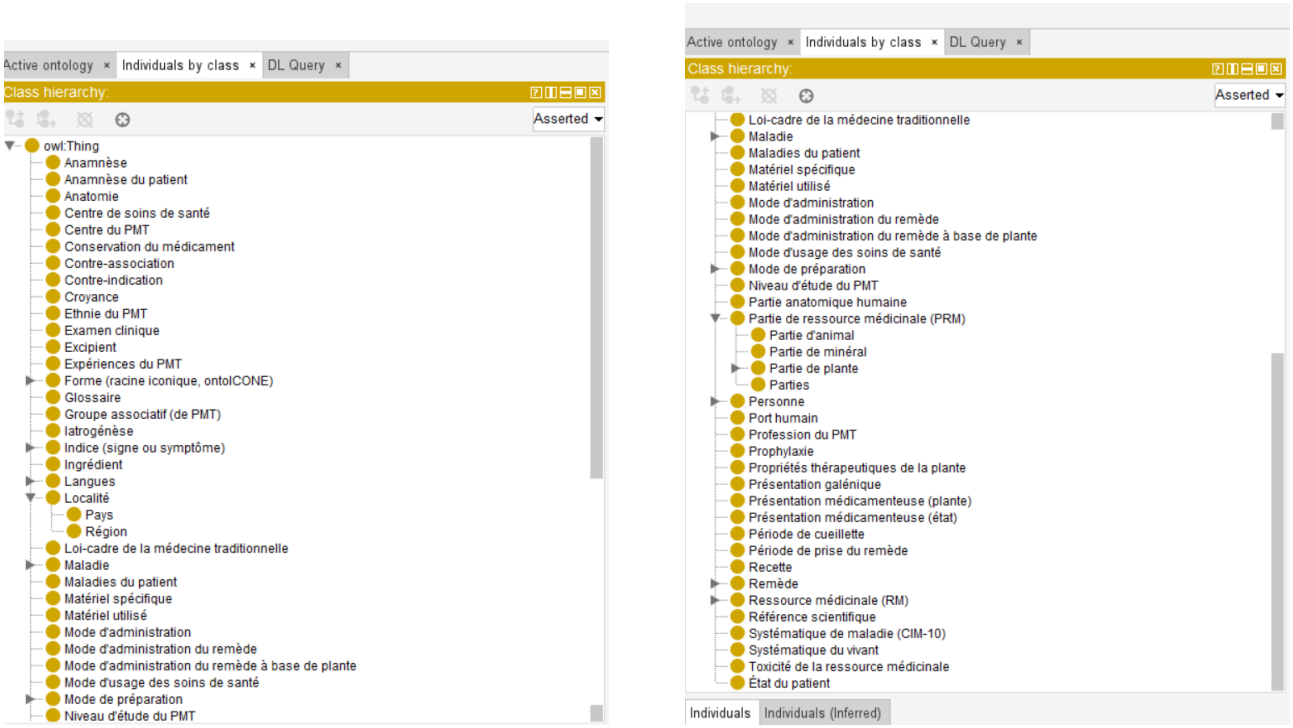
III.1 Ontologie adaptée et enrichie

L'ontologie *ontoMEDTRAD* [27], sélectionnée en phase 1 (section II.2.1 du chapitre II), constituait un point de départ solide mais incomplet pour le contexte burkinabè : couverture restreinte à vingt-deux plantes et trente et un remèdes antipaludéens, absence de noms vernaculaires locaux, silence sur les niveaux de preuve et sur la traçabilité fine des sources. Les adaptations réalisées en phase 4 ont transformé ce modèle. L'enrichissement issu de la phase 5, lui, ne modifie pas l'ontologie : il peuple la base de connaissances orientée graphe, dont l'ontologie fournit le schéma. Nous présentons ici le résultat de l'adaptation : sa vue d'ensemble, puis les classes, propriétés et relations qui l'étendent.

III.1.1 Vue d'ensemble du modèle

L'ontologie d'origine compte 144 concepts, 76 propriétés associatives, 16 propriétés de données, 789 individus et 2 734 axiomes. Elle est formalisée en logique de description *ALCHOIQ*, éditée sous Protégé 5 et vérifiée par les raisonneurs HermiT et Pellet, qui n'y signalent aucune incohérence. Nous avons conduit les adaptations dans le même environnement, en conservant cette formalisation et en maintenant la cohérence du modèle à chaque étape.

La figure **??** présente la structure de l'ontologie initiale telle que reconstituée à partir de la thèse.



(a) Partie supérieure de la hiérarchie

(b) Partie inférieure de la hiérarchie

FIGURE III.1 – L'ontologie initiale ontoMEDTRAD reconstituée sous Protégé 5 (arbre des classes)

Conformément au principe de réutilisation partielle recommandé en ingénierie ontologique, nous avons retenu d'ontoMEDTRAD les concepts relatifs aux plantes médicinales, à leurs parties, aux modes de préparation, aux maladies et à la localisation géographique, que nous avons complétés par les usages médicinaux et les composés chimiques. Nous avons en revanche écarté les modules hors du périmètre de notre étude : la couche d'iconisation (ontoICONE), dédiée à la représentation visuelle des plantes, ainsi que les concepts liés à la pratique de la médecine traditionnelle (praticiens PMT, patients, examen clinique, anamnèse). L'iconisation constitue en effet un choix de représentation, et non de conceptualisation : son abandon ne remet pas en cause la validité du modèle conceptuel réutilisé, qui porte sur les connaissances elles-mêmes. Le tableau **??** détaille ce choix.

Cette réutilisation porte sur la structure conceptuelle, non sur les données. Nous n'avons pas repris les 789 individus d'ontoMEDTRAD : ils relèvent du contexte et des sources propres aux travaux d'origine, alors que notre base de connaissances orientée graphe (Neo4j) est peuplée à partir de la littérature scientifique sur les plantes médicinales du Burkina Faso. Nous n'avons donc réutilisé que les classes, les propriétés et les relations du modèle d'origine. Les instances de notre modèle sont entièrement nouvelles, insérées dans le graphe et rattachées à leurs sources.

TABLE III.1 – Concepts retenus et écartés lors de l'adaptation

Concepts retenus	**Concepts écartés**	**Justification**
Plante, types et parties de plante	Iconisation (ontoICONE : Forme, Silhouette, Couleur. . .)	Représentation visuelle des plantes, hors du périmètre du système
Maladie (catégories CIM-10)	Praticiens (PMT, professions, expériences)	Gestion de la pratique des tradipraticiens, non utilisée
Mode de préparation	Patient, état du patient, anamnèse, examen clinique	Suivi clinique des patients, hors du périmètre
Références scientifiques	Indices (signes, symptômes)	Diagnostic clinique, non exploité
Localité, Pays	Glossaire, croyances, loi-cadre	Dimensions culturelles et réglementaires, non exploitées
Noms vernaculaires en langues locales	Langues (LangueLocales, LangueOfficielle)	Dimension linguistique reprise par les noms vernaculaires

Nous n'avons pas repris tels quels les concepts de recette, d'ingrédient et de remède d'ontoMEDTRAD : le questionnement de notre système s'appuie sur les nœuds *Usage* et *Préparation*, qui en reprennent l'essentiel sous une forme simplifiée. De même, nous n'avons pas repris telle quelle la classe *Langues* d'ontoMEDTRAD, qui recense les langues locales et officielles : la dimension linguistique est portée dans notre modèle par les noms vernaculaires (*nomMooré*, *nomDioula*, *nomFulfuldé*).

La figure **??** présente le modèle ainsi réduit à ces seuls concepts, importé dans Protégé 5 : c'est à partir de lui que s'opèrent les ajouts de l'adaptation.

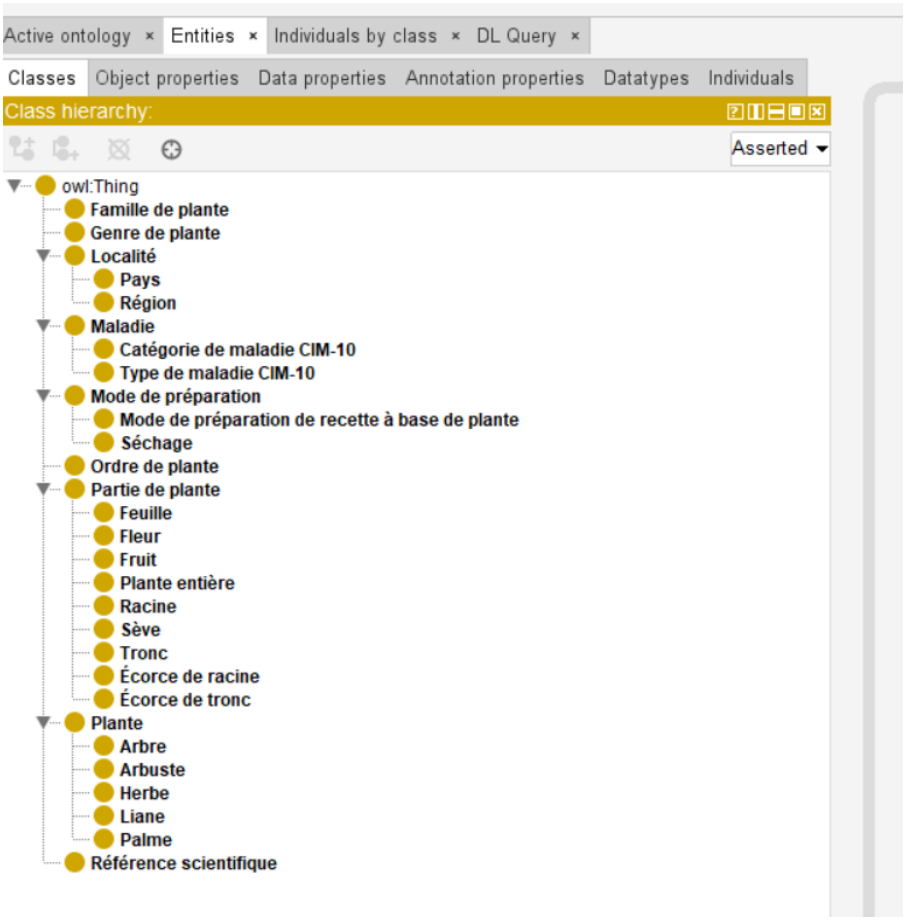


FIGURE III.2 – L'ontologie conservée : les concepts d'ontoMEDTRAD retenus

Le tableau **??** met en regard l'ontologie d'origine et l'ontologie après adaptation.

TABLE III.2 – Statistiques de l'ontologie avant et après adaptation

Indicateur	**Ontologie d'origine**	**Après adaptation**
Concepts (classes)	144	37
Propriétés associatives	76	10
Propriétés de données	16	16
Individus	789	*sans objet*
Axiomes	2 734	227

Les chiffres de la colonne « Après adaptation » sont ceux du fichier `ontoMEDTRAD-adapte.ttl` chargé dans Protégé 5.

Les instances ne sont pas portées par l'ontologie : l'enrichissement consiste à insérer les faits et les instances extraits du corpus dans la base de connaissances orientée graphe (Neo4j), dont l'ontologie fournit le schéma. Les individus de l'ontologie d'origine n'ayant pas été réutilisés, la ligne « Individus » de la colonne « Après adaptation » est sans objet.

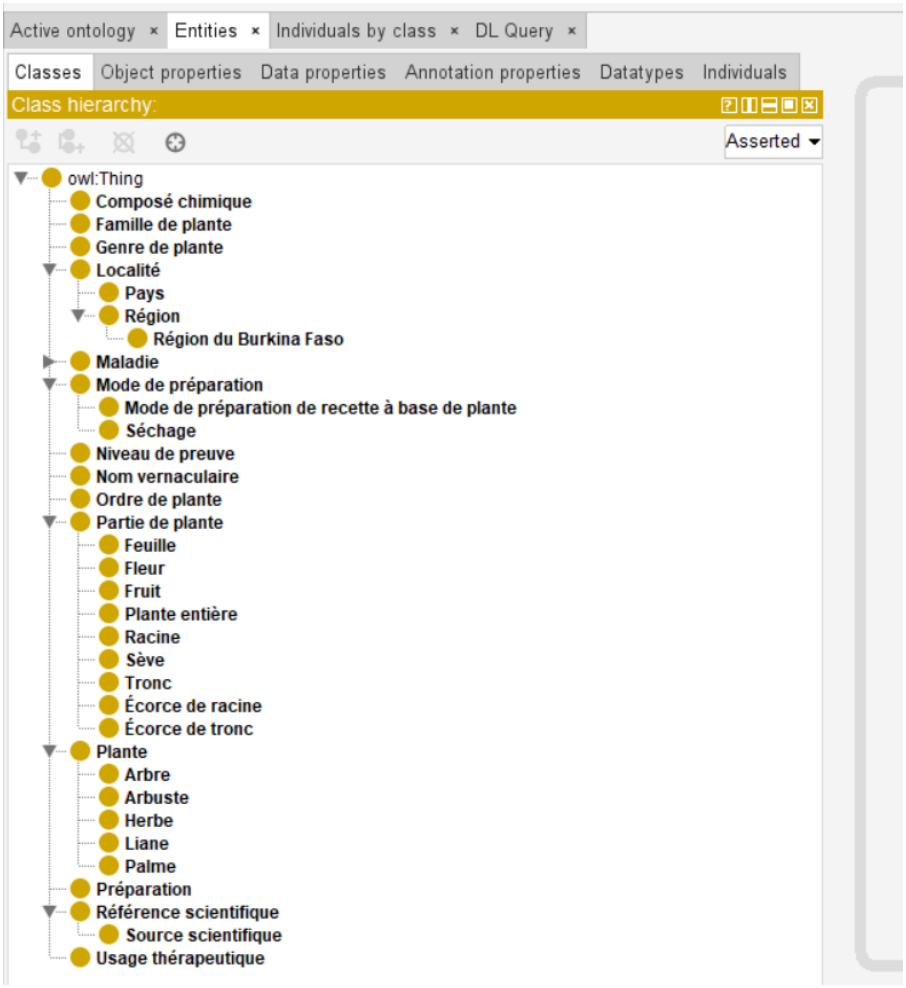


FIGURE III.3 – L'ontologie adaptée et enrichie sous Protégé 5

III.1.2 Classes ajoutées

Nous avons ajouté cinq ensembles de classes pour couvrir ce que le modèle d'origine ignorait du contexte burkinabè. Le tableau **??** les recense avec la lacune qu'ils viennent combler.

TABLE III.3 – Classes ajoutées à l'ontologie

Classe ajoutée	**Ce qu'elle représente**	**Exemples**
Maladies spécifiques du Burkina Faso	Pathologies documentées par la littérature locale	Paludisme, onchocercose, méningite
Noms vernaculaires	Désignations des plantes dans les langues du pays	Mooré, dioula, fulfuldé
Régions	Découverture territoriale du pays	**[TODO : lister les instances réelles de la classe *Région* (Protégé > onglet *Instances*), noms exacts tels qu'ils figurent dans le modèle, séparés par des virgules ; ne pas citer une région absente du modèle]**
Niveaux de preuve	Catégories de preuve rapportées par les sources	Traditionnel, *in vitro*, *in vivo*, clinique
Sources scientifiques	Type du document dont provient l'information	Article, thèse, rapport

Les cinq ensembles s'insèrent dans la hiérarchie existante. *MaladieSpecifiqueBF* est une sous-classe de *Maladie*. *RegionBF* est une sous-classe de *Region*, elle-même sous-classe de *Localite*. *SourceScientifique* est une sous-classe de *ReferenceScientifique*. *NomVernaculaire* et *NiveauDePreuve* sont en revanche des classes racines, directement rattachées à *owl :Thing*. Les classes ajoutées sont volontairement des feuilles : leurs valeurs ne sont pas des sous-classes mais des instances, portées par la base de connaissances orientée graphe et non par l'ontologie.

III.1.3 Propriétés ajoutées

Les propriétés ajoutées portent sur quatre besoins : les noms locaux, la localisation géographique, le niveau de preuve et la traçabilité documentaire. Le tableau **??** les liste.

TABLE III.4 – Propriétés ajoutées à l'ontologie

Propriété	**Rôle**
nomMooré, *nomDioula*, *nomFulfuldé*	Noms vernaculaires de la plante dans les langues locales
estLocaliséeÀ	Localisation géographique de la plante (vers *Localite*)
niveauPreuve, *typeEtude*	Niveau de preuve rapporté par la source et type d'étude
source, *DOI*, page, section	Traçabilité documentaire de chaque connaissance
Dosage, toxicité	Précautions d'emploi documentées par les sources

Les propriétés de données ajoutées sont toutes des chaînes de caractères (*xsd :string*). *nomMooré*, *nomDioula* et *nomFulfuldé* ont pour domaine *Plante*. *niveauPreuve*, *typeEtude*, *source* et *dosage* ont pour domaine *UsageTherapeutique*. *doi*, *page* et *section* ont pour domaine *SourceScientifique*. *toxicite* a pour domaine *Plante*. La localisation, elle, est portée par la propriété objet ajoutée *estLocaliséeÀ* (domaine *Plante*, portée *Localite*), complétée par la propriété de données *aCoordoneesGPS* conservée de l'ontologie d'origine (domaine *Localite*).

III.1.4 Relations ajoutées

Cinq relations nouvelles complètent le modèle, dont la structure initiale, fondée sur la relation « est un » et sur la relation partie-tout, ne couvrait pas les besoins de traçabilité. Le tableau **??** les présente.

TABLE III.5 – Relations ajoutées à l'ontologie

Relation	**Signification**
provientDe	Rattache une connaissance à la source scientifique qui la rapporte
estDocumentéeDans	Relie une plante aux documents qui la décrivent
aPourNomVernaculaire	Rattache une plante à ses désignations locales
estLocaliséeÀ	Associe une plante à sa localisation géographique (*Localite*)
aPourNiveauDePreuve	Rattache un usage au niveau de preuve déclaré par sa source

Nous avons précisé la relation entre remède et maladie par le niveau de preuve : une même association plante-maladie peut désormais être rapportée à plusieurs niveaux, chacun restant celui déclaré par la source qui l'énonce. Le niveau de preuve est porté à la fois par la propriété de données *niveauPreuve* et par la relation *aPourNiveauDePreuve*, qui rattache un usage à la classe *NiveauDePreuve*.

Les cinq relations sont des propriétés objet. *provientDe* relie *UsageTherapeutique* à *SourceScientifique*. *estDocumentéeDans* relie *Plante* à *SourceScientifique*. *aPourNomVernaculaire* relie *Plante* à *NomVernaculaire*. *estLocaliséeÀ* relie *Plante* à *Localite*. *aPourNiveauDePreuve* relie *UsageTherapeutique* à *NiveauDePreuve*.

III.2 Base de connaissances orientée graphe

L'ontologie fournit le modèle. Il fallait une base capable de le recevoir et de le peupler avec les connaissances extraites du corpus. Nous avons retenu Neo4j Desktop, pour les raisons motivées au chapitre II (section II.1.3) : ce choix a été dicté par trois exigences : modéliser naturellement des relations complexes entre plantes, usages, propriétés et sources, interroger le graphe par requêtes expressives, et rendre la traçabilité explicite par le seul jeu des relations. Cette section décrit le passage du modèle ontologique au graphe, puis son import et son interrogation.

III.2.1 Du modèle ontologique au graphe

Nous avons organisé la base en huit types de nœuds : *Plante*, *Maladie*, *Usage*, *Partie*, *Préparation*, *Source*, *ComposéChimique* et *Région*. Chaque nœud correspond à une classe de l'ontologie adaptée. Chaque propriété du graphe reprend une propriété du modèle. Le tableau **??** donne cette correspondance.

TABLE III.6 – Correspondance entre les classes de l'ontologie et les nœuds du graphe

Nœud	**Classe de l'ontologie**	**Propriétés principales**
Plante	*Plante*	Nom scientifique, noms vernaculaires
Maladie	*Maladie*	Nom, pathologie
Usage	*UsageTherapeutique*	Usage thérapeutique, niveau de preuve
Partie	*PartieDePlante*	Partie utilisée (feuille, racine, écorce. . .)
Préparation	*ModeDePreparation*	Mode de préparation (décoction, macération. . .)
Source	*SourceScientifique* (classe ajoutée)	Auteur, année, DOI, page, section
ComposéChimique	*ComposeChimique*	Nom du composé
Région	*RegionBF* (classe ajoutée)	Nom de la région, province, coordonnées GPS

Sept types de relations relient ces nœuds : `TRAITE`, `UTILISE`, `PROVIENT_DE`, `A_POUR_PARTIE`, `A_POUR_PREPARATION`, `CONTIENT` et `EST_LOCALISEE_A`. Quatre propriétés portent sur les nœuds eux-mêmes : le nom, le niveau de preuve, le DOI et les *coordonnéesGPS*.

TABLE III.7 – Relations du graphe de connaissances

Relation	**Sens retenu**
`TRAITE`	**[TODO : à confirmer sur le script d'import réellement exécuté : sens exact de la relation, sous la forme (nœud source) → (nœud cible), par exemple (Usage) → (Maladie) ou (Plante) → (Maladie). Écrire cette flèche dans cette colonne, puis vérifier que les requêtes du § suivant en découlent.]**
`UTILISE`	**[TODO : à confirmer sur le script d'import réellement exécuté : sens exact, sous la forme (nœud source) → (nœud cible), par exemple (Préparation) → (Plante) ou (Usage) → (Plante). Écrire cette flèche dans cette colonne.]**
`PROVIENT_DE`	Rattache une connaissance à sa source scientifique
`A_POUR_PARTIE`	Associe une plante à la partie utilisée
`A_POUR_PREPARATION`	Associe une plante à son mode de préparation
`CONTIENT`	Associe une plante à ses composés chimiques
`EST_LOCALISEE_A`	Localise une plante dans une région

[TODO : Schéma définitif à figer à partir des scripts d'import effectivement exécutés (fichiers .cql ou .cypher du projet) : pour chacune des 7 relations, la flèche exacte source → cible. Si le sens réel diffère des hypothèses des deux tableaux ci-dessus, corriger ces tableaux en même temps. Format : liste complète à remplacer par cette phrase, ou petite figure en 7 flèches que l'on glissera ici (fichier `images/schema_graphe.png`).]

III.2.2 Import et peuplement

L'import suit un chemin en deux temps. Les connaissances extraites par l'intelligence artificielle, d'abord, sont produites en JSON puis converties en CSV selon le modèle de l'ontologie, une table par type de nœud et une table par type de relation. Neo4j, ensuite, charge ces fichiers par des requêtes Cypher qui recréent nœuds et relations. Aucune information absente des sources n'est versée dans le graphe.

```
-- Illustratif : import d'un fichier de plantes
-- TODO : adapter aux noms de fichiers et de colonnes reels
LOAD CSV WITH HEADERS FROM 'file:///plantes.csv' AS row
MERGE (p:Plante {nom: row.nom_scientifique})
SET p.niveauPreuve = row.niveau_preuve;
```

[TODO : Remplacer ce fragment par le code réel du projet : requêtes Cypher effectivement utilisées pour l'import (fichier .cql ou .cypher du dépôt), 10 à 20 lignes consécutives montrant d'abord la création des nœuds puis celle des relations (`LOAD CSV`, `MERGE`, `CREATE`), commentées en français. Exiger : noms de fichiers CSV réels, noms de colonnes réels, aucun mot de passe ni chemin de machine personnelle (remplacer par *). Garder l'environnement `verbatim` et l'ordre des commentaires ; supprimer ensuite la ligne TODO. Indiquer en commentaire LaTeX le nom du fichier source (ex. `import/import.cql`).]**

L'import terminé, nous avons contrôlé l'intégrité des données : présence des nœuds attendus, conservation des relations et des propriétés, absence de nœuds orphelins. Le résultat en est le suivant :

[TODO : Chiffres de peuplement à relever dans Neo4j Browser après l'import, par quatre requêtes : `MATCH (n) RETURN count(n)` (total des nœuds) ; `MATCH ()-[r]->() RETURN count(r)` (total des relations) ; `MATCH (n) RETURN labels(n), count(*) ORDER BY count(*) DESC` (répartition par type de nœud) ; `MATCH ()-[r]->() RETURN type(r), count(*) ORDER BY count(*) DESC` (répartition par type de relation). Rapporter les quatre résultats ici, sous forme de phrase puis de liste, et reporter les volumes au tableau `tab:volumes_requetes` du chapitre IV.]

[TODO : Capture à produire dans Neo4j Browser : base peuplée, double-clic sur un nœud *Plante* pour l'ouvrir, puis étoffer de deux niveaux de voisinage (bouton *), de sorte que l'on voie les relations `TRAITE`, `PROVIENT_DE`, `A_POUR_PARTIE` avec leurs étiquettes. Légendes de nœuds lisibles, couleurs par type de label, fond sombre par défaut accepté. Capture 1200 px de large minimum, enregistrer sous `images/capture_neo4j.png`.]

Vue du graphe peuplé dans Neo4j Browser (extrait du sous-graphe d'une plante)

FIGURE III.4 – Le graphe de connaissances peuplé

III.2.3 Interrogation de la base

Nous avons soumis la base à quatre familles de requêtes, correspondant aux quatre usages anticipés en phase 6 (section II.2.6 du chapitre II) : requêtes simples, requêtes complexes, requêtes de traçabilité et requêtes spatiales. Les exemples suivants sont donnés à titre indicatif.

```
-- 1. Requete simple : plantes documentees contre une maladie
MATCH (p:Plante)-[:TRAITE]->(m:Maladie)
```

```
WHERE m.nom CONTAINS "Paludisme"
RETURN p.nom AS plante

-- 2. Requete complexe : recette a plusieurs plantes
MATCH (p:Plante)-[:A_POUR_PREPARATION]->(prep:Preparation)
MATCH (p)<-[:UTILISE]-(recette)
RETURN recette, collect(p.nom) AS plantes

-- 3. Requete de tracabilite : d'ou vient une information ?
MATCH (p:Plante)-[:PROVIENT_DE]->(s:Source)
WHERE p.nom CONTAINS "Artemisia"
RETURN s.auteur, s.annee, s.doi

-- 4. Requete spatiale : plantes d'une region
MATCH (p:Plante)-[:EST_LOCALISEE_A]->(r:Region)
WHERE r.nom CONTAINS "Sahel"
RETURN p.nom AS plante
```

[TODO : Avant le dépôt : exécuter chacune des 4 requêtes ci-dessus dans Neo4j Browser et (1) aligner le sens des relations sur le schéma définitif confirmé plus haut (§ Relations du graphe), (2) noter le nombre de lignes renvoyé par chacune, (3) reporter ces 4 volumes dans le tableau `tab:volumes_requetes` du chapitre IV. Remplacer éventuellement « à titre indicatif » par « exécutées sur la base peuplée » si les requêtes sont désormais réelles.]

À titre d'exemple, la question « quelles plantes traitent le paludisme dans la région du Sahel ? » se traduit par une requête qui relie les nœuds *Plante*, *Maladie* et *Région*, puis renvoie une liste de noms scientifiques.

Ces vérifications ont établi que la base est fonctionnelle et que les requêtes renvoient les résultats attendus. C'est la condition préalable à l'intégration de l'intelligence artificielle, qui interrogera notre graphe à la place de l'utilisateur.

III.3 Intégration de l'intelligence artificielle

L'intelligence artificielle intervient à deux niveaux distincts du système. En aval, elle donne accès aux connaissances en langage naturel, par le biais du système RAG. En amont, elle a contribué à produire ces mêmes connaissances, en extrayant du corpus scientifique les fiches structurées alimentant la base. Nous présentons successivement l'extraction assistée, puis le système d'accès, puis le fil de traçabilité qui les relie l'un à l'autre.

III.3.1 Extraction assistée des connaissances

Environnement d'extraction

Nous avons exécuté l'extraction sur Google Colab, en notebooks, avec accès aux GPU de la plateforme. Le modèle **Llama 3 70B** y est chargé via Ollama, conformément aux modes d'accès établis au chapitre II (tableau II.3). Le choix d'un modèle ouvert, maîtrisant le français et exécuté dans un environnement reproductible, a été motivé en section II.1.3.

```
# Illustratif : chargement du modele dans le notebook
# TODO : remplacer par l'extrait reel du notebook Colab
from langchain_community.llms import Ollama
```

```
llm = Ollama(model="llama3:70b", temperature=0)
```

Le prompt d'extraction

Nous avons adressé au modèle un prompt unique, décliné selon le type de document, pour chaque pièce du corpus. Il impose le rôle, énumère les champs à renseigner et fixe le format de sortie. Voici sa version complète :

```
Tu es un assistant spécialisé dans l'extraction de connaissances
sur les plantes médicinales du Burkina Faso.

À partir du texte ci-dessous, extrais les informations suivantes :
- Nom scientifique de la plante
- Noms vernaculaires (mooré, dioula, fulfuldé)
- Famille botanique
- Parties utilisées
- Usages thérapeutiques
- Modes de préparation
- Activités pharmacologiques
- Niveau de preuve (traditionnel, in vitro, in vivo, clinique)
- Source (auteur, année, DOI)

Réponds au format JSON.

Texte :
[contenu du document]
```

Les champs absents d'un document restent vides dans la sortie. Aucune valeur n'est comblée par déduction, et le modèle ne se charge pas de produire ce que la source n'a pas dit. Cette règle, posée dès la phase 5, est la condition de fiabilité du système. Une fiche ne contient que ce que la source contient.

Format de sortie

La sortie attendue est un document JSON dont le schéma ci-dessous est donné à titre indicatif :

```
{
  "nom_scientifique": "Artemisia annua L.",
  "noms_vernaculaires": {
    "moore": "...", "dioula": "...", "fulfulde": "..."
  },
  "famille_botanique": "Asteraceae",
  "parties_utilisees": ["feuille"],
  "usages_therapeutiques": [
    {"pathologie": "...", "niveau_preuve": "in vivo"}
  ],
  "modes_preparation": ["decoction"],
  "activites_pharmacologiques": ["antipaludique"],
  "source": {"auteur": "...", "annee": 0000, "doi": "..."}
}
```

[TODO : Remplacer ce JSON par une fiche réelle extraite du fichier produit par la boucle (extrait de `extractions.json`), avec les noms de champs exacts et les valeurs réelles d'une plante (abréger le DOI et les champs longs par « ... » si besoin). Vérifier que les champs vides y figurent

bien sous la forme "" : c'est la preuve visuelle de la règle « rien n'est comblé par déduction ». Garder l'environnement `verbatim`.]

Boucle d'extraction

Nous avons traité les documents un par un, vérifié la qualité des résultats au fur et à mesure et ajusté les prompts lorsqu'il le faut. Le schéma de la boucle est le suivant :

```
# Illustratif : boucle d'extraction sur le corpus
# TODO : remplacer par l'extrait reel du notebook
import json, glob

fiches = []
for chemin in sorted(glob.glob("corpus/*.txt")):
    texte = open(chemin, encoding="utf-8").read()
    reponse = llm.invoke(prompt.format(texte=texte))
    fiche = json.loads(reponse)
    fiche["fichier_source"] = chemin
    fiches.append(fiche)

with open("extractions.json", "w", encoding="utf-8") as f:
    json.dump(fiches, f, ensure_ascii=False, indent=2)
```

[TODO : Chiffres d'exploitation de l'extraction, à relever dans le projet puis à reporter au chapitre IV : (1) nombre total de fiches dans `extractions.json` ; (2) nombre de documents traités sans erreur de format sur 35, et nature des erreurs rencontrées (JSON invalide, troncature, champ manquant) ; (3) deux ou trois ajustements de prompt réellement effectués, décrits en une phrase chacun (ex. ajout d'un champ, consigne sur le niveau de preuve, interdiction d'inventer) ; (4) durée totale de l'exploration.]

III.3.2 Système RAG d'accès aux connaissances

Le système d'accès combine la recherche d'informations dans le graphe et la génération de réponses par le modèle de langage : c'est le principe du *Retrieval-Augmented Generation* [29], présenté au chapitre I. L'architecture retenue relie les maillons suivants : Utilisateur → Streamlit → LangChain → Neo4j → Llama 3 → Réponse (figure **??**).

[TODO : Schéma à produire : les six étapes du listé ci-dessous en six boîtes enchaînées de gauche à droite (ou sur deux lignes de trois) : Utilisateur → Streamlit → LangChain (`GraphCypherQAChain`) → Neo4j → Llama 3 → Réponse sourcée. Flèches étiquetées : « question », « requête Cypher », « sous-graphe / faits », « réponse + sources ». Ajouter une flèche de retour des sources vers la réponse pour montrer où le sourçage s'injecte (étape 6). Boîtes colorées par composant (interface, orchestration, base, modèle). Outil libre (PowerPoint, draw.io), format PNG, 15 cm de large, enregistrer sous `images/architecture_rag.png`.]

Chaîne de traitement du système RAG : des six étapes, de la requête à la réponse sourcée

FIGURE III.5 – Chaîne de traitement du système RAG

Les six étapes de la chaîne de traitement

La requête de l'utilisateur traverse six étapes, chacune confiée au composant qui en a la charge :

1. **Interprétation de la requête.** L'utilisateur formule une question en langage naturel, par exemple « Quelles plantes traitent le paludisme ? ». LangChain reçoit cette question brute, la nettoie et, le cas échéant, la met en contexte à partir de l'historique de la conversation.
2. **Génération de la requête Cypher.** Le composant `GraphCypherQAChain` convertit la question en requête Cypher, guidé par un `PromptTemplate` dans lequel le schéma de la base (types de nœuds, relations, propriétés) est injecté à l'exécution. Le langage naturel y est converti en requête formelle.
3. **Exécution sur Neo4j.** La requête Cypher est soumise à la base, qui renvoie le sous-graphe correspondant : nœuds, relations et propriétés concernés.
4. **Récupération des faits.** Le résultat est ramené sous forme de faits structurés, chaque information y conservant sa propriété de niveau de preuve et son rattachement à une source.
5. **Génération de la réponse.** Le modèle Llama 3 reçoit la question initiale et les faits retrouvés, et rédige une réponse qui ne doit s'appuyer que sur eux. Un fait absent du graphe ne doit pas y figurer.
6. **Affichage des sources.** L'interface présente la réponse, puis, pour chaque affirmation, la référence scientifique qui la soutient (auteur, année, DOI) et le niveau de preuve déclaré par cette source.

Câblage des composants

Nous avons retenu les composants LangChain listés au chapitre II (tableau II.5) : `Neo4jGraph` pour la connexion à la base, `GraphCypherQAChain` pour la génération des requêtes, le modèle via Ollama, `PromptTemplate` pour les invites et `Memory` pour l'historique. Du côté du modèle, l'accès prend deux formes selon le contexte : exécution locale via Ollama pour l'extraction, exposition d'une API via ngrok pour l'application web (tableau II.3).

```
# Illustratif : assemblage de la chaine RAG
# TODO : remplacer par le code reel du projet
from langchain_community.graphs import Neo4jGraph
from langchain.chains import GraphCypherQAChain
from langchain_community.llms import Ollama

graph = Neo4jGraph(
    url="bolt://localhost:7687",
    username="neo4j",
    password="***",
)
llm = Ollama(model="llama3:70b", temperature=0)
chain = GraphCypherQAChain.from_llm(
    llm=llm, graph=graph, verbose=True,
)
```

[TODO : Remplacer ce fragment par le code réel du projet (15 à 25 lignes maximum), qui doit montrer : la connexion Neo4j réelle (identifiant, mot de passe remplacé par *), la configuration de l'accès au modèle via l'API ngrok (variable d'environnement ou URL, sans jeton secret), le `PromptTemplate` effectivement employé pour la réponse, et le câblage de `Memory`. Commenter chaque bloc en français, garder l'environnement `verbatim`, indiquer en commentaire LaTeX le nom du fichier source (ex. `rag/chain.py`). Supprimer les blocs illustratifs devenus faux.]**

III.3.3 Traçabilité des réponses

La traçabilité ne résulte pas d'un module ajouté après coup : elle accompagne chacune des étapes du système. L'extraction n'enregistre que ce que la source déclare, en laissant vide ce qu'elle ne couvre pas. L'import rattache chaque connaissance au nœud *Source* d'où elle provient. La requête de traçabilité remonte cette source en quelques lignes de Cypher. Enfin, la génération de la réponse renvoie explicitement les références utilisées. De l'ontologie jusqu'à l'écran, la chaîne reste continue : toute information affichée dans une réponse peut être reliée à son origine.

Cette continuité a toutefois des limites, déjà signalées en phase 5 : les niveaux de preuve sont rapportés tels quels depuis les sources, sans évaluation indépendante, et les extractions n'ont pas fait l'objet d'une relecture par un expert externe. La qualité de l'ensemble relève du protocole d'évaluation de la phase 8, dont les résultats seront présentés au chapitre **??**.

III.4 Développement de l'application web

Le dernier composant est l'application web, qui rend l'ensemble accessible sans compétence technique : elle accueille l'utilisateur, recueille sa question, appelle la chaîne RAG et restitue la réponse. Développée avec Streamlit (retenu pour les raisons exposées au chapitre II, section II.1.3), elle organise autour de cette boucle un ensemble de fonctions de consultation.

III.4.1 Architecture de l'application

Notre application suit la structure classique d'une application Streamlit : un point d'entrée unique, une page par fonctionnalité, et un état de session partagé. À l'ouverture, l'utilisateur se trouve sur une page d'accueil qui associe le chatbot et les accès de recherche. Chaque interaction avec le chatbot appelle la chaîne LangChain, dont la réponse est rendue sur place, sources comprises.

[TODO : Option privilégiée : deux captures côte à côte de l'application réelle : (a) page d'accueil avec la zone de saisie du chatbot, (b) fiche descriptive d'une plante montrant usages, parties, niveau de preuve et références. Format PNG, 900 px de large chacune, enregistrer sous `images/ecran_accueil.png` et `images/ecran_fiche.png`. Si l'on préfère un schéma : boîtes Question → traitement RAG → réponse affichée avec sources, fichier `images/flux_utilisateur.png`.]

Flux utilisateur : de la question posée à la réponse sourcée (écrans de l'application)

FIGURE III.6 – Flux utilisateur de l'application web

III.4.2 Fonctionnalités

Le tableau **??** récapitule les fonctions prévues, telles qu'établies en phase 7 (section II.2.7).

TABLE III.8 – Fonctionnalités de l'application web

Fonctionnalité	Description	État
Chatbot	Question en langage naturel, réponse générée par le système RAG, sources affichées	**[TODO : Terminé / Partiel / Non réalisé : confirmer par une capture : la réponse s'affiche-t-elle avec ses sources ?]**
Recherche par plante	Consultation d'une fiche à partir du nom scientifique ou vernaculaire	**[TODO : Terminé / Partiel / Non réalisé : vérifier avec un nom vernaculaire réel (ex. en mooré), pas seulement le nom scientifique]**
Recherche par pathologie	Liste des plantes documentées contre une maladie donnée	**[TODO : Terminé / Partiel / Non réalisé : vérifier avec « paludisme » et une maladie moins couverte]**
Fiches descriptives	Usages, parties utilisées, modes de préparation, niveaux de preuve et références	**[TODO : Terminé / Partiel / Non réalisé : indiquer quels champs de la liste sont réellement affichés]**

III.4.3 Gestion de session et déploiement

Nous avons maintenu l'historique de conversation dans l'état de session de Streamlit et le transmettons à LangChain via le composant `Memory`, de sorte qu'une question de suivi, comme « Et contre l'hypertension ? », s'appuie sur le fil de la conversation précédente. Notre déploiement, en phase de développement, repose sur un serveur local complété, pour l'accès au modèle, d'une API exposée par ngrok.

```
# Illustratif : lancement de l'application
# TODO : config reelle (ngrok, variables d'environnement)
streamlit run app.py
```

[TODO : Déploiement réel à décrire en une phrase factuelle : machine (poste local, version de l'OS), commande exacte de lancement (`streamlit run` avec nom de fichier et port), commande ngrok correspondante (`ngrok http <port>`), durée pendant laquelle l'URL publique était active, et état actuel (toujours en ligne ?). Si une mise en ligne pérenne existe (Streamlit Community Cloud, serveur), donner l'URL et le dépôt. Ne pas coller de jeton d'authentification ngrok.]

[TODO : Deux captures de l'application réelle, à choix : (a) la page d'accueil telle qu'elle s'affiche pour l'utilisateur (chatbot + accès de recherche), (b) une fiche où l'on voit explicitement les références sous chaque information (auteur, année, DOI) et les niveaux de preuve. PNG net, 900 px de large minimum, nommées `images/ecran_accueil.png` et `images/ecran_fiche.png` (si ces deux fichiers ont déjà servi à la figure précédente, les réutiliser et ne changer que les légendes).]

Page d'accueil (chatbot) et fiche descriptive d'une plante

FIGURE III.7 – Écrans principaux de l'application web

Conclusion du chapitre

Ce chapitre a présenté le système issu de la démarche méthodologique du chapitre II. L'ontologie *ontoMEDTRAD*, adaptée au contexte burkinabè et enrichie par les connaissances du corpus, en constitue le modèle. La base Neo4j en est la matérialisation : huit types de nœuds, sept types de relations, un graphe peuplé et interrogeable. L'intelligence artificielle intervient à deux endroits. En amont, l'extraction assistée produit les fiches du corpus. En aval, le système RAG convertit une question en langage naturel en requête Cypher puis en réponse. L'application web referme l'ensemble sur une interface accessible.

Ces quatre composants ont tous été conçus autour d'une même préoccupation : la traçabilité. Chaque connaissance provient d'une source, est rattachée à cette source dans le graphe, et apparaît dans une réponse avec la référence qui la soutient. C'est cette continuité qui distingue le système d'un simple moteur de recherche sur texte, et qui justifie les précautions que nous avons prises à chaque étape (champs laissés vides plutôt que comblés, niveaux de preuve rapportés tels quels, origine de chaque affirmation affichée).

Il nous reste à évaluer ce que le système donne effectivement : qualité des extractions, pertinence et fidélité des réponses, pertinence des recherches, utilité perçue de l'interface. Le chapitre **??** présente les résultats de cette évaluation et en discute les limites.

Chapitre IV

Résultats et discussion

Introduction du chapitre

Les chapitres précédents ont exposé, tour à tour, la démarche que nous avons conduite et le système qui en est sorti. Ils ont laissé une question ouverte, reportée explicitement à la phase 8 : notre système tient-il les promesses faites en son nom ? Le présent chapitre y répond. Il présente les résultats de l'évaluation menée à trois niveaux, puis discute ce que ces résultats valent, et ce qu'ils ne valent pas.

L'évaluation suit le protocole fixé avant les tests (section II.2.8 du chapitre II). Trois objets y sont successivement confrontés à leurs critères : l'ontologie adaptée et enrichie, le système RAG qui l'interroge, et l'application web qui les réunit. Nous avions arrêté en amont les critères, les méthodes de mesure et les métriques : les résultats se lisent par rapport à ces critères-là, et non par rapport à ce que les tests ont fait remarquer au passage.

Quatre sections composent le chapitre. Les trois premières suivent l'ordre du protocole : évaluation de l'ontologie, évaluation du système RAG, évaluation de l'application web. La quatrième replace ces résultats dans l'ensemble de la recherche : elle les confronte aux objectifs, les situe par rapport aux systèmes existants, et énonce les limites au-delà desquelles ils n'ont pas de portée.

IV.1 Évaluation de l'ontologie

Nous avons évalué l'ontologie sur les quatre critères retenus en phase 8 : couverture, cohérence, traçabilité et extensibilité (tableau II.11 du chapitre II). Nous reprenons chacun d'eux, avec la méthode employée et le résultat obtenu.

IV.1.1 Couverture

Nous avons apprécié la couverture par vérification manuelle, en confrontant l'ontologie au corpus de 35 documents, plante par plante et usage par usage. Chaque nom scientifique, chaque désignation vernaculaire, chaque pathologie, chaque mode de préparation et chaque source citée dans un document devait trouver sa place dans le modèle. À défaut, nous la notions.

Les résultats de ce rapprochement sont les suivants : **[TODO : relevé dans Protégé 5, onglet *Instances* : nombre d'instances de la classe Plante, nombre d'usages, nombre de sources ; puis taux de couverture = éléments du corpus retrouvés dans le modèle / éléments relevés dans le corpus, en pourcentage. Écrire les trois nombres et le pourcentage, ex. « 87 plantes, 132 usages, 41 sources, couverture 81 % »]**. Ils se comparent aux chiffres du tableau **??** et à ceux du modèle d'origine, qui ne couvrait que vingt-deux plantes et trente et un remèdes antipaludéens [28].

La couverture n'est pas uniforme, et cette irrégularité vient des données plutôt que du modèle. Le corpus s'attarde sur quelques pathologies, le paludisme en tête, et sur un nombre restreint de régions.

Les questions pour lesquelles les sources se taisent, notamment le dosage et la toxicité, restent peu représentées dans la base de connaissances parce qu'elles le sont peu dans les documents. Représenter ce qui est documenté, et rien d'autre, est le principe même de l'extraction (section **??** du chapitre **??**).

IV.1.2 Cohérence

Nous avons contrôlé la cohérence de deux manières. Par les raisonneurs d'abord : nous avons relancé HermiT et Pellet dans Protégé 5 après chaque série de modifications, ajout de classes, ajout de propriétés, création de relations. Ils n'ont signalé d'incohérence à aucune étape du travail. Par des requêtes de test ensuite, qui vérifient que chaque propriété est employée sur le domaine prévu et que les instances nouvelles restent rattachées à leur classe. **[TODO : liste de 3 à 5 requêtes de test réellement exécutées dans Protégé ou Neo4j, avec leur résultat, ex. « tout Usage possède un niveauPreuve : 217/217 conformes ; toute instance de Maladie est reliée à au moins un Usage : 0 orpheline ; aucune propriété hors domaine : conforme ». Chacune sur une ligne.]**

Ce résultat mérite d'être nuancé par ce qu'il mesure : l'absence de contradiction dans le modèle, pas la justesse des connaissances qu'il contient. Une proposition fausse mais cohérente passerait ce contrôle.

IV.1.3 Traçabilité

Le critère de traçabilité vérifie que chaque connaissance reste rattachée à la source qui la rapporte. La règle est structurelle plutôt que déclarative : l'extraction ne remplit que les champs présents dans le document, l'import exige une source, et le graphe ne reçoit rien d'autre (section **??** du chapitre **??**).

Sur échantillon, nous avons contrôlé que chaque usage enregistré porte bien un nœud *Source* doté d'un auteur, d'une année et d'un DOI, ainsi qu'un niveau de preuve déclaré. **[TODO : préciser : taille de l'échantillon (ex. 30 usages tirés au sort sur l'ensemble), nombre de contrôles par fiche (présence de la source, DOI, année, niveau de preuve), et taux = conformes / contrôlés, en pourcentage. Indiquer la date du contrôle si utile.]**. Un usage sans source ne peut pas être importé : dans la chaîne telle qu'elle est câblée, il reste vide et n'atteint pas le graphe.

IV.1.4 Extensibilité

Le protocole prévoit un test d'ajout : introduire une connaissance nouvelle dans le modèle sans le casser. Nous avons mené ce test de fait, en deux temps, avant même que l'évaluation ne commence. En phases 4 et 5, nous avons ajouté cinq ensembles de classes, une série de propriétés et quatre relations au modèle d'origine, et celui-ci a conservé sa structure et sa cohérence tout au long des ajouts. Nous avons porté un test plus ciblé sur un élément non prévu au départ : **[TODO : décrire l'ajout en une phrase : quoi (une plante absente du corpus ? une région ? un niveau de preuve ?), à quel moment du travail, et ce qu'il en a été (arborescence mise à jour, aucun nouveau signalement d'HermiT, instance correctement rattachée à sa classe). Si aucun test ciblé n'a été fait en dehors des phases 4 et 5, le dire explicitement.]**.

IV.1.5 Synthèse de l'évaluation de l'ontologie

Le tableau **??** réunit les quatre critères et leurs résultats.

TABLE IV.1 – Résultats de l'évaluation de l'ontologie

Critère	Méthode	Résultat
Couverture	Vérification manuelle face au corpus de 35 documents	**[TODO : reprendre les chiffres du § Couverture : n/N et taux en %]**
Cohérence	Raisonneurs HermiT et Pellet, requêtes de test	Aucune incohérence signalée. **[TODO : reprendre le résultat ligne par ligne du § Cohérence]**
Traçabilité	Contrôle sur échantillon des relations vers les sources	**[TODO : reprendre le taux du § Traçabilité, sous la forme conformes/contrôlés (%)]**
Extensibilité	Test d'ajout, en cours de phases 4 et 5 puis ciblé	Ajouts intégrés sans rupture. **[TODO : reprendre la phrase du § Extensibilité, en une ligne]**

IV.2 Évaluation du système RAG

Le système RAG est l'endroit où se joue la promesse d'accès : une question posée en langage naturel doit recevoir une réponse pertinente, fidèle à ce que contient le graphe, et accompagnée de ses sources. Le protocole de phase 8 retient quatre critères pour cela : pertinence, fidélité, exactitude et traçabilité, mesurés sur un jeu de 50 questions de référence (tableau II.12 du chapitre II).

IV.2.1 Construction du jeu d'évaluation

Les 50 questions portent sur les plantes, les usages et les propriétés, les trois familles annoncées en phase 8. Pour chacune, nous avons établi la réponse attendue à partir du corpus et du graphe, source par source : c'est cette réponse qui sert de référence aux métriques. **[TODO : donner la répartition chiffrée, ex. « 20 questions plantes/usages, 15 propriétés pharmacologiques, 10 traçabilité, 5 multi-plantes ; total 50 ». Puis décrire en une phrase comment les réponses attendues ont été établies : rédigées par nous puis vérifiées dans Neo4j source par source, ou extraites automatiquement. Noter si une seconde personne a participé au jeu-test (sinon, le dire : c'est repris dans les limites).]**

Les métriques suivent les correspondances que nous avions fixées en phase 8 : la précision sert la pertinence, le rappel sert la fidélité, le F1-score sert l'exactitude, et le taux de couverture des réponses sourcées sert la traçabilité. La précision calcule la part des affirmations de la réponse produite qui figurent dans la réponse attendue ; le rappel calcule la part de la réponse attendue effectivement restituée ; le F1 combine les deux. **[TODO : écrire les trois formules réellement employées, avec leur légende : Précision = VV / (VV + VF), Rappel = VV / (VV + FN), F1 = 2 × P × R / (P + R), où VV = affirmations justes dans la réponse, VF = affirmations fautives, FN = éléments de la réponse attendue absents. Pour la couverture : réponses affichant au moins une source / 50. Vérifier que ces définitions correspondent bien aux colonnes du tableau suivant.]**

IV.2.2 Résultats quantitatifs

Nos mesures sur les 50 questions donnent les résultats du tableau **??**.

TABLE IV.2 – Résultats de l'évaluation du système RAG

Critère	Métrique	Résultat
Pertinence	Précision	**[TODO : valeur calculée sur 50 questions, format français : 0,87]**
Fidélité	Rappel	**[TODO : valeur calculée sur 50 questions, format français : 0,87]**
Exactitude	F1-score	**[TODO : valeur calculée sur 50 questions, format français : 0,87]**
Traçabilité	Taux de couverture des réponses sourcées	**[TODO : réponses avec au moins une source affichée, sous la forme n/50 puis pourcentage]**

Les scores globaux masquent des écarts entre familles de questions. Nous les séparons dans le tableau **??**.

TABLE IV.3 – Résultats par famille de questions

Famille de questions	Effectif	Réponses conformes	Échecs
Questions simples (plante, maladie, usage)	**[TODO : nb de questions de cette famille]**	**[TODO : nb conformes à la réponse attendue]**	**[TODO : effectif - conformes]**
Recettes multi-plantes	**[TODO : nb de questions]**	**[TODO : nb conformes]**	**[TODO : effectif - conformes]**
Traçabilité (d'où vient l'information ?)	**[TODO : nb de questions]**	**[TODO : nb conformes]**	**[TODO : effectif - conformes]**
Questions spatiales (région, localisation)	**[TODO : nb de questions]**	**[TODO : nb conformes]**	**[TODO : effectif - conformes]**

IV.2.3 Volumes d'interrogation de la base

Nous avions promis, en chapitre III, de reporter ici les volumes obtenus par les quatre familles de requêtes prévues en phase 6 (section II.2.6 du chapitre II). Le tableau **??** les rassemble.

TABLE IV.4 – Volumes de résultats des quatre familles de requêtes

Famille	Exemple	Résultats renvoyés
Requêtes simples	Plantes documentées contre une maladie	**[TODO : nombre de lignes renvoyées, relevé dans Neo4j Browser en exécutant la requête du chapitre III]**
Requêtes complexes	Recette associant plusieurs plantes	**[TODO : nombre de lignes renvoyées (requête exécutée telle quelle)]**
Requêtes de traçabilité	Sources d'une plante donnée	**[TODO : nombre de lignes renvoyées]**
Requêtes spatiales	Plantes d'une région donnée	**[TODO : nombre de lignes renvoyées]**

IV.2.4 Observations qualitatives

Les chiffres suffisent peu à eux seuls à décrire ce qui se passe pendant les tests. Les remarques suivantes complètent les métriques.

Les requêtes simples et les requêtes de traçabilité passent dans l'immense majorité des cas : elles se traduisent en Cypher sans difficulté et renvoient un sous-graphe que la génération restitue fidèlement. Nos tests se sont heurtés davantage aux recettes multi-plantes et aux questions formulées indirectement. La conversion en requête Cypher échoue alors plus souvent, ou bien la requête générée est trop large et le modèle peine à trier ce qui revient. **[TODO : décompter les échecs des 50 questions par type de défaillance, sur trois lignes : (1) génération de requête Cypher (erreur, requête vide ou mal ciblée) ; (2) sélection des faits (sous-graphe trop large ou trop étroit) ; (3) rédaction (réponse dépassant les faits du graphe). Donner les nombres, totaliser, et recouper avec le tableau `tab:res_rag_familles`.]**

Un échec n'en est pas toujours un. Lorsque la réponse demandée est absente du graphe, le système ne doit rien produire plutôt que d'improviser : la règle que nous avons posée en phase 5, un fait absent du graphe ne figure pas dans la réponse, prime sur la complétude. Une réponse vide sur une question hors corpus est donc le comportement attendu, et nous l'avons comptée comme tel lors du décompte. C'est ce qui distingue le système d'un modèle de langage seul, qui lui comblerait le trou sans prévenir.

[TODO : temps mesuré sur les 50 questions : temps moyen et temps maximal, en secondes avec une décimale, méthode indiquée (chronométrage manuel ou instrumentation de l'appel de la chaîne, ex. `time.time()` avant/après). Signaler si des questions ont dépassé un seuil raisonnable (ex. 10 s) et combien.].

IV.3 Évaluation de l'application web

Nous avons évalué l'application web sur les quatre critères du protocole : facilité d'utilisation, compréhension des réponses, utilité perçue et performance (tableau II.13 du chapitre II). Nous mesurons les trois premiers par questionnaire, le dernier par chronométrage.

IV.3.1 Campagne de test

Nous avons soumis l'application à **[TODO : nombre exact de participants, ex. 12]** participants, recrutés selon les profils prévus en phase 8 : **[TODO : répartition réelle, ex. 6 étudiants, 4 chercheurs, 2 tradipraticiens ; si le recrutement n'a pas eu lieu, décrire le panel prévu et laisser ce TODO en signalant que les résultats sont alors provisoires]**. Chacun a passé trois scénarios : retrouver la fiche d'une plante à partir de son nom vernaculaire, poser une question au chatbot, puis remonter d'une réponse donnée jusqu'à la source qui la soutient. Nous avons administré un questionnaire après les scénarios. **[TODO : échelle employée, items du questionnaire, conditions de passation]**.

IV.3.2 Résultats du questionnaire

Les résultats par critère figurent au tableau **??**.

TABLE IV.5 – Résultats de l'évaluation de l'application web

Critère	Méthode	Résultat
Facilité d'utilisation	Questionnaire	**[TODO : score moyen des participants sur l'échelle employée, ex. 4,2/5]**
Compréhension des réponses	Questionnaire	**[TODO : score moyen, ex. 4,0/5]**
Utilité perçue	Questionnaire	**[TODO : score moyen, ex. 3,8/5]**
Performance	Mesure du temps de réponse	**[TODO : temps moyen en secondes, une décimale]**

[TODO : Schéma à produire : histogramme horizontal des scores moyens du questionnaire, 3 barres seulement (facilité d'utilisation, compréhension, utilité), échelle de 1 à 5 en abscisse, valeurs chiffrées à l'extérieur de chaque barre. La performance, mesurée en secondes, n'a pas la même échelle : la laisser de côté ici (elle est au tableau ??). Outil Excel, LibreOffice ou matplotlib ; PNG 150 dpi, titre et axes en français, enregistrer sous `images/resultats_questionnaire.png`.]

Scores moyens des trois critères à questionnaire, échelle de 1 à 5

FIGURE IV.1 – Résultats du questionnaire par critère

Les observations que nous avons recueillies pendant les scénarios complètent les scores : **[TODO : 3 à 5 observations factuelles, une phrase chacune, tirées des notes de passation : ex. « deux participants ont cherché en vain un nom vernaculaire sans accent », « la mention du niveau de preuve n'a pas été comprise sans légende », « attente perçue comme longue à la première question ». Éviter les jugements de valeur non étayés.]**.

IV.3.3 Performance

Nos mesures décomposent le temps de réponse en deux temps inégaux : l'interrogation de Neo4j se compte en millisecondes, la génération de la réponse par Llama 3 en secondes. C'est donc le modèle qui pèse dans l'attente, l'API exposée par ngrok ajoutant son propre délai. **[TODO : chiffrer la**

décomposition : temps de requête Cypher en millisecondes (relevé dans Neo4j Browser ou logs LangChain), temps de génération en secondes, délai de l'API ngrok en secondes si mesurable, puis temps moyen et maximal par type d'opération (chatbot, recherche de fiche, affichage de résultats). Une décimale pour les secondes.].

IV.4 Discussion

Les résultats des trois sections précédentes décrivent ce que le système fait. Cette section les replace dans le travail plus large : d'abord par rapport aux questions posées au départ, ensuite par rapport aux systèmes existants, puis dans ce qu'ils ont de limité, enfin dans ce qu'ils suggèrent pour la suite.

IV.4.1 Confrontation aux objectifs de la recherche

La première question de recherche demandait d'identifier les ontologies du domaine et d'en retenir la plus adaptée au contexte burkinabè. Nous avons noté cinq ontologies sur une même grille au chapitre II. *ontoMEDTRAD* y a obtenu le score le plus élevé, 4.7 contre 3.7 pour *WATRIMed*, le meilleur concurrent. Notre choix est documenté et reproductible. Ses limites sont connues elles aussi : le modèle retenu n'est pas le plus riche de tous, c'est celui qui combine l'accès, l'ancrage régional et la documentation.

La deuxième question portait sur les adaptations nécessaires et sur la garantie de la traçabilité. Les cinq ensembles de classes que nous avons ajoutés, les propriétés de noms vernaculaires et les cinq relations de rattachement que nous avons créées répondent au premier volet. Le contrôle d'échantillon de la section **??** répond au second, sous réserve du taux **[TODO : reprendre ici, en toutes lettres, le taux de conformité de la section IV.1 (ex. « taux de conformité de 98 % sur 50 contrôles »)]** retenu.

La troisième question concernait l'exploitation de l'ontologie par un système RAG au service de l'accès en langage naturel. Le système est fonctionnel : il convertit une question en requête Cypher, interroge le graphe et rédige une réponse sourcée. La qualité de cet accès se mesure aux métriques du tableau **??**, encore **[TODO : recopier ici les quatre valeurs du tableau `tab:res_rag`, ex. « précision 0,87, rappel 0,79, F1 0,83, couverture 48/50 » : sinon remplacer « encore » par la formulation adaptée]**.

La quatrième question portait sur l'application web. Elle existe, elle réunit les fonctions prévues au tableau **??**, et nous l'avons mise à disposition des participants, ce qui a fourni les résultats du tableau **??**.

Une réserve traverse les quatre réponses : plus les chiffres ci-dessus restent provisoires, plus cette confrontation elle-même demeure provisoire.

IV.4.2 Confrontation aux systèmes existants

Le modèle d'origine *ontoMEDTRAD* couvrait vingt-deux plantes et trente et un remèdes antipaludéens [28]. Notre enrichissement porte cette couverture à **[TODO : reprendre les mêmes chiffres que la section IV.1 : nombre de plantes, nombre d'usages, nombre de sources après enrichissement]**. L'augmentation réelle, mesurée sur un corpus de 35 documents, reste d'ampleur modeste : notre base n'a pas l'envergure d'une encyclopédie, et elle ne le prétend pas.

Face à *WATRIMed*, riche en concepts mais dont les publications ne donnent aucun moyen de réutiliser l'ontologie, la différence tient à ce qui se passe après le modèle. Chez nous, chaque connaissance descend dans une base interrogable, remonte dans une réponse rédigée et s'accompagne de la référence qui la soutient. Chez *WATRIMed*, le modèle s'arrête au modèle.

L'apport principal n'est donc pas la taille. C'est la continuité du fil qui va de la source scientifique jusqu'à l'écran de l'utilisateur, en passant par l'ontologie, le graphe et la réponse, sans qu'un maillon perde l'information d'origine.

IV.4.3 Limites

Six limites encadrent les résultats qui précèdent. Elles ne sont pas des détails de présentation : elles déterminent la portée de tout ce que nous avons mesuré.

1. **L'évaluation a été conduite par nous-mêmes, les concepteurs du système.** Aucun évaluateur extérieur n'a été mêlé aux tests, et le panel, réduit **[TODO : donner le chiffre exact et sa composition, ex. « 12 participants : 6 étudiants, 4 chercheurs, 2 tradipraticiens », plus les conditions de passation (lieu, durée)]**, n'a pas la taille qui permettrait des comparaisons statistiques solides. Un utilisateur familier du domaine et de l'outil n'aura pas rencontré les mêmes difficultés qu'un premier venant.
2. **Le jeu de 50 questions part du même corpus que l'ontologie.** Nous avons tiré les questions des documents qui ont servi à construire le système. Elles mesurent donc surtout ce qu'il sait déjà faire. Des questions posées par d'autres utilisateurs, sur des documents absents du corpus, donneraient probablement des scores moins élevés.
3. **Les niveaux de preuve sont hérités des sources.** Nous les avons rapportés tels quels, sans réévaluation indépendante, comme nous l'avons dit en phase 5 et au chapitre **??**. Un usage classé « traditionnel » par sa source le reste dans notre base, même si l'étude qui le rapporte ne le vérifie pas.
4. **Nous n'avons pas fait relire les extractions par un expert.** La règle d'or, ne rien ajouter de ce que la source ne dit pas, limite le risque, mais elle ne l'élimine pas : une fiche peut rester fidèle au format tout en déformant le propos. Nous n'avons réalisé aucune relecture systématique par un ethnobotaniste ou un pharmacologue. **[TODO : si un échantillon a malgré tout été relu : donner le nombre de fiches relues, le nombre d'erreurs trouvées et le taux ; sinon, supprimer cette phrase TODO et remplacer par « Aucun échantillon n'a fait l'objet d'une telle relecture. »]**.
5. **L'échelle reste celle d'un prototype.** Trente-cinq documents, **[TODO : reprendre le nombre de fiches extraites donné au chapitre III (nombre d'entrées de extractions.json)]** fiches, un déploiement local complété par un tunnel ngrok : nous n'avons pas mis le système à l'épreuve d'un usage soutenu, ni d'un public large, ni d'une mise en ligne pérenne.
6. **Le périmètre reste celui d'un outil de consultation.** Le système aide à chercher, à lire et à vérifier une information documentée. Il ne pose pas de diagnostic et n'établit pas de prescription, et rien dans les résultats présentés ici ne saurait être lu comme une validation clinique.

S'y ajoute une remarque de méthode : l'hypothèse d'une extraction assistée par modèle de langue meilleure qu'une extraction manuelle n'a pas été testée par une comparaison contrôlée. Elle suppose un protocole à part entière, avec deux groupes traités dans les mêmes conditions, que nous n'avons pas mené.

IV.4.4 Pistes de travail

Quatre prolongements se dégagent des limites qui précèdent.

Faire évaluer le système par d'autres que ses concepteurs : un évaluateur externe pour les extractions, un second panel d'utilisateurs plus nombreux et recruté hors du cercle du projet, dont des tradipraticiens à qui l'application est d'abord destinée.

Élargir le corpus et mesurer l'effet sur la couverture. Les thèses et rapports encore non numérisés constituent le gisement le plus immédiat, et leur intégration donnerait une idée plus juste du lien entre volume documentaire et richesse du modèle.

Fiabiliser l'extraction par une relecture experte échantillonnée, et confronter les réponses du système à des questions formulées par de vrais utilisateurs plutôt que tirées du corpus.

Rendre le service accessible au-delà de la machine de développement, avec un déploiement conteneurisé et une instrumentation discrète des usages, de sorte que la prochaine évaluation puisse s'appuyer sur des données de terrain recueillies en conditions réelles.

Conclusion du chapitre

Ce chapitre a présenté les résultats de l'évaluation prévue en phase 8 et en a discuté la portée. À l'ontologie, les contrôles n'ont révélé ni incohérence ni rupture de traçabilité, et la couverture avance avec le corpus, inégalement selon les pathologies documentées. Au système RAG, les 50 questions de référence livrent des mesures par critère et par famille de questions, des requêtes simples et de traçabilité assurées, et des difficultés concentrées sur les recettes multi-plantes et les conversions de requêtes complexes. À l'application web, les scénarios passés par les participants fournissent un premier retour sur l'usage, dont les scores figurent au tableau **??**.

Nous avons replacé ces résultats face aux quatre questions de la recherche et face aux systèmes existants : le fil qui relie la source scientifique à l'écran de l'utilisateur tient d'un bout à l'autre de la chaîne, et c'est là ce que le travail apporte de plus net. Six limites encadrent ce bilan, dont les principales tiennent à une évaluation conduite par les concepteurs, à un jeu de questions issu du même corpus, et à des extractions non relues par un expert.

Ces limites ne ferment rien. Elles indiquent ce qui resterait à faire pour transformer un prototype documenté en outil de recherche partagé, et c'est ce que la conclusion générale reprend à son tour.

Conclusion générale

Nous sommes partis d'une difficulté d'accès. Les connaissances scientifiques sur les plantes médicinales du Burkina Faso sont abondantes, mais dispersées entre des articles, des thèses, des mémoires et des rapports qui n'emploient ni les mêmes terminologies, ni les mêmes dénominations pour désigner une même plante. Retrouver une information sur une plante, une pathologie ou une recette, et remonter à la source qui la soutient, demandait un travail que les documents seuls ne permettaient pas d'organiser. Pour y répondre, nous avons choisi d'adapter et d'enrichir une ontologie existante à partir de la littérature scientifique, puis d'exploiter cette ontologie au moyen d'un système d'accès intelligent et d'une application web. La démarche a suivi huit phases, chacune produisant les livrables nécessaires à la suivante : de l'étude comparative des ontologies jusqu'à l'évaluation du dispositif.

La première phase a permis d'identifier les ontologies du domaine et de les comparer sur une grille commune. Nous avons retenu *ontoMEDTRAD*, avec le score le plus élevé de la comparaison, devant *WATRIMed*, puis nous l'avons adaptée au contexte burkinabè et enrichie à partir de 35 documents scientifiques. Nous avons ajouté cinq ensembles de classes, les propriétés relatives aux noms vernaculaires et cinq relations de rattachement, tandis que la structure d'origine était préservée. Nous avons versé les connaissances extraites dans une base de connaissances orientée graphe, interrogeable en Cypher, où chaque information reste reliée à la source qui la rapporte. Nous avons mis au point un système RAG, articulant LangChain, le modèle Llama 3 et la base Neo4j, pour traduire une question en langage naturel en une requête sur le graphe et rédiger une réponse fondée sur les faits retrouvés. Une application web, enfin, a réuni l'ensemble derrière une interface de recherche et de consultation. Sur notre dispositif, nous avons mené l'évaluation prévue, à trois niveaux : l'ontologie, le système RAG et l'application.

La vérification des hypothèses s'appuie sur les résultats consignés aux chapitres **??** et **??**.

Hypothèse 1. La revue méthodique de la littérature devait permettre d'identifier et d'enrichir un modèle ontologique capable de représenter les connaissances sur les plantes médicinales du Burkina Faso. Cette hypothèse est confirmée : l'étude comparative a mis en évidence plusieurs modèles candidats, et nous avons pu adapter puis enrichir le modèle retenu à partir du corpus, jusqu'à représenter les plantes, leurs usages, leurs parties utilisées, leurs modes de préparation, leurs propriétés et leurs sources.

Hypothèse 2. L'extraction assistée par un modèle de langue de grande taille devait améliorer la constitution des connaissances par rapport aux méthodes manuelles. Cette hypothèse n'est que partiellement étayée. Nous avons effectivement mis en œuvre l'extraction assistée par LLM, qui a produit des données structurées exploitables, mais nous n'avons pas mené la comparaison contrôlée entre extraction automatique et extraction manuelle. Nous ne pouvons donc pas affirmer, au vu de nos seuls résultats, que la première soit supérieure à la seconde. Cette supériorité reste une hypothèse de travail à éprouver, avec deux groupes traités dans les mêmes conditions.

Hypothèse 3. L'adaptation et l'enrichissement devaient permettre de mieux représenter les connaissances documentées tout en assurant leur traçabilité. Cette hypothèse est confirmée. Face au modèle d'origine, qui couvrait vingt-deux plantes et trente et un remèdes antipaludéens [28], l'ontologie enrichie représente un ensemble plus large, dont les chiffres de couverture figurent au tableau **??**. Les raisonneurs HermiT et Pellet n'ont signalé aucune incohérence au fil des ajouts, et la traçabilité repose sur une règle structurelle : une connaissance sans source ne peut pas entrer dans le graphe. Les

contrôles sur échantillon n'ont pas démenti cette propriété.

Hypothèse 4. L'exploitation de l'ontologie par un système RAG devait faciliter la recherche et la compréhension des connaissances en langage naturel. Cette hypothèse est confirmée pour l'essentiel. Sur les 50 questions de référence, le système traduit correctement les questions simples et les questions de traçabilité, et rédige des réponses sourcées. Les métriques correspondantes sont réunies au tableau **??**. Il rencontre davantage de difficulté sur les recettes associant plusieurs plantes et sur les questions formulées indirectement. Cette réussite doit être lue avec la réserve qui l'accompagne : le jeu de questions provient du corpus qui a servi à construire l'ontologie, et l'évaluation a été conduite par les concepteurs eux-mêmes.

Hypothèse 5. Une application web intégrant le système RAG devait faciliter la vulgarisation et la diffusion des connaissances documentées. Cette hypothèse est confirmée, sous réserve de l'ampleur des tests. L'application existe, elle réunit les fonctions prévues, et les participants l'ont utilisée selon trois scénarios. Leurs retours figurent au tableau **??**. La campagne reste toutefois réduite : le panel est modeste et n'autorise pas de comparaison statistique.

Six limites encadrent ce bilan. L'évaluation a été conduite par nous-mêmes, les concepteurs du système, et le regard extérieur y a manqué. Le jeu de questions part du même corpus que l'ontologie, ce qui le porte à mesurer d'abord ce que le système sait déjà faire. Les niveaux de preuve sont ceux que rapportent les sources, sans réévaluation indépendante. Les extractions n'ont pas été relues par un expert. L'échelle reste celle d'un prototype, déployé localement, sans usage soutenu ni public large. Le périmètre reste enfin celui d'un outil de consultation : le système ne pose pas de diagnostic, n'établit pas de prescription, et rien dans nos résultats ne saurait être lu comme une validation clinique.

Ces limites indiquent les prolongements les plus utiles. Faire évaluer le dispositif par d'autres que ses concepteurs, avec un panel plus large recruté hors du cercle du projet, dont des tradipraticiens à qui l'application est d'abord destinée. Élargir le corpus, en intégrant les thèses et rapports encore non numérisés, et mesurer l'effet de ce volume sur la couverture. Fiabiliser l'extraction par une relecture experte échantillonnée, et confronter les réponses à des questions posées par de vrais utilisateurs plutôt que tirées des documents. Rendre enfin le service accessible au-delà de la machine de développement, par un déploiement conteneurisé et une instrumentation discrète des usages, afin que la prochaine évaluation s'appuie sur des données de terrain.

L'apport de notre travail ne tient pas à la taille de la base, qui reste modeste, mais à la continuité qui la traverse. De la source scientifique jusqu'à l'écran de l'utilisateur, en passant par l'ontologie, le graphe et la réponse, aucun maillon ne perd l'information d'origine : chaque connaissance conserve la référence qui la fonde, et chaque réponse reste rattachée aux faits du graphe. C'est cette exigence de traçabilité, tenue d'un bout à l'autre de la chaîne, qui donne au prototype sa valeur, en attendant que des évaluations plus larges confirment ou corrigent ce qu'il promet.

Bibliographie

[1] AI4D. *Création d'une base de données sur les plantes médicinales pour faciliter l'exploitation des connaissances ethnopharmacologiques locales*. 2020. URL : https://www.ai4d.ai/fr/blog/building-a-medicinal-plant-database (visité le 26/09/2026).

[2] Richard O. Angole et al. « Towards an Ontology Model for African Traditional Medicine ». In : *Advances in Knowledge-Based and Intelligent Information and Engineering Systems*. T. 243. Frontiers in Artificial Intelligence and Applications. IOS Press, 2012, p. 386-395. DOI : 10.3233/978-1-61499-105-2-386.

[3] Richard Okelo Angole, Peter Jehopio et Gilbert Maiga. « Ontology model : Towards bridging the gap between African traditional medicine and conventional medicine ». In : *International Journal of Knowledge-Based and Intelligent Engineering Systems* 17.1 (2013), p. 37-43. DOI : 10.3233/KES-130263.

[4] ARES. *Médecine traditionnelle et système de santé : vers une intégration durable*. 2018. URL : https://moove.ares-ac.be/actu/medecine-traditionnelle-et-systeme-de-sante-vers-une-integration-durable (visité le 26/09/2026).

[5] Armel Ayimdji et al. « Towards A "Deep" Ontology for African Traditional Medicine ». en. In : *Intelligent Information Management* 3.6 (oct. 2011). Number : 6, p. 244-251. DOI : 10.4236/iim.2011.36030. URL : https://www.scirp.org/journal/paperinformation?paperid=8241 (visité le 12/06/2026).

[6] Ricardo Baeza-Yates et Berthier Ribeiro-Neto. *Modern Information Retrieval : The Concepts and Technology behind Search*. 2e éd. Harlow : Addison-Wesley, 2011. URL : https://books.google.com/books/about/Modern_Information_Retrieval.html?id=HbyAAAAACAAJ.

[7] Bruce G. Buchanan et Edward H. Shortliffe, éd. *Rule-Based Expert Systems : The MYCIN Experiments of the Stanford Heuristic Programming Project*. Reading, MA, USA : Addison-Wesley, 1984. ISBN : 0-201-10172-6.

[8] Laurel Cooper et al. « The Plant Ontology as a Tool for Comparative Plant Anatomy and Genomic Analyses ». In : *Plant and Cell Physiology* 54.2 (2013), e1. DOI : 10.1093/pcp/pcs163.

[9] Fred D. Davis. « User acceptance of information technology : system characteristics, user perceptions and behavioral impacts ». In : *International Journal of Man-Machine Studies* 38.3 (mars 1993), p. 475-487. ISSN : 0020-7373. DOI : 10.1006/imms.1993.1022. URL : https://www.sciencedirect.com/science/article/pii/S0020737383710229 (visité le 29/09/2026).

[10] Samuel Nii Odoi Devine, Emmanuel Awuni Kolog et Roger Atinga. « Toward a Knowledge-Based System for African Traditional Herbal Medicine : A Design Science Research Approach ». In : *Frontiers in Artificial Intelligence* 5 (2022). PMC8959699, p. 856705. DOI : 10.3389/frai.2022.856705. URL : https://doi.org/10.3389/frai.2022.856705.

[11] Jacob Devlin et al. « BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding ». In : *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*. 2019, p. 4171-4186. doi : 10.18653/v1/N19-1423. url : https://aclanthology.org/N19-1423/.

[12] Damion M. Dooley et al. « FoodOn : A Harmonized Food Ontology to Increase Global Food Traceability, Quality Control and Data Integration ». In : *npj Science of Food* 2 (2018), p. 23. doi : 10.1038/s41538-018-0032-6. url : https://www.nature.com/articles/s41538-018-0032-6.

[13] Jérôme Euzenat et Pavel Shvaiko. *Ontology Matching*. 2e éd. Springer, 2013. doi : 10.1007/978-3-662-43550-9. url : https://doi.org/10.1007/978-3-662-43550-9.

[14] Élisabeth Flahaut. « Pharmacopée et médecine traditionnelle dans l'Ouest du Burkina Faso : plantes médicinales et soins du couple mère-enfant ». 143 pages. Thèse de doctorat en pharmacie. Université de Lille II, 1999. url : https://passioneuro.fr/wp-content/Documents/These_E-FLAHAUT_1999.pdf.

[15] Luciano Floridi et al. « AI4People—An Ethical Framework for a Good AI Society : Opportunities, Risks, Principles, and Recommendations ». In : *Minds and Machines* 28.4 (2018), p. 689-707. doi : 10.1007/s11023-018-9482-5.

[16] Ralph Grishman. « Twenty-five Years of Information Extraction ». In : *Natural Language Engineering* 25.6 (2019), p. 677-692. doi : 10.1017/S1351324919000512.

[17] Thomas R. Gruber. « A Translation Approach to Portable Ontology Specifications ». In : *Knowledge Acquisition* 5.2 (1993), p. 199-220. doi : 10.1006/knac.1993.1008. url : https://doi.org/10.1006/knac.1993.1008.

[18] Nicola Guarino. « Formal Ontology, Conceptual Analysis and Knowledge Representation ». In : *International Journal of Human-Computer Studies* 43.5–6 (1995), p. 625-640. doi : 10.1006/ijhc.1995.1066.

[19] Sita Guinko. « La végétation de la Haute-Volta ». Deux volumes, 394 pages. Thèse de doctorat ès sciences. Université de Bordeaux III, 1984. url : https://www.scirp.org/reference/referencespapers?referenceid=3387847.

[20] John Hanna et al. « Building a Drug Ontology Based on RxNorm and Other Public Domain Drug Databases ». In : *Journal of Biomedical Semantics* 4 (2013), p. 44. doi : 10.1186/2041-1480-4-44. url : https://pubmed.ncbi.nlm.nih.gov/24345026/.

[21] Michael Heinrich et al. *Fundamentals of Pharmacognosy and Phytotherapy*. Edinburgh : Churchill Livingstone, 2004. isbn : 978-0-443-07132-4.

[22] Robert Hoehndorf et al. « The Flora Phenotype Ontology (FLOPO) : Tool for Integrating Morphological Traits and Phenotypes of Vascular Plants ». In : *Journal of Biomedical Semantics* 7 (2016), p. 65. doi : 10.1186/s13326-016-0107-8. url : https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5109718/.

[23] Syed Hussain et Gihan Athula. « Extending a Conventional Chatbot Knowledge Base to External Knowledge Source and Introducing User Based Sessions for Diabetes Education ». In : (2018), p. 698-703. url : https://ieeexplore.ieee.org/abstract/document/8418155.

[24] Daniel Jurafsky et James H. Martin. *Speech and Language Processing*. 3e éd. 2023. url : https://web.stanford.edu/~jurafsky/slp3/ (visité le 26/09/2026).

[25] Michel C. A. Klein et Dieter Fensel. « Ontology Versioning on the Semantic Web ». In : *Proceedings of the First International Semantic Web Working Symposium (SWWS)*. Stanford, CA, USA, 2001, p. 75-91.

[26] Janet L. Kolodner. *Case-Based Reasoning*. San Mateo, CA, USA : Morgan Kaufmann, 1993. isbn : 1-55860-237-2.

[27] Appoh Kouamé. « Système de gestion de la médecine traditionnelle dans une plateforme web social et sémantique : une approche basée sur une ontologie visuelle ». fr. Thèse de doct. Université Gaston Berger de Saint-Louis (Sénégal), avr. 2018. url : https://hal.science/tel-01842116 (visité le 12/06/2026).

[28] Appoh Kouamé et al. « Visual Representation of African Traditional Medicine Recipes Using Icons and a Formal Ontology, ontoMEDTRAD ». In : *Digital Personalized Health and Medicine – Proceedings of MIE 2020*. T. 270. Studies in Health Technology and Informatics. IOS Press, 2020, p. 791-795. doi : 10.3233/SHTI200269. url : https://ebooks.iospress.nl/doi/10.3233/SHTI200269.

[29] Patrick Lewis et al. « Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks ». In : *Advances in Neural Information Processing Systems*. T. 33. 2020, p. 9459-9474. url : https://arxiv.org/abs/2005.11401.

[30] Mariano Fernández-López et No affiliation. « (PDF) Overview and analysis of methodologies for building ontologies ». en. In : *ResearchGate* (). doi : 10.1017/S0269888902000462. url : https://www.researchgate.net/publication/231908719_Overview_and_analysis_of_methodologies_for_building_ontologies (visité le 29/09/2026).

[31] Meta AI. *Introducing Meta Llama 3 : The Most Capable Openly Available LLM to Date*. Meta AI Blog. Avr. 2024. url : https://ai.meta.com/blog/meta-llama-3/.

[32] Jeanne Millogo-Rasolodimby. « L'homme, le climat et les ressources alimentaires végétales en période de crises de subsistance au Burkina Faso ». Thèse de doctorat ès sciences naturelles. Université de Ouagadougou, 2001. url : https://journals.openedition.org/vertigo/16758.

[33] Odile G. Nacoulma-Ouedraogo. « Plantes médicinales et pratiques médicales traditionnelles au Burkina Faso : cas du plateau central ». Thèse de doctorat d'État. Université de Ouagadougou, 1996. url : https://publication.lecames.org/index.php/pharm/article/download/13/32.

[34] David Nadeau et Satoshi Sekine. « A Survey of Named Entity Recognition and Classification ». In : *Lingvisticae Investigationes* 30.1 (2007), p. 3-26. doi : 10.1075/li.30.1.02nad.

[35] Roberto Navigli, Paola Velardi et Aldo Gangemi. « Ontology Learning and Its Application to Automated Terminology Translation ». In : *IEEE Intelligent Systems* 18.1 (2003), p. 22-31. doi : 10.1109/MIS.2003.1179190.

[36] Fnu Neha, Deepshikha Bhati et Deepak Kumar Shukla. « Retrieval-Augmented Generation (RAG) in Healthcare : A Comprehensive Review ». en. In : *AI* 6.9 (sept. 2025), p. 226. issn : 2673-2688. doi : 10.3390/ai6090226. url : https://www.mdpi.com/2673-2688/6/9/226 (visité le 06/08/2026).

[37] L. Ouédraogo et al. « Ethnobotanical Use and Conservation Assessment of Medicinal Plants Sold in Markets of Burkina Faso ». In : *Ethnobotany Research and Applications* 20 (2020), p. 1-25. doi : 10.32859/era.20.39.1-25. url : https://ethnobotanyjournal.org/index.php/era/article/view/2259.

[38] W Jedida Ouedraogo et al. « Revue des Plantes Médicinales à Potentiel Aromatique du Burkina Faso ». fr. In : 2 (2024).

[39] Colin Raffel et al. « Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer ». In : *Journal of Machine Learning Research* 21.140 (2020), p. 1-67. url : https://jmlr.csail.mit.edu/beta/papers/v21/20-074.html.

[40] D. L. Sackett et al. « Evidence based medicine : what it is and what it isn't ». eng. In : *BMJ* 312.7023 (jan. 1996), p. 71-72. issn : 0959-8138. doi : 10.1136/bmj.312.7023.71.

[41] Hassan Shojaee-Mend, Haleh Ayatollahi et Azam Abdolahadi. « Development and Evaluation of Ontologies in Traditional Medicine : A Review Study ». eng. In : *Methods of Information in Medicine* 58.6 (déc. 2019), p. 194-204. issn : 2511-705X. doi : 10.1055/s-0040-1702236.

[42] SNOMED International. *SNOMED CT : Systematized Nomenclature of Medicine – Clinical Terms*. International Health Terminology Standards Development Organisation (IHTSDO). 2020. url : https://www.snomed.org/.

[43] Borlli Michel Jonas Somé et al. « Design Considerations for a Knowledge Graph : The WATRIMed Use Case ». In : *Healthcare of the Future : Bridging the Information Gap*. T. 259. Studies in Health Technology and Informatics. IOS Press, 2019, p. 59-64. url : https://healthcareofthefuture.ch/wp-content/uploads/2022/03/proceedings_HoF_2019.pdf.

[44] Borlli Michel Jonas Somé et al. « Enabling West African Herbal-Based Traditional Medicine Digitizing : The WATRIMed Knowledge Graph ». In : *MEDINFO 2019 : Health and Wellbeing e-Networks for All*. T. 264. Studies in Health Technology and Informatics. IOS Press, 2019, p. 1548-1549. doi : 10.3233/SHTI190528. url : https://ebooks.iospress.nl/doi/10.3233/SHTI190528.

[45] Abdoulaye Souley. « Trois entités hausa parentes : zahi, sanyi et shawara ». In : *La construction sociale des maladies : les entités nosologiques populaires en Afrique de l'Ouest*. Sous la dir. d'Yannick Jaffré et Jean-Pierre Olivier de Sardan. Presses Universitaires de France, 1999. url : https://horizon.documentation.ird.fr/exl-doc/pleins_textes/divers17-11/010050662.pdf.

[46] Rudi Studer, V. Richard Benjamins et Dieter Fensel. « Knowledge Engineering : Principles and Methods ». In : *Data & Knowledge Engineering* 25.1–2 (1998), p. 161-197. doi : 10.1016/S0169-023X(97)00056-6. url : https://doi.org/10.1016/S0169-023X(97)00056-6.

[47] A. A. Tekemetieu, S. Koussoube et L. P. Fotso. « An Ontology-Based Computer-Aided Diagnosis System in African Traditional Medicine : At the Sorcerer's Stone ». In : *Kybernetes* 45.1 (2016), p. 30-50. url : https://www.ajol.info/index.php/jcmphc/article/download/252453/238490.

[48] André Tibiri et al. « Countrywide Survey of Plants Used for Liver Disease Management by Traditional Healers in Burkina Faso ». In : *Frontiers in Pharmacology* 11 (2020), p. 563751. doi : 10.3389/fphar.2020.563751. url : https://pmc.ncbi.nlm.nih.gov/articles/PMC7883685/.

[49] Mbih Jerome Tosam. « Metaphysical Issues in African Philosophy of Medicine ». In : *African Philosophy of Medicine*. Springer, 2024. doi : 10.1007/978-3-031-73963-7_12. url : https://link.springer.com/chapter/10.1007/978-3-031-73963-7_12.

[50] Safiatou Traoré et al. « Ethnobotanical Survey on Plants Used in the Treatment of Wounds by Traditional Health Practitioners in Burkina Faso ». In : *International Journal of Plant, Animal and Environmental Sciences* 15 (2025). url : https://www.progres.ujkz.gov.bf/publications/11832/details.

[51] Ashish Vaswani et al. « Attention Is All You Need ». In : *Advances in Neural Information Processing Systems*. T. 30. 2017. url : https://arxiv.org/abs/1706.03762.

[52] W3C. *OWL 2 Web Ontology Language Document Overview*. 2012. url : https://www.w3.org/TR/owl2-overview/ (visité le 26/09/2026).

[53] W3C. *RDF 1.1 Concepts and Abstract Syntax*. 2014. url : https://www.w3.org/TR/rdf11-concepts/ (visité le 26/09/2026).

[54] W3C. *SKOS Simple Knowledge Organization System Reference*. 2009. URL : https://www.w3.org/TR/skos-reference/ (visité le 26/09/2026).

[55] World Health Organization. *General Guidelines for Methodologies on Research and Evaluation of Traditional Medicine*. Geneva, 2000. URL : https://iris.who.int/handle/10665/66783 (visité le 26/09/2026).

[56] World Health Organization. *WHO Monographs on Selected Medicinal Plants*. Geneva, 2002. URL : https://iris.who.int/bitstream/handle/10665/42052/9789241547024_eng.pdf (visité le 26/09/2026).

[57] World Health Organization. *WHO Traditional Medicine Strategy 2014–2023*. Geneva, 2013. URL : https://iris.who.int/bitstream/handle/10665/92455/9789241506090_eng.pdf (visité le 26/09/2026).

[58] Patrice Zerbo et al. « Plantes médicinales et pratiques médicales au Burkina Faso : cas des Sanan ». In : *BOIS & FORETS DES TROPIQUES* 307 (mars 2011), p. 41-53. ISSN : 1777-5760, 0006-579X. DOI : 10.19182/bft2011.307.a20481. URL : https://revues.cirad.fr/index.php/BFT/article/view/20481 (visité le 05/08/2026).

[59] Alexander Zizka et al. « Traditional plant use in Burkina Faso (West Africa) : a national-scale analysis with focus on traditional medicine ». en. In : *Journal of Ethnobiology and Ethnomedicine* 11.1 (déc. 2015), p. 9. ISSN : 1746-4269. DOI : 10.1186/1746-4269-11-9. URL : https://ethnobiomed.biomedcentral.com/articles/10.1186/1746-4269-11-9 (visité le 05/08/2026).

[60] Koudbi Jacob Zongo et al. « Ethnopharmacological Study on Medicinal Plants Used for Jaundice and Liver-Related Disorders Management in the Province of Kouritenga in the Central-Eastern of Burkina Faso ». In : *Journal of Advanced Translational and Preclinical Biomedicine* 4.1 (2025). DOI : 10.57220/jatpb.v4i1.213. URL : https://boa.unimib.it/retrieve/444bc5b3-4483-4e23-a45d-f0fe28fbb91a/Zongo%20et%20al-2025-JATPB-VoR.pdf.